



IA Responsable: Ética, Sesgo y Normativa

Módulo 8 · Sesión S1.4 — Una exploración rigurosa de los fundamentos éticos, los riesgos del sesgo algorítmico y el marco regulatorio que toda profesional de la IA debe conocer.

M8 · S1.4

IA RESPONSABLE

¿Qué vamos a ver hoy?

01

Casos que salieron mal

Por qué la ética no es opcional

02

Ética y derechos digitales

Responsabilidad y principios
fundamentales

03

Gobernanza de datos

Gestión, calidad y control

04

Fuentes de sesgo

Datos, etiquetas, modelo y uso

05

Equidad y transparencia

Explicabilidad y XAI

06

Marco normativo

RGPD, LOPDGDD y AI Act

07

Checklist y debate

Puesta en práctica del reto

Capítulo 1

Por qué importa: casos que salieron mal

La IA no es neutra. Cuando los sistemas automatizados fallan, las consecuencias afectan a personas reales: empleos perdidos, detenciones injustas, créditos denegados. Antes de diseñar cualquier solución, necesitamos entender qué puede ir mal —y por qué.



Tres casos que marcaron el debate



COMPAS (EE. UU., 2016)

El algoritmo de predicción de reincidencia criminal de Northpointe fue denunciado por ProPublica: asignaba puntuaciones de riesgo más altas a personas negras que a blancas con historiales similares. Se usaba para decisiones de libertad condicional.



Amazon Recruiting Tool (2018)

Amazon discontinuó su herramienta de cribado de CVs porque penalizaba sistemáticamente a candidatas: el modelo se había entrenado con 10 años de contrataciones históricas, predominantemente masculinas en roles técnicos.



Reconocimiento facial y detenciones erróneas

En EE. UU. se documentaron al menos tres detenciones erróneas de personas negras basadas en identificación facial. Los sistemas presentaban tasas de error hasta 10 veces superiores en pieles oscuras que en pieles claras.

¿Qué tienen en común estos fallos?

Los síntomas

- Resultados discriminatorios mensurables
- Afectación desproporcionada a grupos vulnerables
- Falta de mecanismos de revisión humana
- Opacidad sobre el funcionamiento del modelo

Las causas raíz

- **Datos históricos sesgados** que reflejan desigualdades pasadas
- **Ausencia de análisis de equidad** antes del despliegue
- **Incentivos económicos** que priorizan eficiencia sobre justicia
- **Escasa diversidad** en los equipos de desarrollo

📄 La IA hereda y amplifica los sesgos de sus creadores y de sus datos.

Capítulo 2

Ética, responsabilidad y derechos digitales

Más allá de cumplir la ley, la IA responsable requiere un marco ético explícito. Definir quién decide, quién responde y qué derechos tienen las personas afectadas es el punto de partida de cualquier proyecto bien diseñado.



Los cuatro pilares éticos de la IA



Beneficencia

El sistema debe generar un beneficio real y medible para las personas y la sociedad, maximizando resultados positivos.



No maleficencia

Minimizar activamente los daños potenciales, incluidos los no intencionados. «Primero, no dañar» también aplica a los algoritmos.



Autonomía

Respetar la capacidad de las personas para tomar sus propias decisiones, sin manipulación ni coerción algorítmica.



Justicia

Distribuir equitativamente los beneficios y las cargas. Ningún grupo debe asumir desproporcionadamente los riesgos de la IA.

Responsabilidad: ¿quién responde cuando la IA falla?

La atribución de responsabilidad en sistemas de IA es uno de los desafíos legales y éticos más complejos de la actualidad. La cadena de actores es larga y la causalidad, difusa.



El **AI Act europeo** introduce el concepto de «proveedor» y «desplegente» para distribuir obligaciones. La responsabilidad compartida no puede convertirse en responsabilidad de nadie.

Derechos digitales fundamentales

Derecho a la explicación

Cuando una decisión automatizada te afecta significativamente, tienes derecho a saber por qué. Reconocido por el RGPD (art. 22).

Derecho a la rectificación

Poder corregir datos incorrectos que alimentan decisiones automatizadas sobre ti.

Derecho a intervención humana

En decisiones de alto impacto (crédito, empleo, sanidad), exigir revisión por una persona.

Derecho al olvido


Solicitar la eliminación de tus datos personales cuando ya no sean necesarios o el consentimiento sea retirado.



Capítulo 3

Gobernanza de datos

La calidad del sistema de IA depende directamente de la calidad de sus datos. Una gobernanza sólida no es solo un requisito legal: es una ventaja competitiva y una garantía ética.



¿Qué es la gobernanza de datos?

La gobernanza de datos es el conjunto de políticas, procesos, roles y estándares que aseguran que los datos se gestionan de forma **segura, íntegra, accesible y usable** a lo largo de todo su ciclo de vida.



Principios clave de una buena gobernanza



Calidad e integridad

Los datos deben ser exactos, completos y actualizados. Un modelo entrenado con datos corruptos producirá predicciones poco fiables, independientemente de su arquitectura.



Privacidad por diseño

La protección de datos debe integrarse desde el inicio del proyecto, no añadirse como parche al final. Incluye técnicas como la anonimización, seudonimización y privacidad diferencial.




Trazabilidad y auditoría

Mantener un registro completo del origen, transformaciones y usos de cada conjunto de datos permite detectar problemas, demostrar cumplimiento y reproducir resultados.

Capítulo 4

Fuentes de sesgo: datos, etiquetas, modelo y uso

El sesgo algorítmico rara vez tiene una sola causa. Aparece en múltiples puntos del pipeline de IA y se acumula. Identificar su origen es el primer paso para mitigarlo.



El mapa del sesgo: cuatro orígenes

1. Datos




- Datos históricos desiguales
- Muestras no representativas
- Falta de datos de minorías

2. Etiquetas



- Prejuicios implícitos
- Criterios inconsistentes
- Subjetividad humana

3. Modelo



- Función objetivo no equitativa
- Sobreajuste a la mayoría
- Métricas inapropiadas

4. Uso



- Despliegue inapropiado
- Retroalimentación que amplifica
- Explotación por usuarios

Sesgo en datos vs. sesgo en etiquetas

Sesgo en los datos

Ocurre cuando el conjunto de entrenamiento no representa de forma justa a toda la población relevante.

- **Infrarepresentación:** pocas imágenes de pieles oscuras en datasets de visión
- **Datos históricos:** contrataciones pasadas reflejan discriminación estructural
- **Sesgo de superviviente:** solo existen registros de quienes accedieron al sistema


Sesgo en las etiquetas

Incluso con datos diversos, las etiquetas pueden introducir sesgos humanos en el modelo.

- **Prejuicio implícito:** anotadores que reproducen estereotipos sin saberlo
- **Ambigüedad:** categorías subjetivas como «tono agresivo» en análisis de sentimientos
- **Desacuerdo entre anotadores:** sin protocolo claro, las etiquetas son inconsistentes

Sesgo en el modelo y el efecto de retroalimentación

El sesgo no solo entra por los datos: el propio diseño del modelo y su despliegue pueden introducirlo o amplificarlo.



⚠ Los sistemas de recomendación y los modelos de predicción policial son especialmente vulnerables a estos bucles de retroalimentación.



Capítulo 5

Equidad, transparencia y explicabilidad

Una IA justa no basta con serlo internamente: debe poder demostrarlo. La transparencia y la explicabilidad son las herramientas que permiten que humanos y máquinas trabajen juntos con confianza.

Definir la equidad: el problema de la incompatibilidad

Existen múltiples definiciones matemáticas de equidad, y no siempre son compatibles entre sí. Elegir la métrica correcta depende del contexto y los valores en juego.

Paridad demográfica

Igual proporción de decisiones positivas en todos los grupos.
Ejemplo: mismo porcentaje de aprobaciones de crédito.

Equidad de oportunidad

Igual tasa de verdaderos positivos entre grupos. Importante cuando el coste del error positivo es alto.

Calibración

Las predicciones de probabilidad son igualmente fiables para todos los grupos, sin importar la tasa de positivos.

- ❗ Impossibility Theorem (Chouldechova, 2017): cuando la prevalencia difiere entre grupos, no se pueden satisfacer simultáneamente paridad demográfica, equidad de oportunidad y calibración.

Transparencia y explicabilidad (XAI)

¿Qué diferencia hay?

Transparencia significa que el sistema —su diseño, datos y lógica— puede ser examinado. **Explicabilidad (XAI)** se refiere a la capacidad de comunicar de forma comprensible *por qué* el modelo tomó una decisión concreta.

Técnicas XAI más usadas

- **LIME:** aproxima localmente el modelo con uno interpretable
- **SHAP:** valores de Shapley que cuantifican la contribución de cada variable
- **Saliency maps:** destacan las regiones de la imagen que activaron la decisión
- **Árboles de decisión sombra:** imitan globalmente un modelo complejo



Capítulo 6

RGPD y LOPDGDD: lo esencial para proyectos de IA

El Reglamento General de Protección de Datos y su transposición española establecen el terreno legal en el que operan todos los proyectos de IA que traten datos personales en Europa. Conocerlo no es opcional.



RGPD: los principios que afectan a la IA



Limitación de finalidad

Los datos recogidos para un propósito no pueden reutilizarse libremente para entrenar modelos de IA con fines distintos sin nueva base legal o consentimiento.



Minimización de datos

Solo recopilar lo estrictamente necesario. En IA, esto implica cuestionar cada variable del modelo: ¿es realmente necesaria para la predicción?



Artículo 22: decisiones automatizadas

Prohíbe decisiones basadas únicamente en tratamiento automatizado que produzcan efectos jurídicos significativos, salvo excepciones. Exige derecho a explicación e intervención humana.



EIPD (Evaluación de Impacto)

Obligatoria para tratamientos de alto riesgo: perfilado, decisiones automatizadas, datos sensibles a gran escala. Debe realizarse *antes* del despliegue.

LOPDGDD: especificidades españolas

¿Qué añade a la IA?

- Refuerza la figura del **Delegado de Protección de Datos (DPD)**, obligatorio en muchas organizaciones que usan IA
- Desarrolla el régimen sancionador: hasta **20 M€ o el 4 % de la facturación global**
- Reconoce derechos digitales específicos en el entorno laboral (videovigilancia, geolocalización)
- La **AEPD** es la autoridad de control: emite guías específicas sobre IA y publica resoluciones de referencia

Recurso clave

La Agencia Española de Protección de Datos (AEPD) ha publicado guías prácticas sobre:

- Adecuación de algoritmos al RGPD
- Privacidad diferencial
- IA y datos personales en el sector público

Disponibles en **[aepd.es](https://www.aepd.es)** — lectura recomendada para cualquier proyecto real.

Capítulo 7

AI Act: niveles de riesgo y obligaciones

El Reglamento Europeo de Inteligencia Artificial (AI Act), aprobado en 2024 y en vigor desde agosto de ese año, es el primer marco regulatorio integral de IA del mundo. Establece un enfoque basado en el riesgo con obligaciones escalonadas.

⚠️ ⚠️ Verificar el calendario vigente: los plazos de aplicación son escalonados (6, 12, 24 y 36 meses desde agosto de 2024). Consulta el texto consolidado oficial antes de cualquier decisión de cumplimiento.



Los cuatro niveles de riesgo del AI Act



Obligaciones para sistemas de alto riesgo

- 1 Sistema de gestión de riesgos**
Proceso continuo a lo largo de todo el ciclo de vida del sistema, no solo en el despliegue inicial.
- 2 Gobernanza de datos de entrenamiento**
Documentar origen, representatividad y calidad de los datasets usados.
- 3 Documentación técnica y logs**
Registro automático de operaciones para permitir auditorías ex post.
- 4 Supervisión humana**
Diseño que permita a personas detectar, intervenir y corregir el comportamiento del sistema.



Capítulo 8

Checklist de IA responsable

Esta lista de verificación sintetiza los principios éticos, técnicos y normativos de la sesión. Se presenta aquí como guía y se rellena de forma práctica en el reto. No es una lista exhaustiva, sino un punto de partida estructurado para cualquier proyecto.



Checklist: fase de diseño y datos



Definición del problema

- ¿Está la finalidad del sistema claramente definida y documentada?
- ¿Se ha valorado si la IA es la solución más apropiada?
- ¿Se han identificado los grupos potencialmente afectados?



Datos y gobernanza

- ¿Existe base legal válida para el tratamiento de los datos?
- ¿Los datos son representativos de toda la población objetivo?
- ¿Se ha realizado análisis de calidad, completitud y posibles sesgos?
- ¿Está documentado el linaje de datos (origen, transformaciones)?

Checklist: fase de desarrollo y evaluación



Desarrollo del modelo

- ¿Se ha evaluado el modelo con métricas de equidad (no solo de precisión)?
- ¿Se han analizado los errores desagregados por grupos sensibles?
- ¿Existe documentación técnica del modelo (model card)?



Explicabilidad

- ¿Puede el sistema explicar sus decisiones de forma comprensible?
- ¿Se ha aplicado alguna técnica XAI (SHAP, LIME, etc.)?
- ¿La explicación es útil para los usuarios finales y para auditores?



Cumplimiento normativo

- ¿Se ha realizado la EIPD si el tratamiento es de alto riesgo?
- ¿El sistema cumple el AI Act según su nivel de riesgo clasificado?
- ¿Existen mecanismos de supervisión humana habilitados?

Checklist: fase de despliegue y mantenimiento



Despliegue

- ¿Se ha comunicado a los usuarios que interactúan con IA?
- ¿Existe canal para reportar problemas o apelar decisiones?
- ¿Hay proceso definido de revisión ante incidentes?



Monitorización continua

- ¿Se monitoriza el rendimiento y equidad del modelo en producción?
- ¿Existen alertas para detectar drift o degradación?
- ¿Hay plan de retirada o corrección si se detectan daños?



Rendición de cuentas

- ¿Está clara la cadena de responsabilidad en la organización?
- ¿Se realizan auditorías externas periódicas?
- ¿Se publica información sobre el sistema (transparencia pública)?

Capítulo 9

Preparación del debate: casos y reparto de roles

El debate estructurado es una herramienta poderosa para desarrollar pensamiento crítico sobre IA. Ponerse en el lugar de distintos actores —desarrollador, regulador, ciudadano afectado— permite comprender las tensiones reales que existen en el campo.



Casos propuestos para el debate



Caso A: IA de triaje en urgencias

Un hospital público despliega un sistema que prioriza pacientes en urgencias. Se detecta que pacientes mayores de 75 años reciben puntuaciones de prioridad sistemáticamente más bajas. ¿Eficiencia o discriminación etaria?



Caso B: predicción de reincidencia

Un juzgado usa un sistema de IA para recomendar penas o libertad condicional. El modelo tiene un 80 % de precisión global, pero un 65 % en acusados de origen inmigrante. ¿Es ético usarlo? ¿Bajo qué condiciones?



Caso C: moderación de contenidos

Una plataforma social usa IA para eliminar discurso de odio. El sistema muestra una tasa de falsos positivos tres veces mayor en textos en lenguas minorizadas. ¿Quién es responsable? ¿Qué solución es viable?

Reparto de roles para el debate

Cada grupo adoptará uno de estos roles y deberá argumentar desde esa perspectiva, basándose en los contenidos de la sesión y en la normativa vigente.



Guía para el debate estructurado

Dinámica (30 min)

1. Cada grupo lee el caso asignado (5 min)
2. Preparación de argumentos desde su rol (8 min)
3. Ronda de intervenciones (2 min por rol)
4. Turno de réplica y preguntas cruzadas (7 min)
5. Síntesis colectiva: ¿qué haríais vosotros? (5 min)

Criterios de evaluación

- Rigor argumental
¿Se apoya en conceptos de la sesión y normativa real?
- Coherencia de rol
¿El argumento es coherente con la perspectiva del personaje?
- Propuesta constructiva
¿Se ofrece alguna solución o condición viable?

Síntesis: los cinco compromisos de la IA responsable



Cumplir la normativa

RGPD, LOPDGDD y AI Act no son opcionales. El cumplimiento es el suelo, no el techo.



Gobernar los datos

Calidad, representatividad, trazabilidad y minimización desde el primer día del proyecto.



Detectar y mitigar sesgo

Analizar equidad en cada fase del pipeline, desagregando métricas por grupos relevantes.



Garantizar transparencia

Documentar, explicar y permitir la auditoría del sistema por partes interesadas legítimas.



Mantener supervisión humana

En decisiones de alto impacto, el juicio humano debe poder prevalecer siempre.

Recursos recomendados para profundizar



Normativa

- Texto del AI Act (EUR-Lex, edición consolidada 2024)
- RGPD — Reglamento UE 2016/679
- LOPDGDD — Ley Orgánica 3/2018



Lecturas clave

- *Weapons of Math Destruction* — Cathy O'Neil
- *The Alignment Problem* — Brian Christian
- Guías IA de la AEPD (aepd.es)



Herramientas

- IBM AI Fairness 360 (toolkit de equidad)
- Google What-If Tool
- Microsoft Responsible AI Dashboard