

Estadística y Probabilidad

Una guía clara y visual para comprender los conceptos fundamentales que sustentan el análisis de datos, la toma de decisiones y el pensamiento crítico basado en evidencia.

S2.2 · ESTADÍSTICA Y PROBABILIDAD



¿Qué veremos?

01

Estadística descriptiva

Media, mediana, varianza y cuartiles

03

Probabilidad

Probabilidad clásica y condicionada

02

Distribuciones

Normal, binomial y uniforme

04

Inferencia y errores

Hipótesis, correlación y trampas estadísticas

CAPÍTULO 1

Estadística Descriptiva

Describir, resumir y comprender los datos antes de sacar conclusiones.



Medidas de tendencia central



¿Cuál es el valor representativo?

Media (μ)

Suma de todos los valores dividida entre el número de observaciones. Sensible a valores extremos.

Mediana

Valor central al ordenar los datos. Robusta frente a valores atípicos (*outliers*).

Moda

Valor que aparece con mayor frecuencia. Útil para datos categóricos.


Varianza y dispersión

¿Cuánto se alejan los datos de la media?

La **varianza (σ^2)** mide la dispersión promedio al cuadrado respecto a la media. La **desviación típica (σ)** es su raíz cuadrada y se expresa en las mismas unidades que los datos.


- Una desviación típica baja indica datos muy concentrados; una alta indica alta dispersión.

CONJUNTO A




DATOS AGRUPADOS
BAJA DISPERSIÓN

CONJUNTO B



DATOS DISPERSOS
ALTA DISPERSIÓN

Cuartiles y diagrama de caja



Los cuartiles dividen los datos ordenados en cuatro partes iguales. El **rango intercuartílico** ($IQR = Q3 - Q1$) mide la dispersión del 50% central, siendo muy resistente a valores extremos.

Distribuciones de Probabilidad

Las distribuciones describen cómo se distribuye la probabilidad entre los posibles valores de una variable aleatoria.



Distribución Normal



La campana de Gauss

Simétrica respecto a la media. El **68-95-99,7%** de los datos cae dentro de 1, 2 y 3 desviaciones típicas respectivamente.

- Completamente definida por μ y σ
- Clave en el Teorema Central del Límite
- Base de la mayoría de test estadísticos

Distribución Binomial

Experimentos de éxito o fracaso

Modela el número de éxitos en n ensayos independientes, cada uno con probabilidad de éxito p .

Ejemplo: ¿Cuántos «6» obtenemos al lanzar un dado 10 veces? $n = 10$, $p = 1/6$.

 Se aproxima a la Normal cuando n es grande.



Distribución Uniforme

¿Qué es?

Todos los resultados tienen la **misma probabilidad**. Puede ser discreta (dado) o continua (número aleatorio entre 0 y 1).

Ejemplo discreto

Lanzar un dado justo: $P(1) = P(2) = \dots = P(6) = \mathbf{1/6}$

Ejemplo continuo

Generadores de números aleatorios: cualquier valor en $[a, b]$ es igualmente probable.

Probabilidad

La probabilidad cuantifica la incertidumbre. Es la base matemática para razonar sobre sucesos inciertos.



Reglas fundamentales de probabilidad



Regla de la adición

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$


Evita contar dos veces los sucesos comunes.



Regla de la multiplicación

$$P(A \cap B) = P(A) \cdot P(B|A)$$

Para sucesos independientes: $P(A) \cdot P(B)$.




Complementario

$$P(A^c) = 1 - P(A)$$

La probabilidad de que algo NO ocurra.

Probabilidad condicionada



$P(A | B)$: probabilidad de A dado que B ha ocurrido

Actualiza nuestra creencia sobre A cuando ya conocemos B. Se calcula como:

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

Ejemplo: Si sé que una persona practica deporte, ¿cuál es la probabilidad de que tenga tensión normal?

Teorema de Bayes

CAPÍTULO 4

Permite **actualizar probabilidades** a medida que recibimos nueva información. Es la piedra angular del razonamiento probabilístico.

$$P(A \mid B) = \frac{P(B \mid A) \cdot P(A)}{P(B)}$$

$P(A)$

Probabilidad *a priori* — lo que creemos antes

$P(B|A)$

Verosimilitud — qué tan probable es la evidencia

$P(A|B)$


Probabilidad *a posteriori* — creencia actualizada

Bayes en acción: diagnóstico médico

Escenario


Una enfermedad afecta al **1%** de la población. Un test tiene sensibilidad del 99% y especificidad del 95%. Si el test da **positivo**, ¿cuál es la probabilidad real de estar enfermo?

⚠ La respuesta intuitiva (99%) es incorrecta. Bayes da $\approx 16,7\%$.



Muestreo y Sesgo

Raramente podemos estudiar una población entera. El muestreo nos permite extraer conclusiones generales a partir de una parte representativa.



Tipos de muestreo y sesgos



Aleatorio simple

Cada individuo tiene la misma probabilidad de ser elegido. El más libre de sesgo.



Estratificado

Se divide la población en grupos homogéneos y se muestrea cada uno proporcionalmente.



Por conglomerados

Se seleccionan grupos naturales completos. Más económico pero con mayor varianza.

Sesgos frecuentes

Sesgo de selección

La muestra no representa a toda la población.

Sesgo de respuesta

Los encuestados responden de forma no sincera o sistemática.


Sesgo de supervivencia

Solo se observan los casos que «sobrevivieron» al proceso.

Correlación $\neq$ Causalidad

Una de las confusiones más peligrosas en estadística. Que dos variables estén relacionadas **no implica** que una cause la otra.

Correlación frente a causalidad



El coeficiente de correlación r

Varía entre -1 (correlación negativa perfecta) y $+1$ (correlación positiva perfecta). Un valor de 0 indica ausencia de relación lineal.

⚠ Correlación alta (incluso $r = 0,99$) no prueba causalidad. Siempre busca la variable confusora oculta.


La Paradoja de Simpson

CAPÍTULO 7

Cuando agregar los datos engaña

Una tendencia que aparece en varios grupos de datos **desaparece o se invierte** al combinarlos. Esto ocurre por la presencia de una **variable de confusión** que no se tuvo en cuenta.

Ejemplo clásico: El tratamiento A parece mejor en datos globales, pero el tratamiento B es mejor en cada subgrupo por separado.



Lección clave

Siempre desagrega los datos antes de concluir.

Ignorar variables de confusión puede llevar a decisiones radicalmente erróneas en medicina, política y negocios.

Inferencia Estadística

Usar datos de una muestra para hacer afirmaciones sobre la población, cuantificando siempre la incertidumbre.



Intervalos de confianza




¿Con qué precisión conocemos el parámetro?

Un intervalo de confianza del **95%** significa que, si repitiéramos el muestreo muchas veces, el 95% de los intervalos construidos contendrían el verdadero parámetro poblacional.

- ① Un IC más estrecho → mayor precisión. Se reduce aumentando el tamaño muestral n .

Contraste de hipótesis



El **p-valor** indica la probabilidad de obtener resultados tan extremos como los observados si H_0 fuera cierta. Si $p < \alpha$ (habitualmente 0,05), rechazamos H_0 .

Errores Comunes al Interpretar Estadísticas

Conocer los errores más frecuentes es tan importante como conocer los métodos.



Trampas estadísticas habituales



Confundir significación estadística con relevancia práctica

Un resultado puede ser estadísticamente significativo pero con un efecto tan pequeño que carece de importancia real.



p-hacking y múltiples comparaciones

Realizar muchas pruebas aumenta la probabilidad de encontrar un falso positivo por azar.



Escalar ejes para exagerar diferencias

Un eje Y que no empiece en cero puede hacer que diferencias pequeñas parezcan enormes.

Más errores frecuentes

Usar la media con datos sesgados

Con distribuciones asimétricas (salarios, precios), la mediana es más representativa que la media.

Extrapolar más allá de los datos

Los modelos solo son válidos dentro del rango de valores observados. Extrapolar puede dar resultados absurdos.

Ignorar el tamaño muestral

Porcentajes sin el denominador son engañosos: «el 100% mejoró» con $n = 2$ no dice nada.

Resumen: lo esencial



Describe primero

Media, mediana, varianza y cuartiles revelan la estructura de tus datos.



Conoce tus distribuciones

Normal, binomial y uniforme modelan fenómenos muy distintos.



Actualiza con Bayes

Incorpora nueva evidencia de forma rigurosa y sistemática.



Desconfía de lo obvio

Correlación, Simpson y p-hacking: la estadística exige pensamiento crítico.

Próximos pasos

- Practica con datos reales
Usa conjuntos de datos públicos (INE, Kaggle) para aplicar cada concepto.
- Programa en Python o R
Implementa tú mismo las fórmulas: calcular refuerza la comprensión.
- Cuestiona siempre las fuentes
Antes de creer una estadística, pregunta: ¿quién la mide?
¿cómo? ¿con qué muestra?

