


SESIÓN 3.3

AutoML y MLOps

De entrenar a operar en
producción

Del pipeline automatizado al ciclo de vida continuo del modelo

Machine Learning Aplicado · Guía de arquitectura y despliegue



Qué veremos hoy

De entrenar un modelo a mantenerlo vivo, fiable y rentable en entornos reales

01 AUTOML

02 PLATAFORMAS

03 CICLO MLOPS

04 DERIVA

05 COSTES Y RIESGOS

06 RETO PRÁCTICO

BLOQUE 1

Qué es AutoML y qué automatiza

Ingeniería de variables, selección de algoritmos y búsqueda de hiperparámetros.

BLOQUE 2

Plataformas, ciclo MLOps y deriva

Comparativa de herramientas; versionado, despliegue continuo y monitorización de drift.

BLOQUE 3

Costes, riesgos y reto de la sesión

Gasto oculto de endpoints activos; gobierno de modelos y despliegue del primer servicio.

CONCEPTO CLAVE

AutoML automatiza el trabajo repetitivo de entrenar modelos

Acelera el entrenamiento sin reemplazar el criterio de quien modela.

Selección y optimización

Explora algoritmos, transforma variables y ajusta hiperparámetros.

Entrada simple, salida evaluada

Recibe datos y una métrica objetivo; entrega un modelo candidato evaluado.


Amplifica el criterio

Libera tiempo para formular el problema y cuidar la calidad del dato de origen.



Cómo funciona un flujo AutoML

Cuatro etapas secuenciales desde el dataset crudo hasta el artefacto final listo para inferencia.



La validación cruzada y el split temporal evitan el sobreajuste durante la búsqueda automatizada.

AutoML gana en velocidad, pierde en control

La automatización ofrece una compensación directa entre tiempo de entrega y especificidad algorítmica.

BENEFICIOS

Velocidad y democratización

- **Prototipos rápidos:** Obtención de un benchmark funcional en horas en lugar de semanas de pruebas manuales.
- **Línea base fiable:** Reduce errores humanos en el preprocesamiento y establece una métrica mínima exigente.
- **Acceso transversal:** Permite a equipos de producto y analistas validar hipótesis sin requerir ingeniería avanzada.

LÍMITES

Opacidad y restricciones

- **Menor control fino:** Difícil incorporar restricciones matemáticas de negocio o regularizaciones específicas.
- **Interpretabilidad variable:** Tiende a ensamblados complejos que complican auditorías en sectores regulados.
- **ML artesanal superior:** Cuando existe conocimiento profundo del dominio, la ingeniería manual sigue ganando.

ECOSISTEMA


Cuatro plataformas, una misma idea



Amazon SageMaker

AutoML dentro del ecosistema AWS.


ECOSISTEMA AWS



Google Vertex AI

AutoML y pipelines en Google Cloud.

GOOGLE CLOUD



Azure AutoML

Integrado en Azure Machine Learning.

ENTORNO AZURE



H2O

AutoML de código abierto, usable en local o en la nube.

OPEN SOURCE

Cómo elegir plataforma

Tres criterios arquitectónicos que definen la decisión tecnológica antes del primer entrenamiento.

Criterio	Pregunta clave	Implicación operativa
Residencia de datos	¿Dónde residen ya las tablas transaccionales y el almacén analítico?	Mover petabytes entre nubes genera costes de egress y latencia inasumibles.
Grado de control	¿El equipo requiere inspeccionar el código o busca despliegues en un clic?	Equipos expertos demandan cuadernos abiertos; perfiles mixtos prefieren interfaces gestionadas.
Coste y dependencia	¿Podemos exportar el modelo fuera del proveedor para servirlo en local?	El vendor lock-in condiciona las licencias futuras y el coste mensual del cómputo dedicado.

Regla práctica: entrena donde ya vive el dato y exige siempre la capacidad de exportar los pesos del modelo.

MLOps lleva el modelo del cuaderno a producción

La diferencia entre un experimento en un Jupyter notebook y un servicio en producción fiable.

CICLO INFINITO



Los modelos se degradan aunque nadie toque el código

A diferencia del software tradicional, el rendimiento decae cuando el mundo exterior cambia.

DATA DRIFT

Deriva de datos

Cambia la distribución de las variables de entrada $P(X)$.

Ejemplo: nuevos tipos de tarjetas, cambios demográficos o fallos en sensores.

CONCEPT DRIFT

Deriva de concepto

Cambia la relación entre entradas y resultado $P(Y|X)$.

Ejemplo: patrones de fraude tras una regulación o inflación alterando compras.

DETECCIÓN

Señales de alerta

Pruebas estadísticas continuas (KS, PSI) y caída de métricas de negocio.

Respuesta: reentrenamiento planificado con ventanas temporales móviles.

Costes y riesgos: lo que no sale en la demo

Aspectos operativos que multiplican la factura y amenazan la estabilidad del sistema.

Dimensión	Impacto real en producción	Estrategia de mitigación
Cómputo y hosting	Endpoints activos 24/7 con GPU/CPU reservada y búsqueda AutoML descontrolada.	Límites de presupuesto duros, apagado automático y despliegue serverless.
Sesgos y gobernanza	Falta de trazabilidad sobre qué datos entrenaron qué pesos y modelos huérfanos.	Registro centralizado de modelos, fichas técnicas (Model Cards) y dueño explícito.
Dependencia técnica	Formatos propietarios de serialización que impiden migrar modelos entre nubes.	Uso de estándares abiertos como ONNX, MLflow y contenedores Docker portables.

La mayoría de proyectos de machine learning fallan por descontrol de costes o falta de gobernanza, no por precisión técnica.

Reto: Primer modelo en producción

Aplica lo aprendido implementando el ciclo completo en un entorno controlado.

1

Entrenar con AutoML

Carga el dataset de la práctica, fija la métrica objetivo y genera tu línea base óptima.

2

Desplegar y versionar


Publica el artefacto como API REST funcional e inscríbelo en el registro con versión v1.0.

3

Plan de vida operativa

Define métricas clave de monitorización y los umbrales que activarán el reentrenamiento.

El objetivo es verificar el flujo de extremo a extremo, no maximizar la última décima de F1-Score.



EVALUACIÓN

Entregables y próximos pasos

Tres evidencias verificables para validar la puesta en marcha de tu solución.

ENTREGABLE 1

Endpoint activo y versionado

URL o contenedor funcional con registro de trazabilidad (modelo, datos y commit).

ENTREGABLE 2

Informe sintético de riesgos y costes

Métricas de validación obtenidas, coste estimado de inferencia y posibles sesgos detectados.

ENTREGABLE 3

Estrategia de detección de deriva

Definición de señales de alerta de entrada y protocolo documentado de reentrenamiento.

Fecha límite de entrega: próximo lunes a las 23:59 CET.

