


Sistemas de Recomendación

TEMA 9.2 · APRENDIZAJE AUTOMÁTICO

Los sistemas de recomendación son uno de los casos de uso más impactantes del aprendizaje automático. Desde Netflix hasta Spotify, estos algoritmos moldean qué consumimos, cómo lo descubrimos y qué queda invisible para nosotros. En esta lección exploraremos los fundamentos técnicos, los modelos clave y los retos éticos que plantean.



Contenidos de la lección

Un recorrido estructurado por los conceptos fundamentales de los sistemas de recomendación, desde los tipos de aproximaciones hasta la evaluación y los sesgos.

01	02	03
Tipos de recomendadores Panorama general de las familias de algoritmos existentes	Basado en contenido Recomendaciones a partir de las características de los ítems	Filtrado colaborativo Aprovechar el comportamiento colectivo de los usuarios
04	05	
Factorización de matrices Representaciones latentes y descomposición matricial	Arranque en frío, evaluación y sesgos Retos prácticos y consideraciones éticas	



PARTE 1

Tipos de Recomendadores

Existen tres grandes familias de sistemas de recomendación, cada una con supuestos, fortalezas y limitaciones distintas. La elección del enfoque depende del tipo de datos disponibles y del contexto de aplicación.

Las tres grandes familias

Basado en contenido

Analiza las características intrínsecas de los ítems (género, descripción, metadatos) y las compara con el perfil histórico del usuario. Recomienda lo que es **similar a lo que ya le gustó**.

Filtrado colaborativo

Explora patrones de comportamiento entre usuarios. Si dos usuarios tienen gustos similares, lo que le gusta a uno puede gustarle al otro. No necesita conocer el contenido del ítem.

Sistemas híbridos

Combinan ambos enfoques para aprovechar sus fortalezas y mitigar sus debilidades. Son los más usados en producción (Netflix, Spotify, Amazon).

Recomendación Basada en Contenido

En este enfoque, cada ítem se representa como un **vector de características**: palabras clave, género, director, precio, etc. El perfil de usuario se construye agregando los vectores de los ítems con los que ha interactuado.

La recomendación se calcula midiendo la **similitud coseno** entre el perfil del usuario y los ítems candidatos:

$$\text{sim}(\mathbf{u}, \mathbf{i}) = \frac{\mathbf{u} \cdot \mathbf{i}}{|\mathbf{u}| |\mathbf{i}|}$$

Se recomiendan los ítems con mayor puntuación de similitud que el usuario aún no haya visto.

❏ Ventaja clave: no requiere datos de otros usuarios; puede funcionar desde el primer ítem.

Ejemplo: recomendador de películas

Representa cada película como vector de géneros:


Película	Acción	Drama	Sci-Fi
Película A	1	0	1
Película B	0	1	0
Película C	1	0	1

Si el usuario vio A, se le recomienda C por alta similitud coseno.

PARTE 3

Filtrado Colaborativo

El filtrado colaborativo es el enfoque dominante en la industria. Su premisa: **usuarios con comportamientos similares en el pasado tendrán preferencias similares en el futuro**. No es necesario conocer el contenido de los ítems.



Dos variantes del filtrado colaborativo



Basado en usuarios (User-User)

Encuentra usuarios con valoraciones similares al usuario activo.
Para predecir la valoración de un ítem, pondera las valoraciones de los vecinos más cercanos según su similitud.

$$\hat{r}_{u,i} = \bar{r}_u + \frac{\sum_{v \in N} \text{sim}(u, v) (r_{v,i} - \bar{r}_v)}{\sum_{v \in N} |\text{sim}(u, v)|}$$



Basado en ítems (Item-Item)

Calcula la similitud entre ítems en función de los usuarios que los valoraron. Más estable que el enfoque usuario-usuario: los perfiles de ítems cambian menos que los de usuarios. Es la base de las recomendaciones de Amazon.

- Más eficiente en producción
- Menor varianza ante nuevos usuarios
- Interpretable: "otros que vieron X también vieron Y"

Matriz Usuario-Ítem y Factorización

La matriz de valoraciones

El punto de partida es una matriz $\mathbf{R}$ de dimensión $m \times n$ (usuarios $\times$ ítems). La mayoría de sus celdas están vacías: los usuarios solo han interactuado con una fracción mínima del catálogo.

El objetivo es **completar esa matriz**, prediciendo las valoraciones desconocidas para hacer recomendaciones.

❏ Matrices con 99 % o más de datos ausentes son habituales en plataformas reales.

Factorización matricial (MF)

Descompone $\mathbf{R} \approx \mathbf{P} \cdot \mathbf{Q}^T$, donde:

- $\mathbf{P}$ ($m \times k$): matriz de factores latentes de usuarios
- $\mathbf{Q}$ ($n \times k$): matriz de factores latentes de ítems
- k : dimensión del espacio latente (hiperparámetro)

Se minimiza el error cuadrático con regularización:

$$\min_{\mathbf{P}, \mathbf{Q}} \sum_{(u,i) \in \Omega} (r_{ui} - \mathbf{p}_u^T \mathbf{q}_i)^2 + \lambda (\|\mathbf{p}_u\|^2 + \|\mathbf{q}_i\|^2)$$

SVD y Descenso por Gradiente Estocástico

La factorización se resuelve en la práctica mediante **SGD** o **ALS** (Alternating Least Squares), iterando hasta convergencia.

1

Inicialización

P y Q se inicializan con valores aleatorios pequeños

2

Predicción

Se calcula $\hat{r}_{ui} = \mathbf{p}_u^T \mathbf{q}_i$ para cada par observado

3

Error y gradiente

Se calcula el error e_{ui} y se actualizan $\mathbf{p}_u$ y $\mathbf{q}_i$

4

Convergencia

Tras varias épocas, los vectores capturan preferencias latentes

Los factores latentes aprendidos codifican propiedades abstractas: para películas podrían capturar "intensidad dramática" o "orientación comercial" sin que el modelo conozca estas etiquetas explícitamente.



PARTE 5

El Problema del Arranque en Frío

Uno de los retos más conocidos en sistemas de recomendación: ¿qué recomendar cuando no hay datos históricos suficientes?

Tres escenarios de arranque en frío

Nuevo usuario

El sistema no conoce sus preferencias. Estrategias: encuesta de onboarding para capturar gustos iniciales, recomendaciones de ítems populares, o inferencia a partir de datos demográficos y contexto (hora, dispositivo, ubicación).

Nuevo ítem

No existen valoraciones para el ítem recién incorporado. El filtrado colaborativo puro no puede utilizarlo. Solución: aprovechar sus metadatos (basado en contenido) o aplicar estrategias de exploración activa (A/B testing, bandit algorithms).

Sistema nuevo

La plataforma no tiene ningún dato de interacciones. Se puede partir de contenido editorial curado, importar señales externas (redes sociales, historial de búsqueda) o usar modelos preentrenados en dominios similares.

Evaluación: Precision@k

Evaluar un sistema de recomendación no es trivial. La métrica más utilizada en contextos de ranking es **Precision@k**: ¿cuántos de los k ítems recomendados son realmente relevantes para el usuario?

$$\text{Precision@}k = \frac{|\{\text{ítems relevantes}\} \cap \{\text{top-}k \text{ recomendados}\}|}{k}$$

Otras métricas complementarias:

- **Recall@k**: fracción de ítems relevantes que aparecen en el top- k
- **NDCG@k**: tiene en cuenta la posición del ítem relevante
- **MAP**: promedia la precisión a lo largo de múltiples consultas
- **RMSE / MAE**: para predicción explícita de valoraciones

Ejemplo práctico

El sistema recomienda 5 ítems al usuario ($k = 5$). De esos 5, 3 son relevantes según el historial del usuario.

$$\text{Precision@}5 = \frac{3}{5} = 0.60$$

El sistema recomienda con un 60 % de precisión en el top-5.

- ❏ En producción, la relevancia se mide con datos de interacción offline (clics, compras, reproducciones) o estudios de usuario.

Sesgos y «Burbujas de Filtro»

Los sistemas de recomendación optimizan el engagement, pero este objetivo puede tener consecuencias sociales no deseadas que van más allá de la precisión técnica.



Burbuja de filtro

El sistema refuerza continuamente los intereses ya conocidos del usuario, reduciendo la exposición a contenido diverso o contrario a sus creencias previas.



Sesgo de popularidad

Los ítems muy populares reciben más recomendaciones, lo que los hace aún más populares. Los ítems de nicho quedan sistemáticamente infra-recomendados (long tail problem).



Sesgo de retroalimentación

El modelo se entrena con datos generados por sus propias recomendaciones pasadas, creando un bucle que amplifica errores y sesga la distribución de entrenamiento.



Mitigaciones

Introducir diversidad forzada (serendipia), regularizar por equidad entre grupos, auditar regularmente la distribución de recomendaciones y usar exploración activa.