

Aprendizaje por Refuerzo

Una rama del aprendizaje automático en la que un **agente** aprende a tomar decisiones óptimas interactuando con su entorno, guiado únicamente por señales de recompensa. Descubre los fundamentos, algoritmos clave y aplicaciones reales de esta poderosa técnica.

TEMA 9.3

MACHINE LEARNING



Índice del tema

Recorreremos los conceptos esenciales del aprendizaje por refuerzo, desde sus fundamentos teóricos hasta sus aplicaciones y limitaciones en el mundo real.

01	02	03
Componentes fundamentales	Exploración vs. Explotación	Q-learning
Agente, entorno, estado, acción y recompensa	El dilema central del aprendizaje por refuerzo	Algoritmo tabular fundamental
04	05	
Gymnasium	Aplicaciones y límites	
Entorno de simulación y práctica	Casos reales y fronteras del enfoque	

¿Qué es el Aprendizaje por Refuerzo?

El **aprendizaje por refuerzo** (RL, del inglés *Reinforcement Learning*) es un paradigma en el que un agente aprende a actuar en un entorno de forma autónoma. A diferencia del aprendizaje supervisado, **no existen ejemplos etiquetados**: el agente descubre por sí mismo qué acciones producen mejores resultados, guiado únicamente por una señal de recompensa.

- ❏ Analogía clave: es como entrenar a un animal con premios y castigos, sin explicarle jamás las reglas del juego.



Los Cinco Componentes Fundamentales

Todo problema de aprendizaje por refuerzo queda definido por cinco elementos que forman el marco **MDP** (Proceso de Decisión de Markov).

Agente

El sistema que aprende y toma decisiones. Observa el entorno y selecciona acciones para maximizar la recompensa acumulada.

Entorno

Todo aquello externo al agente. Recibe las acciones, actualiza su estado interno y devuelve una nueva observación y recompensa.

Estado

Representación del entorno en un instante dado. Condensa toda la información relevante para tomar la siguiente decisión.

Acción


Elección que realiza el agente en cada paso. Puede ser discreta (izquierda/derecha) o continua (ángulo de un volante).

Recompensa

Señal escalar que indica cuán buena fue la acción tomada. El objetivo del agente es **maximizar la recompensa total** a largo plazo.

El Ciclo Agente–Entorno

La interacción entre el agente y el entorno sigue un bucle continuo: el agente observa el estado, elige una acción, y el entorno responde con un nuevo estado y una recompensa.



Este proceso se repite en cada **paso de tiempo** (*timestep*) hasta alcanzar un estado terminal o agotar el horizonte del episodio.

Exploración frente a Explotación

Este es el **dilema central** del aprendizaje por refuerzo. El agente debe decidir en cada paso si **explota** el conocimiento ya adquirido para obtener la mayor recompensa posible, o si **explora** acciones nuevas que podrían descubrir estrategias mejores. Un agente puramente explotador queda atrapado en óptimos locales; uno puramente explorador nunca converge.



Estrategias para Gestionar el Dilema

ϵ -greedy (épsilon codicioso)

Con probabilidad ϵ el agente elige una acción aleatoria (exploración); con probabilidad $1-\epsilon$ elige la mejor acción conocida (explotación). El valor de ϵ se va reduciendo a medida que el aprendizaje avanza.

- Simple de implementar
- Muy utilizado en la práctica
- ϵ típico: $1.0 \rightarrow 0.01$ con decaimiento

Otras estrategias habituales

- **Softmax / Boltzmann:** pondera acciones según sus valores estimados usando temperatura
- **UCB (Upper Confidence Bound):** favorece acciones poco exploradas añadiendo un bono de incertidumbre
- **Thompson Sampling:** enfoque bayesiano que muestrea de distribuciones de creencias

 En la mayoría de implementaciones iniciales se usa ϵ -greedy con decaimiento exponencial.

Q-learning: El Algoritmo Fundamental

El **Q-learning** es un algoritmo de diferencia temporal que aprende la función de valor de acción $Q(s, a)$ — la recompensa futura esperada al tomar la acción a en el estado s — sin necesidad de conocer el modelo del entorno.

Regla de actualización

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

- α (alpha): tasa de aprendizaje — velocidad de actualización
- γ (gamma): factor de descuento — importancia del futuro
- r : recompensa inmediata recibida
- s' : estado siguiente tras ejecutar a

La Q-Table

Para entornos discretos, los valores Q se almacenan en una tabla de estados $\times$ acciones. El agente la consulta para elegir la acción con mayor Q en el estado actual.

- ❏ Q-learning converge al óptimo global si α decrece adecuadamente y todos los pares (s,a) se visitan suficientes veces.

Gymnasium: El Banco de Pruebas Estándar

Gymnasium (anteriormente OpenAI Gym) es la librería de referencia para desarrollar y comparar algoritmos de RL. Ofrece una interfaz unificada y una colección de entornos listos para usar, desde juegos clásicos hasta simulaciones físicas complejas.



Entornos clásicos

CartPole, MountainCar, Taxi: ideales para aprender los fundamentos con espacios de estados pequeños y discretos.



MuJoCo / PyBullet

Simulaciones físicas continuas para robótica: **Ant, HalfCheetah, Humanoid.** Espacios de acción continuos y alta dimensionalidad.



Atari Games

Más de 50 juegos de Atari en píxeles. Base de los experimentos originales de **Deep Q-Network (DQN)** de DeepMind.



API sencilla

`env.reset()`, `env.step(action)`, `env.render()`: tres llamadas bastan para ejecutar cualquier entorno.

Aplicaciones Reales del RL

El aprendizaje por refuerzo ha dejado de ser un ejercicio académico para convertirse en una tecnología con impacto directo en industrias clave.



Juegos de estrategia

AlphaGo / AlphaZero
de DeepMind venció a los mejores jugadores humanos de Go y Ajedrez, aprendiendo únicamente jugando contra sí mismo.



Vehículos autónomos

El RL se usa para entrenar políticas de conducción en simulación antes de desplegarlas en coches reales, optimizando seguridad y eficiencia.



Gestión de energía

Google DeepMind redujo el consumo de refrigeración de sus centros de datos en un **40%** usando RL para controlar los sistemas de climatización.



Trading algorítmico

Agentes de RL aprenden estrategias de compraventa en mercados financieros simulados, adaptándose dinámicamente a condiciones cambiantes.



Más Aplicaciones Destacadas

Robótica y control motor

Brazos robóticos que aprenden a manipular objetos con destreza, o robots bípedos que aprenden a caminar en entornos irregulares sin programación explícita de movimientos.

Sistemas de recomendación

Plataformas como YouTube o Netflix modelan la interacción usuario-plataforma como un problema de RL, maximizando el tiempo de visionado y la satisfacción.

Salud y asistencia clínica

Optimización de protocolos de dosificación de medicamentos (p. ej. insulina) y diseño de regímenes de tratamiento personalizados para enfermedades crónicas.

RLHF en LLMs

El **Reinforcement Learning from Human Feedback** es clave en el entrenamiento de modelos de lenguaje como ChatGPT, alineando su comportamiento con preferencias humanas.


Límites y Desafíos del Aprendizaje por Refuerzo

A pesar de sus éxitos, el RL presenta **limitaciones importantes** que restringen su aplicabilidad directa en muchos problemas del mundo real.

1) Muestra ineficiente




2) Diseño de la recompensa




3) Falta de transferencia



4) Seguridad y exploración



5) Escalabilidad



6) Inestabilidad



Resumen y Conclusiones

El aprendizaje por refuerzo ofrece un marco poderoso para que los agentes aprendan comportamientos óptimos mediante la interacción con su entorno. Conocer sus fundamentos es esencial para cualquier profesional del ámbito de la IA.

1 Marco MDP

Agente, entorno, estado, acción y recompensa son los cinco pilares que definen cualquier problema de RL.

2 Exploración vs. Explotación

El dilema central; estrategias como ϵ -greedy permiten equilibrar ambos objetivos de forma práctica.

3 Q-learning

Algoritmo libre de modelo que aprende la función Q iterativamente; base sobre la que se construye el Deep Q-Network.

4 Aplicaciones y límites

Desde AlphaGo hasta RLHF en LLMs, el RL transforma industrias, pero exige cuidado en el diseño de recompensas y gran capacidad de cómputo.

📌 Próximo paso: experimenta con Gymnasium implementando Q-learning en CartPole y observa cómo el agente aprende a equilibrar el palo en cuestión de minutos.