



Detección de Objetos y Segmentación

S11.3 · VISIÓN POR COMPUTADOR

De la clasificación básica a la comprensión espacial completa de una imagen: exploramos las técnicas fundamentales que permiten a los modelos no solo reconocer qué hay en una escena, sino también **dónde está** y **qué píxeles lo componen**.

Agenda

Recorrido estructurado por los conceptos clave de esta sesión:

01

Clasificación, detección y segmentación

El espectro completo de tareas en visión por computador

02

Cajas delimitadoras y métricas

Bounding boxes, IoU y mAP

03

YOLO y detección en tiempo real

La arquitectura que revolucionó la detección

04

Segmentación semántica

Comprensión píxel a píxel de la escena

05

Casos de uso y modelos preentrenados

Aplicaciones reales y cómo reutilizar modelos existentes



Clasificación, Detección y Segmentación

Tres niveles de comprensión visual, cada uno más rico en información espacial que el anterior.

1

Clasificación

¿Qué hay en la imagen? Asigna una o varias etiquetas globales a toda la imagen. Sin información de posición.

2

Detección

¿Qué hay y dónde está? Localiza cada objeto con una caja delimitadora y le asigna una clase.

3

Segmentación

¿Qué píxel pertenece a qué? Proporciona una máscara precisa a nivel de píxel para cada región u objeto.

CONCEPTO CLAVE

Cajas Delimitadoras

Una **bounding box** (caja delimitadora) es el rectángulo mínimo que encierra un objeto detectado en la imagen. Es la forma más sencilla y eficiente de codificar la localización de un objeto.

Se representa habitualmente con cuatro valores:

- **(x, y)** — coordenadas del centro o esquina superior izquierda
- **w, h** — anchura y altura del rectángulo

Durante el entrenamiento, el modelo aprende a predecir simultáneamente la **clase del objeto** y las **coordenadas de la caja**, formulando la detección como un problema de regresión combinado con clasificación.

Formato más común

`[x_min, y_min, x_max, y_max]`

También conocido como formato *xyxy*. Otros formatos habituales son *xywh* (centro + dimensiones) y las coordenadas normalizadas entre 0 y 1.

¿Por qué cajas y no polígonos?

Las cajas son computacionalmente baratas, fáciles de anotar y suficientemente precisas para la mayoría de aplicaciones de detección.

IoU: Intersección sobre Unión

El **Intersection over Union (IoU)** es la métrica estándar para medir cuán bien se solapa una caja predicha con la caja real (*ground truth*).

Definición

Se calcula dividiendo el área de intersección entre las dos cajas entre el área de su unión:

$$\text{IoU} = \frac{\text{Área de Intersección}}{\text{Área de Unión}}$$

Un IoU de **1.0** indica solapamiento perfecto; un IoU de **0.0** significa que no existe ninguna superposición entre las dos cajas.

Umbrales habituales

$$\text{IoU} \geq 0.5$$

Umbral mínimo típico. Se considera detección correcta en evaluaciones estándar (PASCAL VOC).

$$\text{IoU} \geq 0.75$$

Umbral estricto. Usado en COCO para medir precisión de localización de alta calidad.

$$\text{IoU} \geq 0.95$$

Umbral muy estricto. Solo se alcanza con localizaciones casi perfectas.

mAP: Precisión Media Promedio

El **mean Average Precision (mAP)** es la métrica de evaluación más utilizada en benchmarks de detección de objetos. Combina precisión y exhaustividad (*recall*) en una sola cifra por clase, y luego promedia entre todas las clases.

1 Curva Precisión–Recall

Para cada clase, se construye una curva P-R variando el umbral de confianza. La forma de la curva revela el equilibrio entre detectar todo (alto recall) y detectar con certeza (alta precisión).

2 Average Precision (AP)

El área bajo la curva P-R para una clase concreta. Un AP de 1.0 indica detección perfecta en esa clase en todos los umbrales.

3 mAP

Media de los AP de todas las clases del conjunto de datos. En COCO, se reporta adicionalmente el promedio para distintos umbrales de IoU (0.5 a 0.95).



La Idea Detrás de YOLO

YOU ONLY LOOK ONCE

YOLO reformuló la detección de objetos como un **único problema de regresión**: en un solo paso de red, predice simultáneamente las cajas delimitadoras y las probabilidades de clase para toda la imagen.

YOLO: Cómo Funciona

Arquitectura de una sola pasada

La imagen se divide en una cuadrícula de $S \times S$ celdas. Cada celda predice **B cajas** con sus coordenadas, una puntuación de confianza y las probabilidades de clase **C**.

La red procesa la imagen completa de principio a fin en **una sola inferencia**, lo que permite velocidades de detección en tiempo real (30–100+ FPS según la versión).

Velocidad

Inferencia en tiempo real.
YOLOv8 puede superar los 100 FPS en GPU moderna.

Precisión

Las versiones modernas (v5, v8, v9) compiten con detectores de dos etapas en mAP.

Versatilidad

Las variantes actuales soportan detección, segmentación de instancias y estimación de pose.

- ❏ La clave de YOLO es tratar la detección como regresión directa sobre la imagen completa, eliminando la fase costosa de propuesta de regiones.

Segmentación Semántica

La segmentación semántica asigna una **etiqueta de clase a cada píxel** de la imagen, produciendo un mapa de segmentación completo. A diferencia de la detección, no distingue instancias individuales del mismo objeto.



Conducción Autónoma

Clasifica cada píxel como carretera, acera, vehículo, peatón o cielo para navegación segura.





Imagen Médica

Delimita órganos, tumores o lesiones con precisión píxel a píxel para diagnóstico asistido.




Teledetección

Identifica cultivos, zonas urbanas o masas de agua en imágenes satelitales de alta resolución.

Segmentación Semántica vs. Segmentación de Instancias

SEGMENTACIÓN SEMÁNTICA

■ Coche




**Etiqueta cada píxel con una clase.
No distingue instancias individuales.
Ejemplo: Todos los coches tienen
el mismo color.**

SEGMENTACIÓN DE INSTANCIAS

■ Coche 1
■ Coche 2
■ Persona 1

■ Coche 3
■ Persona 2




**Etiqueta cada píxel Y distingue
instancias individuales. Cada
objeto tiene su propia máscara.
Usado por Mask R-CNN.**

La segmentación de instancias combina lo mejor de la detección (distinguir objetos individuales) con lo mejor de la segmentación (máscaras píxel a píxel), a costa de mayor complejidad computacional.

Casos de Uso Reales

La detección de objetos y la segmentación están presentes en sectores críticos donde la comprensión espacial automática tiene un impacto directo.



Aplicaciones por Sector



Automoción y Movilidad

Detección de peatones, vehículos y señales en vehículos autónomos. Sistemas ADAS (Advanced Driver Assistance Systems) que alertan de colisiones inminentes.



Industria y Manufactura

Inspección visual de defectos en líneas de producción. Control de calidad automatizado con tasas de detección superiores a las de inspección humana.



Sanidad

Segmentación de tumores en TAC y resonancias. Detección de pólipos en colonoscopias y análisis de radiografías torácicas para detección de patologías.



Seguridad y Vigilancia

Detección de intrusiones, análisis de aforo en espacios públicos y reconocimiento de comportamientos anómalos en cámaras de circuito cerrado.

Usar un Modelo Ya Entrenado

Gracias al **aprendizaje por transferencia**, no es necesario entrenar desde cero. Podemos aprovechar modelos preentrenados en grandes conjuntos de datos (COCO, ImageNet) y adaptarlos a nuestra tarea específica con pocas líneas de código.

Opciones populares

YOLOv8 / Ultralytics

API sencilla en Python. Detección, segmentación y pose en una sola librería. Ideal para empezar.

Detectron2 (Meta)

Framework avanzado con Mask R-CNN, Faster R-CNN y panóptica. Muy configurable.

Hugging Face Transformers

Acceso a modelos DETR, SAM (Segment Anything Model) y más desde un repositorio centralizado.

Flujo de trabajo típico

1. Cargar el modelo preentrenado con sus pesos
2. Pasar la imagen por el modelo en modo inferencia
3. Filtrar predicciones por umbral de confianza
4. Aplicar Non-Maximum Suppression (NMS)
5. Visualizar cajas, etiquetas y máscaras

📄 Con YOLOv8: solo tres líneas de código para inferencia completa sobre una imagen o vídeo.