




NLP Clásico y Embeddings

S12.2 · PROCESAMIENTO DE LENGUAJE NATURAL

Una introducción completa al procesamiento de lenguaje natural clásico: desde los primeros pasos del pipeline hasta representaciones vectoriales avanzadas como *word2vec*. Exploraremos cómo las máquinas comprenden, representan y clasifican el texto humano.

Contenidos de la sesión

Esta sesión cubre los conceptos fundamentales del NLP clásico, organizados en una progresión lógica que va desde el procesamiento básico hasta la semántica computacional avanzada.

01

Pipeline de NLP

El flujo de trabajo estándar del procesamiento de texto

03

Bolsa de palabras y TF-IDF

Representaciones vectoriales clásicas del texto

05

Word Embeddings y similitud

Representaciones densas con word2vec

02

Tokenización y limpieza

Preparación y normalización del texto crudo

04

Análisis léxico, sintáctico y semántico

Los tres niveles de comprensión lingüística

06

Clasificación y sentimiento

Aplicaciones prácticas del NLP

El Pipeline de NLP

El pipeline de NLP es la secuencia de transformaciones que convierte texto crudo en información estructurada y procesable. Cada etapa prepara la entrada para la siguiente, garantizando que el modelo reciba datos limpios y representados correctamente.



La calidad del resultado final depende críticamente de cada etapa: un error en la limpieza o la tokenización se propaga y amplifica a lo largo de todo el proceso.



Tokenización y limpieza

¿Qué es la tokenización?

Proceso de segmentar el texto en unidades mínimas significativas llamadas **tokens**. Un token puede ser una palabra, subpalabra, carácter o símbolo de puntuación, según el enfoque elegido.

Ejemplo: *"El gato duerme."* → ["El", "gato", "duerme", "."]

Pasos de limpieza habituales

- **Lowercasing:** convertir todo a minúsculas
- **Eliminación de stopwords:** quitar palabras vacías de contenido (*de, la, y...*)
- **Stemming / Lematización:** reducir palabras a su raíz o forma canónica
- **Eliminación de puntuación y ruido:** URLs, HTML, caracteres especiales
- **Normalización de acentos:** gestión de tildes y diacríticos

Bolsa de Palabras (BoW)

El modelo de **Bolsa de Palabras** representa un documento como un vector de frecuencias de términos, ignorando el orden y la gramática. Es simple, interpretable y sorprendentemente efectivo para muchas tareas de clasificación.

Cómo funciona

Se construye un vocabulario global con todos los términos del corpus. Cada documento se representa como un vector de longitud igual al vocabulario, donde cada posición indica cuántas veces aparece ese término.

❏ Limitación clave: BoW no captura el orden ni el significado de las palabras. "El perro muerde al hombre" y "El hombre muerde al perro" producen el mismo vector.

Ejemplo ilustrativo

Término	Doc 1	Doc 2
gato	2	0
perro	0	3
animal	1	1

TF-IDF: Peso Inteligente de Términos

TF-IDF (Term Frequency–Inverse Document Frequency) mejora la Bolsa de Palabras ponderando la importancia real de cada término en un documento relativo a todo el corpus.

TF · Frecuencia de término


Mide con qué frecuencia aparece un término en un documento concreto. Un término muy repetido en un documento recibe mayor peso.

IDF · Frecuencia inversa

Penaliza los términos que aparecen en muchos documentos (como *"el"* o *"de"*), ya que aportan poca información discriminativa.


$$\text{TF-IDF} = \text{TF} \times \text{IDF}$$

El producto final premia palabras frecuentes en un documento pero raras en el corpus: las más informativas y representativas del contenido.




Tres niveles de análisis lingüístico

El NLP aborda el lenguaje en tres capas complementarias. Cada nivel añade una dimensión de comprensión más profunda sobre el texto.



Nivel léxico

Análisis de palabras individuales: tokenización, lematización, categorías gramaticales (POS tagging) e identificación de entidades nombradas (NER). Es la base sobre la que se construyen los análisis superiores.



Nivel sintáctico

Estudio de la estructura gramatical de las oraciones: árboles de dependencias, análisis de constituyentes y relaciones entre palabras. Permite entender cómo se organizan los elementos de una oración.



Nivel semántico

Comprensión del significado: desambiguación del sentido de las palabras (WSD), relaciones semánticas, inferencia y coreferencialidad. Es el nivel más complejo y el que acerca el NLP a la comprensión humana.



Word Embeddings: Palabras en el Espacio Vectorial

Los **word embeddings** son representaciones densas y continuas de las palabras en un espacio vectorial de baja dimensión (típicamente 100–300 dimensiones). A diferencia de BoW, capturan relaciones semánticas y sintácticas de forma implícita.

Intuición clave

Palabras con significados similares aparecen en contextos similares. El modelo aprende a asignarles vectores cercanos en el espacio. Esto se resume en la famosa hipótesis distribucional:

"Una palabra se conoce por la compañía que mantiene." — J.R. Firth

Ventajas sobre BoW

- Vectores densos (no dispersos)
- Capturan similitud semántica
- Permiten analogías algebraicas
- Transfieren conocimiento entre tareas

Word2Vec: Aprendiendo Significado del Contexto

Word2Vec (Mikolov et al., 2013) es el algoritmo de referencia para generar word embeddings. Entrena una red neuronal superficial con uno de dos objetivos:

CBOW · Continuous Bag of Words

Predice la palabra central a partir de su contexto (palabras vecinas). Funciona bien para vocabularios frecuentes y corpus grandes. El contexto actúa como entrada y la palabra objetivo como salida.

Skip-Gram

Predice las palabras de contexto a partir de la palabra central. Funciona mejor con palabras poco frecuentes y produce embeddings de mayor calidad en corpus pequeños.

- ❏ La famosa analogía vectorial: **rey – hombre + mujer $\approx$ reina** emerge de forma natural del entrenamiento de Word2Vec, sin que sea programada explícitamente.

Similitud Semántica

¿Cómo medimos la similitud?

Una vez que las palabras están representadas como vectores, podemos calcular cuánto se parecen semánticamente usando métricas de distancia o ángulo en el espacio vectorial.

La métrica más utilizada es la **similitud coseno**, que mide el ángulo entre dos vectores con independencia de su magnitud:

$$\text{sim}(\vec{a}, \vec{b}) = \frac{\vec{a} \cdot \vec{b}}{|\vec{a}| |\vec{b}|}$$

Aplicaciones prácticas

- **Búsqueda semántica:** encontrar documentos relevantes aunque no compartan términos exactos
- **Recomendación de contenido:** artículos, productos o canciones similares
- **Detección de paráfrasis:** identificar frases que dicen lo mismo de distinta forma
- **Clustering de textos:** agrupar documentos por temática
- **Traducción asistida:** alineamiento entre idiomas en espacios vectoriales

Clasificación de Texto

La **clasificación de texto** es una de las tareas más comunes en NLP: asignar una categoría predefinida a un documento o fragmento de texto. Se aplica en filtros de spam, clasificación de noticias, moderación de contenido y muchos otros contextos.

1

Texto de entrada

Documento crudo sin etiquetar

2

Vectorización

BoW, TF-IDF o embeddings

3

Clasificador

Naive Bayes, SVM, regresión logística

4

Etiqueta predicha

Spam / No spam, Positivo / Negativo...



Análisis de Sentimiento

El **análisis de sentimiento** (o minería de opiniones) es un caso especial de clasificación de texto cuyo objetivo es identificar la polaridad emocional o actitudinal de un texto: positivo, negativo o neutro.

Enfoques principales

1 Léxico-basado

Usa diccionarios de sentimiento (SentiWordNet, AFINN).
Rápido y sin necesidad de datos etiquetados, pero sensible a ironía y contexto.

2 Aprendizaje supervisado

Entrena un clasificador con textos etiquetados manualmente. Mayor precisión, pero requiere corpus anotado y puede no generalizar bien entre dominios.

Casos de uso reales

-  Monitorización de marca en redes sociales
-  Análisis de reseñas de productos
-  Análisis de opinión política en medios
-  Evaluación de satisfacción del cliente (NPS)
-  Análisis de sentimiento financiero en noticias

 El análisis de sentimiento tiene limitaciones importantes: la ironía, el sarcasmo y el contexto cultural siguen siendo retos abiertos de investigación.

Resumen y Próximos Pasos

En esta sesión hemos recorrido el ecosistema completo del NLP clásico, desde los fundamentos del pipeline hasta las representaciones semánticas modernas.



Pipeline NLP

Flujo estándar de transformación de texto crudo a información estructurada



Tokenización y BoW

Segmentación y representación vectorial clásica del texto



Niveles lingüísticos

Léxico, sintáctico y semántico como capas complementarias



Word2Vec y similitud

Embeddings densos que capturan relaciones semánticas algebraicas



Clasificación y sentimiento

Aplicaciones prácticas del NLP para categorizar y analizar opiniones

Próxima sesión: Modelos de lenguaje preentrenados (BERT, GPT) y aprendizaje por transferencia en NLP.