IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Algoritmos y CRISP-DM

Familias de algoritmos, cómo elegir una y las fases de un proyecto de datos

Sprint 1 · S01_02 · presentación (25 min) · día 1 del sprint (200 min)

LA IDEA · REGLAS FRENTE A APRENDIZAJE

Reglas escritas o reglas aprendidas

Programación tradicional: la persona escribe las reglas

Entrada
un correo

+

Reglas
las escribe una persona: «si pone PREMIO, es spam»

→

Salida
spam o no spam

Aprendizaje automático: el algoritmo deduce las reglas de los ejemplos

Entrada
miles de correos

+

Salida esperada
spam o no spam, ya marcado por personas

→

Reglas
las deduce el algoritmo y las aplica a correos nuevos

La clave es que el sistema generaliza: aprende del pasado para predecir casos que no ha visto.

LA IDEA · LOS DATOS (EJEMPLO INVENTADO: UN CLUB DE RUNNING)

Instancia, característica y etiqueta

Instancia	Características		Etiqueta
socio	km_semana	ritmo_entreno	tiempo_10km
2	13	6,8	68
3	17	6,1	59
12	27	5,5	54
20	23	5,0	48

ritmo_entreno en minutos por kilómetro · **tiempo_10km** en minutos, el tiempo real en una carrera de 10 km.

Instancia

Cada **fila**: un socio del club.

Característica (feature)

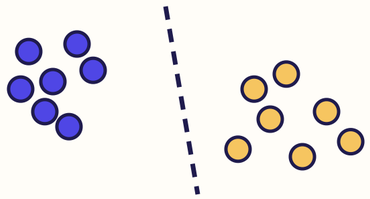
Cada **columna** que describe la fila: lo que ya se sabe.

Etiqueta (label)

La **respuesta** que queremos aprender. Solo existe en el aprendizaje supervisado.

La calidad de la etiqueta marca el techo del modelo: si está mal, ningún algoritmo lo arregla.

Cuatro familias de algoritmos

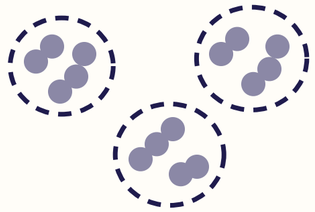


Supervisado

Hay ejemplos **con la respuesta** y quieres **predecir**.

Ej.: estimar el tiempo de un 10 km con carreras pasadas.

Etiquetas: sí

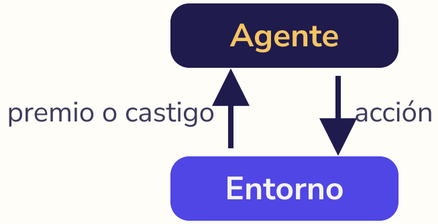


No supervisado

No hay respuestas: buscas estructura.

Ej.: agrupar canciones parecidas.

Etiquetas: no

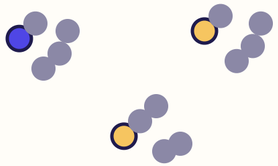


Por refuerzo

Un agente **prueba** y recibe premios o castigos.

Ej.: un programa que aprende un videojuego a base de partidas.

Etiquetas: recompensas



Semisupervisado

Pocas etiquetas y muchos datos sin etiquetar.

Ej.: informes médicos, pocos revisados por una doctora.

Etiquetas: pocas

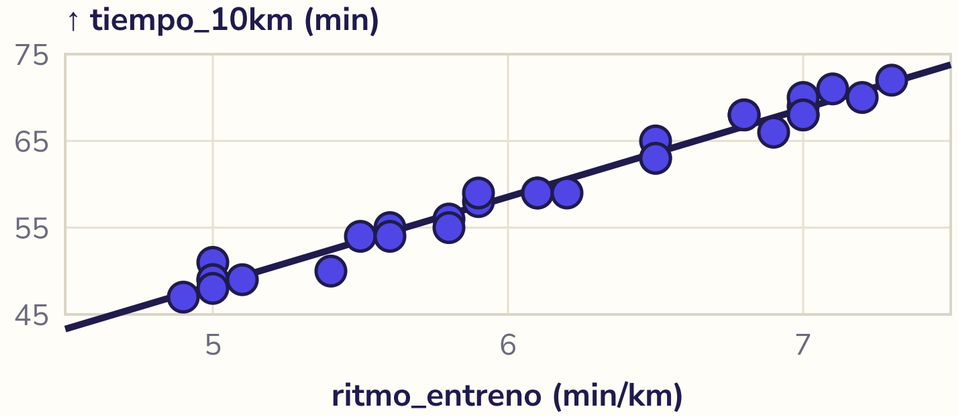
La pregunta que las ordena: ¿tengo ya ejemplos del pasado con la respuesta correcta?

LA IDEA · DENTRO DEL SUPERVISADO

Clasificación o regresión

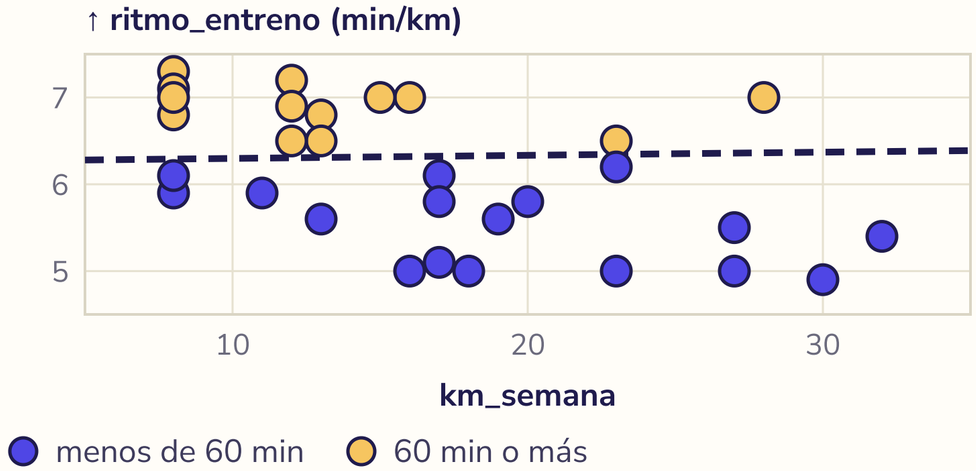
Regresión: ¿cuánto?

La respuesta es un **número**: los minutos del 10 km.



Clasificación: ¿de qué tipo?

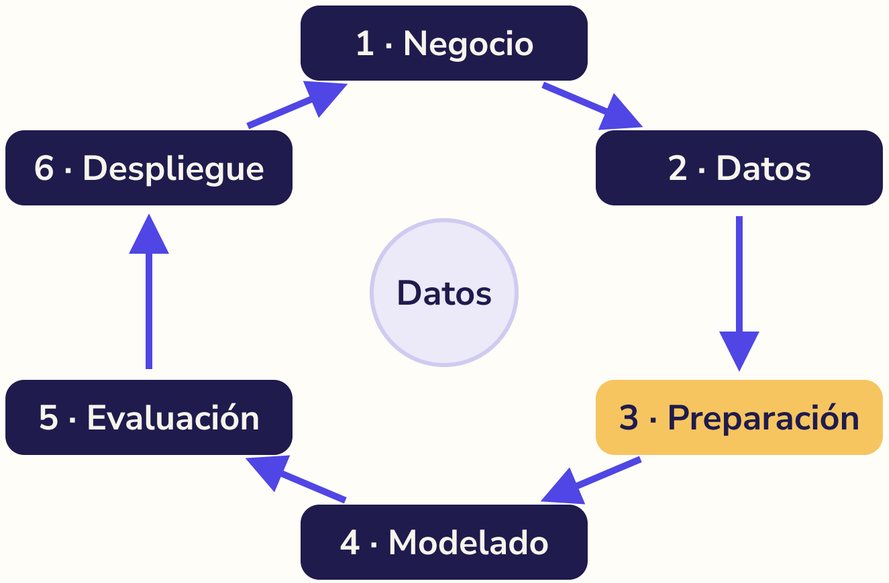
La respuesta es una **categoría**: ¿menos de 60 minutos, sí o no?



Truco: si la respuesta es sí/no o una clase, clasificación. Si es una cantidad que puede tener decimales, regresión.

LA IDEA · UN PROYECTO DE DATOS

CRISP-DM: seis fases en ciclo



Fase	Qué se hace
1 · Negocio	¿Qué decisión mejorará el modelo y cómo se mide el éxito?
2 · Datos	Recopilar, explorar y comprobar la calidad.
3 · Preparación	Limpiar, transformar y unir tablas. Suele ser la más larga: entre el 60 % y el 80 % del tiempo.
4 · Modelado	Elegir, ajustar y comparar algoritmos.
5 · Evaluación	¿Cumple los objetivos del negocio, y no solo la métrica?
6 · Despliegue	Ponerlo en marcha y vigilarlo.

No es lineal: se vuelve atrás muchas veces. Y es un ciclo: lo puesto en marcha genera datos y necesidades nuevas.

LA IDEA · PARA LA PRÁCTICA DE AHORA

Elegir el enfoque, pregunta a pregunta

Si la respuesta es sí…	entonces el enfoque es…
¿Hay una regla exacta que siempre vale?	**Reglas simples.** No hace falta IA.
¿Tengo ejemplos del pasado con la respuesta?	**Supervisado:** regresión si es un número, clasificación si es una categoría.
¿No hay respuestas y busco grupos o rarezas?	**No supervisado.**
¿Aprende probando y recibiendo premios?	**Por refuerzo.**
¿Ya existe un modelo entrenado para esto?	**Preentrenado:** se usa tal cual o se ajusta un poco.

En la Dinámica C, por cada problema

1 · ¿Qué tipo de problema es: un número, una categoría, grupos, una recomendación, contenido nuevo?

2 · ¿Qué enfoque usaríais? La tabla de la izquierda.

3 · ¿Qué datos hacen falta?

4 · ¿Importa poder explicar la decisión? Si hay que justificarla, mejor un modelo sencillo que una red profunda.

Empieza por el modelo *más simple* que pueda resolver el problema.

RETO · CONECTA CON EL INFORME

Qué parte del informe prepara esto

A1	A2	**A3**	A4	A5	**A6**	**A7**
Resumen ejecutivo	Lo que hemos entendido	**Tabla de 5 casos**	Priorización	Riesgos y checklist	**Recomendación**	**Límites del informe**

Apartado del informe	Qué aporta esta presentación
A3 · Tabla de 5 casos	Las columnas **Familia de algoritmos**, **Datos necesarios** y **Métrica de éxito**, y el caso que no necesita IA (primera pregunta de la diapositiva 7).
A6 · Recomendación	CRISP-DM: primero el negocio y el éxito, después el algoritmo.
A7 · Límites del informe	Por qué fracasan los proyectos (diapositiva 10): ayuda a señalar los límites de vuestras conclusiones.

Ahora: Dinámica C · 15 min, con el docente

Elegís la familia de algoritmos en **3 de los 6 problemas**. La columna **Aprendizaje** de la tabla llega en la presentación siguiente.

PARA CONSULTAR · DEL NEGOCIO AL MODELO (EJEMPLO INVENTADO: BICICLETAS COMPARTIDAS)

Del problema de negocio al de ML

Paso	Ejemplo inventado de un servicio de bicicletas compartidas
Problema de negocio	Que no falten bicis en las estaciones a primera hora.
Traducción a ML	Regresión: ¿cuántas bicis se retirarán en esta estación entre las 8:00 y las 9:00?
Variable objetivo	`bicis_retiradas`: un número, que se conoce cuando acaba esa hora.
Métrica de éxito	**Técnica:** error medio en bicis, frente a repetir lo de la semana pasada. **De negocio:** cuántas veces se queda vacía una estación.

Una mala traducción invalida todo el trabajo posterior, aunque el modelo sea excelente.

Baseline = el método sencillo con el que hay que compararse · **variable objetivo** = la etiqueta, lo que queremos predecir.

PARA CONSULTAR · POR QUÉ FRACASAN

Por qué fracasan los proyectos de IA

70–85 %

de los proyectos no llega a producción o no da el valor esperado.

Son estimaciones del sector: el informe de RAND de 2024 recoge que «más del 80 %» fracasan.

- Problema **mal definido** o sin métrica de negocio.
- **Datos** insuficientes, sesgados o mal gestionados.
- El modelo no se integra en el trabajo real: **nadie lo adopta**.
- **No hay plan de vigilancia** tras ponerlo en marcha.
- Se usó IA donde **bastaban reglas** sencillas.

Casi nunca por motivos técnicos: casi siempre por el problema, los datos o las personas.

HOY EN 25 MINUTOS

Tres ideas para elegir el enfoque

Reglas o aprendizaje

En el aprendizaje automático el algoritmo **deduce las reglas** de los ejemplos y generaliza.

Familias y tipos

Supervisado, no supervisado, por refuerzo y semisupervisado. Categoría: **clasificación**. Número: **regresión**.

Seis fases

CRISP-DM: negocio, datos, preparación, modelado, evaluación y despliegue, en ciclo.

Ahora: Dinámica C · elegir la familia de algoritmos en 3 de los 6 problemas · 15 min, con el docente.