IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

IA responsable

Ética, sesgo, datos y normativa: qué mirar antes de usar una IA con personas

Sprint 1 · S01_04 · presentación (50 min) · día 2 del sprint (200 min)

CASOS REALES · TRES QUE SALIERON MAL

Tres sistemas que trataron peor a unas personas

45 % y 23 %

COMPAS · EE. UU. · 2016

Software que puntuaba el riesgo de reincidencia.

Entre quienes **no** volvieron a delinquir, marcó como riesgo alto al 45 % de los acusados negros y al 23 % de los blancos.

10 años

Selección de CV · Amazon · 2018

Aprendió de diez años de contrataciones, mayoritariamente de hombres.

Penalizaba a las candidatas, y la empresa dejó de usarlo.

34,7 % y 0,8 %

Reconocimiento facial · 2018

Tres sistemas comerciales que decían si una cara era de mujer o de hombre.

Error de hasta 34,7 % en mujeres de piel oscura y nunca peor que 0,8 % en hombres de piel clara.

El algoritmo no «es racista»: reproduce lo que había en los datos, y nadie midió la equidad antes de usarlo.

LA IDEA · CUATRO PRINCIPIOS

Cuatro principios para juzgar una IA

Principio	En una frase	Un ejemplo de la vida diaria
Beneficencia	Debe dar un beneficio real y medible	Un termostato inteligente que de verdad ahorra luz: se ve en la factura
No maleficencia	Minimizar daños, también los que nadie buscaba	Una app de rutas no debe mandar un camión por una calle estrecha
Autonomía	Sin manipular ni forzar a las personas	Una tienda web que dice «solo queda 1» sin ser verdad
Justicia	Beneficios y riesgos repartidos con equidad	Una app de reparto que da los mejores pedidos solo a quien tiene el móvil más nuevo

¿Quién responde si falla? El **proveedor** crea el sistema; el **responsable del despliegue** lo pone en uso. Si nadie se hace cargo, la responsabilidad acaba siendo de nadie.

LA IDEA · GOBERNANZA DE DATOS

Cuidar los datos de principio a fin

Etapa	Como la comida en casa	Preguntas clave
1 · Recopilación	Hacer la compra	¿De dónde viene? ¿Hay permiso? ¿Es legal? ¿Representa a todos?
2 · Almacenamiento	Guardarla en la nevera	¿Está seguro y cifrado (en clave)? ¿Quién tiene la llave?
3 · Procesamiento	Cocinarla	Limpiar y **anonimizar**: quitar lo que identifica a la persona
4 · Uso	Comérsela	¿Se usa para lo declarado? ¿Solo los datos necesarios?
5 · Eliminación	Tirar lo caducado	¿Durante cuánto tiempo se guarda? ¿Y el derecho al olvido?

Siempre: **calidad e integridad**, **privacidad por diseño** (desde el principio, no al final) y **trazabilidad** (saber qué se hizo con cada dato).

LA IDEA · SESGO

El sesgo se acumula en todo el proceso

Sesgo = un error sistemático que perjudica a un grupo. No sale de un solo sitio: hay que buscarlo en cada etapa.

Origen	Qué pasa	Un ejemplo de la vida diaria
Datos	Un grupo apenas aparece, o los datos repiten discriminaciones del pasado	Una app de voz entrenada casi solo con voces adultas falla con niñas y niños
Etiquetas	Quien etiqueta tiene estereotipos, o las categorías son ambiguas	Si quien marca «comida sana» solo piensa en su propia cocina, las demás salen mal
Modelo	Una variable hace de **proxy**: adivina un dato sensible sin nombrarlo	El código postal puede delatar el origen o los ingresos, aunque no pongas esa columna
Uso	El modelo decide, cambia el comportamiento y salen datos nuevos sesgados: un **bucle**	Una web enseña lo más visto, y por eso lo más visto se ve todavía más

LA IDEA · EQUIDAD

Equidad: hay varias formas de medirla

Un instituto ofrece tutorías de apoyo a quien **marca** el modelo. Dos grupos de 100 alumnos:

Grupo	Necesitan apoyo	El modelo marca	Marcados que sí lo necesitan	Marcados que no lo necesitan
A	40	40	32	8
B	10	10	8	2

40 % y 10 %

Paridad demográfica

Marca a la misma proporción de cada grupo.

No se cumple.

80 % y 80 %

Igualdad de oportunidades

Encuentra a la misma proporción de quienes lo necesitan.

Se cumple.

80 % y 80 %

Calibración

Cuando marca, acierta lo mismo en los dos grupos.

Se cumple.

Con grupos distintos no se pueden cumplir todas a la vez. Elegir cuál importa más es una decisión humana.

LA IDEA · EXPLICAR Y PODER RECLAMAR

Poder explicar por qué decidió

Transparencia y explicabilidad

Transparencia: se puede examinar cómo funciona el sistema.

Explicabilidad (XAI): se puede contar **por qué** decidió algo en un caso concreto.

LIME y **SHAP** son técnicas que muestran qué datos pesaron más en una decisión.

Como un médico: no basta con «la prueba dice que sí».

Tus derechos en el RGPD

Saber qué datos se usan y, en decisiones automáticas, con qué lógica (arts. 13 a 15).

Rectificar lo que esté mal (art. 16).

Borrar tus datos: el «derecho al olvido» (art. 17).

No quedar sujeto a una decisión solo automática con efectos importantes, y pedir **intervención humana** (art. 22).

Lo que no se puede explicar, no se puede discutir; y lo que no se puede discutir, no se puede corregir.

Lo esencial del RGPD para un proyecto de IA

RGPD = Reglamento general de protección de datos de la UE. **LOPDGDD** = la ley orgánica española que lo completa.

Principio	Qué implica	Un ejemplo de la vida diaria
Finalidad	No reutilizar datos para otro fin sin base legal	El móvil que diste para recibir un paquete no vale para entrenar un modelo
Minimización	Recoger solo lo que hace falta de verdad	Para enviar un paquete no hace falta tu fecha de nacimiento
Art. 22	No decidir **solo con automatización** si hay efectos importantes	Que un algoritmo rechace un crédito sin que lo vea una persona
EIPD	Evaluación de impacto en protección de datos, **antes** de desplegar un tratamiento de alto riesgo	Como un estudio de seguridad antes de abrir un local

DPD (delegado de protección de datos): vigila que se cumpla. AEPD: la autoridad española; sus guías, en aepd.es.

LA LEY · AI ACT

El AI Act clasifica la IA por su riesgo

AI Act = Reglamento (UE) 2024/1689, la norma europea de inteligencia artificial.

Nivel	Qué ocurre	Ejemplos
Inaceptable	**Prohibido**	Puntuación social; manipulación subliminal
Alto	Obligaciones estrictas	Empleo, educación, crédito, justicia
Limitado	**Transparencia**	Un chatbot avisa de que es IA; el contenido creado con IA (deepfakes) se etiqueta
Mínimo	Sin obligaciones específicas	El filtro de spam del correo

Alto riesgo: gestión de riesgos, buenos datos, documentación y registros (logs) y supervisión humana.

PARA CASA · FECHAS Y MULTAS (CASA)

Fechas y multas: se comprueban siempre

Desde	Qué empieza a aplicarse del AI Act
1/8/2024	El Reglamento de IA entra en vigor.
2/2/2025	Se aplican las prácticas **prohibidas**.
2/8/2025	Obligaciones para los **modelos de IA de uso general**.
2/8/2026	Se aplica la **mayoría de las normas**, con la transparencia.
2/12/2026	Nuevas prohibiciones (p. ej., deepfakes sexuales sin consentimiento).
2/12/2027	**Alto riesgo** de uso listado (empleo, educación, crédito...). Antes: 2/8/2026.
2/8/2028	**Alto riesgo** en productos regulados (juguetes, máquinas...). Antes: 2/8/2027.

Multas máximas

RGPD: 20 M€ o el 4 % de la facturación anual mundial, la cifra mayor.

AI Act: 35 M€ o el 7 % en las prácticas prohibidas; 15 M€ o el 3 % en otras obligaciones.

En España: **AEPD** (datos personales) y **AESIA** (supervisión de la IA).

Las fechas del alto riesgo se aplazaron en 2026 (Ómnibus digital de IA). **Verifica el calendario vigente** en el Servicio de Ayuda del AI Act.

EL RETO · LISTA DE COMPROBACIÓN ÉTICA

Diez bloques de preguntas para cada caso

Se rellena **por caso** y empieza con una **ficha rápida** (apartado 0): qué problema resuelve, quién la usa y quién se ve afectado, si la IA **decide o apoya**.

1 · Propósito
¿Hace falta IA? (diap. 3)

2 · Datos y privacidad
Diap. 4 y 8

3 · Sesgo y equidad
Diap. 5 y 6

4 · Transparencia
Diap. 7 y 9

5 · Supervisión humana
Diap. 7 y 8

6 · Robustez
Probar con datos que el modelo no vio (S01_03)

7 · Impacto social
Justicia (diap. 3)

8 · Normativa
RGPD y AI Act (diap. 8 y 9)

9 · Gobernanza
¿Quién responde? (diap. 3)

10 · Resultado
Tabla de riesgos y semáforo

Hay **13 preguntas con (★)**: son las que no se pueden saltar, ni siquiera en los casos resumidos.

EL RETO · CÓMO SE CONTESTA

Del caso al semáforo

Qué se entrega

checklist_etico.md en **sprint-01/**: un bloque por caso.

Completo en los 2 casos que priorizáis; **resumido** en los otros 3: ficha rápida, preguntas (★) y semáforo.

En el AI Act, anotad «verificar calendario vigente».

Cómo se contesta una fila

Pregunta 1.1 (★): ¿el problema es real y está explicado con datos? Caso: una panadería que quiere predecir cuántas barras hornear.

Vale: «Sí: tira unas 12 barras al día; lo vemos en su cuaderno de ventas».

No vale: «Sí, es un problema importante».

Se responde S, N, NA (no aplica) o ? y se añade algo **comprobable**.

Verde
se puede avanzar

Ámbar
avanzar con medidas

Rojo
no avanzar sin cambios

Un caso en rojo también es un buen resultado: detectar a tiempo un proyecto dañino es parte del trabajo.

PARA LLEVARSE

Pensar antes de poner una IA en marcha

Casos y principios

Tres casos reales de sesgo.

Beneficencia, no maleficencia, autonomía, justicia.

Quién responde debe quedar escrito.

Datos, sesgo y equidad

Cuidar los datos en cada etapa.

El sesgo se acumula en todo el proceso.

Hay **varias** definiciones de equidad.

La ley

RGPD: finalidad, minimización, art. 22.

AI Act: cuatro niveles de riesgo.

Las fechas se **comprueban** siempre.

Antes de usar una IA con personas: ¿a quién puede perjudicar, quién responde y qué dice la ley?