Apuntes del Sprint 1 · Qué es la IA, cómo aprende y cómo usarla con responsabilidad

Las diapositivas del Sprint 1 (S01_01 a S01_04) son un esquema muy comprimido. Estos apuntes **cuentan lo mismo con calma**, con ejemplos de TurisData y sin dar nada por sabido. Léelos antes de las dinámicas o cuando una palabra te suene rara. No hay que memorizar: hay que **entender para qué sirve cada idea**. No hace falta saber programar ni matemáticas para seguirlos.

0. De qué va el sprint (en 1 minuto)

Este sprint responde a cuatro preguntas, una por cada presentación:

Presentación	Pregunta	Idea clave
S01_01 Introducción a la IA	¿Qué es la IA y qué puede (y no puede) hacer?	IA ≠ magia: aprende patrones de datos
S01_02 Algoritmos y CRISP-DM	¿Qué tipos de problemas hay y cómo se organiza un proyecto?	Primero el problema, después el algoritmo
S01_03 Tipos de aprendizaje	¿Cómo aprende un modelo y cómo sé si lo hace bien?	Hay que evaluar con datos que no ha visto
S01_04 IA responsable	¿Qué puede salir mal con las personas y la ley?	Sesgo, privacidad, RGPD y AI Act

El reto: elegir casos de uso de IA para TurisData y **analizarlos con una lista de comprobación ética**, decidiendo cuáles son recomendables y cuáles no.

DÍA 1 · Qué es la IA y cómo se organiza un proyecto

1. ¿Qué es la IA, en lengua normal?

Hay dos formas de definirla:

Definición	Qué dice
Clásica	Un sistema que hace tareas que, si las hiciera una persona, requerirían inteligencia (razonar, aprender, percibir, decidir)
Operativa (la que usaremos)	Algoritmos que **aprenden patrones a partir de datos** para predecir, clasificar o generar contenido, **sin que nadie programe cada caso**

Lo que NO es: no entiende, no siente, no tiene conciencia. Es una herramienta potente con límites claros. Cuando un chatbot dice «lo siento», no lo siente: ha aprendido que esa frase encaja ahí.

El mapa: muñecas rusas

Los términos se confunden mucho porque **unos están dentro de otros**:

```
IA  (el campo completo, incluye reglas escritas a mano)
 └── Machine Learning  (aprende de ejemplos, no de reglas)
      └── Deep Learning  (redes neuronales profundas, muchos datos)
           └── IA generativa  (crea texto, imagen, audio, código: GPT, etc.)
```

- Un **antivirus con una lista de reglas escritas a mano** es IA, pero **no** es machine learning.
- Un **filtro de spam que aprende de millones de correos** es machine learning.
- **ChatGPT** es deep learning y además generativa.

Débil, general y superinteligencia

Tipo	Estado hoy
IA débil	Es **todo lo que existe**: muy buena en una tarea concreta (traducir, reconocer caras…)
IA general (AGI)	Hipotética: una IA que haría cualquier tarea intelectual humana
Superinteligencia	Especulativa

Cuando oigas «la IA va a dominar el mundo», recuerda: lo que hay hoy es IA débil.

2. Veranos e inviernos (por qué importa la historia)

La IA ha vivido ciclos de **entusiasmo (verano)** y **desencanto (invierno)**:

Época	Qué pasó
1950-60	Turing, Dartmouth: optimismo sin límites
1970	**Primer invierno:** poca potencia, se acaba la financiación
1980-90	Sistemas expertos (reglas a mano); **segundo invierno** al escalar mal
2012	**Deep learning**: AlexNet gana el concurso ImageNet gracias a las tarjetas gráficas (GPU) y muchos datos
2022-hoy	La IA generativa llega al gran público

Para qué sirve saberlo: para tener **expectativas realistas**. Cada ola prometió más de lo que cumplió a corto plazo.

3. Modalidades: qué percibe y qué genera la IA

Modalidad	Ejemplo
Visión	Detectar objetos, imagen médica
Lenguaje	Traducir, resumir, chatbots
Voz	Transcribir, asistentes
Recomendación	Netflix, Spotify, actividades para turistas
Datos tabulares y series	Predecir ocupación o cancelaciones (**lo que más haremos en el curso**)
Generativa	Crear texto, imagen, audio, código
Robótica	Percibir el entorno y adaptar la conducta

Muchos sistemas mezclan varias (un asistente de voz: voz + lenguaje + generativa).

Casos en Canarias: chatbots multiidioma y predicción de ocupación en turismo; mantenimiento predictivo en puertos; visión para la calidad del plátano y el tomate; clasificación de expedientes y atención ciudadana en la administración; tutores adaptativos y detección de abandono en educación; diagnóstico asistido por imagen y triaje en salud.

4. Tres mitos y los límites reales

Mito	Realidad
«La IA lo entiende todo»	**Asocia patrones**; no comprende el significado
«La IA es objetiva»	**Hereda los sesgos de los datos** con los que aprendió
«Sustituirá todos los empleos»	**Automatiza tareas**, no profesiones; exige supervisión humana

Límites reales: *alucinaciones* (inventa cosas con mucha seguridad), depende de datos de calidad, es una *caja negra* (a veces no sabemos por qué decide algo), consume mucha energía y **no tiene sentido común** fuera de lo que vio al entrenar.

5. Qué necesita un proyecto de IA

No es solo «un modelo»:

Necesita	Por qué
Datos suficientes, relevantes, limpios y representativos	Sin ellos el modelo es inútil o sesgado
Personas: técnicas y expertas del negocio	Hay que entender el problema, no solo programar
Infraestructura (cómputo, plataformas, MLOps)	Para entrenar, desplegar y vigilar el modelo
Cambio organizativo (liderazgo, formación, cultura de probar)	Un proyecto técnicamente bueno puede fracasar si nadie lo usa

6. Reglas frente a aprendizaje

La diferencia fundamental:

Programación tradicional	Aprendizaje automático
Tú escribes las reglas	**La máquina deduce las reglas** de los ejemplos
Entrada + reglas → salida	Entrada + salida esperada → reglas aprendidas
Frágil ante lo imprevisto	Se adapta a patrones nuevos
«Si el correo contiene *premio*, es spam»	Aprende spam de millones de correos

La clave es que el sistema **generaliza**: aprende del pasado para predecir casos que **no ha visto**.

7. Las familias de algoritmos

Familia	Cuándo	Ejemplo	¿Etiquetas?
Supervisado	Hay datos con la respuesta conocida y quieres predecir	Cancelaciones, fraude	Sí
No supervisado	No hay respuestas; buscas estructura	Agrupar clientes	No
Por refuerzo	Un agente prueba acciones y recibe premios o castigos	Robótica, juegos	Recompensas
Semisupervisado	Pocas etiquetas y muchos datos sin etiquetar	Texto médico parcial	Pocas

Dentro de lo supervisado hay **dos tipos de problema**, y confundirlos es el error más frecuente:

	Pregunta	Salida	Ejemplo TurisData
Clasificación	¿De qué tipo es? ¿Sí o no?	Una **categoría**	¿Esta reserva se cancelará? (sí/no)
Regresión	¿Cuánto?	Un **número**	¿Cuántos euros ingresará mañana?

Truco: si la respuesta es «sí/no» o una clase → clasificación. Si es una cantidad que puede tener decimales → regresión.

8. Instancias, características y etiquetas

Imagina una tabla de reservas de TurisData:

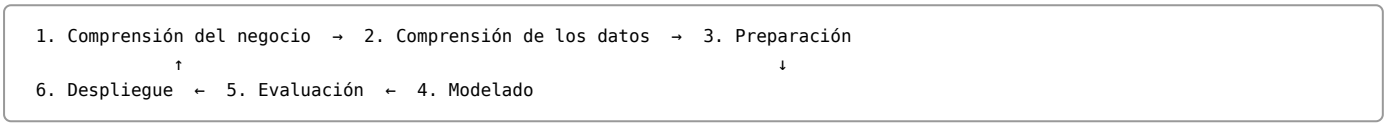
canal	tarifa	antelacion_dias	cancelada
web	flexible	45	no
agencia	no reembolsable	3	no
web	flexible	60	**sí**

- **Instancia** = cada **fila** (una reserva).
- **Característica (feature)** = cada **columna** que describe la fila (canal, tarifa, antelación).
- **Etiqueta (label)** = la **respuesta que queremos aprender** (`cancelada`). Solo existe en el aprendizaje supervisado.

Regla importante: la calidad de la etiqueta marca el **techo del modelo**. Si las etiquetas están mal, ningún algoritmo lo arregla.

9. CRISP-DM: las seis fases de un proyecto de datos

Es el «manual de ruta» estándar:



Fase	Qué se hace
1. Negocio	¿Qué decisión mejorará el modelo? ¿Cómo se mide el éxito?
2. Datos	Recopilar, explorar y comprobar la calidad
3. Preparación	Limpiar, transformar, unir tablas (**60-80 % del tiempo**)

Fase	Qué se hace
4. Modelado	Elegir, ajustar y comparar algoritmos
5. Evaluación	¿Cumple los objetivos del **negocio** (no solo la métrica)?
6. Despliegue	Ponerlo en producción y vigilarlo

No es lineal: se vuelve atrás muchas veces. Y es un **ciclo**: el despliegue genera datos y necesidades nuevas.

Del problema de negocio al problema de ML

Es el paso donde más gente se equivoca. Ejemplo en TurisData:

Paso	Ejemplo
Problema de negocio	«Reducir las habitaciones vacías por cancelaciones de última hora»
Traducción a ML	Clasificación binaria: ¿esta reserva se cancelará?
Variable objetivo	`cancelada` (0 / 1)
Métrica de éxito	Detectar las cancelaciones (exhaustividad o *recall*) sin saturar de falsas alarmas

Una mala traducción **invalida todo el trabajo posterior**, aunque el modelo sea excelente.

Cómo elegir un algoritmo

Se mira: **cuántos datos** hay (los modelos complejos necesitan más), **explicabilidad** (¿hay que justificar decisiones?), y **coste/tiempo** (¿en tiempo real o por lotes?). Rara vez se maximizan exactitud, explicabilidad y coste a la vez.

> **Regla de oro:** empieza por el modelo **más simple** que pueda resolver el problema.

Por qué fracasan los proyectos de IA

Según el informe de RAND (2024), **más del 80 %** de los proyectos de IA fracasan: no llegan a producción o no dan el valor esperado, **y casi nunca por motivos técnicos**:

1. Problema mal definido o sin métrica de negocio.
2. Datos insuficientes, sesgados o mal gestionados.
3. El modelo no se integra en el trabajo real; nadie lo adopta.
4. No hay plan de vigilancia tras desplegar.
5. Se usó IA donde bastaban reglas sencillas.

DÍA 1 · Cómo aprenden los modelos y cómo evaluarlos

10. Los tipos de aprendizaje

Tipo	Idea	Algoritmos del curso	Sprint
Supervisado	Ejemplos con respuesta conocida	Regresión lineal y logística, k-NN, Naive Bayes, árboles, ensembles, SVM, redes	7-8, 10
No supervisado	Sin etiquetas: busca estructura	k-means, clustering jerárquico, PCA	9
Por refuerzo	Recompensas por actuar bien	Q-learning	9
Autosupervisado / preentrenado	Aprende de datos sin etiquetas (por ejemplo, **adivinar la palabra que falta**) y luego se ajusta	Transformers, LLM	12

Supervisado, con una imagen: es como estudiar con **un libro de ejercicios con soluciones**. El modelo ve pares (X, y), predice, compara con la solución y **ajusta sus parámetros para equivocarse menos**.

No supervisado: te dan 1.000 fichas de clientes **sin decir nada** y te piden que las ordenes en montones parecidos. Eso es *clustering*. También existe *reducción de dimensión*: resumir muchas variables en pocas.

Por refuerzo: como entrenar a un perro con premios. El agente prueba, recibe recompensa o castigo y aprende una *política* (qué hacer en cada situación).

> Si vas a entrenar con datos **vuestros ya etiquetados**, es aprendizaje **supervisado**, aunque el modelo parta de uno preentrenado.

11. Entrenamiento, validación y test: el examen justo

Para saber si un modelo aprende **de verdad** (y no solo se ha aprendido las respuestas de memoria) se reparten los datos en tres grupos:

Conjunto	Para qué	Cuándo se usa
Entrenamiento	El modelo ajusta sus parámetros	Siempre
Validación	Comparar modelos y ajustar *hiperparámetros* (los «botones» del algoritmo)	Durante el desarrollo
Test	Medir el rendimiento final	**Una sola vez**, al final

Analogía del examen:

- **Entrenamiento** = los ejercicios con los que estudias.
- **Validación** = los simulacros para ver si vas bien.
- **Test** = el examen real. **Si lo ves antes para decidir cosas, deja de ser un examen**: es un ejercicio que ya has visto.

Con **datos temporales** (reservas por fecha) se entrena con lo **antiguo** y se evalúa con lo **reciente**: no se puede usar el futuro para predecir el pasado.

12. Sobreajuste e infraajuste

Son los dos errores clásicos:

	Infraajuste (underfitting)	Sobreajuste (overfitting)
Qué pasa	Modelo demasiado simple	Modelo demasiado ajustado: **memoriza el ruido**
En entrenamiento	Va mal	Va **muy bien**
Con datos nuevos	Va mal	Va **mal**
Remedio	Modelo más flexible, mejores variables	Más datos, simplificar, regularizar, validación cruzada

Ejemplo numérico:

```
Modelo A:  entrenamiento 62 %,  validación 60 %   → infraajuste (flojo en todo)
Modelo B:  entrenamiento 99 %,  validación 70 %   → SOBREAJUSTE (memoriza)
Modelo C:  entrenamiento 85 %,  validación 83 %   → bien equilibrado
```

La señal de alarma: una gran diferencia entre entrenamiento y validación (en B: 99 − 70 = **29 puntos**). Se dice también *sesgo alto = infraajuste* y *varianza alta = sobreajuste*.

Analogía: un alumno que memoriza las respuestas del libro (sobreajuste) saca 10 en los ejercicios y suspende cuando cambian los números.

13. Evaluar: exactitud y matriz de confusión

La exactitud (accuracy) y su trampa

Exactitud = aciertos ÷ total. Parece perfecta, pero **engaña cuando la clase importante es rara**.

Imagina 100 reservas, de las que solo **5 se cancelan**. Un «modelo» que **siempre dice que no cancela**:

```
Aciertos = 95 (las 95 que no cancelan)   →   exactitud = 95/100 = 95 %
Cancelaciones detectadas = 0 de 5
```

Parece excelente (95 %) **y es completamente inútil**: no detecta ninguna cancelación.

La matriz de confusión

Es una tabla que cuenta **cómo acierta y cómo se equivoca**:

	Predice: no cancela	**Predice: cancela**
Real: no cancela	Acierto (VN)	**Falsa alarma** (FP)
Real: cancela	**Cancelación no detectada** (FN)	Acierto (VP)

Ejemplo con otro modelo sobre esas mismas 100 reservas (5 cancelan):

```
VP = 4  (cancelaciones detectadas)      FN = 1  (cancelación que se le escapó)
FP = 6  (falsas alarmas)                VN = 89 (no cancelan y acertó)

Total: 4 + 1 + 6 + 89 = 100
Exactitud = (4 + 89) / 100 = 93 %       ← MENOS que el modelo inútil (95 %)
Recall    = 4 / (4 + 1)    = 80 %       ← detecta 4 de cada 5 cancelaciones
Precisión = 4 / (4 + 6)    = 40 %       ← de cada 10 avisos, 4 son ciertos
```

Fíjate: **tiene peor exactitud (93 % < 95 %) y es muchísimo más útil**. Por eso se mira siempre la matriz y se compara con un **modelo de referencia muy simple** (baseline).

> Métricas más finas (precisión, exhaustividad o *recall*, AUC) se ven en los Sprints 6, 7 y 13. Aquí basta con entender **por qué la exactitud sola no sirve**.

DÍA 2 · IA responsable: ética, sesgo y normativa

14. Casos que salieron mal

Caso	**Qué pasó**
COMPAS (EE. UU., 2016)	Software que predecía riesgo de reincidencia. ProPublica comparó sus puntuaciones con lo que pasó después: entre quienes **no** volvieron a delinquir, marcó como riesgo alto al **45 %** de los acusados negros y al **23 %** de los blancos
Amazon, selección de CV (2018)	Se retiró: **penalizaba a las candidatas** porque aprendió de diez años de contrataciones mayoritariamente masculinas
Reconocimiento facial	Errores muy distintos según el grupo: **34,7 %** en mujeres de piel oscura frente a **0,8 %** en hombres de piel clara (estudio *Gender Shades*, de Buolamwini y Gebru, 2018, con tres sistemas comerciales: error de **hasta** 34,7 % en un caso y **nunca más de** 0,8 % en el otro)

Qué tienen en común: resultados discriminatorios, con **datos históricos sesgados** y nadie midió la equidad antes de desplegar. El algoritmo no «es racista»: **reproduce lo que había en los datos**.

15. Los cuatro pilares éticos

Principio	**En una frase**
Beneficencia	Debe dar un beneficio real y medible
No maleficencia	Minimizar daños, también los no intencionados
Autonomía	Sin manipular ni forzar a las personas
Justicia	Beneficios y riesgos repartidos con equidad

¿Quién responde si falla? La cadena es larga (quien desarrolla, quien vende, quien usa). El AI Act distingue **proveedor** (quien lo crea) y **responsable del despliegue** (quien lo pone en uso). Si la responsabilidad se reparte sin cuidado, **acaba siendo de nadie**.

16. Gobernanza de datos: el ciclo de vida

Etapa	**Preguntas clave**
1. Recopilación	¿De dónde viene? ¿Hay consentimiento? ¿Es legal? ¿Representa a todos?

Etapa	Preguntas clave
2. Almacenamiento	¿Seguro? ¿Cifrado? ¿Quién accede?
3. Procesamiento	Limpieza, **anonimización**
4. Uso	¿Para la finalidad declarada? ¿Solo los datos necesarios?
5. Eliminación	¿Plazos? ¿Derecho al olvido?

Y siempre: **calidad e integridad**, **privacidad por diseño** (se piensa desde el principio, no al final) y **trazabilidad** (poder saber qué se hizo con cada dato).

17. De dónde sale el sesgo

El sesgo **no aparece en un solo sitio**: se acumula a lo largo de todo el proceso.

Origen	Ejemplo
Datos	Poca representación de un grupo; datos históricos discriminatorios; *sesgo de supervivencia* (solo vemos a quien «sobrevivió»)
Etiquetas	Quien etiqueta tiene estereotipos; categorías ambiguas
Modelo	Variables que actúan de **proxy**: el código postal puede «adivinar» el origen o los ingresos aunque no pongas esa variable
Uso	El modelo decide → cambia el comportamiento → genera datos nuevos sesgados (**bucle de retroalimentación**)

Ejemplo del bucle: un modelo manda más policía a un barrio → se detectan más delitos allí → los datos dicen que ese barrio es «más peligroso» → el modelo manda aún más policía.

18. Equidad y explicabilidad

- **Equidad:** hay **varias definiciones** (paridad demográfica, igualdad de oportunidades, calibración) y **no se pueden cumplir todas a la vez** si los grupos tienen tasas distintas. Se elige según el contexto, y esa elección es una decisión humana.
- **Transparencia:** se puede examinar el sistema. **Explicabilidad (XAI):** se puede comunicar **por qué** decidió algo. Técnicas: LIME, SHAP, mapas de saliencia, árboles «sombra».
- **Derechos de las personas:** información y acceso, rectificación y olvido (RGPD, arts. 13 a 17) e **intervención humana** en las decisiones automatizadas (art. 22).

19. RGPD y LOPDGDD en lo esencial

Principio	Qué implica en un proyecto de IA
Limitación de finalidad	No reutilizar datos para entrenar con otros fines sin base legal
Minimización	¿Hace falta **de verdad** cada variable? Si no, no se recoge
Art. 22	No decidir **solo con automatización** cuando hay efectos jurídicos relevantes
EIPD	Evaluación de impacto **antes** de desplegar tratamientos de alto riesgo

En España: figura del **DPD** (delegado de protección de datos), sanciones de hasta **20 M€ o el 4 %** de la facturación mundial anual, la cifra que sea mayor, en las infracciones más graves (RGPD, art. 83), y la **AEPD** como autoridad (guías en aepd.es).

20. AI Act: cuatro niveles de riesgo

La norma europea de IA clasifica los sistemas por riesgo:

Nivel	Qué ocurre	Ejemplos
Inaceptable	**Prohibido**	Puntuación social, manipulación subliminal
Alto	Obligaciones estrictas	Empleo, educación, crédito, justicia
Limitado	Transparencia	Un chatbot debe decir que es IA; los *deepfakes* se etiquetan
Mínimo	Sin obligaciones específicas	Filtros de spam

Los sistemas de **alto riesgo** necesitan gestión de riesgos, gobernanza de datos, documentación y registros, y **supervisión humana**. Los plazos son escalonados: **consulta siempre el calendario vigente** antes de decidir.

Calendario (Reglamento (UE) 2024/1689, comprobado en noviembre de 2026; verifícalo antes de citarlo): entró en vigor el 1/8/2024; las prácticas prohibidas se aplican desde el 2/2/2025; los modelos de IA de uso general, desde el 2/8/2025; la mayoría de las normas, con la transparencia, desde el 2/8/2026 (el 2/12/2026, el marcado de los contenidos generados por sistemas ya comercializados y dos nuevas prohibiciones: imágenes íntimas falsas sin consentimiento y material de abuso sexual infantil); el alto riesgo de uso listado (empleo, educación, crédito…), desde el 2/12/2027, y el de productos regulados (juguetes, máquinas…), desde el 2/8/2028, tras el aplazamiento del «Ómnibus digital de IA» (Reglamento (UE) 2026/1744). Hay excepciones según el tipo de sistema y la fecha en que se comercializó, y las fechas pueden volver a cambiar.

Multas máximas del AI Act: 35 M€ o el 7 % de la facturación mundial anual en las prácticas prohibidas, 15 M€ o el 3 % en otras obligaciones y 7,5 M€ o el 1 % por dar información engañosa a las autoridades (siempre la cifra mayor; en las pymes, la menor). En España vigilan la **AEPD** (datos personales) y la **AESIA** (Agencia Española de Supervisión de la Inteligencia Artificial).

Ejemplo TurisData: un chatbot de reservas es riesgo **limitado** (avisar de que es IA). Un sistema que **filtra currículums** para contratar personal sería **alto** riesgo.

21. La lista de comprobación ética

En el reto rellenaréis `checklist_etico_v1.md` para cada caso de uso. Hay una ficha rápida del caso y diez bloques de preguntas:

1. **Propósito y proporcionalidad:** ¿hace falta IA?
2. **Datos y privacidad**
3. **Sesgo y equidad**
4. **Transparencia**
5. **Supervisión humana**
6. **Robustez y seguridad**
7. **Impacto social y ambiental**
8. **Normativa** (orientación)
9. **Gobernanza**
10. **Resultado:** tabla de riesgos y semáforo (verde, ámbar o rojo)

> **Un caso puede salir en rojo («no avanzar sin cambios») y eso también es un buen resultado.** Detectar a tiempo un proyecto dañino es parte del trabajo.

22. Dónde practicar cada cosa

Si no entiendes…	Mira la sección	Practica en
Qué es IA, modalidades, casos de uso	1-5	Dinámica A: `tarjetas_casos_uso.md`
Clasificación frente a regresión, features y etiqueta	7-8	`ejemplo_clasificacion_caso.md`
Del problema de negocio a ML, CRISP-DM	9	Reto (pasos 1-2: elegir casos)
Entrenamiento / validación / test, sobreajuste	11-12	Ejercicio HTML «bueno o malo»
Exactitud y matriz de confusión	13	Ejercicios HTML de matriz de confusión
Sesgo, ética, casos que salieron mal	14-18	`casos_debate_ia_responsable.md`
RGPD, AI Act, lista de comprobación	19-21	Reto (pasos 3-5) y `checklist_etico_v1.md`

23. Chuleta de vocabulario

Palabra	En lengua normal
Machine learning	La máquina aprende reglas a partir de ejemplos
Deep learning	ML con redes neuronales de muchas capas
IA generativa	IA que crea contenido nuevo (texto, imagen, código…)
IA débil	Buena en una sola tarea: es toda la IA actual
Alucinación	Respuesta inventada pero dicha con seguridad
Instancia	Una fila de la tabla (un ejemplo)

Palabra	En lengua normal
Característica / feature	Una columna que describe la instancia
Etiqueta / label	La respuesta que queremos aprender
Supervisado	Con respuestas conocidas
No supervisado	Sin respuestas; busca grupos o estructura
Clasificación	Predecir una categoría
Regresión	Predecir un número
Sobreajuste	Memoriza el ruido; falla con datos nuevos
Infraajuste	Demasiado simple; falla en todo
Baseline	Modelo muy simple con el que comparar
Matriz de confusión	Tabla de aciertos y errores por tipo
Sesgo (bias)	Error sistemático que perjudica a un grupo
Proxy	Variable que «adivina» un dato sensible sin nombrarlo
RGPD	Reglamento europeo de protección de datos
AI Act	Norma europea que regula la IA según su riesgo
DPD	Delegado de protección de datos

24. Cómo estudiar estos apuntes

1. **Antes de cada presentación**, lee el día correspondiente (1 o 2) a ritmo tranquilo.
2. **Haz los ejemplos numéricos a mano** (matriz de confusión, sobreajuste): son lo que más se pregunta.
3. **Antes del reto**, relee las secciones 7-9 y 14-21: son las que usarás para elegir y analizar los casos.
4. Si una palabra te bloquea, **mira la chuleta** (sección 23) y sigue; se aclara con los ejemplos.