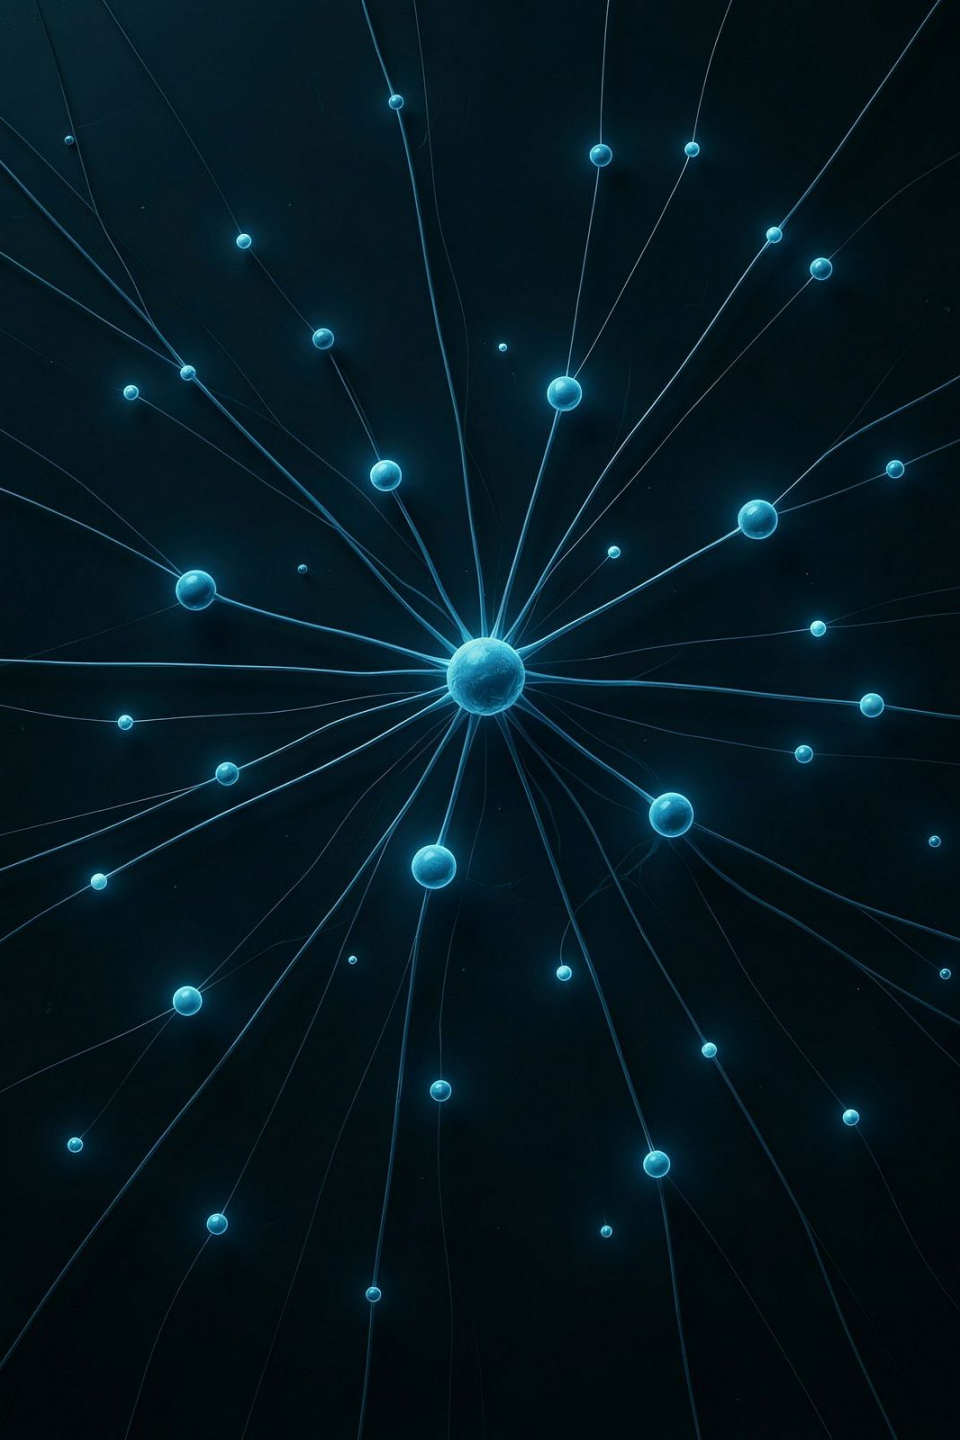


S1.2 · Panorama de Algoritmos y CRISP-DM

Una visión integral del ecosistema del aprendizaje automático: desde la lógica detrás de los algoritmos hasta la metodología que estructura proyectos reales de ciencia de datos.

MÓDULO 1 · SESIÓN 2

Contenido de esta sesión

Recorremos los conceptos fundamentales que todo profesional de ML debe dominar antes de escribir una sola línea de código.

01

Reglas vs. Aprendizaje

Por qué las máquinas aprenden en lugar de seguir instrucciones fijas

02

Familias de algoritmos

Supervisado, no supervisado, por refuerzo y más

03

Datos, características y etiquetas

El combustible del aprendizaje automático

04

CRISP-DM

Las 6 fases del proceso estándar de minería de datos

05

Criterios de selección y errores típicos

Cómo elegir bien y qué evitar en proyectos reales



Reglas Programadas frente a Aprendizaje Automático

Durante décadas, la inteligencia artificial se basó en **reglas escritas a mano** por expertos humanos: sentencias *if-then-else* que cubrían cada caso posible. Este enfoque funciona bien en dominios pequeños y estables, pero se vuelve inmanejable cuando el mundo es complejo o cambiante.

El Cambio de Paradigma

Programación tradicional

- El programador escribe las reglas explícitamente
- Entrada + Reglas → Salida
- Frágil ante situaciones no previstas
- Escala mal con la complejidad
- Ejemplo: filtros de spam basados en palabras clave

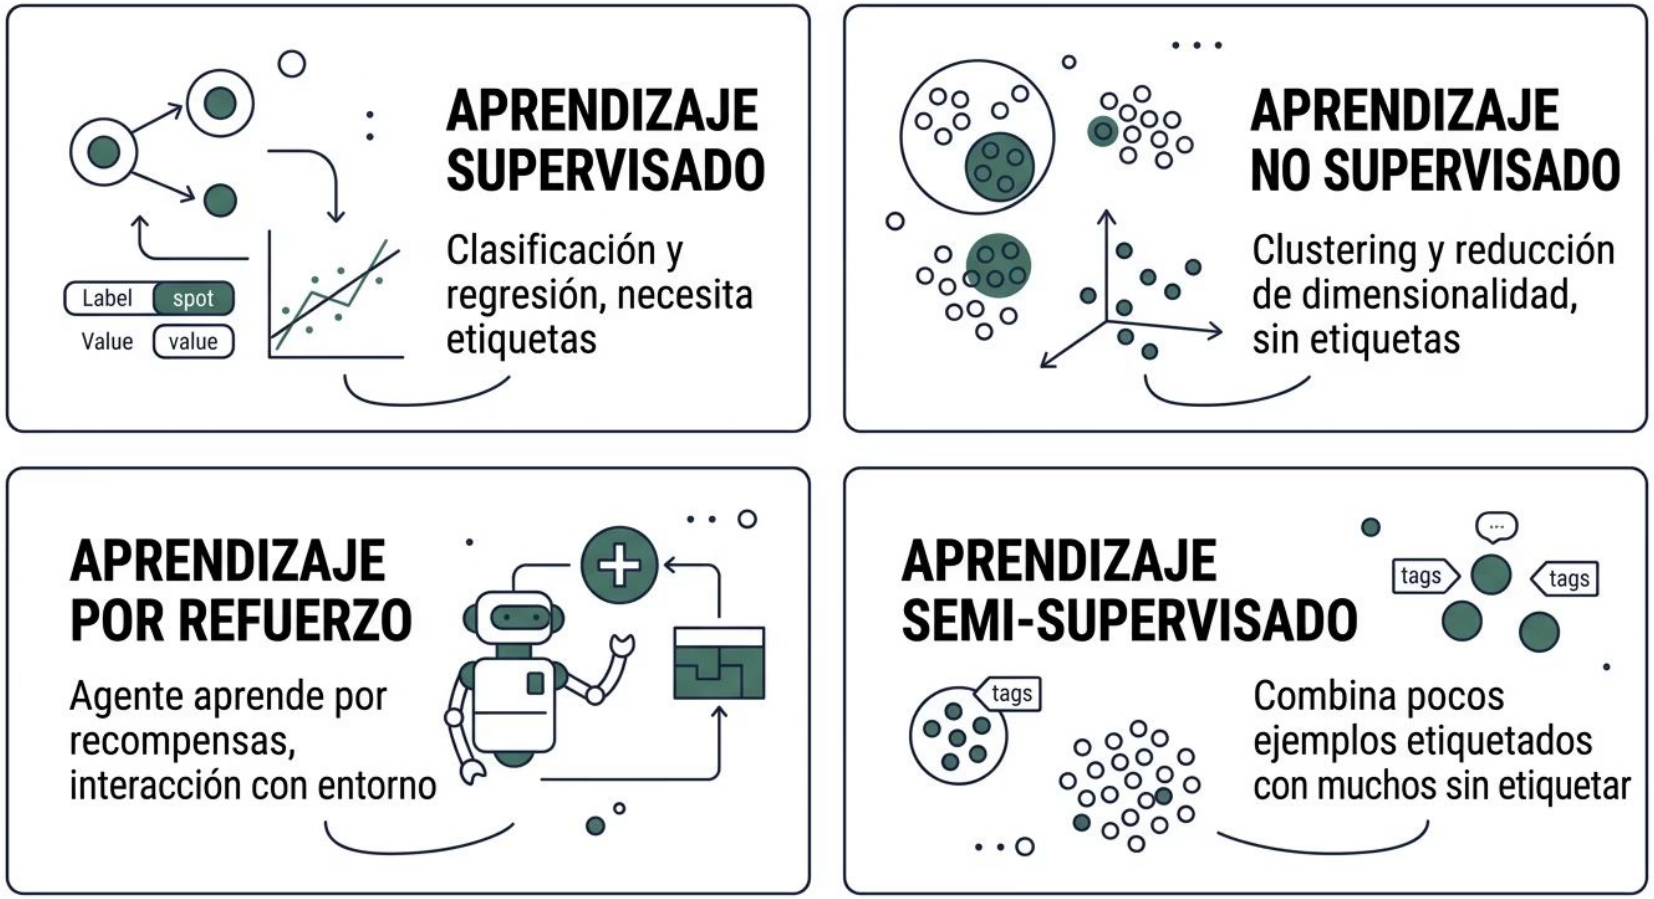
Aprendizaje automático

- La máquina **induce** las reglas a partir de ejemplos
- Entrada + Salida esperada → Reglas aprendidas
- Se adapta a patrones nuevos y complejos
- Mejora con más datos y más tiempo
- Ejemplo: filtros de spam que aprenden de millones de correos

La clave del ML es que el sistema **generaliza**: aprende de ejemplos pasados para predecir situaciones futuras no vistas.

Familias de Algoritmos de ML

El aprendizaje automático no es un único método, sino un ecosistema de familias con objetivos y requisitos muy distintos. Elegir la familia correcta es el primer paso crítico en cualquier proyecto.



¿Cuándo Usar Cada Familia?

La elección de la familia algorítmica depende fundamentalmente del tipo de datos disponibles y del objetivo del problema.

Familia	Cuándo usarla	Ejemplos de uso	Requiere etiquetas
Supervisado	Tienes datos etiquetados y quieres predecir	Detección de fraude, diagnóstico médico	✅ Sí
No supervisado	No tienes etiquetas, buscas estructura oculta	Segmentación de clientes, detección de anomalías	❌ No
Por refuerzo	El agente interactúa con un entorno dinámico	Videojuegos, robótica, trading algorítmico	⚙️ Recompensas
Semi-supervisado	Pocos datos etiquetados, muchos sin etiquetar	Clasificación de texto médico, visión industrial	🔶 Parcial

Dentro del Aprendizaje Supervisado

Clasificación

La salida es una **categoría discreta**. El modelo aprende a asignar cada entrada a una clase.

- ¿Es spam o no spam?
- ¿Qué dígito es esta imagen?
- ¿El paciente tiene diabetes?

Regresión

La salida es un **valor numérico continuo**. El modelo aprende a predecir magnitudes.

- ¿Cuánto costará este piso?
- ¿Qué temperatura habrá mañana?
- ¿Cuántas unidades venderemos?

La distinción parece sencilla, pero elegir incorrectamente entre clasificación y regresión es uno de los errores más frecuentes en proyectos de ML.

Datos, Características y Etiquetas

Antes de aplicar cualquier algoritmo, es fundamental entender los elementos básicos con los que trabaja el aprendizaje automático. Sin datos de calidad, ningún modelo puede funcionar correctamente.



Los Tres Pilares del Aprendizaje



Datos (instancias)

Cada **fila** de nuestro conjunto de datos es una instancia u observación: un ejemplo concreto del mundo real. Puede ser un correo electrónico, una transacción bancaria, una imagen o el historial de un paciente.



Características (features)

Cada **columna** es una característica o atributo: una medida que describe la instancia. Pueden ser numéricas, categóricas, texto o imágenes. La ingeniería de características es un arte crítico en ML.



Etiquetas (labels)

La **respuesta correcta** que queremos que aprenda el modelo. Solo existen en el aprendizaje supervisado. Su calidad determina directamente el techo de rendimiento del modelo.

Ejemplo Práctico: Detección de Correo Spam

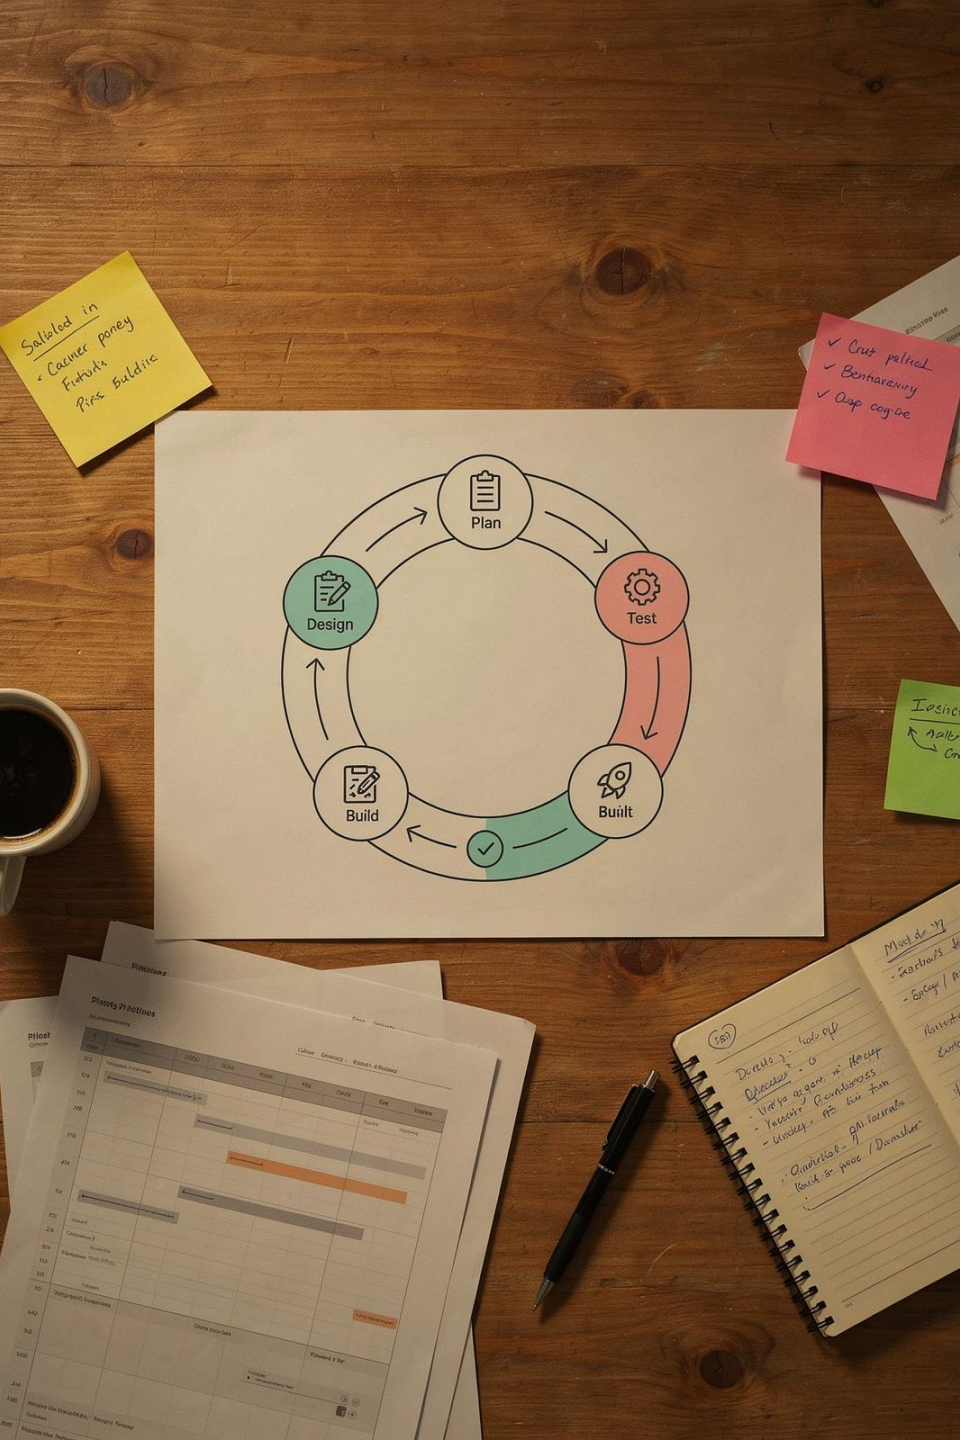
Estructura del dataset

Característica	Tipo	Ejemplo
Longitud del asunto	Numérico	42 caracteres
Contiene "GRATIS"	Binario	Sí / No
Remitente conocido	Binario	Sí / No
Nº de enlaces	Numérico	7 enlaces
Etiqueta (label)	Categórico	Spam / No spam

¿Qué aprende el modelo?

El modelo analiza miles de correos ya clasificados y aprende qué combinación de características se asocia con el spam. Después aplica ese conocimiento a correos nuevos que nunca ha visto.

La etiqueta es la columna objetivo. Sin ella, no hay supervisión posible.



METODOLOGÍA

CRISP-DM

El estándar de facto para estructurar proyectos de minería de datos y aprendizaje automático. Más de 25 años vigente y más relevante que nunca.

CRISP-DM: Las 6 Fases del Proceso

Cross-Industry Standard Process for Data Mining es una metodología iterativa y cíclica que guía los proyectos desde la comprensión del negocio hasta el despliegue en producción. No es lineal: se retrocede y avanza entre fases según lo que se descubre.



1. Comprensión del negocio

Definir el objetivo desde la perspectiva organizativa



2. Comprensión de los datos

Recopilar, explorar y verificar la calidad de los datos



3. Preparación de datos

Limpiar, transformar e integrar los datos



4. Modelado

Seleccionar y entrenar los algoritmos adecuados



5. Evaluación

Valorar si el modelo cumple los objetivos de negocio



6. Despliegue

Poner el modelo en producción y monitorizar



Fase 1: Comprensión del Negocio

La fase más crítica y frecuentemente subestimada. Antes de tocar un solo dato, el equipo de datos debe entender a fondo **qué problema real intenta resolver la organización**, cuáles son las restricciones, qué se considera éxito y qué recursos están disponibles.

Preguntas clave

¿Qué decisión mejorará el modelo? ¿Quién usará los resultados?

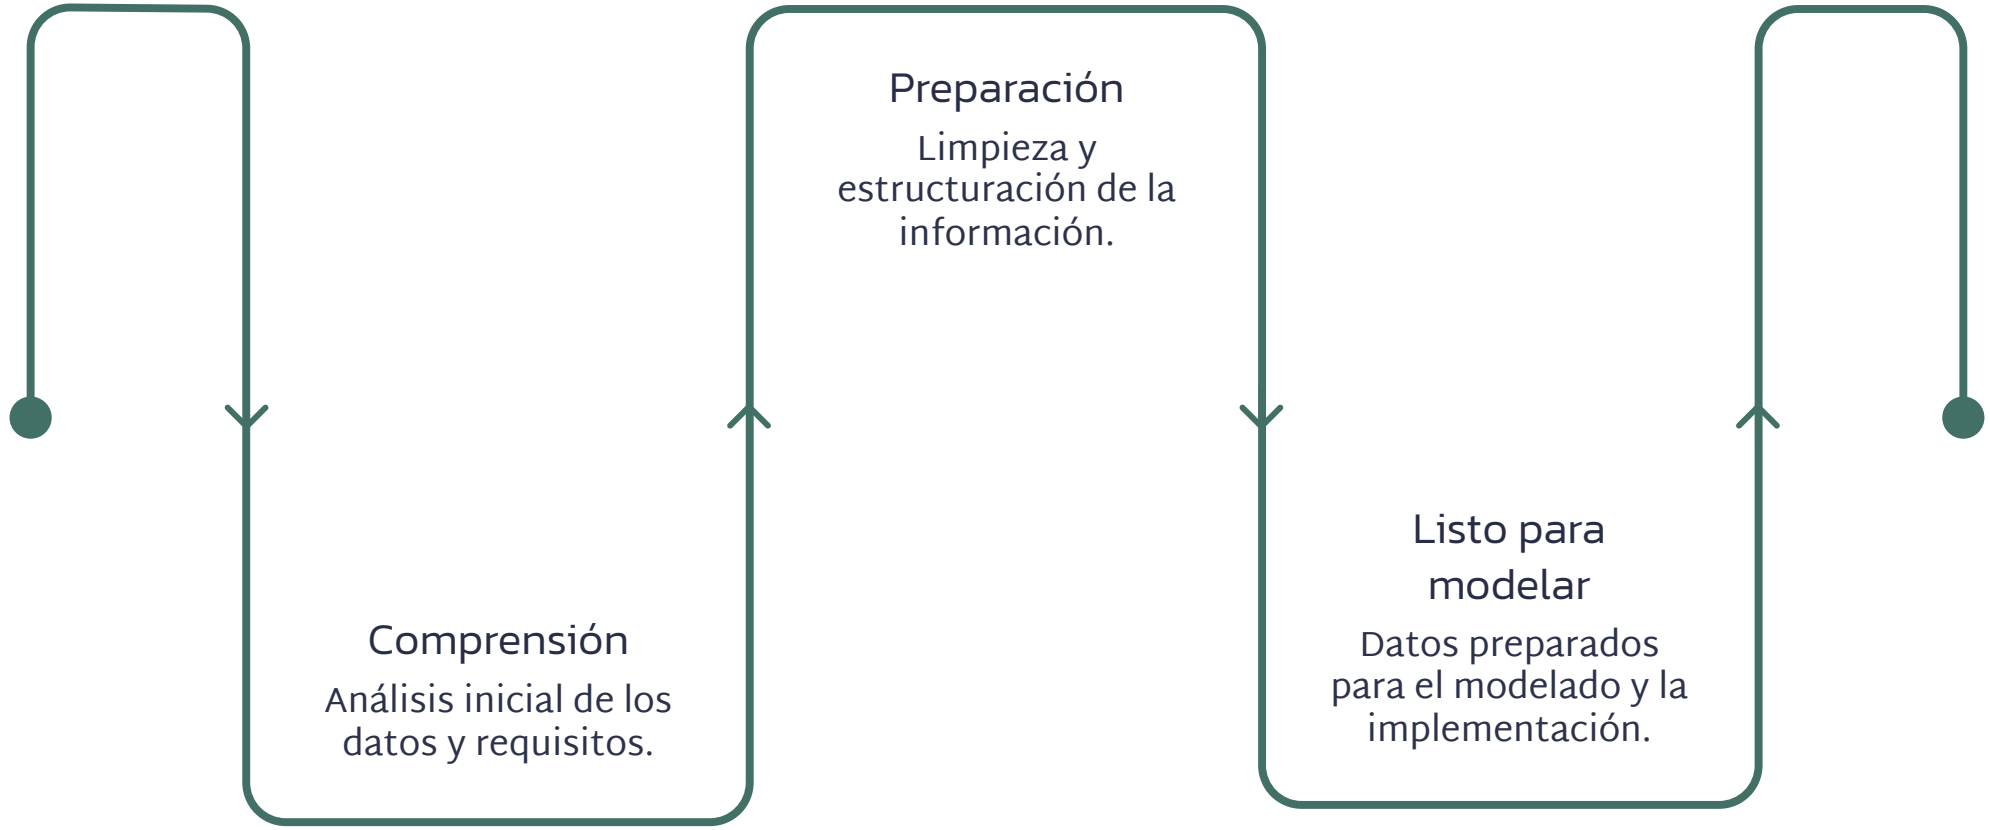
Criterio de éxito

¿Qué métrica de negocio mejorará? ¿En cuánto?

Restricciones

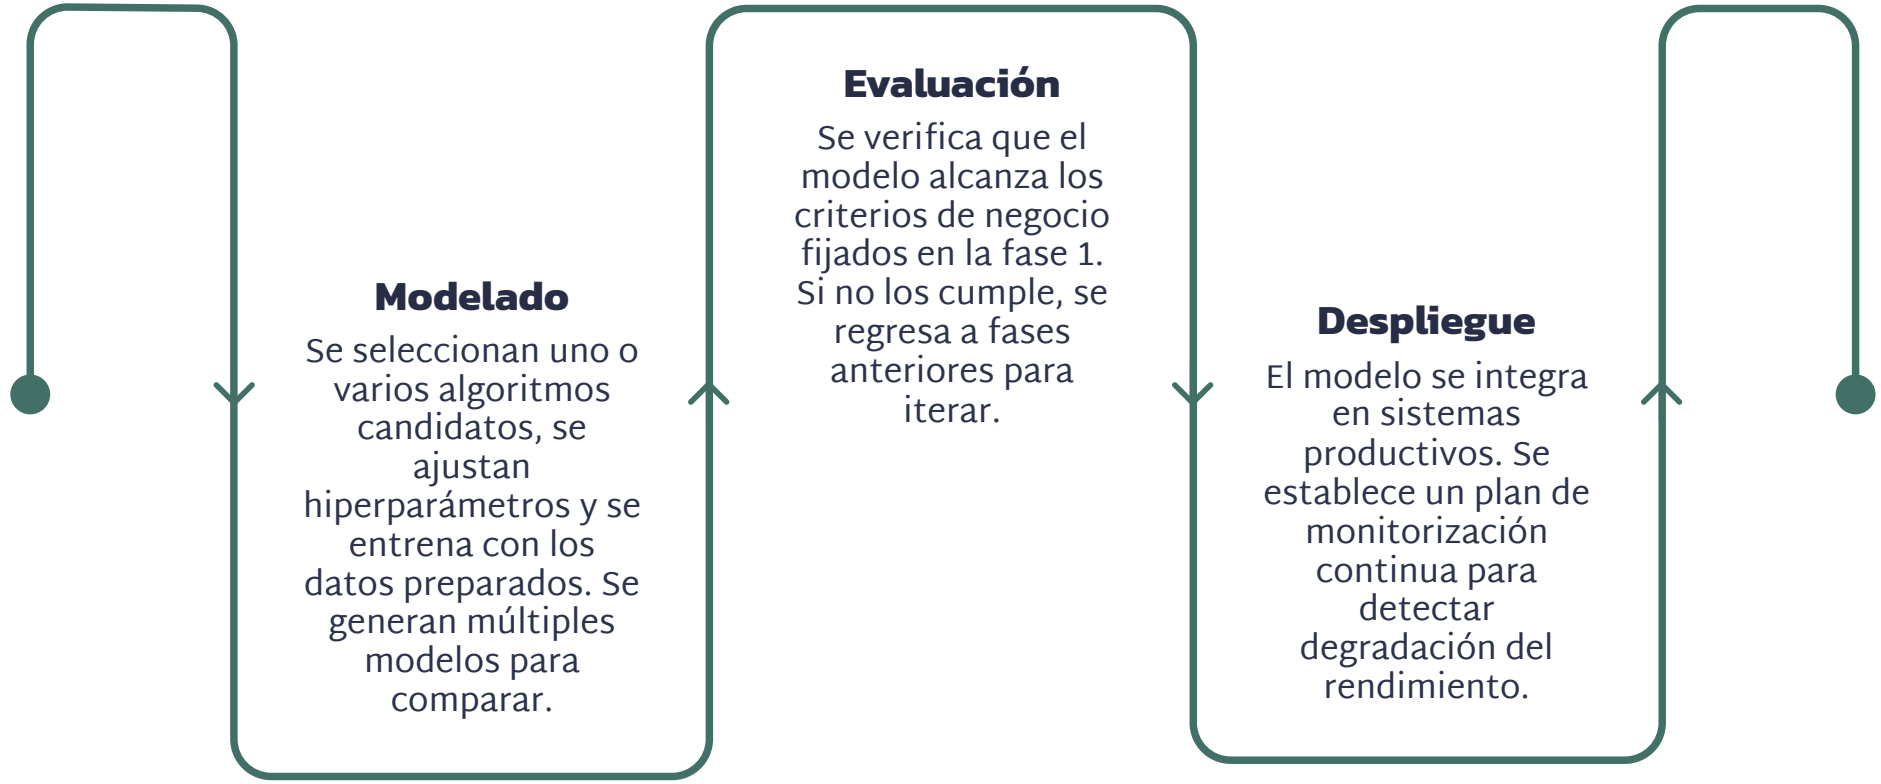
Tiempo, presupuesto, regulación, privacidad de datos

Fases 2 y 3: Del Dato en Bruto al Dato Listo



En la práctica, la preparación de datos consume entre el **60% y el 80%** del tiempo total de un proyecto de ML. La calidad del dato determina el techo del modelo: *garbage in, garbage out*.

Fases 4, 5 y 6: Modelar, Evaluar y Desplegar



CRISP-DM es un ciclo: tras el despliegue, los nuevos datos y las necesidades cambiantes del negocio reinician el proceso.

Del Problema de Negocio al Problema de ML

Traducir un objetivo empresarial en un problema técnico de ML bien formulado es una habilidad esencial. Un error en esta traducción invalida todo el trabajo posterior, independientemente de la calidad del modelo.

1

🏢 Problema de negocio

"Queremos reducir la tasa de abandono de clientes el próximo trimestre."

2

🔄 Traducción a ML

Clasificación binaria: predecir qué clientes tienen probabilidad >70% de cancelar su contrato en los próximos 30 días.

3

📊 Variable objetivo (label)

Cancelación efectiva en los 30 días siguientes a la predicción. Fuente: base de datos de contratos históricos.

4

✅ Métrica de éxito

Recall ≥ 80% en la clase positiva (no queremos perder clientes en riesgo), con Precision aceptable para no saturar al equipo de retención.

Criterios para Elegir un Algoritmo

No existe el "mejor algoritmo universal". La elección correcta depende de múltiples factores que deben evaluarse conjuntamente antes de comenzar a experimentar.

Volumen y tipo de datos

¿Cuántos ejemplos tenemos? ¿Son estructurados o no estructurados (imágenes, texto)? Los modelos complejos necesitan más datos para no sobreajustar.

Explicabilidad requerida

En sectores regulados (banca, sanidad) el modelo debe poder justificar sus decisiones. Los árboles de decisión son más interpretables que las redes neuronales profundas.

Coste computacional

El tiempo de entrenamiento, la infraestructura necesaria y el coste de inferencia en producción son restricciones reales que limitan las opciones viables.

Latencia de predicción

¿La predicción debe ser en tiempo real (milisegundos) o puede ser diferida (batch nocturno)? Esto descarta muchas arquitecturas complejas.

El Triángulo de Compensaciones



Precisión vs. Explicabilidad vs. Coste

Rara vez se pueden maximizar los tres simultáneamente. El arte del científico de datos está en encontrar el equilibrio adecuado para cada contexto:

- **Alta precisión**: redes neuronales profundas, pero cajas negras y costosas
- **Alta explicabilidad**: regresión logística, árboles, pero menor capacidad
- **Bajo coste**: modelos lineales simples, pero limitados en problemas complejos

> Empieza siempre con el modelo más simple que pueda resolver el problema. Complejiza solo si es necesario.

LECCIÓN CRÍTICA

¿Por Qué Fracasan los Proyectos de IA?

Estudios de Gartner y McKinsey estiman que **entre el 70% y el 85% de los proyectos de IA no llegan a producción** o no generan el valor esperado. Las causas rara vez son técnicas.



Errores Típicos en Proyectos de IA

🎯 Problema mal definido

Se construye un modelo sin entender claramente qué decisión debe mejorar ni quién lo usará. El modelo técnicamente funciona, pero nadie lo necesita.

🗑️ Datos de baja calidad

Datos incompletos, sesgados, desactualizados o mal etiquetados. El modelo aprende patrones incorrectos y falla en producción.

📏 Métrica equivocada

Optimizar accuracy cuando el problema es de clases desbalanceadas. Un modelo que predice siempre "no fraude" tiene 99% de accuracy pero es inútil.

🚀 Sobreingeniería prematura

Usar deep learning cuando una regresión logística habría bastado. Más complejidad sin más valor es deuda técnica y coste innecesario.

🔄 Ignorar el ciclo de vida del modelo

Los datos del mundo cambian. Un modelo sin monitorización se degrada silenciosamente. El despliegue no es el fin, sino el inicio.

El Error Más Peligroso: el Sesgo en los Datos

Cuando el modelo aprende las injusticias del pasado

Si los datos históricos reflejan decisiones humanas sesgadas, el modelo aprenderá y perpetuará esos sesgos a escala. Ejemplos reales:

- Sistemas de contratación que discriminaban a mujeres
- Algoritmos de crédito que penalizaban a minorías
- Modelos de recidivismo con disparidad racial

La explicabilidad y la auditoría del modelo no son opcionales en estos contextos: son obligaciones éticas y, en Europa, legales (AI Act).

Principios para mitigarlo

- Analizar la distribución de los datos antes de modelar
- Medir el rendimiento por subgrupos
- Involucrar a expertos de dominio y ética
- Documentar las decisiones de diseño

Resumen: Criterios de Selección de Algoritmo



ACTIVIDAD PRÁCTICA · 15 MINUTOS · CON EL DOCENTE

Actividad: 6 Problemas, ¿Qué Familia Elegimos?

En gran grupo y guiados por el docente, resolvemos 3 de los 6 problemas (los elige el docente). Para cada uno decid: 1) qué tipo de problema es (número, categoría, agrupación, recomendación, generación…), 2) qué familia de algoritmos usaríais, 3) qué datos necesitáis y 4) si os importa poder explicar la decisión. Las respuestas se anotan en la tabla de la Dinámica C (tarjetas_casos_uso.md).

1

P1 Precio por noche

Estimar el precio por noche de un alojamiento nuevo según tamaño, zona, temporada y plazas.

2

P2 Cancelaciones

Decidir si una reserva se cancelará o no, con los datos de reservas de los dos últimos años.

3

P3 Grupos de huéspedes

Agrupar 1.200 huéspedes con hábitos parecidos, sin etiquetas previas.

4

P4 Fotos de alojamientos

Reconocer si una foto es dormitorio, baño o piscina; hay 20.000 fotos y solo se pueden etiquetar 1.000.

5

P5 Quejas por ruido

Detectar si un huésped se ha quejado de ruido en 1.500 reseñas en texto libre.

6

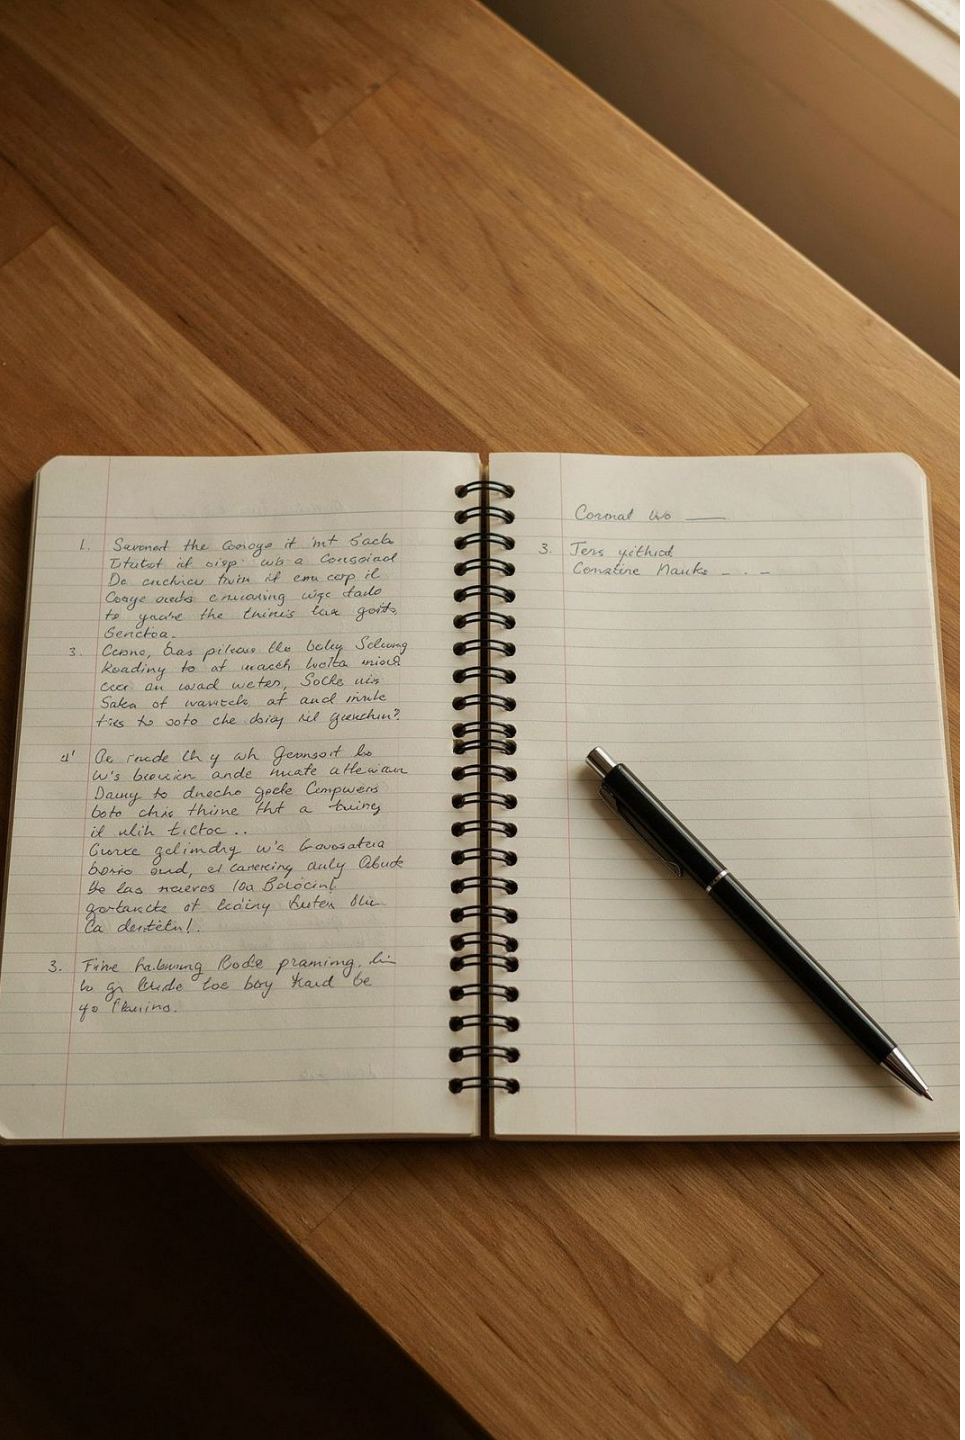
P6 Limpiadoras por día

Calcular cuántas limpiadoras hacen falta según la ocupación, con la regla «1 por cada 6 apartamentos ocupados».

Soluciones Propuestas a la Actividad

Comparad vuestras respuestas con las propuestas. No hay una única solución correcta. Los nombres concretos de algoritmos los veremos en los sprints 3 y 4. Ojo: P6 no necesita IA.

Problema	Tipo de problema	Familia o enfoque	Explicabilidad
P1 Precio por noche	Regresión (predecir un número)	Aprendizaje supervisado	Media/alta
P2 ¿Se cancela?	Clasificación binaria	Aprendizaje supervisado (modelos sencillos y explicables)	Alta: recepción necesita saber por qué
P3 Grupos de huéspedes	Agrupación (clustering)	Aprendizaje no supervisado	Se interpretan los grupos a posteriori
P4 Tipo de foto	Clasificación de imágenes	Supervisado con modelo preentrenado (solo 1.000 fotos etiquetadas)	Baja
P5 Ruido en reseñas	Clasificación de texto (o búsqueda de palabras)	Empezar con reglas de palabras clave; si no basta, supervisado o modelo de lenguaje	Alta con reglas
P6 Limpiadoras	Regla / aritmética (no hace falta ML)	Ninguna: si la regla es exacta, se programa	Total



Conclusiones Clave de esta Sesión

El ML aprende de ejemplos, no de reglas escritas

Esto lo hace poderoso en dominios complejos, pero exige datos de calidad y una definición precisa del problema.

CRISP-DM es un mapa, no una receta

La metodología guía el proceso iterativo desde el negocio hasta el despliegue, pero requiere criterio en cada fase.

La elección del algoritmo no es lo más importante

Definir bien el problema, preparar los datos y elegir la métrica correcta son decisiones más críticas que el algoritmo en sí.

Los proyectos fracasan por razones no técnicas

Problema mal definido, datos de baja calidad y falta de monitorización son los culpables más frecuentes del fracaso en IA.