




S1.2 · Panorama de Algoritmos y CRISP-DM

Una visión integral del ecosistema del aprendizaje automático: desde la lógica detrás de los algoritmos hasta la metodología que estructura proyectos reales de ciencia de datos.

MÓDULO 1 · SESIÓN 2

Contenido de esta sesión

Recorremos los conceptos fundamentales que todo profesional de ML debe dominar antes de escribir una sola línea de código.

01

Reglas vs. Aprendizaje

Por qué las máquinas aprenden en lugar de seguir instrucciones fijas

02

Familias de algoritmos

Supervisado, no supervisado, por refuerzo y más

03

Datos, características y etiquetas

El combustible del aprendizaje automático

04

CRISP-DM

Las 6 fases del proceso estándar de minería de datos

05

Criterios de selección y errores típicos

Cómo elegir bien y qué evitar en proyectos reales



Reglas Programadas frente a Aprendizaje Automático

Durante décadas, la inteligencia artificial se basó en **reglas escritas a mano** por expertos humanos: sentencias *if-then-else* que cubrían cada caso posible. Este enfoque funciona bien en dominios pequeños y estables, pero se vuelve inmanejable cuando el mundo es complejo o cambiante.

El Cambio de Paradigma

Programación tradicional

- El programador escribe las reglas explícitamente
- Entrada + Reglas → Salida
- Frágil ante situaciones no previstas
- Escala mal con la complejidad
- Ejemplo: filtros de spam basados en palabras clave


Aprendizaje automático

- La máquina **induce** las reglas a partir de ejemplos
- Entrada + Salida esperada → Reglas aprendidas
- Se adapta a patrones nuevos y complejos
- Mejora con más datos y más tiempo
- Ejemplo: filtros de spam que aprenden de millones de correos

- ❏ La clave del ML es que el sistema **generaliza**: aprende de ejemplos pasados para predecir situaciones futuras no vistas.

Familias de Algoritmos de ML

El aprendizaje automático no es un único método, sino un ecosistema de familias con objetivos y requisitos muy distintos. Elegir la familia correcta es el primer paso crítico en cualquier proyecto.



¿Cuándo Usar Cada Familia?

La elección de la familia algorítmica depende fundamentalmente del tipo de datos disponibles y del objetivo del problema.

Familia	Cuándo usarla	Ejemplos de uso	Requiere etiquetas
Supervisado	Tienes datos etiquetados y quieres predecir	Detección de fraude, diagnóstico médico	✓ Sí
No supervisado	No tienes etiquetas, buscas estructura oculta	Segmentación de clientes, detección de anomalías	✗ No
Por refuerzo	El agente interactúa con un entorno dinámico	Videojuegos, robótica, trading algorítmico	⚙️ Recompensas
Semi-supervisado	Pocos datos etiquetados, muchos sin etiquetar	Clasificación de texto médico, visión industrial	◆ Parcial

Dentro del Aprendizaje Supervisado

Clasificación

La salida es una **categoría discreta**. El modelo aprende a asignar cada entrada a una clase.

- ¿Es spam o no spam?
- ¿Qué dígito es esta imagen?
- ¿El paciente tiene diabetes?

Regresión

La salida es un **valor numérico continuo**. El modelo aprende a predecir magnitudes.

- ¿Cuánto costará este piso?
- ¿Qué temperatura habrá mañana?
- ¿Cuántas unidades venderemos?

La distinción parece sencilla, pero elegir incorrectamente entre clasificación y regresión es uno de los errores más frecuentes en proyectos de ML.

Datos, Características y Etiquetas

Antes de aplicar cualquier algoritmo, es fundamental entender los elementos básicos con los que trabaja el aprendizaje automático. Sin datos de calidad, ningún modelo puede funcionar correctamente.



Los Tres Pilares del Aprendizaje



Datos (instancias)

Cada **fila** de nuestro conjunto de datos es una instancia u observación: un ejemplo concreto del mundo real. Puede ser un correo electrónico, una transacción bancaria, una imagen o el historial de un paciente.



Características (features)

Cada **columna** es una característica o atributo: una medida que describe la instancia. Pueden ser numéricas, categóricas, texto o imágenes. La ingeniería de características es un arte crítico en ML.



Etiquetas (labels)

La **respuesta correcta** que queremos que aprenda el modelo. Solo existen en el aprendizaje supervisado. Su calidad determina directamente el techo de rendimiento del modelo.

Ejemplo Práctico: Detección de Correo Spam

Estructura del dataset

Característica	Tipo	Ejemplo
Longitud del asunto	Numérico	42 caracteres
Contiene "GRATIS"	Binario	Sí / No
Remitente conocido	Binario	Sí / No
Nº de enlaces	Numérico	7 enlaces
Etiqueta (label)	Categorico	Spam / No spam

¿Qué aprende el modelo?


El modelo analiza miles de correos ya clasificados y aprende qué combinación de características se asocia con el spam. Después aplica ese conocimiento a correos nuevos que nunca ha visto.

📌 La etiqueta es la columna objetivo. Sin ella, no hay supervisión posible.

Sallalad in
- Caener money
Futurals
Piss Buldive

✓ Out pelted
✓ Bentareny
✓ Out cogive

Iosic
vale
↻ On



METODOLOGÍA

CRISP-DM

El estándar de facto para estructurar proyectos de minería de datos y aprendizaje automático. Más de 25 años vigente y más relevante que nunca.

Priority Practices

Phase	Task	Start	End	Status
1	1.1	1/1/2020	1/1/2020	Completed
2	2.1	1/1/2020	1/1/2020	Completed
3	3.1	1/1/2020	1/1/2020	Completed
4	4.1	1/1/2020	1/1/2020	Completed
5	5.1	1/1/2020	1/1/2020	Completed
6	6.1	1/1/2020	1/1/2020	Completed
7	7.1	1/1/2020	1/1/2020	Completed
8	8.1	1/1/2020	1/1/2020	Completed
9	9.1	1/1/2020	1/1/2020	Completed
10	10.1	1/1/2020	1/1/2020	Completed
11	11.1	1/1/2020	1/1/2020	Completed
12	12.1	1/1/2020	1/1/2020	Completed
13	13.1	1/1/2020	1/1/2020	Completed
14	14.1	1/1/2020	1/1/2020	Completed
15	15.1	1/1/2020	1/1/2020	Completed
16	16.1	1/1/2020	1/1/2020	Completed
17	17.1	1/1/2020	1/1/2020	Completed
18	18.1	1/1/2020	1/1/2020	Completed
19	19.1	1/1/2020	1/1/2020	Completed
20	20.1	1/1/2020	1/1/2020	Completed

100
Dress - 100 off
Dress - 100
Vest - 100
T-shirt - 100
Socks - 100
Shoes - 100
Hat - 100
Gloves - 100
Jacket - 100
Coat - 100
Suit - 100
Dress - 100
T-shirt - 100
Socks - 100
Shoes - 100
Hat - 100
Gloves - 100
Jacket - 100
Coat - 100
Suit - 100

CRISP-DM: Las 6 Fases del Proceso

Cross-Industry Standard Process for Data Mining es una metodología iterativa y cíclica que guía los proyectos desde la comprensión del negocio hasta el despliegue en producción. No es lineal: se retrocede y avanza entre fases según lo que se descubre.



1. Comprensión del negocio

Definir el objetivo desde la perspectiva organizativa



2. Comprensión de los datos

Recopilar, explorar y verificar la calidad de los datos



3. Preparación de datos

Limpiar, transformar e integrar los datos



4. Modelado

Seleccionar y entrenar los algoritmos adecuados



5. Evaluación

Valorar si el modelo cumple los objetivos de negocio



6. Despliegue

Poner el modelo en producción y monitorizar



Fase 1: Comprensión del Negocio

La fase más crítica y frecuentemente subestimada. Antes de tocar un solo dato, el equipo de datos debe entender a fondo **qué problema real intenta resolver la organización**, cuáles son las restricciones, qué se considera éxito y qué recursos están disponibles.

Preguntas clave

¿Qué decisión mejorará el modelo? ¿Quién usará los resultados?


Criterio de éxito

¿Qué métrica de negocio mejorará? ¿En cuánto?

Restricciones


Tiempo, presupuesto, regulación, privacidad de datos

Fases 2 y 3: Del Dato en Bruto al Dato Listo



En la práctica, la preparación de datos consume entre el **60% y el 80%** del tiempo total de un proyecto de ML. La calidad del dato determina el techo del modelo: *garbage in, garbage out*.


Fases 4, 5 y 6: Modelar, Evaluar y Desplegar



 CRISP-DM es un ciclo: tras el despliegue, los nuevos datos y las necesidades cambiantes del negocio reinician el proceso.

Del Problema de Negocio al Problema de ML

Traducir un objetivo empresarial en un problema técnico de ML bien formulado es una habilidad esencial. Un error en esta traducción invalida todo el trabajo posterior, independientemente de la calidad del modelo.



Criterios para Elegir un Algoritmo

No existe el "mejor algoritmo universal". La elección correcta depende de múltiples factores que deben evaluarse conjuntamente antes de comenzar a experimentar.

Volumen y tipo de datos

¿Cuántos ejemplos tenemos? ¿Son estructurados o no estructurados (imágenes, texto)? Los modelos complejos necesitan más datos para no sobreajustar.

Explicabilidad requerida

En sectores regulados (banca, sanidad) el modelo debe poder justificar sus decisiones. Los árboles de decisión son más interpretables que las redes neuronales profundas.

Coste computacional

El tiempo de entrenamiento, la infraestructura necesaria y el coste de inferencia en producción son restricciones reales que limitan las opciones viables.

Latencia de predicción

¿La predicción debe ser en tiempo real (milisegundos) o puede ser diferida (batch nocturno)? Esto descarta muchas arquitecturas complejas.

El Triángulo de Compensaciones



Precisión vs. Explicabilidad vs. Coste

Rara vez se pueden maximizar los tres simultáneamente. El arte del científico de datos está en encontrar el equilibrio adecuado para cada contexto:

- **Alta precisión:** redes neuronales profundas, pero cajas negras y costosas
- **Alta explicabilidad:** regresión logística, árboles, pero menor capacidad
- **Bajo coste:** modelos lineales simples, pero limitados en problemas complejos

❏ Empieza siempre con el modelo más simple que pueda resolver el problema. Complejiza solo si es necesario.

LECCIÓN CRÍTICA

¿Por Qué Fracasan los Proyectos de IA?

Estudios de Gartner y McKinsey estiman que **entre el 70% y el 85% de los proyectos de IA no llegan a producción** o no generan el valor esperado. Las causas rara vez son técnicas.



Errores Típicos en Proyectos de IA



Problema mal definido

Se construye un modelo sin entender claramente qué decisión debe mejorar ni quién lo usará. El modelo técnicamente funciona, pero nadie lo necesita.



Datos de baja calidad

Datos incompletos, sesgados, desactualizados o mal etiquetados. El modelo aprende patrones incorrectos y falla en producción.



Métrica equivocada

Optimizar accuracy cuando el problema es de clases desbalanceadas. Un modelo que predice siempre "no fraude" tiene 99% de accuracy pero es inútil.



Sobreingeniería prematura

Usar deep learning cuando una regresión logística habría bastado. Más complejidad sin más valor es deuda técnica y coste innecesario.



Ignorar el ciclo de vida del modelo

Los datos del mundo cambian. Un modelo sin monitorización se degrada silenciosamente. El despliegue no es el fin, sino el inicio.

El Error Más Peligroso: el Sesgo en los Datos

Cuando el modelo aprende las injusticias del pasado

Si los datos históricos reflejan decisiones humanas sesgadas, el modelo aprenderá y perpetuará esos sesgos a escala. Ejemplos reales:

- Sistemas de contratación que discriminaban a mujeres
- Algoritmos de crédito que penalizaban a minorías
- Modelos de recidivismo con disparidad racial


La explicabilidad y la auditoría del modelo no son opcionales en estos contextos: son obligaciones éticas y, en Europa, legales (AI Act).

Principios para mitigarlo


- Analizar la distribución de los datos antes de modelar
- Medir el rendimiento por subgrupos
- Involucrar a expertos de dominio y ética
- Documentar las decisiones de diseño

Resumen: Criterios de Selección de Algoritmo

1. Volumen & Complejidad




2. Tipo & Arquitectura



3. Etiquetas & Aprendizaje



4, 5 & 6. Coste, Velocidad & Explicabilidad



Actividad: 6 Problemas, ¿Qué Familia Elegimos?

Trabajad en parejas. Para cada problema, identificad: la **familia de algoritmos** más adecuada, si necesita etiquetas, y qué característica podría ser crítica como variable predictora.

1

Predicción de ventas

Una cadena de supermercados quiere prever las ventas semanales de cada producto para optimizar el stock.

2

Segmentación de clientes

Un banco quiere agrupar a sus clientes por comportamiento financiero sin saber de antemano cuántos grupos existen.

3

Detección de fallos

Una planta industrial quiere detectar anomalías en sensores de temperatura antes de que ocurra un fallo.

4

Clasificación de reseñas

Una plataforma de e-commerce quiere clasificar automáticamente reseñas como positivas, neutras o negativas.

5

Optimización de rutas

Un sistema de entrega quiere que un agente aprenda a minimizar el tiempo de entrega en una ciudad.

6

Diagnóstico médico

Un hospital quiere predecir si un paciente desarrollará diabetes tipo 2 en los próximos 5 años.

Soluciones Propuestas a la Actividad

Comparad vuestras respuestas con las propuestas. No hay una única solución correcta: el debate sobre las alternativas es parte del aprendizaje.

Problema	Familia	Tipo	¿Etiquetas?
Predicción de ventas	Supervisado	Regresión	✔ Ventas históricas
Segmentación de clientes	No supervisado	Clustering	✗ No necesita
Detección de fallos	No supervisado	Detección de anomalías	✗ / ♦ Opcional
Clasificación de reseñas	Supervisado	Clasificación multiclase	✔ Reseñas etiquetadas
Optimización de rutas	Por refuerzo	RL (agente-entorno)	⚙ Recompensa por ruta
Diagnóstico médico	Supervisado	Clasificación binaria	✔ Diagnósticos históricos

Conclusiones Clave de esta Sesión

El ML aprende de ejemplos, no de reglas escritas

Esto lo hace poderoso en dominios complejos, pero exige datos de calidad y una definición precisa del problema.

CRISP-DM es un mapa, no una receta

La metodología guía el proceso iterativo desde el negocio hasta el despliegue, pero requiere criterio en cada fase.

La elección del algoritmo no es lo más importante

Definir bien el problema, preparar los datos y elegir la métrica correcta son decisiones más críticas que el algoritmo en sí.

Los proyectos fracasan por razones no técnicas

Problema mal definido, datos de baja calidad y falta de monitorización son los culpables más frecuentes del fracaso en IA.