Tipos de aprendizaje

Cómo aprenden los modelos, cómo se **evalúa de forma honesta** y el error más importante del curso: **el sobreajuste**.

Los tipos de aprendizaje y sus algoritmos

Tipo	Idea	Algoritmos del curso	Sprint
Supervisado	ejemplos con respuesta conocida	regresión lineal y logística, k-NN, Naive Bayes, árboles, ensembles, SVM, redes	7–8, 10
No supervisado	sin etiquetas: estructura	*k-means*, clustering jerárquico, PCA	9
Por refuerzo	recompensas por actuar bien	Q-learning	9
Autosupervisado / preentrenado	aprende de datos sin etiquetas (adivinar la palabra que falta) y se ajusta	transformers, LLM	12

La infografía completa está en `sprints/S01/infografias/` (*tipos de aprendizaje y algoritmos*).

Supervisado: clasificación y regresión

- El modelo ve pares **(X, y)** y ajusta sus parámetros para **minimizar el error** entre lo que predice y la etiqueta real.
- **Clasificación**: salida **categórica** (¿cancela? ¿qué clase?).
- **Regresión**: salida **numérica** (precio, demanda, temperatura).
- Si hay que entrenar con datos vuestros ya etiquetados, es **supervisado**, aunque el modelo parta de uno preentrenado.

No supervisado y por refuerzo

No supervisado

Sin etiquetas. **Clustering**: grupos de clientes parecidos. **Reducción de dimensión**: resumir muchas variables en pocas.

Por refuerzo

Un **agente** prueba acciones en un entorno y recibe **recompensas**. Aprende una política. Robótica, juegos.

Semisupervisado

Pocas etiquetas y muchos datos sin etiquetar: se aprovechan ambos.

Entrenamiento, validación y test

Conjunto	Para qué	Cuándo se usa
Entrenamiento	el modelo ajusta sus parámetros	siempre
Validación	comparar modelos y ajustar hiperparámetros	durante el desarrollo
Test	medir el rendimiento **final**	**una sola vez**, al final

> Si usas el test para decidir, deja de ser un examen: es un ejercicio que ya has visto.

Con datos temporales, se entrena con lo **antiguo** y se evalúa con lo **reciente**.

Sobreajuste e infraajuste

	Infraajuste (*underfitting*)	Sobreajuste (*overfitting*)
Qué pasa	demasiado simple: falla **también al entrenar**	demasiado ajustado: **memoriza** el ruido
Entrenamiento	mal	**muy bien**
Datos nuevos	mal	**mal**
Remedio	modelo más flexible, mejores variables	más datos, regularizar, simplificar, validación cruzada

- **Sesgo** alto = infraajuste; **varianza** alta = sobreajuste.
- La señal de alarma: **gran diferencia** entre entrenamiento y validación.

Evaluar: exactitud y matriz de confusión

	Predice: no cancela	Predice: cancela
Real: no cancela	acierto	falsa alarma
Real: cancela	**cancelación no detectada**	acierto

- **Exactitud** = aciertos / total. **Engaña** si la clase importante es rara: si solo se cancela el 5 %, «nunca cancela» acierta el 95 %.
- Por eso se mira la **matriz de confusión** y se compara siempre con un **modelo de referencia** muy simple.
- Métricas más finas (precisión, *recall*, AUC): **Sprint 6 y 13**.

Ahora, a practicar

Lo que viene a continuación está en tu repositorio; no hace falta buscar ejercicios fuera.

ACTIVIDAD

Actividad

10 min

Dinámica B: clasificación «a mano» (demostración en la pizarra)

RETO

Reto del sprint

25 min

Lluvia de ideas y elección de casos (paso 2)

sprints/S01/guia/Reto_Sprint_01.md