

Tipos de Aprendizaje en Machine Learning

Una guía completa para entender cómo los modelos aprenden de los datos. Exploraremos los grandes paradigmas del aprendizaje automático, las trampas más comunes del entrenamiento y las métricas esenciales para evaluar cualquier modelo.

S1.3 · SESIÓN DE FUNDAMENTOS



¿Qué vamos a aprender hoy?

Esta sesión cubre los pilares conceptuales sobre los que se construye cualquier sistema de aprendizaje automático. Desde los diferentes paradigmas de entrenamiento hasta las herramientas para medir el rendimiento de un modelo.

01

Paradigmas de aprendizaje

Supervisado, no supervisado, semisupervisado y por refuerzo

03

Errores clásicos

Overfitting, underfitting, sesgo y varianza

02

Protocolo de entrenamiento

División en conjuntos de entrenamiento, validación y test

04

Métricas de evaluación

Exactitud, error y matriz de confusión



Aprendizaje Supervisado

El paradigma más extendido del ML. El modelo aprende a partir de un conjunto de ejemplos **etiquetados**: para cada entrada X existe una salida conocida Y . El algoritmo ajusta sus parámetros para minimizar el error entre sus predicciones y las etiquetas reales.

¿Cómo funciona el aprendizaje supervisado?

Tareas de clasificación

La salida es una categoría discreta. Ejemplos: detectar si un correo es spam, reconocer dígitos escritos a mano o diagnosticar si una imagen médica muestra un tumor.

Tareas de regresión

La salida es un valor continuo. Ejemplos: predecir el precio de una vivienda, estimar el consumo energético de un edificio o pronosticar las ventas del próximo trimestre.

En ambos casos, la clave está en la **calidad y cantidad de los datos etiquetados**. Etiquetar datos es costoso, lo que motiva los paradigmas alternativos que veremos a continuación.



Aprendizaje No Supervisado

No disponemos de etiquetas. El modelo debe **descubrir por sí solo la estructura** latente en los datos. El objetivo ya no es predecir una salida conocida, sino encontrar patrones, agrupaciones o representaciones compactas que expliquen los datos.

Técnicas principales no supervisadas



Clustering

Agrupar ejemplos similares sin etiqueta previa. Algoritmos como *k-means* o DBSCAN identifican segmentos naturales en los datos (clientes, documentos, genes).



Reducción de dimensionalidad

PCA, t-SNE o UMAP proyectan datos de alta dimensión en espacios más manejables, facilitando la visualización y el análisis exploratorio.



Modelos generativos

Aprenden la distribución de los datos para generar nuevas muestras realistas: autoencoders, VAE o GAN son ejemplos destacados.

Aprendizaje Semisupervisado y Autosupervisado

Dos enfoques que responden a la escasez de datos etiquetados, uno de los mayores cuellos de botella del ML industrial.

Semisupervisado

Combina una **pequeña porción de datos etiquetados** con una gran cantidad de datos sin etiquetar. El modelo aprovecha la estructura no supervisada para mejorar su capacidad supervisada. Muy útil en medicina o análisis de texto.

Autosupervisado

El modelo genera sus **propias etiquetas** a partir de los datos en bruto, sin intervención humana. Es la base de modelos de lenguaje como BERT o GPT, que aprenden a predecir palabras enmascaradas o la siguiente oración.

-  El aprendizaje autosupervisado ha impulsado la revolución de los grandes modelos de lenguaje (LLMs) al aprovechar billones de tokens sin etiquetar.

Aprendizaje por Refuerzo

Un paradigma radicalmente diferente: el modelo (**agente**) aprende interactuando con un **entorno**. En cada paso, el agente elige una acción, recibe una recompensa (o penalización) y actualiza su política para maximizar la recompensa acumulada a largo plazo.



Los componentes del aprendizaje por refuerzo



AlphaGo, los sistemas de recomendación y los coches autónomos son aplicaciones reales de este paradigma.

Resumen: los cuatro paradigmas


SUPERVISADO

**Clasificación
y Regresión**



NO SUPERVISADO

**Clustering y
Reducción**




SEMISUPERVISADO

**Modelos como
BERT y GPT**



REFUERZO

**Interacción y
Recompensa**




Entrenamiento, Validación y Test

Una vez elegido el paradigma, necesitamos un **protocolo riguroso** para saber si nuestro modelo realmente aprende o simplemente memoriza. La solución es dividir los datos en tres conjuntos completamente independientes.



Los tres conjuntos de datos



⚠ Usar el conjunto de test para tomar decisiones de diseño contamina la evaluación y produce estimaciones optimistas y engañosas.

Overfitting y Underfitting

Los dos errores fundamentales que debemos aprender a diagnosticar y corregir en cualquier modelo de ML.

Overfitting: cuando el modelo memoriza

El modelo aprende **demasiado bien los datos de entrenamiento**, incluyendo el ruido y las excepciones. Como resultado, falla ante datos nuevos porque ha memorizado en lugar de generalizar.


Síntomas: error de entrenamiento muy bajo, pero error de validación/test mucho más alto.

Soluciones habituales:

- Más datos de entrenamiento
- Regularización (L1, L2, Dropout)
- Simplificar el modelo
- Parada temprana (*early stopping*)



Underfitting: cuando el modelo no aprende



El modelo es **demasiado simple** para capturar la complejidad del problema. No logra aprender ni siquiera los patrones presentes en los datos de entrenamiento.

Síntomas: error alto tanto en entrenamiento como en validación.

Soluciones habituales:

- Aumentar la complejidad del modelo
- Añadir más características relevantes
- Reducir la regularización excesiva
- Entrenar durante más épocas

El dilema overfitting / underfitting



El objetivo es encontrar el **punto de equilibrio** donde el modelo es suficientemente complejo para aprender los patrones reales, pero no tanto como para memorizar el ruido.



Sesgo y Varianza: la intuición

El **dilema sesgo-varianza** es la explicación teórica de por qué ocurren el underfitting y el overfitting. Entender la intuición detrás de estos conceptos es esencial para diagnosticar cualquier modelo de ML.

Entendiendo sesgo y varianza

 **Sesgo (Bias)** — error sistemático

Mide qué tan lejos están, **en promedio**, las predicciones del modelo del valor real. Un sesgo alto indica que el modelo tiene suposiciones incorrectas o es demasiado simple (*underfitting*). El modelo apunta siempre en la dirección equivocada.


 **Varianza** — sensibilidad al ruido

Mide cuánto cambian las predicciones del modelo si lo entrenamos con distintos subconjuntos de datos. Una varianza alta indica que el modelo es muy sensible al ruido específico de los datos de entrenamiento (*overfitting*). El modelo apunta en direcciones muy distintas cada vez.

 **El compromiso inevitable**

Reducir el sesgo (aumentar complejidad) tiende a aumentar la varianza, y viceversa. El objetivo es encontrar la **zona óptima** que minimiza el error total = $\text{sesgo}^2 + \text{varianza} + \text{ruido irreducible}$.

Visualizando sesgo y varianza



La analogía de la diana es la más intuitiva: el **sesgo** es qué tan lejos del centro apuntas en promedio; la **varianza** es qué tan dispersos están tus disparos.



Métricas de Evaluación

Una vez entrenado el modelo, necesitamos cuantificar su rendimiento de forma objetiva. Las métricas de evaluación nos permiten comparar modelos, detectar problemas y comunicar resultados de forma precisa.

Exactitud y Error

Exactitud (Accuracy)

Proporción de predicciones correctas sobre el total de ejemplos evaluados.

$$\text{Exactitud} = \frac{\text{Predicciones correctas}}{\text{Total de ejemplos}}$$

Fácil de interpretar, pero puede ser **engañosa** si las clases están desequilibradas (ej. 95% de ejemplos negativos: un modelo que predice siempre «negativo» obtiene 95% de exactitud).

Error de clasificación


Complemento de la exactitud: la proporción de predicciones incorrectas.

$$\text{Error} = 1 - \text{Exactitud}$$

En regresión se usan métricas distintas: Error Absoluto Medio (MAE), Error Cuadrático Medio (MSE) o su raíz cuadrada (RMSE), que penaliza más los errores grandes.

La Matriz de Confusión

La herramienta más completa para analizar el rendimiento de un clasificador binario. Desglosa las predicciones en cuatro categorías que revelan **dónde** falla el modelo, no solo cuánto.



VP: predijo pos. y era pos. / **FP:** error tipo I / **FN:** error tipo II / **VN:** predijo neg. y era neg.

Métricas derivadas de la matriz de confusión

Precisión

De todos los que el modelo predijo como positivos, ¿cuántos lo eran realmente?

$$\text{VP} / (\text{VP} + \text{FP})$$

Importante cuando los falsos positivos son costosos.

Recall (Sensibilidad)

De todos los positivos reales, ¿cuántos detectó el modelo?

$$\text{VP} / (\text{VP} + \text{FN})$$

Crítico cuando los falsos negativos son peligrosos (ej. diagnóstico médico).

F1-Score

Media armónica entre precisión y recall. Equilibra ambas métricas cuando hay desbalance de clases.

$$2 \cdot (\text{P} \cdot \text{R}) / (\text{P} + \text{R})$$

❏ No existe una métrica universal perfecta. La elección depende del coste relativo de los errores en el contexto del problema.

Dinámica: Clasificación a Mano con Tarjetas

¡Manos a la obra! Esta actividad os permite experimentar en primera persona el proceso de entrenamiento y evaluación de un clasificador, antes de que lo haga ningún ordenador.



Instrucciones de la dinámica

1 Fase de entrenamiento

Cada equipo recibe un conjunto de tarjetas con ejemplos **etiquetados**.
Observad los patrones y acordad entre vosotros una **regla de clasificación** explícita.

2 Fase de validación

Aplicad vuestra regla a un nuevo conjunto de tarjetas **sin etiqueta**.
¿Funciona bien vuestra regla?
¿Necesitáis ajustarla? Debatid en equipo.

3 Fase de test y reflexión

Se revelan las etiquetas reales.
Construid vuestra **matriz de confusión** y calculad la exactitud.
¿Dónde falló más el modelo humano?
¿Por qué?

Conceptos clave de la sesión



4 paradigmas

Supervisado, no supervisado, semisupervisado/autosupervisado y por refuerzo



División de datos

Entrenamiento, validación y test: cada uno con su rol irremplazable



Sesgo vs. varianza

El compromiso fundamental que guía el diseño de modelos eficaces



Métricas

Exactitud, precisión, recall, F1 y matriz de confusión para evaluar modelos

📌 En la próxima sesión implementaremos estos conceptos en Python con scikit-learn usando conjuntos de datos reales.