

IA responsable

SPRINT 1 · ÉTICA, SESGO Y NORMATIVA · S01.4

Ética, gobernanza de datos, RGPD y AI Act. Al terminar tendrás una lista de comprobación ética que usarás en el reto y en el proyecto final.

Casos que salieron mal

COMPAS (EE. UU., 2016)

Puntuaba más alto el riesgo de reincidencia de personas negras con historiales similares.

Amazon, selección de CV (2018)

Se retiró: penalizaba a candidatas porque aprendió de 10 años de contrataciones masculinas.

Reconocimiento facial

Detenciones erróneas; errores hasta 10 veces mayores en pieles oscuras.

Síntomas: resultados discriminatorios y sin revisión humana.

Causas: datos históricos sesgados y nadie midió la equidad antes de desplegar.

Los cuatro pilares éticos

Principio	Idea
Beneficencia	beneficio real y medible
No maleficencia	minimizar daños, también los no intencionados
Autonomía	sin manipulación ni coerción algorítmica
Justicia	beneficios y riesgos repartidos con equidad

¿Quién responde cuando falla?

La cadena de actores es larga: el AI Act distingue proveedor y desplegante. La responsabilidad compartida no puede acabar siendo de nadie.

Gobernanza de datos

1. **Recopilación:** fuente, consentimiento, legalidad, representatividad.
2. **Almacenamiento:** seguridad, cifrado, acceso.
3. **Procesamiento:** limpieza, anonimización.
4. **Uso:** finalidad declarada y minimización.
5. **Eliminación:** plazos y derecho al olvido.

Calidad e integridad · privacidad por diseño · trazabilidad

Un modelo con datos corruptos no es fiable, sea cual sea su arquitectura.

De dónde sale el sesgo

Origen	Ejemplo
Datos	infrarepresentación, datos históricos discriminatorios, sesgo de supervivencia
Etiquetas	anotadores con estereotipos, categorías ambiguas
Modelo	variables que actúan como proxy (código postal)
Uso	el modelo decide → cambia el comportamiento → nuevos datos sesgados: bucle de retroalimentación

Se acumula en todo el pipeline: hay que buscarlo en cada etapa.

Equidad y explicabilidad

- **Equidad:** hay varias definiciones (paridad demográfica, igualdad de oportunidades, calibración) y no se pueden cumplir todas a la vez si la prevalencia difiere entre grupos. Se elige según el contexto.
- **Transparencia:** se puede examinar el sistema. **Explicabilidad (XAI):** se puede comunicar por qué decidió.
- **Técnicas:** LIME, SHAP, mapas de saliencia, árboles «sombra».

Derechos

explicación, rectificación, intervención humana y olvido (RGPD, art. 22).

RGPD y LOPDGDD en lo esencial

Principio	Qué implica para un proyecto de IA
Limitación de finalidad	no reutilizar datos para entrenar con otros fines sin base legal
Minimización	¿hace falta de verdad cada variable?
Art. 22	no decidir solo con automatización efectos jurídicos relevantes
EIPD	evaluación de impacto antes de desplegar tratamientos de alto riesgo

España: figura del DPD, sanciones de hasta 20 M€ o el 4 % de la facturación, y la AEPD como autoridad (guías en aepd.es).

AI Act: cuatro niveles de riesgo

Nivel	Qué ocurre	Ejemplos
Inaceptable	prohibido	puntuación social, manipulación subliminal
Alto	obligaciones estrictas	empleo, educación, crédito, justicia
Limitado	transparencia	un chatbot debe decir que es IA; los deepfakes se etiquetan
Mínimo	sin obligaciones específicas	filtros de spam

Alto riesgo: gestión de riesgos, gobernanza de datos, documentación y logs, supervisión humana. Los plazos son escalonados: consulta el calendario vigente antes de decidir.

La lista de comprobación ética

checklist_etico_v1.md: se rellena para cada caso de uso del reto.

1. Propósito y proporcionalidad: ¿hace falta IA?
2. Datos y privacidad
3. Sesgo y equidad
4. Transparencia.
5. Supervisión humana
6. Robustez y seguridad
7. Impacto social y ambiental.
8. Normativa (orientación)
9. Gobernanza
10. Resultado.

> Un caso puede salir «no recomendable» y eso también es un buen resultado del análisis.

Ahora, a practicar

Lo que viene a continuación está en tu repositorio.

Tipo	Qué hacer	Tiempo
ACTIVIDAD	Debate de casos éticos con roles (2 de los 5 casos) (sprints/S01/actividades/casos_debate_ia_responsable.md)	25 min
RETO	Fichas de 4 casos (el 5.º, en versión breve), lista de comprobación ética (completa en los 2 casos priorizados), matriz de priorización y redacción (pasos 3–5) (sprints/S01/plantillas/checklist_etico_v1.md)	75 min