IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Estadística y probabilidad

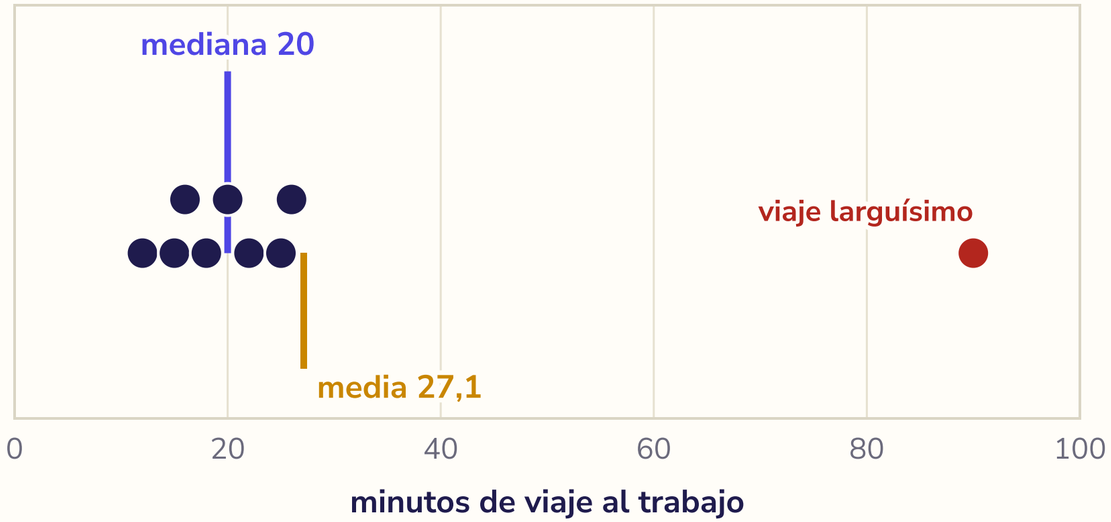
Leer un dato sin dejarse engañar: de dónde sale y a quién representa

Sprint 2 · S02_02 · presentación (35 min)

DESCRIPTIVA · HOJA 2: E1 Y E2

Resumir datos: el centro y la dispersión

Nueve compañeros, nueve viajes



La **media (27,1)** no representa a casi nadie: la arrastra el 90. La **mediana (20)** sí es un viaje típico.

Medida	Qué dice	Aquí
Media	suma ÷ cuántos	27,1 min
Mediana	el valor de en medio	20 min

Dispersión: la desviación típica σ

Cuánto se alejan los datos de la media, **en sus mismas unidades**. Dos autobuses con la misma espera media, 10 min: el A (9, 10, 10, 11) tiene **σ ≈ 0,7** y casi siempre llega a su hora; el B (4, 8, 12, 16) tiene **σ ≈ 4,5**: es una lotería.

Con valores extremos, manda la **mediana**.

PROBABILIDAD · HOJA 2: E3

Probabilidad: contar casos y «sabiendo que»

1 000 días	Con paraguas	Sin paraguas	Total
Llueve	180	20	200
No llueve	160	640	800
Total	340	660	1 000

Sabiendo que llueve

P(paraguas | llueve) = 180 ÷ 200 = **90 %**

Sabiendo que hay paraguas

P(llueve | paraguas) = 180 ÷ 340 = **52,9 %**

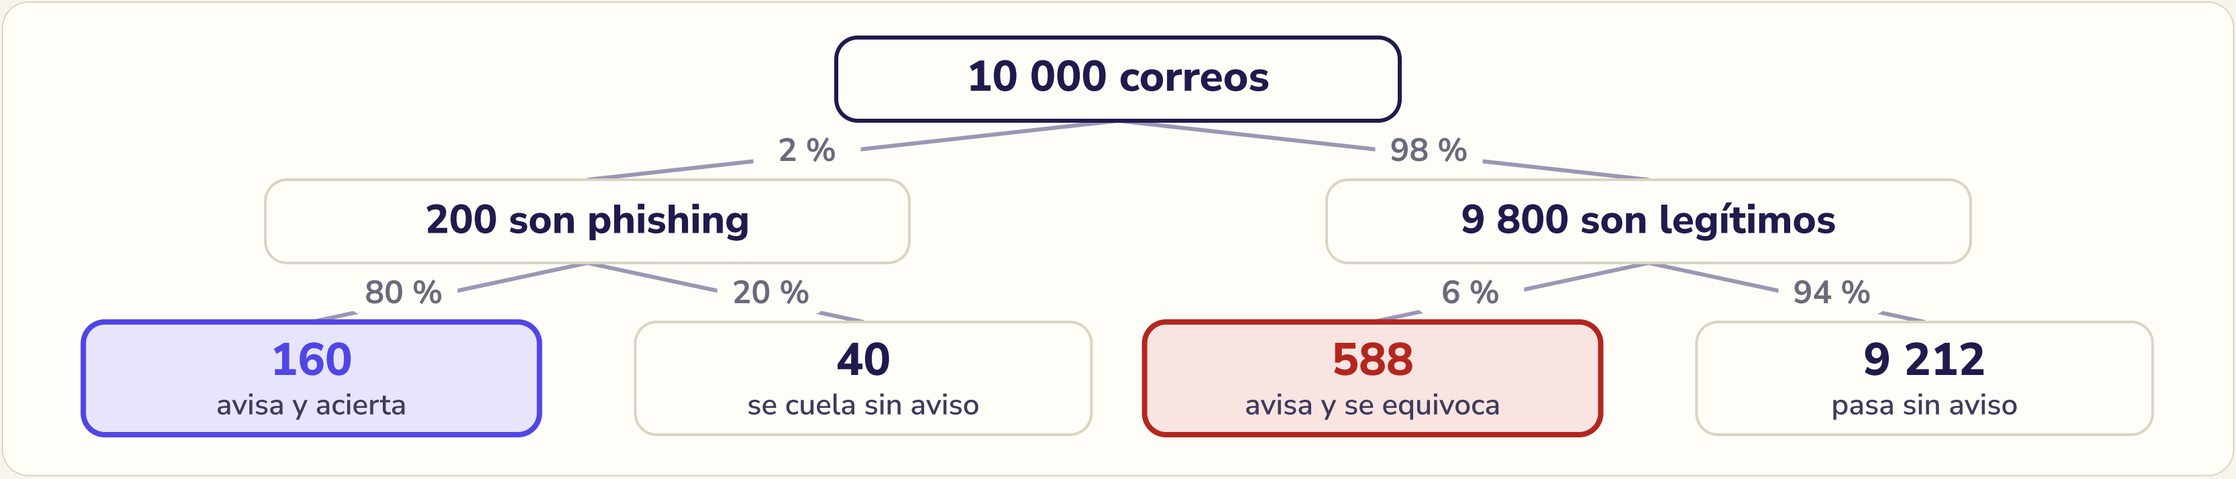
No es simétrico: P(A | B) no es lo mismo que P(B | A).

Con un dado: P(6) = 1/6 · P(no 6) = 1 − 1/6 = 5/6 · dos seises seguidos = 1/6 · 1/6 = 1/36 (sucesos independientes: **se multiplican**). Truco: pasa los porcentajes a «personas de cada 1 000».

BAYES · HOJA 2: E7

Bayes: un filtro «fiable» que falla mucho

Phishing son los correos de estafa: el **2 %** de los correos. El filtro detecta el **80 %** de ellos y marca por error el **6 %** de los legítimos.

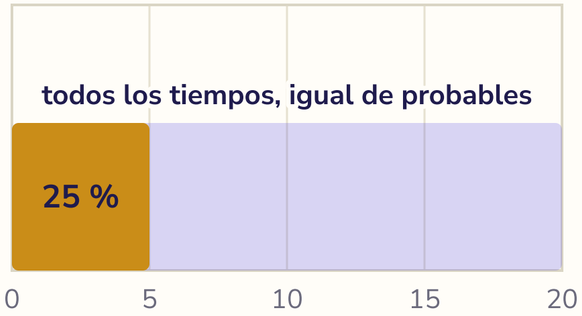


Avisos: 160 + 588 = 748. Los acertados son 160 de 748 = 21,4 %.

El filtro acierta el 93,7 % de los correos y, aun así, solo 1 de cada 5 avisos es real. Es la fórmula de Bayes, pero **contando personas**.

Tres formas típicas de repartirse los datos

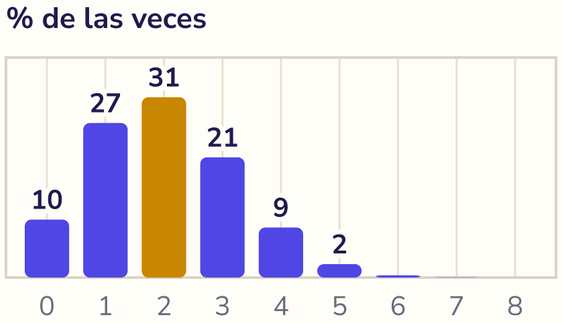
Uniforme



Un autobús que pasa **cada 20 minutos**: da igual cuándo llegues.

P(esperar menos de 5 min) = 5 ÷ 20 = **25 %**

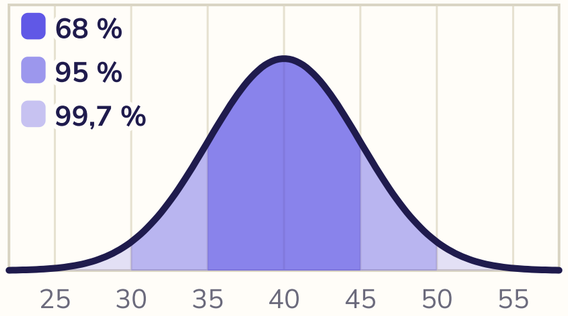
Binomial



Test de **8 preguntas** con 4 opciones, contestado al azar.

Lo más probable: **2 aciertos** (31,1 %). 5 o más: 2,7 %.

Normal



Un trayecto en tranvía: media **40** min, σ = **5** min.

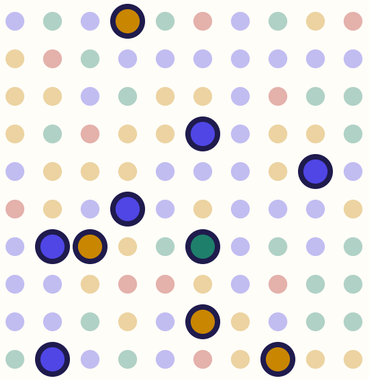
A 1, 2 y 3 σ de la media cae casi todo.

Cada una sirve para un tipo de dato: **uniforme** (todo igual de probable), **binomial** (cuántos «éxitos» en n intentos) y **normal** (la campana: casi todo cerca de la media).

MUESTREO · HOJA 2: E8

Muestreo: a quién le preguntamos

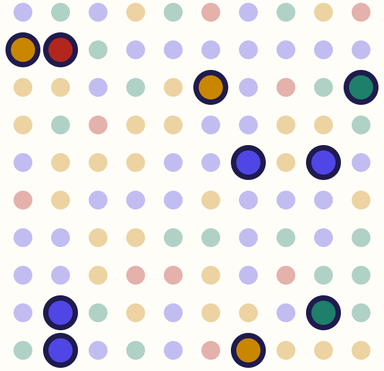
Aleatorio simple



Se sortean 10 al azar: todos con la misma probabilidad.

Por suerte puede faltar un grupo: aquí, 0 de fin de semana.

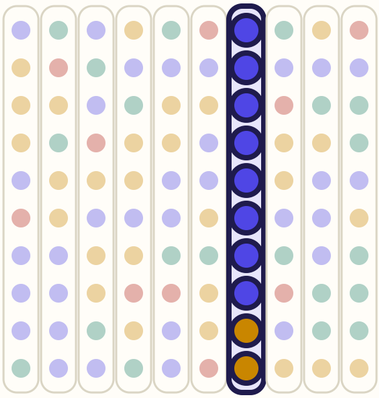
Estratificado



Se sortea dentro de cada grupo, en su proporción.

4 · 3 · 2 · 1: justo la proporción de la población.

Por conglomerados



Se elige un grupo entero (un bloque, un hotel).

Más barato, pero la mezcla puede salir rara: aquí, **8 · 2 · 0 · 0**.

mañana (40) · tarde (30) · noche (20) · fin de semana (10)

La misma población en las tres rejillas: 100 socios de un gimnasio, por turno. Los puntos con borde oscuro son la muestra de 10.

SESGOS · HOJA 2: E8 Y E9

Sesgos: ¿quién falta y sobre cuántos?

De selección

La muestra no representa a todos. Ej.: preguntar por el carril bici solo a la puerta de un club ciclista.

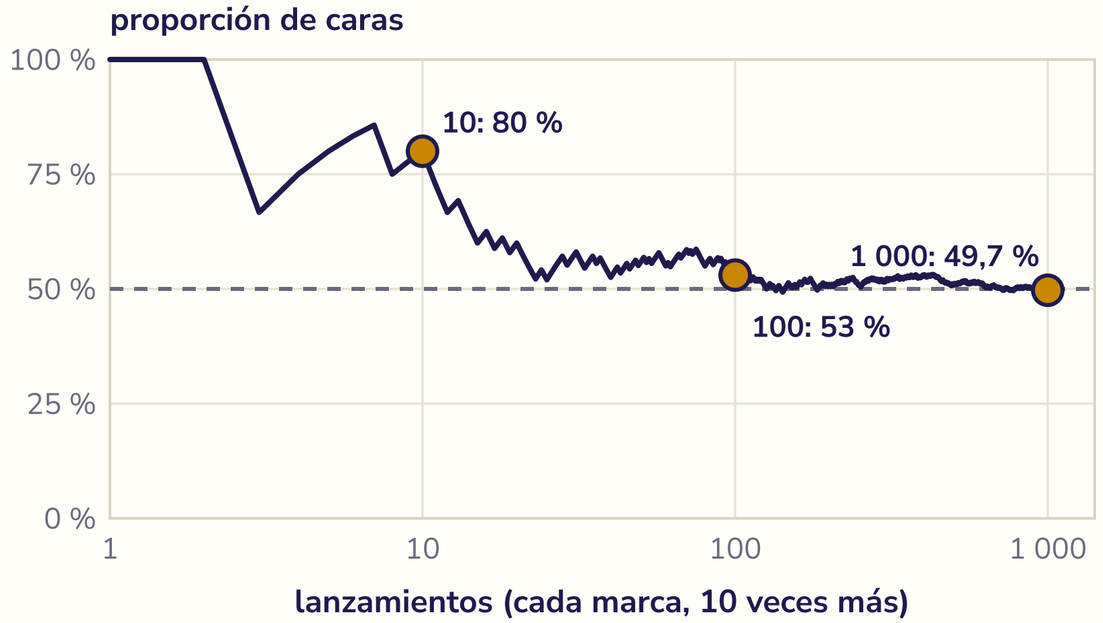
De respuesta

Quien contesta no es sincero o no es como el resto. Ej.: «¿cuántos refrescos azucarados bebes?».

De supervivencia

Solo vemos lo que llegó hasta el final. Ej.: preguntar solo a quien terminó la maratón.

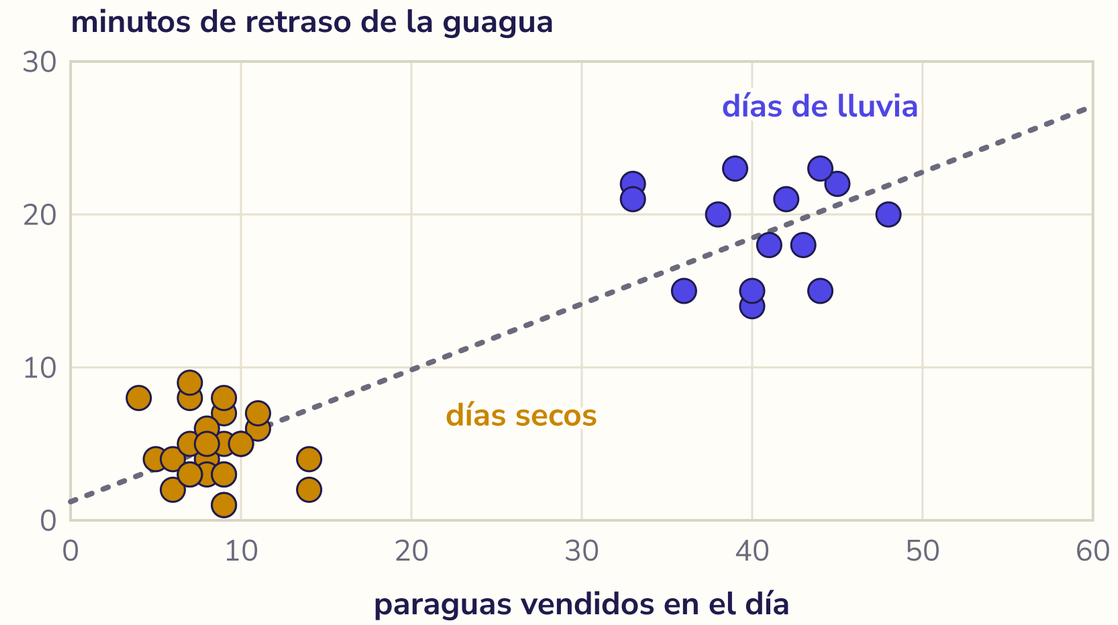
¿Sobre cuántos? Una moneda justa



Siempre pregunta: ¿quién falta? ¿sobre cuántos?

Correlación no es causalidad

40 días: r = 0,91



La línea de puntos sugiere que **una cosa arrastra a la otra**.

El coeficiente r

Va de **−1 a +1**. Cerca de +1, las dos cosas suben juntas; cerca de −1, una sube y la otra baja; cerca de 0, no hay relación en línea recta.

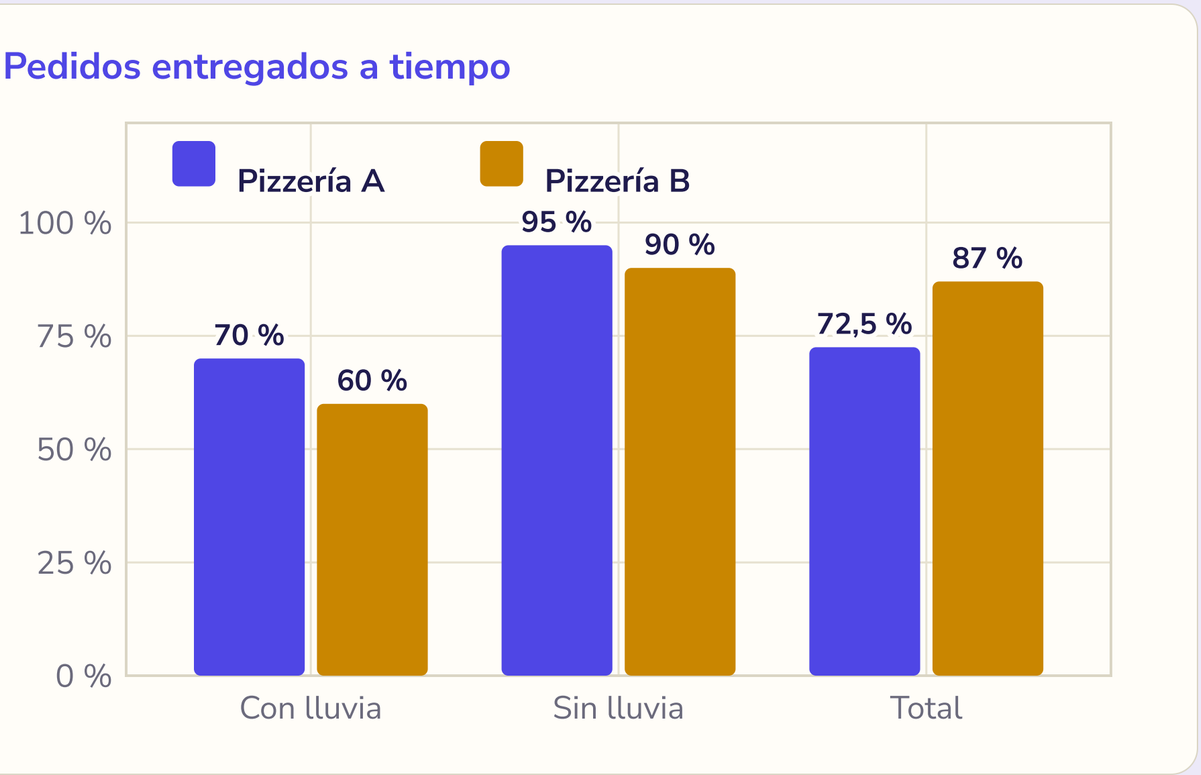
Una causa escondida

Los paraguas no retrasan las guaguas: los dos aumentan cuando **llueve**. Por colores, la relación desaparece: r = −0,01 con lluvia y r = −0,17 sin ella.

Para decir que algo causa otra cosa hace falta un **experimento**.

SIMPSON · HOJA 2: E14

La paradoja de Simpson: separa por grupos



A tiempo	Pizzería A	Pizzería B
Con lluvia	126 de 180	12 de 20
Sin lluvia	19 de 20	162 de 180
Total	145 de 200	174 de 200

¿Quién es mejor?

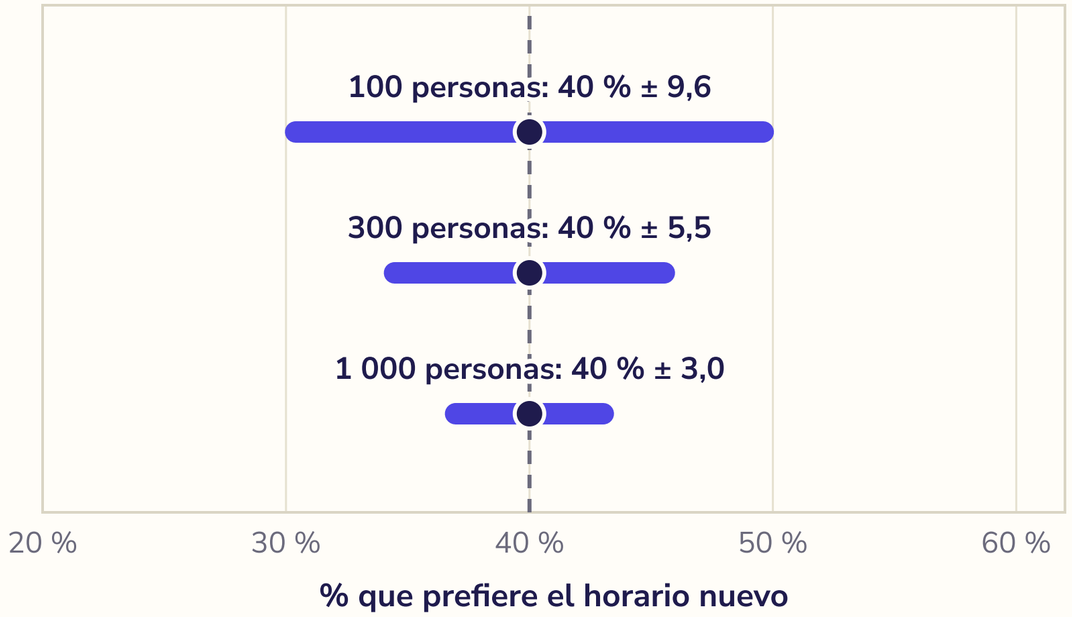
En cada tipo de día gana A. En el total parece mejor B.

¿Por qué? A reparte casi todo con lluvia (180 de 200) y B casi todo en seco (180 de 200). La lluvia retrasa a cualquiera: el total mezcla cosas distintas.

Desagrega antes de concluir.

Intervalo de confianza y p-valor

Misma encuesta, con 100, 300 y 1 000 personas



Con más gente, el intervalo se **estrecha**.

Intervalo de confianza al 95 %

En vez de «el 40 %», decimos «entre 30,4 % y 49,6 %». Si repitiéramos la encuesta muchas veces, el 95 % de los intervalos así contendría el valor real.

No es «hay un 95 % de probabilidad de que esté aquí».

Contraste y p-valor

Se parte de «no pasa nada» (H_0). Con una moneda justa, ver 9 caras o más en 10 lanzamientos pasa el **1,1 %**: es raro (menos de 0,05), y sospechamos.

El p-valor **no es** la probabilidad de que H_0 sea cierta.

DICTAMEN DEL RETO · 4 MIN

La lista de trampas para auditar una frase

Trampa	La pregunta que la destapa
1. Comparación sin fuente	¿Con qué se compara? ¿Hay algún dato que lo respalde?
2. Paradoja de Simpson	Si separo por grupos, ¿cambia el resultado?
3. Muestra pequeña	¿Cuántos datos hay? ¿De qué momento?
4. Muestra sesgada	¿Quién ha respondido y quién falta?
5. Correlación no es causa	¿Hay una tercera cosa que explique las dos?
6. Base de comparación distinta	¿Se comparan cosas iguales (mismos días, misma situación)?
7. Eje truncado	¿Dónde empieza el eje?
8. Sesgo de supervivencia	¿Solo se mira a quien «llegó hasta el final»?

Las cartas 7 y 8 son trampas que este informe no contiene. Y una más, que no es carta: **significativo ≠ importante** (¿es lo bastante grande como para importar?).

Para cada frase, tres preguntas

1 · ¿Qué afirma, exactamente?

2 · ¿Qué falla o qué falta?

3 · ¿Cómo debería decirse?

Veredictos posibles

fiable · parcialmente fiable · no fiable · no se puede saber

«No se puede saber» es una respuesta válida: no inventes números.

DICTAMEN Y RETO · DE CONSULTA

Qué prepara esta presentación

Si te atascas en…	Mira la diapositiva
Poner nombre al error de una frase (la carta)	11 y 7 a 9
Rehacer una cuenta: una tasa o una probabilidad	2 y 3
Saber qué datos faltan	6 y 7
Escribir cómo debería decirse	11
La frase de IA responsable	7
Hoja 2: E1, E2, E6, E8 y E10	2, 5, 7 y 8

Para entregar

En **sprint-02/**: el **dictamen** con al menos cuatro de las seis afirmaciones (carta, veredicto, cálculo rehecho, cómo debería decirse y qué datos faltan), una recomendación de tres líneas, una frase de IA responsable y el mínimo de las hojas.

No entra en el dictamen

Distribuciones y Bayes no se piden en el reto, pero los usarás: **sprint 5** (estadística con Python), **sprint 7** (Naive Bayes).

Al terminar el día: sé auditar un informe con números y emitir un dictamen razonado.

HOY HAS APRENDIDO

Cómo no dejarse engañar por los datos

1 · Describir

Con extremos, la **mediana**; la **σ** dice cuánto se separan los datos

2 · Contar personas

«Sabiendo que» y **Bayes**: pasa los porcentajes a casos de cada mil

3 · Preguntar

¿Quién falta? ¿Sobre cuántos? Una muestra mal elegida arrastra el error

4 · Separar

Correlación no es causa y, antes de comparar totales, **separa por grupos**

Ahora, a cazar números engañosos: los casos de estadísticas engañosas, el test de M1a y, después, el dictamen del reto.