Sprint 2 · Las matemáticas y la estadística detrás

¿en qué se apoyan los modelos y cuándo no debemos fiarnos de un dato?

FECHAS
mié 21/10 – vie 23/10 (el relevo con el Sprint 3 se hace a mitad de jornada del viernes)
HORAS
10 h en total: **5 h de teoría (T) · 3 h de práctica (P) · 2 h de reto (PBL)**
MÓDULO
M1a (UD 1a.4, 1a.5 y 1a.6)
BLOQUE
A · Sin Python: papel, calculadora, Desmos/GeoGebra y (si queréis) una hoja de cálculo
EVALUACIÓN
Test corto de M1a (conceptos, matemáticas y estadística), dictamen del reto y hojas de ejercicios

Qué aprenderás

1. Operar con **vectores y matrices** y entender qué hace un modelo cuando "multiplica" datos por pesos.
2. Interpretar una **derivada**, un **gradiente** y el **descenso del gradiente** como la forma en que un modelo mejora poco a poco.
3. Resumir datos con **media, mediana, desviación típica y cuartiles**, y calcular **probabilidades**, incluida la **probabilidad condicionada** y el teorema de **Bayes**.
4. Detectar **muestras sesgadas**, la **confusión entre correlación y causalidad** y la **paradoja de Simpson**.
5. Conocer el **ecosistema de software** de IA (Python, Colab, librerías, GPU) y tener tus cuentas listas.

Requisitos previos

Sprint 1 terminado. Matemáticas de secundaria (fracciones, potencias, porcentajes). Una calculadora o el móvil.

Materiales del sprint

Material	Contenido	Tiempo	Cuándo
`alta_cuentas.md`	Alta en Colab y GitHub (checklist)	1 h	Práctica (mié 21/10, **antes del 22/10**)
`ejercicios_algebra_calculo.md`	12 ejercicios: vectores, matrices, derivadas, gradiente (papel y Desmos/GeoGebra)	1 h en clase + resto en el equipo	Práctica
`ejercicios_estadistica.md`	14 ejercicios: estadística, probabilidad, Bayes, muestreo, sesgo, Simpson	dentro de la teoría y en el equipo	Práctica
`estadisticas_enganosas.md`	9 casos de estadísticas engañosas	40-60 min	Práctica
`../../datos/informe_cliente.md` y `../../datos/informe_cliente.csv`	**Informe del cliente** y datos del reto (no se copian aquí: están en la carpeta `datos/` del repositorio)	reto	Reto

(Como no hay notebooks en este bloque, no hay enlaces a Colab: los materiales son `.md` para trabajar en papel o pantalla.)

Mínimo para el entregable de la hoja de ejercicios: al menos **8 de los 12** ejercicios de la hoja 1 (con los M7, M10 y M11 obligatorios) y **10 de los 14** de la hoja 2 (con E7, E8, E10 y E14 obligatorios). Escribid **cómo lo habéis hecho**, no solo el resultado.

RETO Ficha del reto · "¿Nos fiamos de este informe?"

En pocas palabras (léelo primero)

Qué os pide el cliente. La dirección de TurisData ha escrito un borrador de informe con **seis afirmaciones** sobre cancelaciones y lo va a presentar al consejo. Antes, os pide que lo reviséis como lo haría una persona auditora: *«Decidme si nos podemos fiar de cada frase; y si no, cómo debería decirse»*. Una de las afirmaciones (la 2) influye en una decisión importante: a qué canal de venta dar prioridad.

Qué vais a hacer, en cuatro pasos:

1. **Leer** el informe y comprobar si las **cuentas** de cada frase salen de los datos.
2. **Detectar el error** de cada una (cada frase tiene un problema distinto) y ponerle nombre.
3. **Rehacer los cálculos** bien, con una calculadora u hoja de cálculo.
4. **Escribir un dictamen** (2–3 páginas) con el veredicto de cada afirmación y una recomendación para la dirección.

No se programa. Basta una calculadora o una hoja de cálculo (Excel, Calc, Google Sheets).

Qué vais a entregar: el dictamen de auditoría, la recomendación sobre el canal y la hoja de ejercicios del sprint (con el mínimo exigido).

Qué vais a aprender haciéndolo: a **no creerse una estadística solo porque salga en un informe**. Es la habilidad más útil antes de entrenar cualquier modelo, porque **un modelo entrenado con datos mal interpretados aprende mal**.

Cuánto tiempo: 2 horas de reto, entre el miércoles 21/10 y el viernes 23/10. Además, recordad dar de alta vuestra cuenta de Colab y GitHub **antes del 22/10**.

Palabras que van a aparecer en este reto

Palabra	Qué significa, en sencillo
Auditar	Revisar el trabajo de otra persona para comprobar si es correcto
Dictamen	El documento donde dais vuestra opinión razonada («veredicto»)
Tasa	Una proporción: cuántas cancelaciones hay por cada 100 reservas
Muestra	Un trozo pequeño de los datos con el que se pretende hablar de todo
Muestra sesgada	Una muestra que no representa a todos (por ejemplo, solo clientes que dejaron su correo)
Correlación	Dos cosas que suben o bajan a la vez. **No significa que una cause la otra**
Causalidad	Una cosa produce la otra
Paradoja de Simpson	Un resultado que parece cierto al mirar el total, pero se invierte al separar por grupos
Base de comparación	Aquello con lo que se compara. Si la base es distinta, la comparación no es justa
Reproducible	Que otra persona, con los mismos datos y pasos, obtenga la misma cifra

Escena del cliente

La dirección de *TurisData Canarias* ha preparado un **borrador de informe** sobre cancelaciones para presentarlo al consejo. Antes de hacerlo, la directora os lo pasa: *"Un cliente del consejo me dijo que hay que revisar estos números con ojo crítico. Decidme si nos podemos fiar de cada afirmación, y si no, qué debemos decir en su lugar. Y cuidado: la decisión de a qué canal dar prioridad depende de esto."*

Qué tenéis que entregar

1. **Dictamen de auditoría** (2-3 páginas en `.md` o PDF): para cada una de las **seis afirmaciones** del informe, indicad: - **Veredicto:** *fiable · parcialmente fiable · no fiable · no se puede saber*. - **Problema detectado** (tipo de error estadístico) y **por qué**. - **Cálculo rehecho** cuando haya datos (tabla con vuestros números). - **Cómo debería decirse** (redacción corregida) y **qué datos faltan**.
2. **Recomendación** para la dirección sobre el canal (afirmación 2): qué decidir y qué cautelas.
3. **La hoja de ejercicios** del sprint, con el mínimo exigido en el README del sprint (8 de 12 de la hoja 1 y 10 de 14 de la hoja 2).

Datos y recursos

- **`informe_cliente.md`** (carpeta `datos/` del repositorio): el borrador del informe con las seis afirmaciones.
- **`informe_cliente.csv`** (carpeta `datos/` del repositorio): datos de **2.400 reservas**, agrupadas por `tarifa` y `canal`, con columnas `reservas` y `cancelaciones`. El archivo tiene 4 filas (una por combinación de tarifa y canal).
- Vuestras hojas de ejercicios, la lista de control de `estadisticas_enganosas.md` y una calculadora u hoja de cálculo. **No hace falta Python.**

Restricciones

- **Tiempo:** 2 h de reto en clase (dentro de las 10 h del sprint).
- **Extensión:** 2-3 páginas.
- Cada cifra que aparezca en el dictamen debe poder **rehacerse** con los datos entregados (reproducibilidad).
- Cuando no haya datos para comprobar una afirmación, **no inventéis números**: decid qué datos harían falta.

- Si usáis un asistente de IA para redactar o calcular, **declarad dónde** y **comprobad** los cálculos a mano al menos en las afirmaciones 2 y 6.

Criterios de evaluación

Cada entregable se evalúa de 0 a 4 en los cuatro criterios de la rúbrica de retos.

Criterio	1 · Insuficiente	2 · Suficiente	3 · Bueno	4 · Excelente
Corrección técnica	Cálculos erróneos o errores no detectados	Detecta la mayoría de los errores, con fallos de cálculo o de nombre	Detecta los seis problemas y rehace los cálculos correctamente	Además cuantifica la incertidumbre (p. ej. intervalos) o razona cuándo la diferencia es real
Reproducibilidad	No se ve cómo se han obtenido las cifras	Cifras sin todos los pasos	Cada cifra se puede rehacer con los datos y los pasos indicados	Además hay tabla de cálculo o hoja adjunta y las fuentes están citadas
Análisis y comunicación al cliente	Solo dice "está mal"	Explica cada error de forma correcta pero técnica	Explica con lenguaje claro y propone redacciones corregidas	Recomendación accionable sobre el canal, con límites y datos a pedir
IA responsable	No se considera	Menciona "cuidado con los sesgos"	Relaciona los errores con riesgos de entrenar o decidir con datos así (muestra sesgada, confusión)	Propone comprobaciones concretas antes de usar estos datos para un modelo

Pasos sugeridos (2 h de reto)

Momento	Qué hacer
Mié 21/10 · planning (30 min)	Leed el informe, repartid las 6 afirmaciones entre las personas del equipo (con revisión cruzada) y preparad el tablero
Jue 22/10 (30 min)	Primera lectura de cada afirmación con la lista de control; anotad vuestras **hipótesis** de error
Vie 23/10 (30 min)	Rehaced los cálculos, redactad el dictamen y la recomendación, revisión cruzada y DoD
Vie 23/10 · última media hora	Review (5 min por equipo) y retro

Pistas (sin destriparlo)

- Empezad por comprobar **las cuentas**: ¿las cifras que da el informe salen de los datos?
- En la afirmación 2, **mirad la tabla completa** y comparad canal por canal **dentro de cada tarifa**. Calculad también **cuántas reservas** de cada canal son de cada tarifa.
- En la 5 y la 6, pensad en qué **debería compararse** en lugar de lo que se compara.
- En la 1 y la 3, ¿"la media del sector" y "el depósito reduce" están respaldados por los datos entregados?
- ¡Ojo!: puede haber afirmaciones con cuentas correctas pero conclusión incorrecta.

Guía paso a paso para principiantes

Paso 1 · Planning (miércoles 21/10, 30 minutos)

1. Leed el informe (`informe_cliente.md`) **en voz alta**, afirmación por afirmación.
2. Repartid las seis afirmaciones entre las personas del equipo (por ejemplo, de dos en dos). Cada afirmación tendrá **una persona responsable** y **una persona que la revisa**.
3. Abrid la hoja de datos (`informe_cliente.csv`) en una hoja de cálculo y mirad qué columnas tiene: `tarifa`, `canal`, `reservas` y `cancelaciones`. Son solo **4 filas**.

Paso 2 · Primera lectura con la lista de control (jueves 22/10, 30 minutos)

Usad la lista de `estadisticas_enganosas.md`. Para **cada** afirmación, respondeos tres preguntas:

1. **¿Qué afirma exactamente?** (con vuestras palabras).
2. **¿Qué falla o qué falta?** Pensad en el tipo de error: ¿muestra pequeña o sesgada?, ¿correlación tomada por causa?, ¿comparación con otra base?, ¿cuentas mal hechas?, ¿resultado que cambia al separar por grupos?
3. **¿Qué datos necesitaría para comprobarlo?**

Escribid vuestra **hipótesis** de error. Todavía no la deis por buena: en el paso 3 la comprobaréis.

Paso 3 · Rehacer los cálculos (viernes 23/10, primera media hora)

Cómo se calcula una tasa de cancelación: `cancelaciones ÷ reservas × 100`.

Ejemplo inventado (no son los datos del reto): si en una tarifa hay 500 reservas y 50 cancelaciones, la tasa es 50 ÷ 500 × 100 = **10 %**.

Aplicad la misma idea a vuestros datos:

1. **Afirmación 1:** calculad la tasa global (todas las cancelaciones ÷ todas las reservas) y comprobad si coincide con la cifra del informe. Luego pensad: ¿de dónde sale «la media del sector»? ¿Hay algún dato que lo respalde?
2. **Afirmación 2:** calculad la tasa **por canal** (primero con todas las reservas) y después **por canal dentro de cada tarifa**. Calculad también **cuántas reservas de cada canal pertenecen a cada tarifa**. Comparad: ¿lo que veis en el total se mantiene al separar?
3. **Afirmaciones 3 a 6:** mirad qué se compara en cada una, con qué tamaño de muestra y quién respondió o quedó fuera.

Una tabla de ayuda para la afirmación 2 (rellenadla con vuestros números):

Tarifa	Canal	Reservas	Cancelaciones	Tasa (%)
…	…	…	…	…

Paso 4 · Dictamen y recomendación (viernes 23/10, última parte)

Para **cada una de las seis afirmaciones**, escribid un bloque con esta estructura:

Campo	Qué poner
Veredicto	*fiable · parcialmente fiable · no fiable · no se puede saber*
Problema	El nombre del error y **por qué** lo es, en lenguaje que entienda la dirección
Cálculo rehecho	Una tabla pequeña con vuestras cifras (si hay datos)
Cómo debería decirse	Una frase corregida
Qué datos faltan	Lo que pediríais al cliente para cerrar la duda

«No se puede saber» es una respuesta válida y honrada. Si no hay datos para comprobar algo, **no inventéis números**.

Cerrad con la **recomendación sobre el canal** (afirmación 2): qué decidiría la dirección con los datos correctos y qué cautelas debe tener.

Cómo usar la IA en este reto

Aquí la IA es un **ayudante de explicación**, pero **no una calculadora fiable**. Muchas IA de texto se equivocan al hacer porcentajes y tablas, y lo hacen con mucha seguridad.

Para qué	Ejemplo de petición	Qué tenéis que comprobar
Entender un error	«Explícame qué es la paradoja de Simpson con un ejemplo de un hotel, sin fórmulas»	Que vosotros podáis explicarlo con vuestras palabras
Redactar con claridad	«Reescribe esta frase para que la entienda una directora no técnica: *[tu frase]*. No cambies las cifras»	Que **las cifras sigan siendo las mismas**
Detectar fallos	«Aquí tienes mi dictamen de la afirmación 4. ¿Qué argumento me falta?»	Que no añada datos inventados

Regla obligatoria del reto: si la IA os hace un cálculo, **comprobadlo a mano**, al menos en las afirmaciones 2 y 6. Y escribid en el dictamen **dónde habéis usado IA** y **qué habéis verificado**.

Nunca peguéis datos personales reales: aquí no los hay, pero es una buena costumbre.

Errores frecuentes (y cómo evitarlos)

Error	Por qué ocurre	Cómo evitarlo
Decir solo «está mal»	Se detecta el fallo, pero no se explica	Cada veredicto debe tener **qué falla, por qué y cómo se diría bien**
Dar por buena una cuenta sin rehacerla	«Si lo dice el informe…»	Rehaced **todas** las cifras con los datos
Mirar solo el total	El total esconde diferencias entre grupos	Separad por tarifa y canal; comparad dentro de cada grupo

Error	Por qué ocurre	Cómo evitarlo
Confundir correlación con causa	Dos cosas suben a la vez y parece obvio	Preguntaos: ¿puede haber una **tercera cosa** que explique ambas?
Inventar la «media del sector»	Queda bien	Si no hay fuente en los datos, decid «no se puede saber» y qué dato falta
Redondear antes de tiempo	Se pierde exactitud	Calculad con todos los decimales y redondead solo al presentar

Un buen resultado se parece a...

Ejemplo **inventado** (no corresponde a ninguna afirmación real del reto) de cómo debe quedar un bloque:

> **Afirmación X:** «Las reseñas de 5 estrellas han subido un 30 %». **Veredicto:** parcialmente fiable. **Problema:** el informe compara un mes con 50 reseñas y otro con 200. Los porcentajes dependen de cuántas reseñas hay. **Cálculo rehecho:** mes A, 25 de 50 = 50 %; mes B, 120 de 200 = 60 %. La subida real es de 10 puntos porcentuales, no del 30 %. **Cómo debería decirse:** «El porcentaje de reseñas de 5 estrellas pasó del 50 % al 60 %». **Datos que faltan:** el número de reseñas por canal.

Fijaos en que cada parte responde a **una pregunta concreta** y se entiende sin saber estadística.

Antes de entregar: autoevaluación rápida

Pregunta	Sí / No
¿Hay un veredicto para **las seis** afirmaciones?	
¿Cada error tiene su **nombre** y su explicación en lenguaje sencillo?	
¿Se pueden **rehacer** todas las cifras con los datos del CSV?	
¿La afirmación 2 tiene tabla por tarifa y canal y una recomendación con cautelas?	
¿Hay una lista de datos que faltan?	
¿Hemos relacionado al menos un error con IA responsable (qué pasaría si entrenáramos un modelo con estos datos)?	
¿Hemos comprobado a mano los cálculos que hizo la IA (si la usamos)?	
¿Están hechas las altas en Colab y GitHub?	

Si os atascáis

- **No sabemos si una afirmación es buena o mala:** probad a **formularla de otra manera** (con números absolutos, con otra base de comparación) y mirad si la conclusión cambia.
- **Los números no nos cuadran:** revisad si estáis dividiendo por el total correcto (reservas del grupo, no reservas totales).
- **No sabemos cómo se llama el error:** la lista de control de `estadisticas_enganosas.md` tiene todos los nombres.
- Más ayuda: Cómo se trabaja un reto.

Qué se enseña en la review (5 min por equipo)

- **Una afirmación** de las seis y vuestro dictamen (veredicto + por qué).
- **La tabla de cálculo** de la afirmación 2 y vuestra recomendación sobre el canal.
- **El error que más os ha costado** ver.
- Los datos que pediríais a TurisData para cerrar las dudas.

Checklist Definition of Done

- ☐ Dictamen de 2-3 páginas con **las seis afirmaciones** y su veredicto
- ☐ Cálculos rehechos con los datos (afirmaciones 1, 2 y 6), con los pasos visibles
- ☐ La afirmación 2 tiene tabla por tarifa y canal, y una recomendación con cautelas
- ☐ Cada error tiene su **nombre** (muestreo, correlación/causalidad, Simpson, base...)
- ☐ Redacción corregida de cada afirmación
- ☐ Lista de datos que faltan
- ☐ Al menos una relación con **IA responsable** (qué pasaría si entrenáramos un modelo con estos datos)

- [ ] Hoja de ejercicios con el mínimo exigido
- [ ] Revisión cruzada, subido a Git, tablero actualizado
- [ ] Autoevaluación y coevaluación rellenadas
- [ ] Alta en Colab y GitHub hecha (**antes del 22/10**)

Preguntas de la retrospectiva

1. ¿Cómo repartimos las seis afirmaciones? ¿Fue justo?
2. ¿Qué error nos ha resultado más difícil de ver? ¿Por qué?
3. ¿Qué habríamos pedido al cliente antes de empezar?

Recursos

1. **Desmos** (desmos.com/calculator) y **GeoGebra** (geogebra.org): para dibujar funciones, tangentes y puntos.
2. Un texto divulgativo sobre la **paradoja de Simpson** y otro sobre **cómo mentir con estadísticas** (buscad divulgación de calidad y citad la fuente).
3. **Khan Academy** (en español): álgebra lineal, derivadas y estadística (para repasar).
4. Los apuntes y las presentaciones S2.1, S2.2 y S2.3.
5. `estadisticas_enganosas.md`: lista de control para leer una estadística.