SPRINT 2 · MATEMÁTICAS Y ESTADÍSTICA · S02.1

Matemáticas para IA

Vectores, matrices, derivadas y gradiente: **lo justo** para entender cómo aprende un modelo. Sin demostraciones; con ideas y ejemplos.

Tres ideas que lo sostienen todo

Datos como vectores

Una reserva, una imagen o un texto se convierten en **listas de números**.

Aprender = minimizar un error

Entrenar es encontrar los parámetros con **menor coste**. El cálculo nos dice hacia dónde moverlos.

Incertidumbre

Toda predicción lleva un margen de duda: la estadística (S02.2) lo mide.

Vectores y producto escalar

```
import numpy as np
reserva = np.array([3, 89.24, 21])        # noches, precio/noche, antelación (días)
pesos   = np.array([2.0, 0.5, 1.0])       # lo que "importa" cada variable
z = reserva @ pesos                        # producto escalar = 2·3 + 0.5·89.24 + 1·21
```

- **Vector**: lista ordenada de números. **Norma**: su longitud.
- **Producto escalar**: suma de productos; da **un número** y mide cuánto se «alinean» dos vectores.
- Una neurona hace exactamente esto: `z = w · x + b` (ejercicio **M2**, modelos de precio).

Matrices y su producto

- Una **matriz** es una tabla: **filas = muestras**, **columnas = variables**. Dimensión `m × n`.
- **Producto `A·B`**: cada elemento es el producto escalar de una fila de A por una columna de B. Las columnas de A deben coincidir con las filas de B.
- **Transpuesta** A^T intercambia filas y columnas. **Inversa** A^{-1} «deshace» la matriz (solo cuadradas no singulares; en la práctica se evita calcular).
- **Autovector**: solo cambia de escala al multiplicarlo ($A \cdot v = \lambda \cdot v$). Base de PCA (Sprint 9).

> Una **capa densa** de una red neuronal es $y = A \cdot x + b$.

La derivada: cuánto cambia algo si lo muevo un poco

Función	Derivada
x^n	$n \cdot x^{n-1}$
e^x	e^x
$\ln(x)$	$1/x$
sigmoide $\sigma(x)$	$\sigma(x) \cdot (1 - \sigma(x))$

- **Geometría**: la pendiente de la recta tangente. Derivada **cero** = posible mínimo o máximo (**M7**).
- **Regla de la cadena**: derivar funciones anidadas, $d/dx\ f(g(x)) = f'(g(x)) \cdot g'(x)$. Es la base de la **retropropagación** en las redes (**M8**).

Derivadas parciales y gradiente

```
f(x, y) = 3x² + 2xy + y³
∂f/∂x = 6x + 2y              ∂f/∂y = 2x + 3y²
∇f = ( ∂f/∂x , ∂f/∂y )       <- el gradiente: todas las parciales juntas
```

- **Parcial**: derivar respecto a una variable **manteniendo las demás fijas.**
- El **gradiente** apunta hacia donde la función **más crece.** Para minimizar, vamos en el sentido **contrario.**
- Ejercicios **M9** y **M12** (explorar con Desmos o GeoGebra).

Descenso del gradiente

$$\theta \leftarrow \theta - \alpha \cdot \nabla L(\theta)$$

1. Empezar con parámetros al azar. 2. Calcular el **coste** `L(θ)`. 3. Calcular el **gradiente**.
2. Dar un paso **contrario** al gradiente. 5. Repetir hasta que el coste deje de bajar.

> **α (tasa de aprendizaje)**: muy pequeña, lento; muy grande, el modelo **oscila o diverge**. Es el hiperparámetro más importante del entrenamiento.

Lo practicarás con una variable (**M10**) y con una función de coste (**M11**). En el **Sprint 5** lo programas desde cero.

Conectando todo

Paso del entrenamiento	Matemáticas
Entrada → predicción	**matrices y vectores** (`y = A·x + b`)
Predicción → error	**función de coste** (diferencia con lo real)
Error → cómo corregir	**gradiente** (regla de la cadena = retropropagación)
Corregir	**descenso del gradiente** con tasa α

El resto del curso, hasta los transformers, es **esto mismo a mayor escala**.

Ahora, a practicar

Lo que viene a continuación está en tu repositorio; no hace falta buscar ejercicios fuera.

ACTIVIDAD

Actividad

55 min

Ejercicios de matemáticas (hoja 1) con Desmos o GeoGebra

RETO

Reto del sprint

60 min

Primera lectura del informe con la lista de control (paso 2)

sprints/S02/guia/Reto_Sprint_02.md