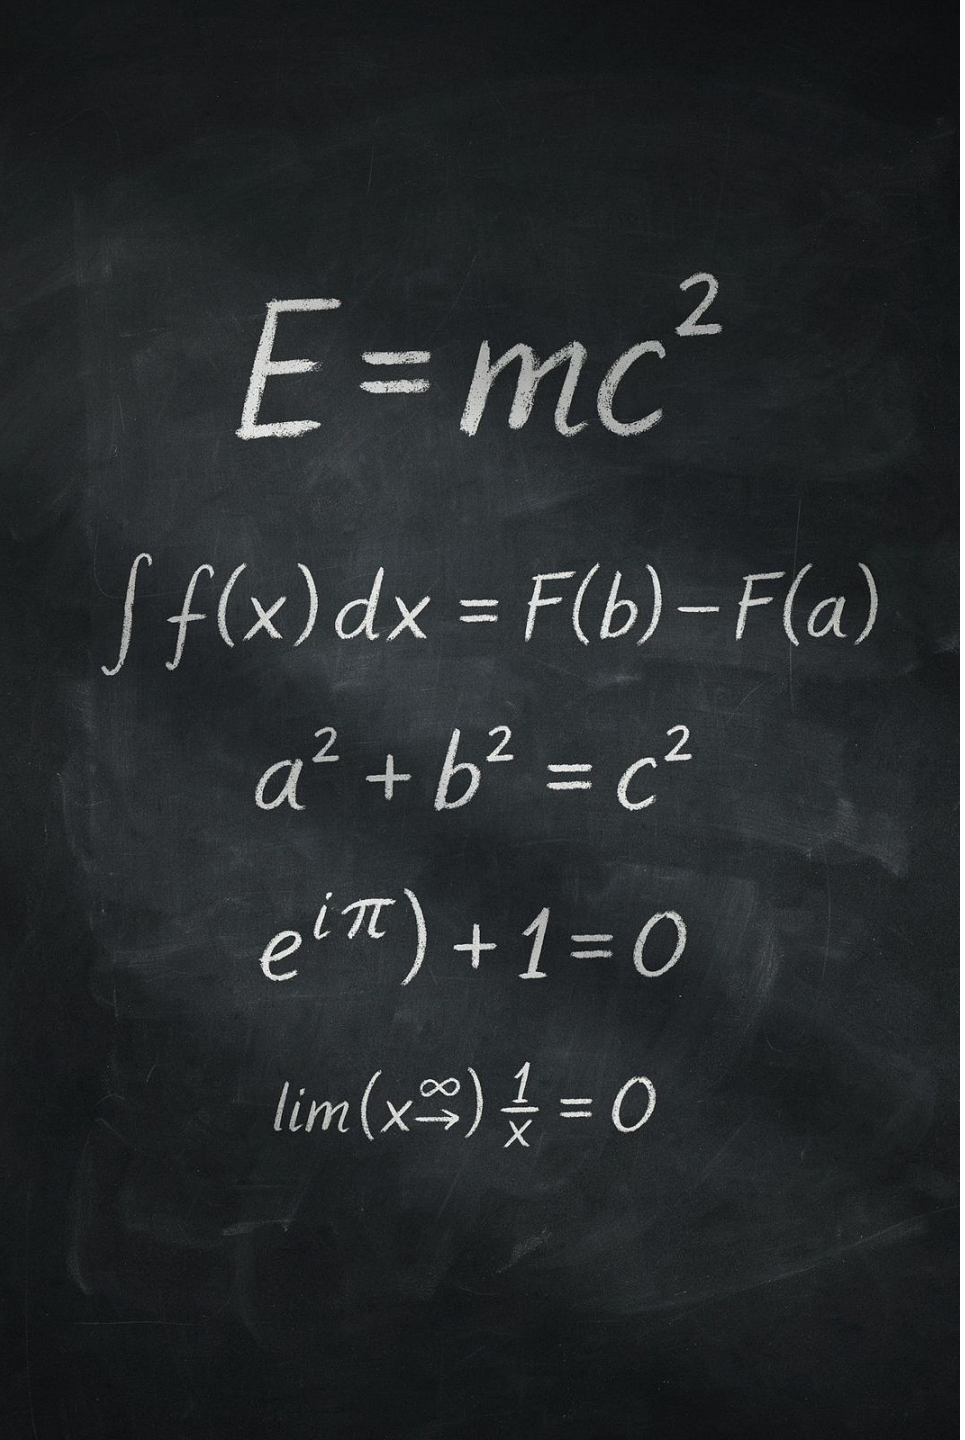


Matemáticas para IA

SPRINT 2 · MATEMÁTICAS Y ESTADÍSTICA · S02.1

Vectores, matrices, derivadas y gradiente: lo justo para entender cómo aprende un modelo. Sin demostraciones; con ideas y ejemplos.

Tres ideas que lo sostienen todo

Datos como vectores

Una reserva, una imagen o un texto se convierten en listas de números.

Aprender = minimizar un error

Entrenar es encontrar los parámetros con menor coste. El cálculo nos dice hacia dónde moverlos.

Incertidumbre

Toda predicción lleva un margen de duda: la estadística (S02.2) lo mide.

Vectores y producto escalar

```
import numpy as np
reserva = np.array([3, 89.24, 21])       # noches, precio/noche, antelación (días)
pesos   = np.array([2.0, 0.5, 1.0])      # lo que "importa" cada variable
z = reserva @ pesos                      # producto escalar = 2·3 + 0.5·89.24 + 1·21
```

- **Vector:** lista ordenada de números. **Norma:** su longitud.
- **Producto escalar:** suma de productos; da un número y mide cuánto se «alinean» dos vectores.
- Una neurona hace exactamente esto: $z = w \cdot x + b$ (ejercicio M2, modelos de precio).

Matrices y su producto

- Una matriz es una tabla: filas = muestras, columnas = variables. Dimensión $m \times n$.
- Producto $A \cdot B$: cada elemento es el producto escalar de una fila de A por una columna de B. Las columnas de A deben coincidir con las filas de B.
- Transpuesta A^T intercambia filas y columnas. Inversa A^{-1} «deshace» la matriz (solo cuadradas no singulares; en la práctica se evita calcular).
- Autovector: solo cambia de escala al multiplicarlo ($A \cdot v = \lambda \cdot v$). Base de PCA (Sprint 9).

Una capa densa de una red neuronal es $y = A \cdot x + b$.

La derivada: cuánto cambia algo si lo muevo un poco

Función	Derivada
x^n	$n \cdot x^{n-1}$
e^x	e^x
$\ln(x)$	$1/x$
sigmoide $\sigma(x)$	$\sigma(x) \cdot (1 - \sigma(x))$

- Geometría: la pendiente de la recta tangente. Derivada cero = posible mínimo o máximo (M7).
- Regla de la cadena: derivar funciones anidadas, $d/dx\ f(g(x)) = f'(g(x)) \cdot g'(x)$. Es la base de la retropropagación en las redes (M8).

Derivadas parciales y gradiente

$f(x, y) = 3x^2 + 2xy + y^3$ $\partial f/\partial x = 6x + 2y$ $\partial f/\partial y = 2x + 3y^2$ $\nabla f = (\partial f/\partial x , \partial f/\partial y)$ <- el gradiente: todas las parciales juntas

- Parcial: derivar respecto a una variable manteniendo las demás fijas.
- El gradiente apunta hacia donde la función más crece. Para minimizar, vamos en el sentido contrario.
- Ejercicios M9 y M12 (explorar con Desmos o GeoGebra).

Descenso del gradiente

$$\theta \leftarrow \theta - \alpha \cdot \nabla L(\theta)$$

1. Empezar con parámetros al azar.
2. Calcular el coste $L(\theta)$.
3. Calcular el gradiente.
4. Dar un paso contrario al gradiente.
5. Repetir hasta que el coste deje de bajar.

> **α (tasa de aprendizaje):** muy pequeña, lento; muy grande, el modelo oscila o diverge. Es el hiperparámetro más importante del entrenamiento.

Lo practicarás con una variable (M10) y con una función de coste (M11). En el Sprint 5 lo programas desde cero.

Conectando todo

Paso del entrenamiento	Matemáticas
Entrada → predicción	matrices y vectores ($y = A \cdot x + b$)
Predicción → error	función de coste (diferencia con lo real)
Error → cómo corregir	gradiente (regla de la cadena = retropropagación)
Corregir	descenso del gradiente con tasa α

El resto del curso, hasta los transformers, es esto mismo a mayor escala.

Ahora, a practicar

Lo que viene a continuación está en tu repositorio.

Tipo	Actividad	Tiempo
ACTIVIDAD	Ejercicios de matemáticas (hoja 1) con Desmos o GeoGebra (sprints/S02/actividades/ejercicios_algebra_calculo.md)	55 min
RETO	Primera lectura del informe con la lista de control (paso 2) (sprints/S02/Reto_S02/Reto_Sprint_02.md)	60 min