Estadística y probabilidad

Antes de entrenar un modelo hay que saber leer datos sin dejarse engañar. Esta sesión es la caja de herramientas para auditar el informe del cliente.

SPRINT 2 · MATEMÁTICAS Y ESTADÍSTICA · S02.2



Describir: centro y dispersión

Medida	Qué dice	Cuidado
Media	el promedio	la arrastran los valores extremos
Mediana	el valor central	robusta ante outliers
Moda	el más frecuente	útil en categorías
Varianza / desviación típica σ	cuánto se alejan los datos de la media	σ está en las mismas unidades que el dato
Cuartiles, IQR (Q3 – Q1)	dispersión del 50 % central	base del diagrama de caja

ⓘ Con datos asimétricos (salarios, precios) manda la mediana, no la media.

Distribuciones y probabilidad

Normal

Simétrica; el 68-95-99,7 % cae a 1, 2 y 3 σ de la media.

Binomial

Nº de éxitos en n ensayos con probabilidad p (ej. cancelaciones entre 20 reservas).

Uniforme

Todos los resultados igual de probables.

- Adición: $P(A \cup B) = P(A)+P(B)-P(A \cap B)$. Complementario: $P(\text{no } A) = 1 - P(A)$.
- Condicionada: $P(A|B) = P(A \cap B)/P(B)$; si son independientes, $P(A \cap B) = P(A) \cdot P(B)$.

Teorema de Bayes

$$P(A \mid B) = P(B \mid A) \cdot P(A) / P(B)$$

- P(A): lo que creemos antes (a priori).
- P(B|A): cómo de probable es la evidencia.
- P(A|B): la creencia actualizada.

```
prevalencia, sensibilidad, especificidad = 0.01, 0.99, 0.95
positivo = sensibilidad * prevalencia + (1 - especificidad) * (1 - prevalencia)
print(sensibilidad * prevalencia / positivo)     # 0.1667
```

⚠ Test «fiable al 99 %» y solo un 16,7 % de los positivos están enfermos. Lo mismo pasa con un detector de reservas fraudulentas si el fraude es raro (E7; caso 9 de «Estadísticas engañosas»).

Muestreo y sesgos

Muestreo	Idea
Aleatorio simple	todos con la misma probabilidad: el menos sesgado
Estratificado	se muestrea cada grupo en su proporción
Por conglomerados	se eligen grupos completos: más barato, más varianza

- Sesgo de selección: la muestra no representa a la población.
- Sesgo de respuesta: quien contesta no es sincero o es distinto.
- Sesgo de supervivencia: solo vemos lo que «sobrevivió» (caso 8: «los negocios antiguos tienen buenas valoraciones»).

Correlación no es causalidad

- El coeficiente r va de –1 a +1; 0 = sin relación lineal.
- Un r = 0,99 no prueba causa: puede haber una variable oculta (caso 6: más helados, más reservas; la causa común es el verano).

Paradoja de Simpson

Una tendencia que aparece en cada grupo desaparece o se invierte al juntarlos. En TurisData: el depósito o el canal pueden parecer mejores o peores según se mire el total o dentro de cada tarifa (caso 3 y afirmación 2 del reto).

Regla: desagrega antes de concluir.

Inferencia: intervalos y contraste

- Intervalo de confianza 95 %: si repitiéramos el muestreo muchas veces, el 95 % de los intervalos contendría el valor real. Más muestra → intervalo más estrecho.
- Contraste de hipótesis: 1) plantear H_0 y H_1; 2) fijar α (0,05); 3) calcular el estadístico y el p-valor; 4) decidir. Si $p < \alpha$, se rechaza H_0.
- El p-valor es la probabilidad de ver datos así de extremos si H_0 fuera cierta; no es la probabilidad de que H_0 sea cierta.

Trampas habituales (lista de control del reto)

1. Significativo ≠ relevante: un efecto minúsculo puede tener $p < 0{,}05$.
2. p-hacking: probar muchas cosas hasta que una «sale».
3. Ejes truncados que exageran diferencias; porcentajes sin denominador («el 100 % lo recomienda» con $n = 2$).
4. Base de comparación distinta: «+50 %» y «−10 %» no se suman (caso 7); julio→agosto no es agosto→julio (caso 5).
5. Media con datos sesgados (caso 2) y extrapolar fuera del rango.

ⓘ Para cada frase del informe: ¿qué afirma?, ¿qué falla o falta?, ¿cómo debería decirse?

Ahora, a practicar

Lo que viene a continuación está en tu repositorio.

ACTIVIDAD	Estadísticas engañosas (sprints/S02/actividades/estadisticas_enganosas.md): 4 de los 9 casos en clase; para casa, el resto y la hoja 2 de ejercicios de estadística (sprints/S02/actividades/ejercicios_estadistica.md) — 45 min.
RETO	Rehacer los cálculos, dictamen y recomendación (pasos 3 y 4) (sprints/S02/Reto_S02/Reto_Sprint_02.md) — 55 min.