SPRINT 2 · MATEMÁTICAS Y ESTADÍSTICA · S02.2

# Estadística y probabilidad

Antes de entrenar un modelo hay que saber **leer datos sin dejarse engañar**. Esta sesión es la caja de herramientas para auditar el informe del cliente.

# Describir: centro y dispersión

| Medida | Qué dice | Cuidado |
|---|---|---|
| **Media** | el promedio | la arrastran los valores extremos |
| **Mediana** | el valor central | robusta ante *outliers* |
| **Moda** | el más frecuente | útil en categorías |
| **Varianza / desviación típica σ** | cuánto se alejan los datos de la media | σ está en las **mismas unidades** que el dato |
| **Cuartiles, IQR (Q3 − Q1)** | dispersión del 50 % central | base del diagrama de caja |

Con datos asimétricos (salarios, precios) manda la **mediana**, no la media.

# Distribuciones y probabilidad

### Normal

Simétrica; el 68-95-99,7 % cae a 1, 2 y 3 σ de la media.

### Binomial

Nº de éxitos en *n* ensayos con probabilidad *p* (ej. cancelaciones entre 20 reservas).

### Uniforme

Todos los resultados igual de probables.

- **Adición**: $P(A \cup B) = P(A) + P(B) - P(A \cap B)$. **Complementario**: $P(\text{no } A) = 1 - P(A)$.
- **Condicionada**: $P(A \mid B) = P(A \cap B) / P(B)$; si son independientes, $P(A \cap B) = P(A) \cdot P(B)$.

# Teorema de Bayes

$$P(A|B) = P(B|A) \cdot P(A) / P(B)$$

- `P(A)`: lo que creemos **antes** (a priori). `P(B|A)`: cómo de probable es la evidencia. `P(A|B)`: la creencia **actualizada**.

```
prevalencia, sensibilidad, especificidad = 0.01, 0.99, 0.95
positivo = sensibilidad * prevalencia + (1 - especificidad) * (1 - prevalencia)
print(sensibilidad * prevalencia / positivo)     # 0.1667
```

Test «fiable al 99 %» y solo un **16,7 %** de los positivos están enfermos. Lo mismo pasa con un detector de reservas fraudulentas si el fraude es raro (**E7**; caso 9 de «Estadísticas engañosas»).

# Muestreo y sesgos

| Muestreo | Idea |
|---|---|
| **Aleatorio simple** | todos con la misma probabilidad: el menos sesgado |
| **Estratificado** | se muestrea cada grupo en su proporción |
| **Por conglomerados** | se eligen grupos completos: más barato, más varianza |

- **Sesgo de selección**: la muestra no representa a la población.
- **Sesgo de respuesta**: quien contesta no es sincero o es distinto.
- **Sesgo de supervivencia**: solo vemos lo que «sobrevivió» (caso 8: «los negocios antiguos tienen buenas valoraciones»).

# Correlación no es causalidad

- El coeficiente **r** va de −1 a +1; **0** = sin relación **lineal.**
- Un **r = 0,99 no prueba causa**: puede haber una **variable oculta** (caso 6: más helados, más reservas; la causa común es el verano).

# Paradoja de Simpson

Una tendencia que aparece en cada grupo **desaparece o se invierte** al juntarlos. En TurisData: el **depósito** o el **canal** pueden parecer mejores o peores según se mire el total o **dentro de cada tarifa** (caso 3 y afirmación 2 del reto).

> **Regla**: desagrega antes de concluir.

# Inferencia: intervalos y contraste

- **Intervalo de confianza 95 %**: si repitiéramos el muestreo muchas veces, el 95 % de los intervalos contendría el valor real. Más muestra → intervalo **más estrecho**.
- **Contraste de hipótesis**: 1) plantear $H_0$ y $H_1$; 2) fijar $\alpha$ (0,05); 3) calcular el estadístico y el **p-valor**; 4) decidir. Si `p < α`, se rechaza $H_0$.
- El p-valor es la probabilidad de ver datos así de extremos **si $H_0$ fuera cierta**; no es la probabilidad de que $H_0$ sea cierta.

# Trampas habituales (lista de control del reto)

1. **Significativo ≠ relevante**: un efecto minúsculo puede tener p < 0,05.
2. **p-hacking**: probar muchas cosas hasta que una «sale».
3. **Ejes truncados** que exageran diferencias; **porcentajes sin denominador** («el 100 % lo recomienda» con n = 2).
4. **Base de comparación distinta**: «+50 %» y «−10 %» no se suman (caso 7); julio→agosto no es agosto→julio (caso 5).
5. **Media con datos sesgados** (caso 2) y **extrapolar** fuera del rango.

> Para cada frase del informe: ¿qué afirma?, ¿qué falla o falta?, ¿cómo debería decirse?

S02 · EN EL REPOSITORIO DEL CURSO

# Ahora, a practicar

Lo que viene a continuación está en tu repositorio; no hace falta buscar ejercicios fuera.

ACTIVIDAD

## Actividad

45 min

Estadísticas engañosas (4 de los 9 casos en clase). Para casa: el resto y la hoja 2 de ejercicios de estadística

sprints/S02/actividades/estadisticas_enganosas.md

RETO

## Reto del sprint

55 min

Rehacer los cálculos, dictamen y recomendación (pasos 3 y 4)

sprints/S02/guia/Reto_Sprint_02.md