Listado de pasos y preguntas de AutoML · S03 (cuaderno S3.5_lab_autogluon)

QUÉ ES

el índice de todo lo que hay que hacer en el laboratorio de AutoML, para saber **qué toca** y **llevar la cuenta**. A diferencia de SQL y NoSQL, aquí **no hay celdas con `...` que rellenar**: el cuaderno ya trae el código y vuestro trabajo es **ejecutarlo, leer el resultado y responder**. Cómo abrirlo: apartado 1 de la guía en parejas.

CÓMO USARLO

marcad la casilla cuando la celda haya terminado **y** tengáis anotado vuestro dato en la hoja de registro. Después podéis contrastar con el solucionario paso a paso.

ORDEN

de arriba abajo, **una celda cada vez**. Si reiniciáis el entorno de Colab, volved a ejecutar desde el paso 0. Las cifras de la guía son orientativas: en el informe van **las vuestras**.

ARCHIVO

`S3.5_lab_autogluon.ipynb` · Abrir en Colab

Qué datos usa

Un CSV con **6.000 reservas y 18 columnas**, `reservas_turisdata.csv` (la celda 0 lo descarga sola). Son las columnas de la tabla `reservas` de `turisdata.db`, sin `id_cliente` ni `id_alojamiento`; las explica el esquema de turisdata.db.

Grupo	Columnas
Identificador (no se usa para predecir)	`id_reserva`
Fechas	`fecha_reserva`, `fecha_llegada`, `antelacion_dias`
La estancia	`noches`, `adultos`, `ninos`, `tipo_habitacion`, `regimen`, `precio_noche`
Cómo se reservó	`canal`, `tarifa`, `deposito`, `peticiones_especiales`
El cliente	`pais_origen` (138 vacíos), `cliente_repetidor`, `cancelaciones_previas`
Lo que predecimos	**`cancelada`** (`1` = se canceló, `0` = no)

En clase (≈ 100 minutos)

	Paso	Qué se hace	Dato que hay que anotar
☐	**Instalación**	Instalar AutoGluon (2–3 min) y, si Colab lo pide, reiniciar el entorno	—
☐	**0 · Configuración**	Descargar el CSV y fijar `LIMITE_TIEMPO` (120 s) y la semilla	—
☐	**1 · Cargar**	Leer el CSV y ver las primeras filas	Forma de la tabla: **(6000, 18)**
☐	**2 · Explorar**	Tipos de dato, nulos, proporción de cancelaciones, resumen numérico	% de cancelaciones y columna con nulos
☐	**3 · Partición temporal**	Entrenar con el 80 % más antiguo, probar con el 20 % más reciente	Filas y fechas de cada parte
☐	**4 · Entrenar**	`TabularPredictor.fit(...)`: AutoGluon prueba modelos y elige el mejor	Mejor modelo y tiempo de entrenamiento
☐	**5 · Leaderboard**	Tabla de candidatos con `score_test`, `score_val` y `fit_time`	`score_test` del mejor
☐	**6 · Evaluar**	Precisión, recall, F1, ROC-AUC y matriz de confusión con umbral 0,5 y 0,3	Precisión y recall de cada umbral
☐	**6b · Umbral con costes**	Poner precio a los errores y buscar el umbral más barato	**Vuestros costes** y umbral elegido
☐	**7 · Importancia de variables**	Ver qué columnas pesan más	Las tres primeras
☐	**8 · Guardar y recargar**	Guardar el modelo en `modelo_cancelaciones` y volver a cargarlo	Probabilidades de ejemplo
☐	**9 · Función de predicción**	Predecir **una** reserva suelta	Probabilidad y alerta

	Paso	Qué se hace	Dato que hay que anotar
☐	**10 · API**	Llamar a `/salud` y `/predecir` con `TestClient`	Código de respuesta (200)
☐	**11 · Informe de recursos**	Tiempo, tamaño del modelo, coste	Tiempo, MB, 0 €
☐	**Cerrar**	*Entorno de ejecución → Desconectar y eliminar entorno*	Captura de la prueba

Preguntas del cuaderno (se responden en pareja y se anotan)

	Paso	Pregunta
☐	**2**	¿Está **desbalanceada** la clase objetivo? ¿Qué métrica conviene?
☐	**2**	¿Qué columnas podrían provocar **fuga de datos** (información posterior al desenlace)?
☐	**3**	¿Por qué se parte **por fechas** y no al azar?
☐	**5**	¿El mejor modelo es un **ensamblado**? ¿Cuánto tarda cada uno? ¿Merece la pena el coste de cómputo?
☐	**5**	¿Por qué `score_val` es **más alto** que `score_test`?
☐	**6**	¿Qué cuesta más, una **cancelación no prevista** o una **alerta falsa**? ¿Qué umbral elegiríais?
☐	**6b**	¿Gana el modelo a **«avisar a todos»**? ¿Y si la alerta falsa costara **5 €** en vez de 40?
☐	**7**	¿Tienen sentido las variables más importantes para el negocio? ¿Alguna **sospechosa de fuga**?
☐	**10**	Probad una reserva con datos imposibles (`"noches": 0`): ¿qué error da la API y por qué?

En casa (para el informe del reto)

	Tarea	Qué piden
☐	**Cambiar los costes**	En el paso 6b, sustituid 100 € y 40 € por **vuestras hipótesis** (con una frase que las justifique) y volved a ejecutar
☐	**Repetir con otro tiempo**	Poned `LIMITE_TIEMPO = 15` y comparad el `score_test` con el de 120 s: ¿cambia algo?
☐	**Escribir el informe**	Máximo 4 páginas: planteamiento y datos · modelos y resultados · umbral y negocio · qué pesa en la predicción · evidencia de la API · recursos y costes
☐	**Tabla de recursos**	Recurso · cuándo se creó · tiempo usado · coste · cerrado · prueba

Total: 15 filas de pasos (instalación, 0 a 11, 6b y cierre) + 9 preguntas + 4 tareas para casa.