Guía de laboratorio · AutoML con AutoGluon (S3.5)

Sprint 3 · Reto «Primer modelo en producción» · TurisData Canarias. Es el **resumen** del laboratorio. Para trabajarlo paso a paso en pareja (roles, plan de 100 minutos, respuestas explicadas) usad la guía en parejas.

1. Objetivo y tiempo

- **Objetivo:** predecir si una reserva de TurisData **se cancelará**, con un modelo AutoML, elegir cuándo dar la alerta y ofrecer la predicción por una API.
- **Flujo:** datos → experimento AutoML → evaluación → umbral con costes → explicabilidad → API → informe de recursos.
- **Tiempo:** unos **100 minutos** en clase. El entrenamiento dura menos de un minuto.
- **Coste: 0 €**. Datos **sintéticos** (inventados).

2. Antes de empezar

- **Qué necesitáis:** una cuenta de Google (para Colab), o Python 3.10–3.13 con 8 GB de RAM en vuestro ordenador.
- **Abrid el cuaderno en Colab:** S3.5_lab_autogluon.ipynb. Guardad una copia en vuestro Drive.
- **Ejecutad las celdas de una en una**, de arriba abajo (Mayús+Intro). No uséis «Ejecutar todo».
- **La primera celda instala AutoGluon** y tarda 2 o 3 minutos. Si Colab pide reiniciar el entorno, aceptad y seguid desde el paso 0.
- **No hay que subir ningún archivo:** la celda del paso 0 **descarga sola** el CSV `reservas_turisdata.csv` y la API (hace falta internet). Solo si la descarga fallase, subid el CSV al panel de archivos de Colab.
- **En local:** descargad la carpeta `laboratorio_automl/` (el CSV viene dentro), ejecutad `pip install -r requirements.txt` y abrid el cuaderno con Jupyter o VS Code. El script `S3.5_lab_autogluon.py` hace lo mismo y necesita el CSV en su misma carpeta.

Comprobación de arranque: tras el paso 1 debe salir `(6000, 18)`.

3. Pasos guiados

Paso	Qué hacéis	Qué debe salir (orientativo)
0 · Configuración	Se descarga el CSV y se fija `LIMITE_TIEMPO` (120 s)	Nada visible
1 · Cargar	Leer el CSV	`(6000, 18)`
2 · Explorar	Tipos, nulos, proporción de cancelaciones	138 nulos en `pais_origen`; 0,459 de canceladas
3 · Partición temporal	Entrenar con el 80 % más antiguo y probar con el 20 % más reciente	4.800 filas de entrenamiento y 1.200 de prueba
4 · Entrenar	`TabularPredictor.fit(...)` prueba modelos y se queda con el mejor	`Best model: WeightedEnsemble_L2`, unos 36 s
5 · Leaderboard	Comparar candidatos con datos que no han visto	El mejor ronda 0,72 (`score_test`)
6 · Evaluar	Precisión, recall, F1 y matriz de confusión con umbral 0,5 y 0,3	AUC 0,72; recall 0,60 con 0,5 y 0,88 con 0,3
6b · Umbral con costes	Poner precio a cada tipo de error	Tabla de costes por umbral

Paso	Qué hacéis	Qué debe salir (orientativo)
7 · Importancia	Qué variables pesan más	`antelacion_dias`, `deposito`, `canal`, `tarifa`
8 · Guardar	El modelo queda en `modelo_cancelaciones` y se recarga	Probabilidades de ejemplo
9 · Predecir	Una reserva suelta	`{'probabilidad_cancelacion': …, 'alerta': …}`
10 · API	`GET /salud` y `POST /predecir` con `TestClient`	Respuesta `200`
11 · Recursos	Tiempo, tamaño del modelo y coste	Unos 225 MB y 0 €

Dos ideas que hay que llevarse:

1. **La partición es por fechas** porque en la vida real el modelo se usa en el futuro. Por eso la nota de prueba (0,72) es más baja y más honesta que la de validación (0,78).
2. **El mejor modelo gana por muy poco.** El ensamblado supera al resto por milésimas y cuesta más tiempo y espacio: hay que justificar la elección, no solo mirar el número.

4. El umbral se elige con costes (paso 6b)

El modelo da una **probabilidad**, no un «sí o no». El **umbral** es el punto de corte para dar la alerta. Elegirlo es una decisión de negocio: depende de **cuánto cuesta cada error**.

- **Cancelación no prevista:** una habitación que queda vacía.
- **Alerta falsa:** una acción innecesaria (llamar al cliente, regalar un descuento).

Regla: conviene dar la alerta cuando **probabilidad > coste de alerta falsa ÷ (coste de alerta falsa + coste de no prevista)**.

El cuaderno trae un **ejemplo**: 100 € por no prevista y 40 € por alerta falsa, lo que da un umbral teórico de 0,29. **Sustituidlos por vuestras hipótesis** y justificadlas en el informe. Con el ejemplo, el umbral habitual 0,5 cuesta unos 8.400 € más que el 0,3.

Comparad siempre con las alternativas tontas: «avisar a todos» y «no avisar nunca». Si el modelo no las mejora, no se justifica.

5. Comprobaciones

- [ ] El CSV tiene 6.000 filas y la proporción de canceladas ronda el 46 %.
- [ ] Entrenamiento y prueba están separados por fecha y no se solapan.
- [ ] El leaderboard muestra al menos un modelo ensamblado.
- [ ] Habéis calculado el coste de varios umbrales con **vuestros** importes y elegido uno con razón de negocio.
- [ ] `POST /predecir` devuelve `probabilidad_cancelacion`, `alerta` y `umbral`, y tenéis **captura** de la respuesta.
- [ ] El informe de recursos está completo y habéis **cerrado la sesión** de Colab (*Entorno de ejecución → Desconectar y eliminar entorno*), con captura como prueba.

6. Preguntas de reflexión

1. ¿Por qué un modelo con mejor AUC no siempre es el mejor para el negocio?
2. ¿Qué variable sería sospechosa de **fuga de datos** y por qué?
3. Los datos son sintéticos: ¿qué no podríais afirmar de un hotel real?
4. ¿Qué cambiaría si el modelo se desplegara en una nube de pago (cuentas, claves, apagado de recursos)?

7. Equivalencias con una nube de pago

Servicio en la nube	Este laboratorio
Subir el dataset	Cargar el CSV con pandas
Experimento AutoML	`TabularPredictor.fit`
Candidatos y métricas	`leaderboard` y pasos 6–7
Endpoint	API con FastAPI
Claves y permisos	Concepto: aquí no hay cuenta que proteger
Informe de costes y cierre	Informe de recursos; desconectar Colab

8. Ampliación opcional

- Subid `presets="high_quality"` y comparad el tiempo y la métrica.
- Añadid una columna derivada (por ejemplo, temporada) y medid si mejora.
- Probad con otros costes y comprobad **cuándo deja de compensar el modelo** frente a «avisar a todos».

9. Entregable del reto y más material

Entregable: informe de máximo 4 páginas con el mejor modelo (métricas en datos no vistos), el **umbral elegido con vuestros costes y su justificación**, qué variables pesan, **captura de la llamada a la API** e informe de recursos con prueba de cierre.

Más material:

- Guía en parejas: roles, plan de la sesión, errores frecuentes y hoja de registro.
- Listado de pasos y preguntas.
- Solucionario paso a paso: para mirar **después** de intentarlo.
- Código explicado línea a línea: qué hace cada celda del cuaderno, para entender el código que habéis ejecutado.
- Esquema de turisdata.db: las columnas del CSV.