# Guía de laboratorio · AutoML con AutoGluon (S3.5)

**Sprint 3 · Reto «Primer modelo en producción» · TurisData Canarias.** Es el **resumen** del laboratorio. Para trabajarlo paso a paso en pareja (roles, plan de 100 minutos, respuestas explicadas) usad la guía en parejas.

## 1. Objetivo y tiempo

- **Objetivo:** predecir si una reserva de TurisData **se cancelará**, con un modelo AutoML, elegir cuándo dar la alerta y ofrecer la predicción por una API.
- **Flujo:** datos → experimento AutoML → evaluación → umbral con costes → explicabilidad → API → informe de recursos.
- **Tiempo:** unos **100 minutos** en clase. El entrenamiento dura menos de un minuto.
- **Coste: 0 €**. Datos **sintéticos** (inventados).

## 2. Antes de empezar

- **Qué necesitáis:** una cuenta de Google (para Colab), o Python 3.10–3.13 con 8 GB de RAM en vuestro ordenador.
- **Abrid el cuaderno en Colab:** S3.5_lab_autogluon.ipynb. Guardad una copia en vuestro Drive.
- **Ejecutad las celdas de una en una**, de arriba abajo (Mayús+Intro). No uséis «Ejecutar todo».
- **La primera celda instala AutoGluon** y tarda 2 o 3 minutos. Si Colab pide reiniciar el entorno, aceptad y seguid desde el paso 0.
- **No hay que subir ningún archivo:** la celda del paso 0 **descarga sola** el CSV `reservas_turisdata.csv` y la API (hace falta internet). Solo si la descarga fallase, subid el CSV al panel de archivos de Colab.
- **En local:** descargad la carpeta `laboratorio_automl/` (el CSV viene dentro), ejecutad `pip install -r requirements.txt` y abrid el cuaderno con Jupyter o VS Code. El script `S3.5_lab_autogluon.py` hace lo mismo y necesita el CSV en su misma carpeta.

**Comprobación de arranque:** tras el paso 1 debe salir `(6000, 18)`.

## 3. Pasos guiados

| Paso | Qué hacéis | Qué debe salir (orientativo) |
|---|---|---|
| **0 · Configuración** | Se descarga el CSV y se fija `LIMITE_TIEMPO` (120 s) | Nada visible |
| **1 · Cargar** | Leer el CSV | `(6000, 18)` |
| **2 · Explorar** | Tipos, nulos, proporción de cancelaciones | 138 nulos en `pais_origen`; 0,459 de canceladas |
| **3 · Partición temporal** | Entrenar con el 80 % más antiguo y probar con el 20 % más reciente | 4.800 filas de entrenamiento y 1.200 de prueba |
| **4 · Entrenar** | `TabularPredictor.fit(...)` prueba modelos y se queda con el mejor | `Best model: WeightedEnsemble_L2`, unos 36 s |
| **5 · Leaderboard** | Comparar candidatos con datos que no han visto | El mejor ronda 0,72 ( `score_test` ) |
| **6 · Evaluar** | Precisión, recall, F1 y matriz de confusión con umbral 0,5 y 0,3 | AUC 0,72; recall 0,60 con 0,5 y 0,88 con 0,3 |
| **6b · Umbral con costes** | Poner precio a cada tipo de error | Tabla de costes por umbral |

| Paso | Qué hacéis | Qué debe salir (orientativo) |
|---|---|---|
| **7 · Importancia** | Qué variables pesan más | `antelacion_dias`, `deposito`, `canal`, `tarifa` |
| **8 · Guardar** | El modelo queda en `modelo_cancelaciones` y se recarga | Probabilidades de ejemplo |
| **9 · Predecir** | Una reserva suelta | `{'probabilidad_cancelacion': …, 'alerta': …}` |
| **10 · API** | `GET /salud` y `POST /predecir` con `TestClient` | Respuesta `200` |
| **11 · Recursos** | Tiempo, tamaño del modelo y coste | Unos 225 MB y 0 € |

**Dos ideas que hay que llevarse:**

1. **La partición es por fechas** porque en la vida real el modelo se usa en el futuro. Por eso la nota de prueba (0,72) es más baja y más honesta que la de validación (0,78).
2. **El mejor modelo gana por muy poco.** El ensamblado supera al resto por milésimas y cuesta más tiempo y espacio: hay que justificar la elección, no solo mirar el número.

## 4. El umbral se elige con costes (paso 6b)

El modelo da una **probabilidad**, no un «sí o no». El **umbral** es el punto de corte para dar la alerta. Elegirlo es una decisión de negocio: depende de **cuánto cuesta cada error**.

- **Cancelación no prevista:** una habitación que queda vacía.
- **Alerta falsa:** una acción innecesaria (llamar al cliente, regalar un descuento).

**Regla:** conviene dar la alerta cuando **probabilidad > coste de alerta falsa ÷ (coste de alerta falsa + coste de no prevista)**.

El cuaderno trae un **ejemplo**: 100 € por no prevista y 40 € por alerta falsa, lo que da un umbral teórico de 0,29. **Sustituidlos por vuestras hipótesis** y justificadlas en el informe. Con el ejemplo, el umbral habitual 0,5 cuesta unos 8.400 € más que el 0,3.

**Comparad siempre con las alternativas tontas:** «avisar a todos» y «no avisar nunca». Si el modelo no las mejora, no se justifica.

## 5. Comprobaciones

- [ ] El CSV tiene 6.000 filas y la proporción de canceladas ronda el 46 %.
- [ ] Entrenamiento y prueba están separados por fecha y no se solapan.
- [ ] El leaderboard muestra al menos un modelo ensamblado.
- [ ] Habéis calculado el coste de varios umbrales con **vuestros** importes y elegido uno con razón de negocio.
- [ ] `POST /predecir` devuelve `probabilidad_cancelacion`, `alerta` y `umbral`, y tenéis **captura** de la respuesta.
- [ ] El informe de recursos está completo y habéis **cerrado la sesión** de Colab (*Entorno de ejecución → Desconectar y eliminar entorno*), con captura como prueba.

## 6. Preguntas de reflexión

1. ¿Por qué un modelo con mejor AUC no siempre es el mejor para el negocio?
2. ¿Qué variable sería sospechosa de **fuga de datos** y por qué?
3. Los datos son sintéticos: ¿qué no podríais afirmar de un hotel real?
4. ¿Qué cambiaría si el modelo se desplegara en una nube de pago (cuentas, claves, apagado de recursos)?

## 7. Equivalencias con una nube de pago

| Servicio en la nube | Este laboratorio |
|---|---|
| Subir el dataset | Cargar el CSV con pandas |
| Experimento AutoML | `TabularPredictor.fit` |
| Candidatos y métricas | `leaderboard` y pasos 6–7 |
| Endpoint | API con FastAPI |
| Claves y permisos | Concepto: aquí no hay cuenta que proteger |
| Informe de costes y cierre | Informe de recursos; desconectar Colab |

## 8. Ampliación opcional

- Subid `presets="high_quality"` y comparad el tiempo y la métrica.
- Añadid una columna derivada (por ejemplo, temporada) y medid si mejora.
- Probad con otros costes y comprobad **cuándo deja de compensar el modelo** frente a «avisar a todos».

## 9. Entregable del reto y más material

**Entregable:** informe de máximo 4 páginas con el mejor modelo (métricas en datos no vistos), el **umbral elegido con vuestros costes y su justificación**, qué variables pesan, **captura de la llamada a la API** e informe de recursos con prueba de cierre.

**Más material:**

- Guía en parejas: roles, plan de la sesión, errores frecuentes y hoja de registro.
- Listado de pasos y preguntas.
- Solucionario paso a paso: para mirar **después** de intentarlo.
- Esquema de turisdata.db: las columnas del CSV.