

Guía de Laboratorio · AutoML con AutoGluon

Reto «Primer modelo en producción» — Aprende a predecir cancelaciones de reservas turísticas usando AutoML, evaluar el modelo, explicar sus decisiones y servirlo mediante una API REST. Todo ello con coste **0 EUR**.



Objetivo y Tiempo

¿Qué vamos a construir?

Predecir si una reserva de TurisData se cancelará, entrenar un modelo AutoML y ofrecer la predicción a través de una API REST.

Flujo de trabajo

Dato → Experimento AutoML → Evaluación → Explicabilidad → Servicio por API → Informe de recursos.

3h

Duración total

Tiempo estimado del laboratorio completo

2min

Entrenamiento

Duración del entrenamiento con límite por defecto

0€

Coste total

El laboratorio es completamente gratuito

Requisitos Previos

Antes de comenzar, asegúrate de tener todo lo necesario para ejecutar el laboratorio sin interrupciones.



Entorno de ejecución

Una cuenta de Google (Colab) o Python 3.10–3.13 en tu PC con al menos **8 GB de RAM**.



Archivos del laboratorio

`generar_reservas_turisdata.py`,
`S3.5_lab_autogluon.py`, `api_cancelaciones.py`,
`requirements.txt`.



Instalación en Colab

Primera celda obligatoria:

```
!pip install -q  
"autogluon.tabular[lightgbm,xgboost,catboost]"
```



Dataset CSV

El archivo `reservas_turisdata.csv` contiene **6.000 reservas sintéticas**. Súbelo al panel de archivos de Colab o créalo con `python generar_reservas_turisdata.py`.



En Colab: sube el CSV al panel de archivos lateral antes de ejecutar las celdas de carga de datos. [CAPTURA 1: panel de archivos de Colab con el CSV subido]

Pasos Guiados: Carga, Partición y Entrenamiento

El laboratorio está dividido en celdas `# %%`; en Colab copia cada bloque en una celda nueva.

- 1** Cargar y explorar (celdas 1-2)
Mira los tipos de datos, los nulos (`pais_origen` tiene ausentes) y la proporción de cancelaciones (~46 %).
Pregunta: ¿qué métrica conviene si las clases están casi equilibradas?
- 2** Partición temporal 80/20 (celda 3)
Se entrena con el pasado y se prueba con el futuro. **Pregunta:** ¿por qué no una partición aleatoria? La separación temporal evita la fuga de información futura al modelo.
- 3** Entrenar (celda 4)
Ejecuta `TabularPredictor(...).fit(time_limit=120, presets="medium_quality")`. Para un ensayo rápido baja `TIME_LIMIT` a unos 15 segundos.
[CAPTURA 2: salida del entrenamiento]

Pasos Guiados: Evaluación y Explicabilidad

Leaderboard (celda 5)

Compara candidatos y tiempos; identifica el modelo ensamblado que AutoGluon construye automáticamente combinando los mejores candidatos individuales. [CAPTURA 3: tabla del leaderboard]

Evaluar (celda 6)

Calcula precisión, recall y F1 con umbral **0,5** y **0,3**, y genera la matriz de confusión.

Decisión de negocio: ¿qué cuesta más, una cancelación no prevista o una alerta falsa? Elige el umbral y justifícalo con criterio de negocio.

Explicabilidad (celda 7)

Calcula la importancia de variables del modelo. Las variables más esperadas son:

antelacion_dias

Días de antelación de la reserva

deposito

Si se realizó depósito o no

canal

Canal de distribución de la reserva

tarifa

Tarifa aplicada a la reserva

[CAPTURA 4: tabla de importancia de variables]

Pasos Guiados: API, Guardado y Recursos



Guardar y recargar (celdas 8-9)

El modelo queda en la carpeta

`modelo_cancelaciones`.

Prueba la función

`predecir_cancelacion` para verificar que la carga funciona correctamente.



Servir por API (celda 10)

En local: `uvicorn`

`api_cancelaciones:app --`

`reload`, abre

`http://127.0.0.1:8000/docs` y

prueba `POST /predecir`. En

Colab usa `TestClient` de

FastAPI. [CAPTURA 5:

pantalla `/docs` con la

respuesta]



Informe de recursos (celda 11)

Registra el tiempo total de entrenamiento, el tamaño del modelo (~225 MB) y confirma el coste de **0 EUR**.



La respuesta de `POST /predecir` debe incluir tres campos: `probabilidad_cancelacion`, `alerta` y `umbral`.

Comprobaciones Finales

Antes de dar por completado el laboratorio, verifica que se cumplen todos los puntos siguientes:

- ☐ El CSV tiene 6.000 filas y la clase `cancelada` ronda el 46 %.
- ☐ Entrenamiento y prueba están separados por fecha y no se solapan.
- ☐ El leaderboard muestra al menos un modelo ensamblado.
- ☐ Has probado dos umbrales (0,5 y 0,3) y elegido uno con razón de negocio.
- ☐ `POST /predecir` devuelve `probabilidad_cancelacion`, `alerta` y `umbral`.
- ☐ El informe de recursos está completo con tiempo, tamaño y coste.

Preguntas de Reflexión

Estas preguntas están diseñadas para profundizar en la comprensión conceptual del laboratorio. Respóndelas en tu informe final.

1

AUC vs. valor de negocio

¿Por qué un modelo con mejor AUC no siempre es el mejor para el negocio? Piensa en los costes asimétricos de los errores tipo I y tipo II.

2

Fuga de datos

¿Qué variable sería sospechosa de fuga de datos y por qué? Identifica columnas que solo podrían conocerse *después* de que ocurra la cancelación.

3

Datos sintéticos

Los datos son sintéticos: ¿qué no podrías afirmar de un hotel real? Reflexiona sobre la validez externa del modelo y sus limitaciones de generalización.

4

Despliegue en nube de pago

¿Qué cambiaría si el modelo se desplegara en una nube de pago? Considera cuentas, claves de acceso, gestión de permisos y apagado de recursos para evitar costes.

Equivalencias con una Nube de Pago

Este laboratorio replica en local los mismos conceptos que encontrarías en plataformas cloud de pago como AWS SageMaker, Azure ML o Google Vertex AI.

Servicio en la nube	Este laboratorio
Subir el dataset	Cargar el CSV con pandas
Experimento AutoML	TabularPredictor.fit
Candidatos y métricas	leaderboard y celdas 6–7
Endpoint	API local con FastAPI
Claves y permisos	Concepto: en local no hay cuenta que proteger
Informe de costes y cierre	Informe de recursos; desconectar Colab

 Comprender estas equivalencias te prepara directamente para trabajar con plataformas MLOps en entornos profesionales de producción.

Ampliación Opcional y Entregable del Reto



Ampliación opcional

Si terminas antes de tiempo o quieres profundizar más, prueba estas extensiones:



Sube la calidad del preset

Cambia a `presets="high_quality"` y compara el tiempo de entrenamiento y la métrica obtenida frente a `medium_quality`.



Ingeniería de características

Añade una columna derivada (por ejemplo, **temporada** a partir de la fecha) y mide si mejora el rendimiento del modelo.



Optimización del umbral

Busca el umbral que maximiza el beneficio con costes inventados por ti, simulando un escenario de negocio real.



Entregable del reto

Tu informe final debe incluir los siguientes elementos para considerarse completo:

- **Informe del mejor modelo:** métricas obtenidas (precisión, recall, F1), umbral elegido y justificación de negocio.
- **Captura de la llamada a la API:** pantalla de `/docs` con la respuesta de `POST /predecir` mostrando los tres campos requeridos.
- **Informe de recursos:** tiempo total de entrenamiento, tamaño del modelo y confirmación de coste 0 EUR.

El entregable demuestra que has completado el ciclo completo: desde el dato crudo hasta un modelo explicable servido por API.