README Sprint S03 · Del dato al modelo en la nube

Pregunta guía: ¿podemos tener un primer modelo funcionando, sin programar?
Fechas: 26–27/10 · **Horas:** 12 h (4 h teoría · 4 h práctica · 4 h proyecto)

📄 **Para imprimir:** todos los documentos del sprint en PDF, a color y ecofriendly, están juntos en la carpeta `pdf/` (descárgalos para que funcionen los enlaces).

> **Sigue el orden de arriba abajo y abre solo lo que pone en cada fila.** Los demás documentos del sprint son para consultar si te atascas (apartado «Si te atascas»). Si el tiempo aprieta, haz solo lo que pone en las filas de cada día: lo demás es para casa.

Qué aprenderás

1. A **consultar y modificar** una base de datos relacional con SQL (`SELECT`, `JOIN`, `GROUP BY`, subconsultas, `INSERT`/`UPDATE`/`DELETE`).
2. A **modelar** datos con claves, restricciones e índices, y a explicar por qué importan.
3. A guardar el mismo dato como **documentos** en MongoDB y a decidir cuándo conviene SQL o NoSQL.
4. A lanzar un **experimento de AutoML**, leer sus métricas y elegir un umbral con criterio de negocio.
5. A **servir un modelo por API** y a controlar y cerrar los recursos que usas.

Antes de empezar

- Haber terminado el Sprint 2 (cuentas y herramientas preparadas).
- Un navegador actual. Para SQL: **DB Browser for SQLite** instalado, o un cliente SQLite en línea (consulta con tu docente cuál).
- No hace falta saber programar en este sprint. Los ejercicios de SQL y AutoML no usan Python; solo el laboratorio opcional de NoSQL (y el laboratorio de AutoML basado en cuadernos, si se usa).
- Datos: `turisdata.db` (SQLite con las tablas `alojamientos`, `clientes` y `reservas`). Son datos **sintéticos**: sirven para practicar, no son estadísticas reales del turismo en Canarias.

Día 1 · Lunes 26/10

☐	Qué haces	Abre	Min
☐	🔔 Ceremonia · Planning del reto «Primer modelo en producción»: leed la ficha y repartid roles	—	10
☐	📖 Teoría · Modelo relacional, SQL, CRUD y nociones de administración	Presentación S03_01	40
☐	💻 Práctica · Scripts SQL 01–06 en DB Browser, en este orden: `SELECT`, `JOIN`, `GROUP BY` y subconsultas; después, CRUD sobre una copia y modelado e índices	`SELECT`	105
☐	📖 Teoría · Bases de datos NoSQL (demostración corta)	Presentación S03_02	15
☐	💻 Práctica · NoSQL con documentos (o, si usáis MongoDB Compass, la guía de MongoDB)	NoSQL con documentos	30

En clase: 3 h 20 min.

Al acabar el día, deberías poder decir:

☐ Sé escribir un `SELECT` con `JOIN` y `GROUP BY`.
☐ Sé cuándo elegir una base relacional y cuándo una NoSQL.

Día 2 · Martes 27/10

☐	Qué haces	Abre	Min
☐	📖 Teoría · Introducción a AutoML y MLOps	Presentación S03_03	20
☐	💻 Práctica · Carga, exploración y primer experimento de AutoML: cuaderno en Colab con la guía en parejas y el listado de pasos (pasos 0 a 5)	cuaderno en Colab	35
☐	🎯 Reto · Reto «Primer modelo en producción»: entender el problema → comparar modelos → elegir el umbral → publicar el servicio → **cerrar y borrar los recursos** → informe (pasos 1–6)	Reto en una página	80
☐	📝 Test · **Test del bloque M6–M8** (bases de datos, AutoML y responsabilidad), solo se abre hoy	Abrir	25
☐	🔔 Ceremonia · Entrega en `sprint-03/`, autoevaluación y coevaluación, review y retrospectiva	—	40

En clase: 3 h 20 min.

Al acabar el día, deberías poder decir:

☐ Informe del mejor modelo, evidencia de la llamada al servicio e informe de recursos en `sprint-03/`.
☐ Recursos cerrados y borrados (0 €).
☐ Test M6–M8 hecho y autoevaluación/coevaluación rellenadas.

El reto en pocas palabras

Qué os pide el cliente. TurisData ha perdido dinero porque algunas reservas se cancelan a última hora y la habitación se queda vacía. Os envía su histórico de reservas y os pide: *«¿Se puede construir algo que avise de qué reservas tienen más riesgo de cancelarse, y que mi equipo de reservas lo consulte desde otra aplicación?»* Es decir: **un modelo de IA funcionando como un servicio**, no solo un experimento.

Qué vais a entregar: un único informe de máximo 4 páginas con tres partes: el mejor modelo (con su umbral y sus costes), la evidencia de la llamada a la API y el informe de recursos y costes, con la prueba de que habéis cerrado todo.

Núcleo y extra. Núcleo: el mejor modelo con su umbral (con vuestros costes), la llamada al servicio, el cierre y borrado de recursos (0 €) y el informe con riesgos y recomendación. Extra: comparar más modelos o ajustes, probar la API con datos imposibles, estimar el beneficio en euros o comprobar un posible sesgo con los datos.

Para trabajar: reto en una página. Para entregar: qué se sube y rúbrica. Para consultar: ficha del reto (qué pide el cliente, ayudas y errores frecuentes) y cada paso explicado.

✅ Antes de cerrar el sprint (Definition of Done)

Archivos subidos en el repositorio del equipo, carpeta `sprint-03/` (marca cada uno cuando lo veas en GitHub): ☐ `informe_modelo.md` · lo creáis a partir de una plantilla
☐ `captura_cierre.png` · lo creáis
☐ `autoevaluacion_nombre.md` · **uno por persona** (la coevaluación va dentro del mismo fichero): plantilla

Total en `sprint-03/`: 2 ficheros del equipo + 1 hoja por persona (un equipo de 3 sube 5). Aparte: S3.5_lab_autogluon.ipynb; los extras solo si los hacéis. La *review* y la *retro* no se suben.

Comprobaciones antes de dar el sprint por cerrado: ☐ Test de conocimientos hecho el mar 27/10
☐ Informe con las tres partes, en 4 páginas o menos
☐ Métrica y umbral justificados en lenguaje de negocio, y variables excluidas por fuga explicadas
☐ Llamada a la API probada, sin credenciales
☐ Recursos cerrados o eliminados, con prueba
☐ Alguien que **no escribió esa parte** ha revisado el entregable con la rúbrica y lo ha anotado en el propio entregable

En casa (cuando puedas)

- Los ejercicios de cada cuaderno que **no** se hacen en clase. Se autocorrigen, y debajo llevan una «Solución de referencia» plegada por si te quedas atascado.
- Si quieres repasar la teoría con calma: apuntes del sprint.

Si te atascas

1. Lee primero la parte «Si os atascáis» de la ficha completa del reto.
2. Pregunta a tu equipo y, después, al docente. Si usas IA, cuenta en el README qué te dijo y qué comprobaste.

Todo el material, por carpetas

Las carpetas están **numeradas en el orden en que las usas**. Cada documento está en `.md`.

Carpeta	Qué hay
`1_Teoria/`	Las presentaciones del sprint y los apuntes para repasar
`2_Practica/`	Las actividades del sprint: dinámicas, hojas de ejercicios, guías y scripts
`3_Reto/`	`1_Trabajar` (reto en una página, plantillas y datos) · `2_Entregar` (qué se sube, rúbrica y autoevaluación) · `3_Consultar` (ficha del reto y cada paso explicado)
`4_Referencia/`	Infografías del sprint

Cómo se trabaja un reto, en todos los sprints: método de trabajo.

Temario oficial de este sprint

Unidad	Conceptos que entran
M6a · Bases de datos SQL y NoSQL (UD 6a.1 a 6a.3)	Tablas, claves, relaciones, normalización básica · DDL/DML y CRUD: CREATE, INSERT, SELECT, UPDATE, DELETE; WHERE, ORDER BY, JOIN, GROUP BY · Índices, transacciones (ACID), copias de seguridad, usuarios y permisos · Buenas prácticas: nombrado, integridad, evitar SELECT , consultas parametrizadas · Tipos: documental, clave-valor, columnar, grafos; comparativa con SQL · CRUD en MongoDB (Compass/Atlas); cuándo elegir cada tipo
M7 · AutoML y MLOps (UD 7.1 a 7.4)	Qué es AutoML; beneficios y límites frente al ML tradicional · Plataformas: SageMaker (Canvas/Autopilot), Vertex AI, Azure AutoML, H2O · Principios de MLOps: ciclo, versionado, despliegue, monitorización, deriva de datos · Cuenta, IAM, costes y buenas prácticas de seguridad; almacenamiento en S3 · Carga y tratamiento del dataset; visualización y calidad de datos · Tipo de problema y métrica objetivo; lanzamiento del experimento · Revisión de modelos candidatos, explicabilidad, validación y evaluación · Despliegue de un endpoint; invocación por API · Seguridad de acceso (IAM, API Gateway/Lambda), monitorización, control de costes

Y ahora: Sprint 4 · Python para IA (martes 3/11).

12 h (4 h teoría · 4 h práctica · 4 h PBL).