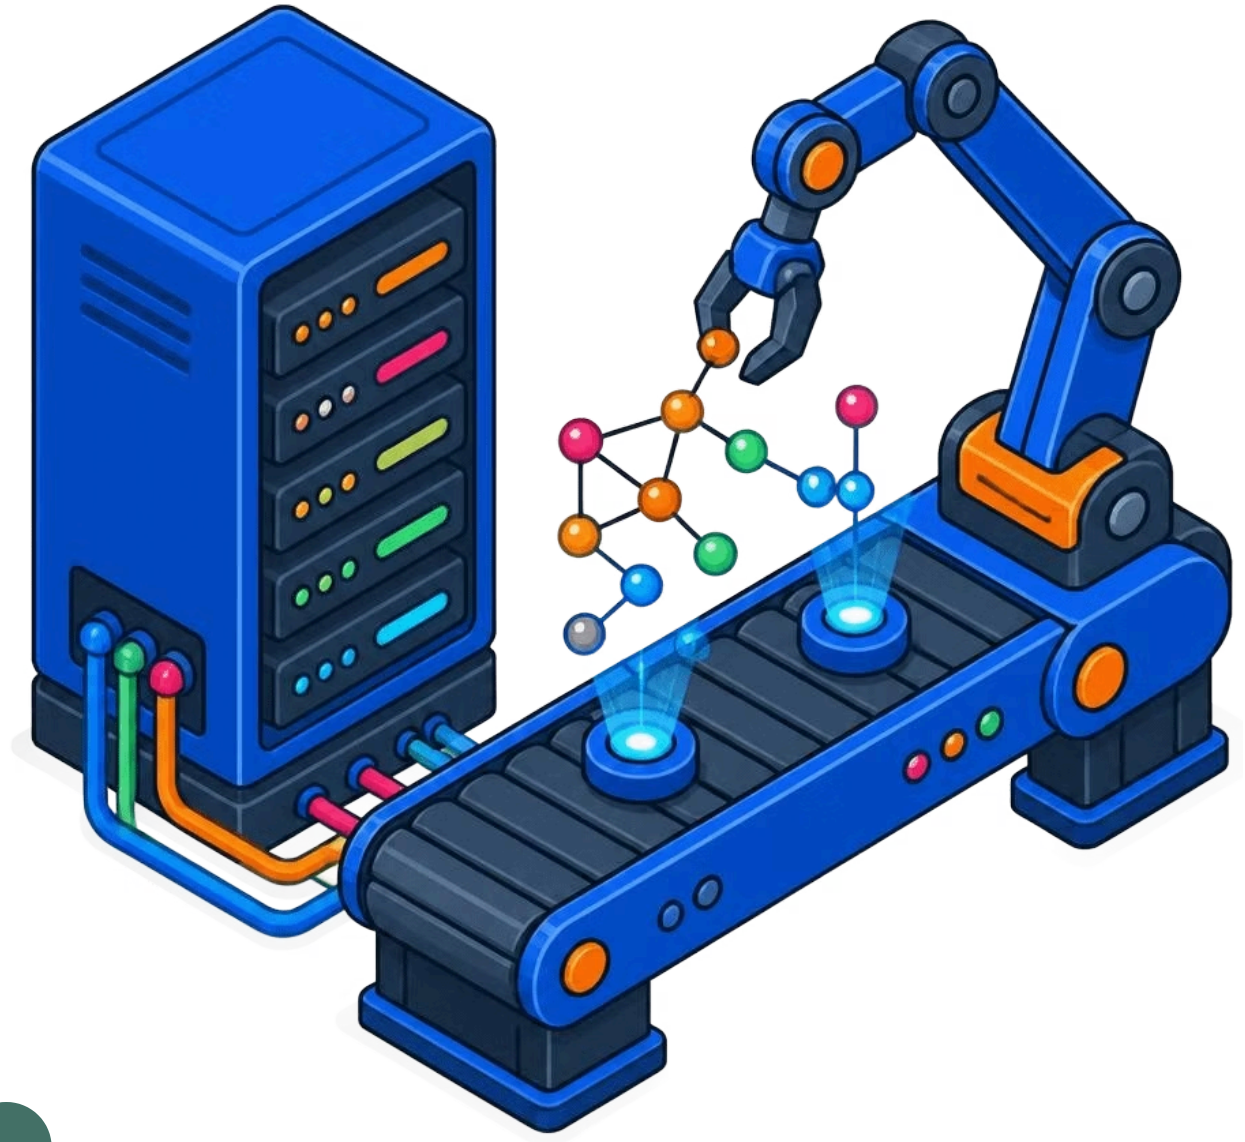
SESIÓN 3.3

AutoML y MLOps

De entrenar a operar en producción

Del pipeline automatizado al ciclo de vida continuo del modelo

Machine Learning Aplicado · Guía de arquitectura y despliegue



CONCEPTO CLAVE

AutoML automatiza el trabajo repetitivo de entrenar modelos

Acelera el entrenamiento sin reemplazar el criterio de quien modela.

Selección y optimización

Explora algoritmos, transforma variables y ajusta hiperparámetros.

Entrada simple, salida evaluada

Recibe datos y una métrica objetivo; entrega un modelo candidato evaluado.

Amplifica el criterio

Libera tiempo para formular el problema y cuidar la calidad del dato de origen.



PIPELINE AUTOMÁTICO

Cómo funciona un flujo AutoML

Cuatro etapas secuenciales desde el dataset crudo hasta el artefacto final listo para inferencia.

01 DATOS

Cargar y etiquetar

Ingesta del dataset y definición de la variable objetivo o target.

02 BÚSQUEDA

Explorar modelos

Prueba paralela de arquitecturas, encoders y configuraciones.

03 RANKING

Validar y ordenar

Evaluación cruzada y ordenación estricta según la métrica elegida.

04 DESPLIEGUE

Exportar o servir

Generación del contenedor o exportación de pesos para producción.

La validación cruzada y el split temporal evitan el sobreajuste durante la búsqueda automatizada.

BALANCE TÉCNICO

AutoML gana en velocidad, pierde en control

La automatización ofrece una compensación directa entre tiempo de entrega y especificidad algorítmica.

BENEFICIOS

Velocidad y democratización

- **Prototipos rápidos:** Obtención de un benchmark funcional en horas en lugar de semanas de pruebas manuales.
- **Línea base fiable:** Reduce errores humanos en el preprocesamiento y establece una métrica mínima exigente.
- **Acceso transversal:** Permite a equipos de producto y analistas validar hipótesis sin requerir ingeniería avanzada.

LÍMITES

Opacidad y restricciones

- **Menor control fino:** Difícil incorporar restricciones matemáticas de negocio o regularizaciones específicas.
- **Interpretabilidad variable:** Tiende a ensamblados complejos que complican auditorías en sectores regulados.
- **ML artesanal superior:** Cuando existe conocimiento profundo del dominio, la ingeniería manual sigue ganando.

ECOSISTEMA

Plataformas AutoML y cómo elegir

Cuatro plataformas

- **Amazon SageMaker:** AutoML dentro del ecosistema AWS.
- **Google Vertex AI:** AutoML y pipelines en Google Cloud.
- **Azure AutoML:** integrado en Azure Machine Learning.
- **H2O:** AutoML de código abierto, usable en local o en la nube.

Tres criterios de decisión

- **Residencia de datos:** entrena donde ya viven las tablas y el almacén analítico.
- **Control:** ¿el equipo necesita inspeccionar el código o busca despliegues en un clic?
- **Coste y lock-in:** exige poder exportar el modelo fuera del proveedor.

OPERACIONES CONTINUAS

MLOps lleva el modelo del cuaderno a producción

CICLO INFINITO

La diferencia entre un experimento en un Jupyter notebook y un servicio en producción fiable.

1. Versionado

Trazabilidad estricta de código, conjuntos de datos y modelos entrenados.

2. Despliegue

Canalización automatizada, tests de integración y empaquetado como API.

3. Monitorización

Observación continua de latencia, calidad de inferencias y degradación.

4. Reentrenamiento

Disparo automático de reentrenamientos ante alertas de calidad o deriva.

> Un modelo en producción no es un entregable cerrado: es un sistema vivo con dependencias activas.

DEGRADACIÓN SILENCIOSA

Los modelos se degradan aunque nadie toque el código

A diferencia del software tradicional, el rendimiento decae cuando el mundo exterior cambia.

DATA DRIFT

Deriva de datos

Cambia la distribución de las variables de entrada $P(X)$.

Ejemplo: nuevos tipos de tarjetas, cambios demográficos o fallos en sensores.

CONCEPT DRIFT

Deriva de concepto

Cambia la relación entre entradas y resultado $P(Y|X)$.

Ejemplo: patrones de fraude tras una regulación o inflación alterando compras.

DETECCIÓN

Señales de alerta

Pruebas estadísticas continuas (KS, PSI) y caída de métricas de negocio.

Respuesta: reentrenamiento planificado con ventanas temporales móviles.

GASTO OCULTO · RIESGO OPERATIVO · MITIGACIÓN

Costes y riesgos: lo que no sale en la demo

Aspectos operativos que multiplican la factura y amenazan la estabilidad del sistema.

Dimensión	Impacto real en producción	Estrategia de mitigación
Cómputo y hosting	Endpoints activos 24/7 con GPU/CPU reservada y búsqueda AutoML descontrolada.	Límites de presupuesto duros, apagado automático y despliegue serverless.
Sesgos y gobernanza	Falta de trazabilidad sobre qué datos entrenaron qué pesos y modelos huérfanos.	Registro centralizado de modelos, fichas técnicas (Model Cards) y dueño explícito.
Dependencia técnica	Formatos propietarios de serialización que impiden migrar modelos entre nubes.	Uso de estándares abiertos como ONNX, MLflow y contenedores Docker portables.

La mayoría de proyectos de machine learning fallan por descontrol de costes o falta de gobernanza, no por precisión técnica.

TRABAJO APLICADO

Reto: Primer modelo en producción

Aplica lo aprendido implementando el ciclo completo en un entorno controlado.

1

Entrenar con AutoML

Carga el dataset de la práctica, fija la métrica objetivo y genera tu línea base óptima.

2

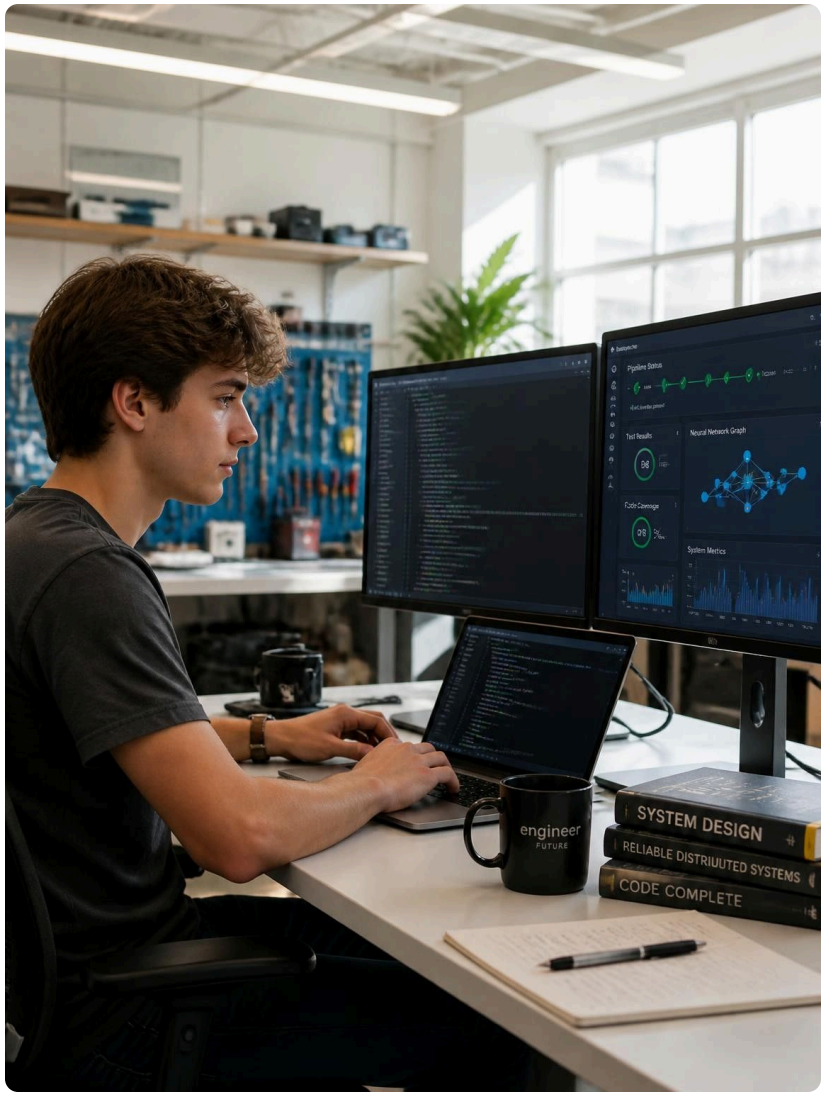
Desplegar y versionar

Publica el artefacto como API REST funcional e inscríbelo en el registro con versión v1.0.

3

Plan de vida operativa

Define métricas clave de monitorización y los umbrales que activarán el reentrenamiento.



El objetivo es verificar el flujo de extremo a extremo, no maximizar la última décima de F1-Score.