IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Contrastes y causalidad

¿Casualidad o diferencia real?

Sprint 5 · S05_05 · cuaderno completo para casa

CONTRASTE DE HIPÓTESIS

Un juicio con presunción de inocencia

1 · H0

La hipótesis nula: **«no hay diferencia»**. Es el acusado inocente.

2 · p-valor

La probabilidad de ver una diferencia **así de grande si H0 fuera cierta**.

3 · Decisión

Si **p < 0,05**, rechazamos H0: es poco probable que sea casualidad.

Ojo: el p-valor NO es la probabilidad de que H0 sea cierta.

Y «no rechazo H0» **no** demuestra que no haya diferencia: quizá faltaban datos.

T DE STUDENT · EJERCICIO 1

Comparar las medias de dos grupos

Ocupación (%)	Datos	Media
Festivos (6 días)	82, 90, 78, 86, 84, 80	83,3
Normales (8 días)	72, 64, 76, 68, 80, 66, 74, 70	71,3

```
stats.ttest_ind(festivos, normales, equal_var=False)   # p ≈ 0.0005
```

12,1

puntos de diferencia

festivos – normales

0,0005

p-valor

menor que 0,05: **rechazamos H0**

TAMAÑO DEL EFECTO · EJERCICIO 2

Significativo no es lo mismo que importante

d de Cohen = (media A – media B) / desviación combinada

0,2	0,5	0,8
pequeño	medio	grande

✓ En el ejemplo de festivos y días normales, d ≈ 2,4: un efecto muy grande.

El **p-valor** dice si es casualidad o no; el **tamaño del efecto** dice cuánto importa. Con 6.000 reservas una diferencia minúscula puede dar p = 0,001 y no valer nada en la práctica. **Mira siempre las dos cosas.**

CHI-CUADRADO · EJERCICIO 3

¿Están relacionadas dos categorías?

Ejemplo A · cancelaciones por canal

Canal	Cancela	No cancela
Web	45	55
Directo	25	75

Ejemplo B · otra muestra

Canal	Cancela	No cancela
Web	30	70
Directo	20	80

```
p = stats.chi2_contingency(tabla)[1]
```

A · p = 0,005

Menor que 0,05: **el canal influye** en cancelar.

B · p = 0,14

No rechazamos H0, pero eso **no prueba** que no haya relación: quizá faltan datos.

CORRELACIÓN · EJERCICIO 4

El coeficiente r va de −1 a +1

−1

Inversa perfecta

Una sube y la otra baja siempre.

0

Ninguna relación lineal

Una no dice nada de la otra.

+1

Directa perfecta

Las dos suben y bajan juntas.

	temperatura	ocupación
temperatura	1	−1
ocupación	−1	1

```
df.corr()          # matriz de correlaciones
```

Los 4 días de álgebra lineal (15 a 30 °C, ocupación 90 a 60) están sobre una recta que baja: r = −1. La diagonal siempre es 1.

CORRELACIÓN NO ES CAUSALIDAD

La variable de confusión

El mes influye a la vez en las dos

Una variable que influye en las dos y crea una falsa relación se llama **variable de confusión**.

Mes → temperatura

En verano hace más calor.

Mes → ocupación

El invierno es temporada alta.

Resultado: más calor, menos ocupación. Pero «enfriar el hotel» no vendería más.

CONTROLAR LA CONFUSIÓN · EJERCICIO 5

Añadir el mes al modelo

```
smf.ols("ocupacion_pct ~ temperatura_c + festivo + C(mes)", data=df).fit()
```

Modelo simple

La temperatura parece **frenar** la ocupación.

Con C(mes)

El efecto de la temperatura **se diluye**.

El festivo

Su efecto **resiste**.

Con datos observacionales no se demuestra causalidad: se descartan explicaciones simples. Para demostrar causa hace falta un experimento.

UN VISTAZO BAYESIANO · EJERCICIO 6

Creencia inicial + datos = creencia nueva

Web: **3 canceladas de 10**. Directo: **1 cancelada de 10**. La creencia actualizada de una tasa es una distribución **Beta(1 + c, 1 + n − c)**.

```
post_web    = rng.beta(1 + 3, 1 + 10 - 3, 10000)
post_directo = rng.beta(1 + 1, 1 + 10 - 1, 10000)
(post_web > post_directo).mean()      # ≈ 0.84
```

«Hay un 84 % de probabilidad de que la web cancele más que el directo»

Una frase que entiende un cliente

A diferencia del p-valor, dice directamente **cuánta probabilidad** hay.

QUÉ DECIR AL CLIENTE

Tres preguntas antes de afirmar algo

¿Es casualidad?

Mira el p-valor y el intervalo.

¿Importa?

Mira el tamaño del efecto.

¿Es la causa?

Busca variables de confusión.

Mini-reto para casa: ¿ocupación de invierno frente a verano?