IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Dos ejemplos de modelos supervisados

Regresión (precio por noche) y clasificación (cancelación de la reserva): hipótesis, análisis en Python y evaluación

Turisdata · 6 000 reservas hoteleras · scikit-learn

EL MÉTODO

Dos problemas, dos tipos de métrica

	A · Regresión	B · Clasificación
Pregunta	¿Cuánto cuesta la noche?	¿Cancelará la reserva?
Se predice	Un número: **precio_noche** (€)	Una clase: **cancelada** (sí / no)
Modelo	Regresión lineal	Regresión logística
Evaluación	**MSE, RMSE, MAE, R^2**	**Matriz de confusión**, accuracy, precision, recall, F1, AUC
Datos	6 000 reservas · 4 800 para entrenar · 1 200 para evaluar	Mismas reservas · partición estratificada · semilla 42

ANTES DE EMPEZAR

Vocabulario básico

Término	En palabras sencillas
Variable objetivo	Lo que queremos predecir: **precio_noche** (A) o **cancelada** (B)
Variables predictoras	Los datos que usa el modelo para predecir: tipo de habitación, antelación, depósito…
Entrenamiento / prueba	El modelo aprende con el 80 % de las reservas y se examina con el 20 % que no ha visto
Variable dummy (0/1)	Una columna por categoría: vale 1 si la reserva es de ese tipo y 0 si no
Coeficiente	Cuánto cambia la predicción al cambiar esa variable, con las demás fijas
Referencia (baseline)	Modelo ingenuo con el que comparar: la media (A) o la clase más frecuente (B)
Residuo	Error de una reserva: precio real – precio predicho

EJEMPLO A · REGRESIÓN

Hipótesis: el precio depende del tipo y de la temporada

H_1 El precio sube con la categoría: una **suite** cuesta más que una habitación estándar.

H_2 En **temporada alta** (ene–mar, jul–ago, dic) el precio sube respecto a la baja.

H_0 Si tipo y temporada no importaran, lo mejor sería predecir siempre el **precio medio de las 6 000 reservas: 102.87 €**.

Medias de las 6 000 reservas	€/noche
Estándar	78.63
Superior	107.06
Familiar	123.85
Suite	179.20
Temporada baja	91.53
Temporada alta	113.99

H_1 es lo que creemos que ocurre; **H_0** (hipótesis nula) es lo que ocurriría si estuviéramos equivocados. El modelo tiene que **batir a H_0**. Temporada alta = enero–marzo, julio–agosto y diciembre.

EJEMPLO A · REGRESIÓN

Análisis con Python

```
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split

# 1 · variables: tipo de habitación + temporada
alta = [1, 2, 3, 7, 8, 12]
X = pd.get_dummies(df[["tipo_habitacion"]], drop_first=True)
X["temporada_alta"] = df["mes_llegada"].isin(alta).astype(int)
y = df["precio_noche"]

# 2 · partición 80 / 20 con semilla fija
X_ent, X_test, y_ent, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42)

# 3 · entrenar y predecir sobre datos no vistos
modelo = LinearRegression().fit(X_ent, y_ent)
pred = modelo.predict(X_test)
```

1. **get_dummies**: el tipo de habitación pasa a columnas 0/1 (la estándar es la referencia).
2. **4 800** reservas para entrenar y **1 200** para evaluar; **random_state** repite la partición.
3. **fit** calcula los coeficientes; **predict** da el precio de las reservas de prueba.

EJEMPLO A · REGRESIÓN

Lo que ha aprendido el modelo

Término	Coeficiente	Lectura
Base (estándar, temporada baja)	**67.27 €**	Precio de partida: el de la categoría de **referencia**
tipo = familiar	**+44.96 €**	Una familiar cuesta ~45 € más que una estándar
tipo = superior	**+28.40 €**	Una superior cuesta ~28 € más
tipo = suite	**+101.18 €**	**H_1 confirmada**: la suite es la más cara con diferencia
temporada alta	**+22.41 €**	**H_2 confirmada**: la temporada alta añade ~22 € por noche

precio ≈ 67.27 + 44.96·familiar + 28.40·superior + 101.18·suite + 22.41·temporada_alta

Cómo leerlo: cada coeficiente son los euros que se suman al precio al pasar de la referencia a esa categoría; la variable vale 1 si la reserva es de ese tipo y 0 si no.

EJEMPLO A · EVALUACIÓN (1/4)

Primero, una referencia: ¿y si no usáramos el modelo?

102.87 €	Es el **precio medio por noche** de las 6 000 reservas: se suman todos los precios y se divide entre 6 000.
Referencia	Un «modelo» sin inteligencia: **predecir siempre el precio medio** (102.59 €, la media de las 4 800 reservas de entrenamiento; casi igual), sea una suite o una estándar.
25.56 €	Con esa referencia nos equivocamos de media **25.56 €** por reserva de prueba (MAE) y el **R^2 es ≈ 0**: no explica nada.
Objetivo	El modelo solo es útil si **falla bastante menos** que la referencia.

EJEMPLO A · EVALUACIÓN (2/4)

Cómo se calculan los errores: 5 reservas de prueba

Reserva	Precio real	Predicho	Error (real – predicho)	Error sin signo	Error al cuadrado	Error sin signo de la referencia
Familiar · alta	143.19 €	134.65 €	+8.54	8.54	72.93	40.60
Superior · baja	91.73 €	95.67 €	−3.94	3.94	15.52	10.86
Suite · baja	160.12 €	168.45 €	−8.33	8.33	69.39	57.53
Estándar · alta	88.85 €	89.68 €	−0.83	0.83	0.69	13.74
Superior · alta	121.45 €	118.08 €	+3.37	3.37	11.36	18.86
Media de las 5				**5.00 = MAE**	**33.98 = MSE**	**28.32**

El cuadrado quita el signo y hace pesar más los errores grandes (MSE, en €²); su raíz, el **RMSE = √33.98 = 5.83 €**, vuelve a euros. El modelo (5.00) falla mucho menos que la referencia (28.32).

EJEMPLO A · EVALUACIÓN (3/4)

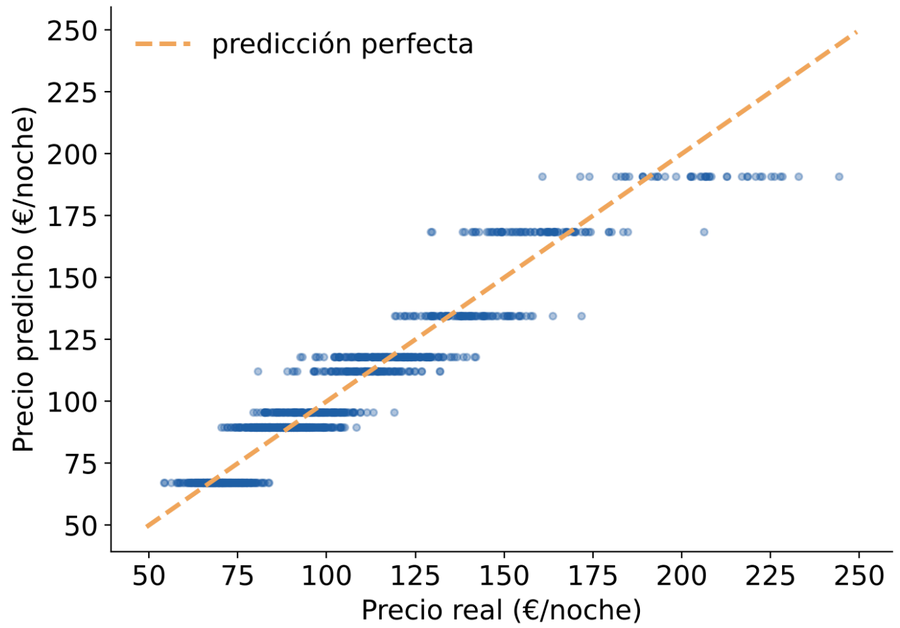
Lo mismo con las 1 200 reservas de prueba

Métrica	Cómo se calcula y cómo leerla	Modelo	Referencia (precio medio)
MSE	Media de los errores al cuadrado (€²) · **cuanto más bajo, mejor**	**94.16**	1 110.75
RMSE	Raíz cuadrada del MSE: error típico en euros · **más bajo, mejor**	**9.70 €**	33.33 €
MAE	Media de los errores sin signo: cuánto falla de media · **más bajo, mejor**	**7.24 €**	25.56 €
R^2	1 − MSE modelo / MSE referencia = 1 − 94.16 / 1 110.75 · **1 = perfecto, 0 = no mejora a la referencia**	**0.915**	≈ 0 (−0.002)

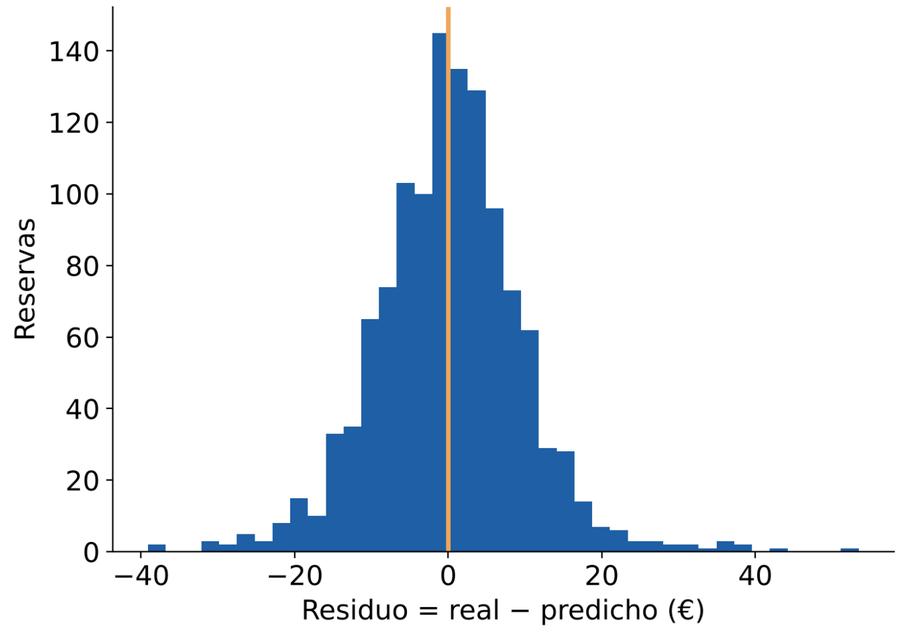
Lectura: el modelo falla de media **7.24 €** por noche; la referencia, **25.56 €**: **3.5 veces menos error**. Explica el **91.5 %** de cómo varían los precios y deja sin explicar el 8.5 %.

EJEMPLO A · EVALUACIÓN (4/4)

Mirar los errores, no solo los números



Cómo leerlo: cada punto es una reserva de prueba. Eje horizontal: precio real; eje vertical: precio predicho. Sobre la **línea naranja** el modelo acierta exacto; cuanto más pegados a ella, mejor.



Cómo leerlo: residuo = real − predicho. Cada barra cuenta cuántas reservas tienen ese error. **Centrado en 0**: no falla siempre por exceso ni por defecto; casi todos entre ±20 €.

EJEMPLO B · CLASIFICACIÓN

Hipótesis: cancela más quien reserva con mucha antelación y sin depósito

H_1	Cuanta más **antelación** (días entre reservar y llegar), más probabilidad de cancelar.
H_2	Un **depósito** o una tarifa **no reembolsable** reducen la cancelación.
H_0	Sin relación, lo mejor sería decir siempre «no cancela» (54.1 % de aciertos).

% de reservas canceladas	%
Sin depósito	54.0
Depósito parcial	40.9
Depósito total	26.4
≤ 30 días de antelación	27.8
31–90 días	39.4
91–180 días	54.8
> 180 días	76.9

Tasa de cancelación = reservas canceladas / reservas totales de ese grupo (global: 45.9 %). **H_0**: no hay relación; **modelo tonto**: dice siempre «no cancela».

EJEMPLO B · CLASIFICACIÓN

Análisis con Python

```
# variables numéricas (num) y categóricas (cat)
prep = ColumnTransformer([
    ("num", make_pipeline(SimpleImputer(strategy="median"),
                          StandardScaler()), num),
    ("cat", make_pipeline(SimpleImputer(strategy="most_frequent"),
                          OneHotEncoder(handle_unknown="ignore")), cat)])

modelo = make_pipeline(prep, LogisticRegression(max_iter=1000))

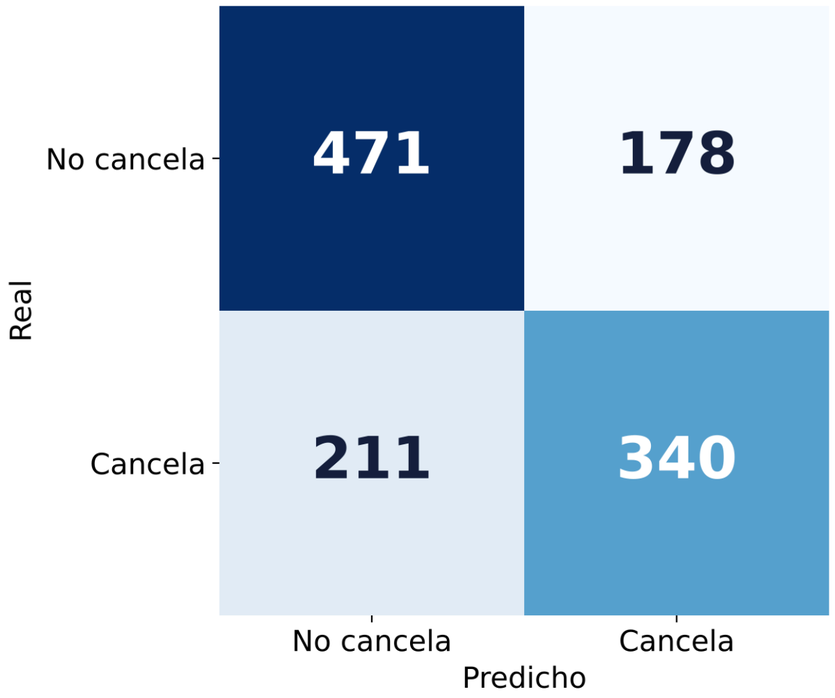
X_ent, X_test, y_ent, y_test = train_test_split(
    X, y, test_size=0.2, stratify=y, random_state=42)

modelo.fit(X_ent, y_ent)
pred = modelo.predict(X_test) # clase 0 / 1
prob = modelo.predict_proba(X_test)[:, 1] # probabilidad
```

1. **9** variables numéricas se escalan y **6** categóricas pasan a 0/1.
2. **stratify** mantiene el 45.9 % de cancelaciones en entrenamiento y prueba.
3. **predict_proba** da una probabilidad; con **umbral** 0.5 (a partir de ahí, «cancela») sale la clase.
4. **Pipeline**: encadena preprocesado y modelo para tratar igual entrenamiento y prueba.

EJEMPLO B · EVALUACIÓN

Matriz de confusión



Celda	Nº	Significa
VN	471	**Verdadero negativo**: no cancela y lo acertamos
VP	340	**Verdadero positivo**: cancela y lo detectamos
FP	178	**Falso positivo** (falsa alarma): avisamos de una cancelación que no llega
FN	211	**Falso negativo**: cancelación que no vimos venir (el error más caro)

Cómo leerla: filas = lo que pasó de verdad; columnas = lo que predijo el modelo; positivo = «cancela». Suma: 471 + 340 + 178 + 211 = **1 200** reservas; los aciertos están en la diagonal.

EJEMPLO B · EVALUACIÓN

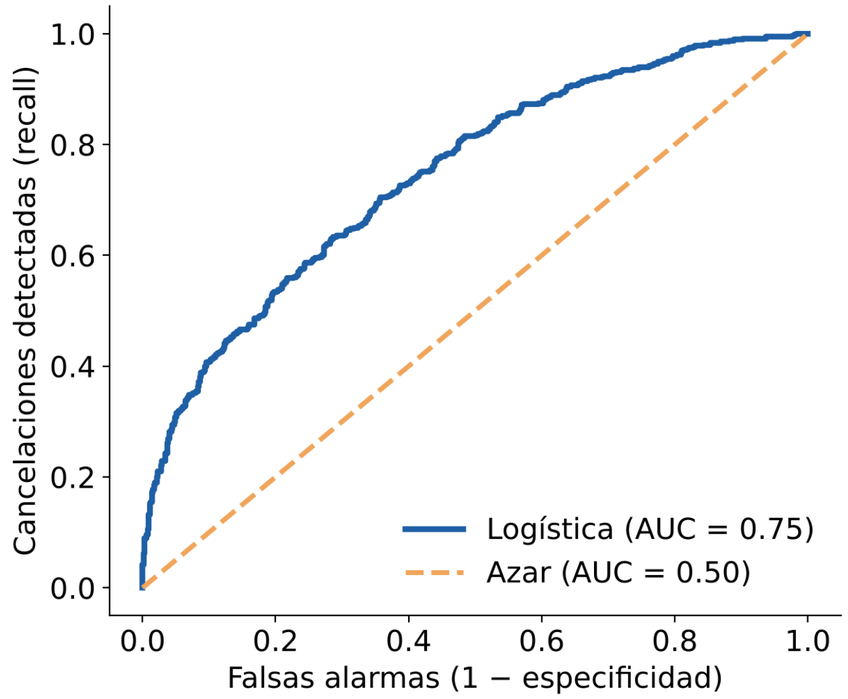
De la matriz a las métricas

Métrica	Cálculo con la matriz	Valor	Responde a…
Accuracy	(VP + VN) / total = 811 / 1 200	**0.676**	¿Qué proporción acierta?
Precision (precisión)	VP / (VP + FP) = 340 / 518	**0.656**	Si avisa de cancelación, ¿cuántas veces acierta?
Recall (sensibilidad)	VP / (VP + FN) = 340 / 551	**0.617**	De las cancelaciones reales, ¿cuántas detecta?
F1	2·P·R / (P + R)	**0.636**	Equilibrio entre precision y recall
AUC	Área bajo la curva ROC	**0.746**	¿Ordena bien cancelaciones frente a no cancelaciones? (0.5 = azar)

VP = 340 · VN = 471 · FP = 178 · FN = 211. Todas valen 0–1: **cuanto más cerca de 1, mejor**. Referencia, el modelo «tonto» (siempre «no cancela»): accuracy **0.541** y recall **0**.

EJEMPLO B · EVALUACIÓN

Curva ROC y efecto de cada variable



Variable	Odds ratio	Lectura
Antelación (+1 desv. típica)	**× 2.12**	Las odds de cancelar se **duplican**: H_1 confirmada
Depósito total	**× 0.44**	Reduce las odds a menos de la mitad
Tarifa no reembolsable	**× 0.60**	Reduce las odds un 40 %: H_2 confirmada

Cómo leer la curva: eje horizontal = falsas alarmas; eje vertical = cancelaciones detectadas (recall); cada punto es un umbral distinto. Cuanto más cerca de la esquina superior izquierda, mejor; la diagonal es el azar (AUC 0.50).

Odds = probabilidad de cancelar / probabilidad de no cancelar. El **odds ratio** dice por cuánto se multiplican al cambiar la variable: ×2 = el doble, ×0.5 = la mitad (resto de variables fijas).

PARA COMPARAR

¿Qué métrica para qué problema?

Problema	Qué predice	Herramientas	Cuándo fiarse
Regresión	Un número (€, kg, días…)	MSE · RMSE · MAE · R^2	MAE pequeño frente a la escala y R^2 muy por encima de la referencia (0)
Clasificación	Una categoría (sí / no…)	Matriz de confusión · accuracy · precision · recall · F1 · AUC	Mejor que el modelo tonto y que el azar, y con el error que más cuesta controlado
Siempre	—	Partición entrenamiento / prueba	Evaluar con datos que el modelo no ha visto y comparar con una referencia

MSE, RMSE y MAE son errores: cuanto más **bajos**, mejor. **R^2, accuracy, precision, recall, F1 y AUC**: cuanto más cerca de **1**, mejor.

PARA LLEVARSE

Conclusiones

	A · Regresión (precio)	B · Clasificación (cancelación)
¿Se cumple la hipótesis?	**Sí.** La suite cuesta 101.18 € más que la estándar y la temporada alta suma 22.41 € por noche.	**Sí.** A más antelación, más cancelaciones (odds × 2.12); con depósito total o tarifa no reembolsable, menos (× 0.44 y × 0.60).
¿Qué tal funciona el modelo?	Se equivoca **7.24 €** de media; la referencia (predecir siempre el precio medio), 25.56 €. Explica el **91.5 %** de la variación (R^2).	Acierta el **67.6 %** (la referencia, 54.1 %) y detecta el **62 %** de las cancelaciones. AUC = 0.75 (el azar, 0.50).
¿Para qué sirve?	Estimar el precio de una noche con un error de unos 7 €.	Señalar reservas con riesgo de cancelar, sabiendo que **211** se escapan y hay **178** falsas alarmas.
Cuidado con…	Solo usa tipo y temporada, y muestra una **asociación** en estos datos, no una causa.	Es un modelo **mejorable** (aciertos moderados) y también muestra asociación, no causalidad.