

Sprint 5 · Matemáticas y estadística en código

PREGUNTA GUÍA: ¿PODEMOS DEMOSTRAR CON CÓDIGO LO QUE VIMOS EN TEORÍA?

29/10 – 3/11

13 H TOTALES

Bienvenidos al **Sprint 5**. En este sprint uniremos matemáticas, estadística y programación para responder a preguntas reales de negocio mediante datos y modelos. Catorce horas de formación repartidas entre teoría, seis prácticas guiadas con autocorrección y un reto PBL centrado en modelar la ocupación de nuestro cliente **TurisData Canarias** a partir de series temporales sintéticas.

4 h Teoría
NumPy, álgebra lineal, descenso del gradiente, estadística inferencial y contrastes

6 h Práctica
Seis cuadernos autocorrije con assert (incluye 1 h de CRUD desde Python)

3 h Reto PBL
«¿La ocupación depende de esto?»: SQLite, regresión lineal desde cero y statsmodels

¿Qué aprenderás?

- 1

Datos numéricos con NumPy
Manejo de arrays, vectorización, *broadcasting* y operaciones fundamentales de álgebra lineal.
- 2

Entrenar un modelo desde cero
Entender el gradiente y programar la regresión lineal con descenso del gradiente sin librerías externas.
- 3

Estadística con Python
Describir datos, usar distribuciones de probabilidad, simulación (Monte Carlo) y construcción de intervalos de confianza.
- 4

Contrastar hipótesis
Interpretar p-valores, tamaños de efecto y comprender a fondo la diferencia entre **correlación** y **causalidad**.
- 5

CRUD desde Python
Operaciones CRUD sobre SQLite y MongoDB (con mongomock) y poblar una base de datos relacional.

⚠ Requisitos previos: Haber hecho el Sprint 4 (Python básico, funciones, ficheros). Colab o Jupyter con Python 3.11 (numpy, pandas, matplotlib, scipy, statsmodels, scikit-learn, sqlite3, mongomock). Los datos son sintéticos y se descargan solos.

Prácticas (6 h)

Cuaderno	Tema	Tiempo	Colab
S05_01_numpy	NumPy: arrays, máscaras, vectorización, broadcasting, semillas	45 min	Abrir
S05_02_algebra_lineal	Vectores, matrices, producto matricial, sistemas de ecuaciones, ecuación normal	45 min	Abrir
S05_03_gradiente_regresion	Derivada, MSE, descenso del gradiente y regresión lineal desde cero	90 min	Abrir
S05_04_estadistica_descriptiva_i c	Estadística descriptiva, distribuciones, Monte Carlo e intervalos de confianza	60 min	Abrir
S05_05_contrastes_causalidad	Contrastes de hipótesis, correlación frente a causalidad, statsmodels, Bayes	60 min	Abrir
S05_06_crud_python	CRUD desde Python: sqlite3, pymongo/mongomock (M6b)	60 min	Abrir

Ficha del reto · «¿La ocupación depende de esto?»

TURISDATA CANARIAS

RETO PBL · 3 H

TurisData Canarias quiere planificar personal y precios de su alojamiento de referencia. Le han dicho que «cuando hace calor se llena menos» y que «los festivos llenan». Antes de tomar decisiones quiere saber **cuánto** cambia la ocupación diaria con la temperatura y con los festivos, y **con cuánta seguridad** podemos decirlo. Tenéis su serie diaria de tres años (ocupacion_diaria.csv). Los datos son sintéticos.

Qué tenéis que entregar

Un **cuaderno** (S05_07_reto_ocupacion, con la plantilla) y una **base de datos** SQLite entregados y defendidos en la review de 5 minutos:

1 · Base de datos SQLite

Serie diaria cargada en turisdata_reto.db (tabla ocupacion_diaria con 1096 filas) y leída desde Python con SQL.

2 · Regresión desde cero

Regresión lineal implementada con descenso del gradiente propio (modelo simple y modelo con control de estacionalidad).

3 · Comparación y estadística

Comparación con statsmodels, contraste de hipótesis, intervalos de confianza y p-valores interpretados.


4 · Respuesta al cliente

Texto de máximo 150 palabras: hallazgos cuantitativos, recomendación accionable y límites/lo que no se puede afirmar.

Restricciones del reto

- **Tiempo**
3 h de reto dentro del sprint.
- **Descenso del gradiente**
Lo escribís vosotros; sin LinearRegression en la implementación (la librería solo para contrastar).
- **Datos sintéticos**
No generalicéis conclusiones a otros alojamientos ni al turismo real.
- **Ejecución limpia**
Semillas fijas y el cuaderno debe ejecutarse de arriba abajo sin errores.

Pasos sugeridos (3 h de reto)



Qué se enseña en la review

Una demostración ágil de **5 minutos** ante el docente y el grupo:

- **1. Pregunta y base de datos:** formulación del problema y verificación de los datos en SQLite.
- **2. Convergencia del gradiente:** cómo converge vuestro descenso y comparación con statsmodels.
- **3. Resultado clave e incertidumbre:** estimaciones numéricas con su intervalo de confianza.
- **4. Correlación frente a causalidad:** cómo habéis distinguido lo que los datos muestran de lo que no demuestran.
- **5. Recomendación al cliente:** propuesta accionable y límites claros del análisis.

Criterios de evaluación

RÚBRICA DEL CURSO

0 A 4 POR CRITERIO

Cada entregable se evalúa de **0 a 4 puntos** en los cuatro criterios de la rúbrica de retos del curso. A continuación se detallan los aspectos específicos evaluados en el Reto PBL del Sprint 5 («¿La ocupación depende de esto?»):

Criterio	Qué se mirará en este reto
Corrección técnica	El gradiente converge y coincide con statsmodels; los contrastes e intervalos están bien calculados; se controla la estacionalidad.
Reproducibilidad	Reiniciar y ejecutar todo funciona; se crea o entrega la base; se indican versiones y semilla.
Análisis y comunicación al cliente	La respuesta se entiende sin ser técnico, incluye cifras con su incertidumbre y una recomendación accionable con límites explicados.
IA responsable	Se distingue correlación y causalidad, se explican los límites (datos sintéticos, un solo alojamiento) y se propone una cautela concreta sobre el uso del modelo.

Claves para alcanzar la máxima puntuación

La evaluación valora tanto el rigor matemático y de programación como la honestidad metodológica y la capacidad de comunicar incertidumbre al cliente de negocio:



Gradiente propio validado

Implementad el descenso del gradiente paso a paso y mostrad la curva de pérdida cotejando los coeficientes finales con statsmodels.



Correlación vs. causalidad

Explicad con claridad qué relaciones observadas implican causalidad o mera correlación, y recordad el carácter sintético de los datos.



Reproducibilidad total

Fijad semillas y comprobad que el cuaderno se ejecute de arriba abajo sin errores y la base SQLite contenga exactamente las 1096 filas.



Respuesta al cliente (≤ 150 palabras)

Sintetizad hallazgos con intervalos de confianza y ofreced recomendaciones directas sin ocultar los supuestos ni las limitaciones del modelo.

Definition of Done y Recursos

CHECKLIST DOD (7 PUNTOS)

SPRINT 5

RECURSOS OFICIALES

Antes de entregar el Sprint 5 y realizar la review de 5 minutos, verificad que vuestro cuaderno y base de datos cumplan todos los requisitos de la Definition of Done. Asimismo, disponéis de la documentación y recursos recomendados para apoyar el desarrollo de las prácticas y el reto.

Checklist Definition of Done (7 puntos)

- ☐ Todos los puntos de control (assert) del cuaderno pasan.
- ☐ `turisdata_reto.db` existe y contiene la tabla `ocupacion_diaria` con 1096 filas.
- ☐ La regresión desde cero coincide con `statsmodels` (tolerancia razonable) y hay una curva de aprendizaje.
- ☐ Hay al menos un p-valor, un intervalo de confianza y una medida del tamaño del efecto interpretados con palabras.
- ☐ La respuesta al cliente (≤ 150 palabras) incluye recomendación y límites.
- ☐ Gráficos con título y ejes en español.
- ☐ Reiniciar y ejecutar todo funciona sin errores; alguien del grupo ha revisado el trabajo con la rúbrica.

Plantilla del cuaderno

El reto dispone de un cuaderno base preparado con la estructura de partida y los puntos de verificación:

- Cuaderno `S05_07`

[Abrir plantilla S05_07 reto ocupacion en Colab](#)

- Aviso importante

Los datos son sintéticos: sirven para practicar análisis riguroso, no para extraer conclusiones reales del sector turístico canario.

Recursos recomendados

Documentación oficial y materiales de apoyo recomendados para profundizar en los conceptos del sprint:

1

Documentación de NumPy

numpy.org/doc/stable/user/absolute_beginners.html · Guía oficial de NumPy para principiantes (arrays, operaciones vectorizadas e indexación).

2

Documentación de SciPy Stats

docs.scipy.org/doc/scipy/reference/stats.html · Referencia de distribuciones estadísticas, pruebas de hipótesis y funciones probabilísticas en SciPy.

3

Documentación de statsmodels

statsmodels.org/stable/index.html · Modelado estadístico en Python, ajuste por MCO (OLS) e informes diagnósticos completos.

4

Módulo `sqlite3` de Python

docs.python.org/es/3/library/sqlite3.html · Guía de la biblioteca estándar de Python para interactuar con bases de datos relacionales SQLite.

5

Videos «Essence of linear algebra»

3blue1brown.com/topics/linear-algebra · Serie visual de 3Blue1Brown (con subtítulos) sobre la intuición geométrica del álgebra lineal.