Apuntes del Sprint 5 · Matemáticas y estadística en código: NumPy, gradiente, contrastes y CRUD

Las diapositivas del Sprint 5 mezclan matemáticas, estadística y Python en muy poco espacio. Estos apuntes **explican qué ocurre en cada paso**, con ejemplos pequeños cuyo resultado puedes comprobar a mano. Se apoyan en los apuntes del Sprint 2 ([apuntes_matematicas_y_estadistica.ipynb]): allí está **qué es** un vector, una derivada o un intervalo; aquí **cómo se programa**. Si algo de matemáticas te suena raro, vuelve a la sección correspondiente del Sprint 2 (la tabla del final te dice cuál).

0. De qué va el sprint (en 1 minuto)

Presentación	Idea central	Cuadernos
S05.1 NumPy y álgebra lineal	Operar con **muchos números a la vez**, sin bucles	S05_01, S05_02
S05.2 Gradiente y regresión desde cero	**Así aprende un modelo**: mide el error y da un paso cuesta abajo	S05_03
S05.3 Estadística y CRUD	Responder al cliente **con números, no con intuiciones**	S05_04, S05_05, S05_06

El reto: con la serie de ocupación de TurisData, cargar los datos en una base, mirar los datos, programar una regresión desde cero, compararla con una librería, **medir cuánta confianza merece el resultado** y responder al cliente en 150 palabras.

DÍA 1 · NumPy y álgebra lineal

1. Por qué NumPy

Los modelos de IA **no son más que muchas operaciones con vectores y matrices**. NumPy las hace **sin bucles y a gran velocidad**.

Un **array** es una **tabla de números del mismo tipo**. Tiene tres «datos de identidad»:

Atributo	Qué dice	Ejemplo
`shape`	Forma: (filas, columnas)	`(1096, 4)`
`dtype`	Tipo de los números	`float64`
`ndim`	Número de dimensiones	`2`

En el sprint se usa `ocupacion_diaria.csv`: **1.096 días** (2023-2025) con ocupación, temperatura, festivo y precio medio. Al cargarlo, `tabla.shape` da `(1096, 4)`: **filas = días, columnas = variables**.

2. Seleccionar sin bucles

Con una mini-tabla (3 filas × 2 columnas):

```
import numpy as np
tabla = np.array([[10, 20],
                  [30, 40],
                  [50, 60]])

tabla[1, 1]       # 40          → un valor (fila 1, columna 1; se empieza a contar en 0)
tabla[:, 0]       # [10 30 50]  → la columna 0 entera (":" significa "todo")
tabla[0:2, :1]    # [[10],[30]] → filas 0 y 1, solo la primera columna
```

La regla: `tabla[filas, columnas]`. `a:b` va **de a hasta b, sin incluir b**.

Máscaras: filtrar con condiciones

Una comparación devuelve **un True/False por cada elemento**. Usada como índice, **deja solo los True**:

```
ocupacion = np.array([60, 80, 70, 90, 50])
festivo   = np.array([0, 1, 0, 1, 0])
precio    = np.array([100, 130, 110, 140, 90])

ocupacion[festivo == 1].mean()                    # (80 + 90) / 2 = 85.0
ocupacion[(festivo == 0) & (precio > 95)]         # [60 70]
```

- `&` = **y**, `|` = **o**, `~` = **no**. Cada condición **entre paréntesis**.
- Segunda línea: días no festivos (60, 70, 50) **y** con precio > 95 (el de 50 tiene precio 90 → fuera) → `[60 70]`.

3. Vectorizar y broadcasting

Vectorizar = operar **con todo el array a la vez**, sin escribir un `for`.

```
ingreso_diario = ocupacion / 100 * 120 * precio     # 120 habitaciones, una cuenta por cada día
```

La primera posición sería 60/100 × 120 × 100 = 7.200 €. NumPy hace las 5 (o las 1.096) cuentas de una vez.

Estandarizar (z-score)

Pasa una variable a **«cuántas desviaciones típicas se aleja de la media»** (media 0, desviación 1):

```
ocupacion_z = (ocupacion - ocupacion.mean()) / ocupacion.std()
```

Con `[60, 80, 70, 90, 50]`: media = 70, desviación típica = 14,14. El valor 90 → (90 − 70) / 14,14 = **+1,41**; el 50 → **−1,41**; el 70 → **0**. Sirve para comparar variables con unidades distintas (ºC, %, €) y, como verás, **para que el descenso del gradiente funcione bien**.

Broadcasting: NumPy «estira» el array pequeño

Restar a una matriz `(3, 2)` un vector de 2 valores **funciona directamente**: el vector se aplica a cada fila.

```
M = np.array([[1, 2], [3, 4], [5, 6]])
M - np.array([3, 4])        # [[-2 -2], [0 0], [2 2]]
```

Así se estandariza una tabla entera: `(tabla - tabla.mean(axis=0)) / tabla.std(axis=0)`. **`axis=0` calcula por columna** (baja por las filas); **`axis=1` por fila**.

4. Aleatorios reproducibles y media móvil

```
rng = np.random.default_rng(SEMILLA)               # misma semilla → mismos números
simulada = np.clip(rng.normal(68.5, 9.6, 365), 0, 100)
```

- `rng.normal(68.5, 9.6, 365)`: 365 números «al azar» con media 68,5 y desviación 9,6.
- `np.clip(..., 0, 100)`: recorta para que no haya ocupaciones negativas ni mayores de 100.
- **Fijar la semilla** hace que **tú mañana y el cliente obtengáis el mismo resultado**: eso es **reproducibilidad**.

Media móvil: suaviza una serie promediando cada valor con sus vecinos. Con `x = [1,2,3,4,5,6]` y ventana de 3:

```
np.convolve(x, np.ones(3) / 3, mode="valid")       # [2. 3. 4. 5.]
```

Cada resultado es la media de 3 consecutivos: (1+2+3)/3 = 2; (2+3+4)/3 = 3… Con ventana 7 se ve la tendencia semanal sin el ruido diario.

5. Álgebra lineal con NumPy (repaso del Sprint 2)

Operación	En NumPy	Qué significa
Producto escalar	`a @ b`	Multiplicar elemento a elemento y **sumar**
Producto matricial	`A @ B`	(m×n) @ (n×k) = (m×k)
Transpuesta	`A.T`	Cambia filas por columnas
Inversa	`np.linalg.inv(A)`	Solo existe si el determinante no es 0

Ejemplo de producto escalar: un día con 2, 1 y 0 noches vendidas a 80, 100 y 90 €:

```
noches_dia = np.array([2, 1, 0]); precios = np.array([80, 100, 90])
noches_dia @ precios        # 2·80 + 1·100 + 0·90 = 260
```

Resolver un sistema de ecuaciones

Se sabe cuánto se facturó en dos días, y cuántas noches de cada tipo (A y B) se vendieron, pero **no los precios**:

```
2·A + 1·B = 260
1·A + 3·B = 330
```

```
noches   = np.array([[2, 1], [1, 3]])
facturado = np.array([260, 330])
np.linalg.solve(noches, facturado)       # [90. 80.]  → A cuesta 90 €, B cuesta 80 €
```

Comprobación: 2·90 + 80 = 260 y 90 + 3·80 = 330 .

La regresión lineal es un sistema de ecuaciones (ecuación normal)

```
w = np.linalg.solve(X.T @ X, X.T @ ocupacion)
```

`X` lleva **una columna de unos** (para el término independiente) y otra con la temperatura. Ejemplo con 4 días:

Temperatura	15	20	25	30
Ocupación	90	80	70	60

Se obtiene `w = [120, −2]`: **ocupación = 120 − 2 × temperatura**. A 25 ºC: 120 − 50 = **70** (coincide con la tabla). La pendiente es **negativa** (más calor, menos ocupación). Pero… ¿el calor provoca menos reservas? Lo discutiremos en el día 3.

DÍA 2 · Así aprende un modelo: descenso del gradiente

> Si no recuerdas qué es una derivada o un gradiente, relee las secciones de derivadas y gradiente de los apuntes del Sprint 2. Aquí solo lo usamos.

6. La derivada: la pendiente en un punto

- **Positiva:** la curva sube. **Negativa:** baja. **Cero:** estás en un mínimo o un máximo.

Se puede **aproximar sin fórmulas** con un paso `h` muy pequeño:

```
def derivada_numerica(func, x, h=1e-6):
    return (func(x + h) - func(x - h)) / (2 * h)
```

Es literalmente «la pendiente de un trocito minúsculo de curva». Para `g(x) = x² − 6x + 20`, en `x = 10` da ≈ 14 (la fórmula exacta: 2·10 − 6 = 14).

7. La función de coste: el error cuadrático medio (MSE)

El modelo necesita **un número que diga cómo de mal lo está haciendo**:

```
def mse(y_real, y_pred):
    return np.mean((y_real - y_pred) ** 2)
```

Ejemplo: reales `[2, 4, 6]`, predicciones `[3, 4, 5]`. Errores: −1, 0, +1 → al cuadrado: 1, 0, 1 → media = **2/3 = 0,67**.

¿Por qué al cuadrado? Para que **los errores grandes pesen más** y **no se cancelen** (un +1 y un −1 sumarían 0 y parecería perfecto).

El modelo ingenuo (referencia a batir): predecir siempre la media. Con `[2, 4, 6]` (media 4) el MSE es (4 + 0 + 4)/3 = **2,67**. Tu modelo debe mejorar esa cifra; si no, no aporta nada.

8. Descenso del gradiente en una dimensión

La idea: estás en una montaña con niebla y quieres bajar al valle. No ves el valle, pero **notas hacia dónde baja el suelo bajo tus pies**. Das un paso en esa dirección y repites.

```
x ← x − tasa · pendiente
```

Ejemplo: `g(x) = x² − 6x + 20` (mínimo en x = 3; derivada = 2x − 6). Empezamos en x = 10 con tasa 0,1:

Paso	x	Pendiente 2x − 6	Nuevo x = x − 0,1·pendiente
1	10	14	10 − 1,4 = **8,6**
2	8,6	11,2	8,6 − 1,12 = **7,48**
3	7,48	8,96	7,48 − 0,896 = **6,584**
…	…	…	…
50			**≈ 3,0001**

Cada paso se acerca al mínimo (3) y los pasos se hacen más pequeños porque la pendiente baja.

La tasa de aprendizaje: el tamaño del paso

Tasa	Qué pasa
Muy pequeña	Llega, pero **lentísimo**
Buena	Converge en pocos pasos
Muy grande	**Se pasa del mínimo y puede divergir**

Con tasa = 1,1 desde x = 10: tras 5 pasos x ≈ **−14,4**, y cada paso se aleja más. **Diverge.**

9. Regresión lineal con gradiente

Ahora el «terreno» es el error MSE y lo que se ajusta son **los pesos** `w` del modelo.

- **Modelo:** `ocupación ≈ w0 + w1 · temperatura`, es decir `y_pred = X @ w`.
- **Gradiente del MSE:** `(2 / n) · Xᵀ (X w − y)`.
- **Estandarizamos** la temperatura (media 0, desviación 1) para que el descenso sea **estable**: si una variable va de 0 a 1.000 y otra de 0 a 1, el «valle» queda estirado y cuesta bajar.

```
def gradiente_mse(X, y, w):
    return (2 / len(y)) * X.T @ (X @ w - y)

def entrenar(X, y, tasa=0.1, epocas=200):
    w = np.zeros(X.shape[1])            # empieza con pesos cero
    historial = []
    for _ in range(epocas):
        w = w - tasa * gradiente_mse(X, y, w)        # un paso cuesta abajo
        historial.append(mse(y, X @ w))              # apunta el error
    return w, historial
```

Cada **época** es una vuelta completa: calcular el gradiente → dar un paso → anotar el error. **La curva `historial` debe bajar.**

Ejemplo mínimo: con los puntos `(1,2), (2,4), (3,6)` (la recta `y = 2x`), el entrenamiento converge a `w ≈ [0, 2]`: intercepto 0 y pendiente 2.

Comprobación de seguridad: el `assert` compara **tu gradiente con el calculado por derivadas numéricas**. Si no coinciden, hay un error en la fórmula.

Elegir la tasa: qué mirar si algo va mal

Síntoma	Causa	Arreglo
El error **sube o sale** `nan`	Tasa demasiado grande	**Dividirla entre 10**
Baja, pero **muy despacio**	Tasa pequeña o variables sin estandarizar	Estandarizar; más épocas
Pendientes absurdas en unidades originales	Olvidaste deshacer la estandarización	`coef / desviación`

Deshacer la estandarización y comparar con una librería

Si entrenaste con la temperatura estandarizada, para volver a «puntos por grado»:

```
pendiente  = w[1] / desv
intercepto = w[0] - w[1] * media / desv
np.isclose(pendiente, lr.coef_[0], atol=1e-3)      # ¿coincide con scikit-learn?
```

Si tu modelo «desde cero» **coincide con `LinearRegression`, has entendido cómo aprende un modelo**. Todo lo que viene después (redes neuronales incluidas) es **este mismo bucle con más pesos**.

DÍA 3 · Estadística con Python y CRUD

10. Describir los datos

Tipo de medida	Qué mide	Cómo
Centro	Dónde está el «medio»	Media (sensible a extremos) y **mediana** (el valor central)
Dispersión	Cuánto se separan los datos	Desviación típica; rango intercuartílico (IQR = percentil 75 − percentil 25)
Forma	Si es simétrica	Asimetría (*skew*); `describe()` da un resumen rápido

Ejemplo de por qué importa la mediana: noches de 5 reservas: `[2, 3, 4, 5, 100]` (un grupo grande). La **media** = 22,8 (engañosa); la **mediana** = 4 (representa a la mayoría).

```
resumen = {"media": serie.mean(), "mediana": serie.median()}
media_por_mes = df.groupby("mes")["ocupacion_pct"].mean()     # una media por cada mes
```

11. Distribuciones y simulación Monte Carlo

Con `scipy.stats` se calculan probabilidades de distribuciones conocidas. `norm` (normal) y `binom` (binomial) tienen:

Función	Responde a
`.cdf(x)`	P(valor **≤ x**)
`.sf(x)`	P(valor **> x**) (lo contrario de cdf)
`.ppf(p)`	El valor `x` que deja una probabilidad `p` por debajo

Ejemplo con TurisData: la tasa de cancelación es 45,9 %. Si hay 20 reservas, ¿cuál es la probabilidad de que se cancelen 10 **o más**?

```
stats.binom.sf(9, 20, 0.459)       # ≈ 0.44  → un 44 %
```

(`sf(9)` = P(más de 9) = P(10 o más).)

Monte Carlo: «si la fórmula es difícil, simula muchas veces y cuenta»

Pregunta del cliente: *vendemos 170 reservas para 100 habitaciones; ¿qué probabilidad hay de tener que reubicar a alguien (que se presenten más de 100)?*

Cada reserva se presenta con probabilidad 1 − 0,459 = 0,541. Se simulan **10.000 días**:

```
presentados   = (rng.random((10000, 170)) < (1 - 0.459)).sum(axis=1)
prob_reubicar = (presentados > 100).mean()          # ≈ 0.09
```

Se leen así: la comparación genera True/False por reserva y día; `sum(axis=1)` cuenta cuántas se presentan cada día; `(presentados > 100).mean()` es la **proporción de días con más de 100**. En media se presentan 170 × 0,541 ≈ **92** personas, con desviación ≈ 6,5, y superar 100 ocurre en **≈ 9 % de los días**.

> **La estadística da el número (≈ 9 %); la decisión es del cliente.** ¿Compensa el riesgo de reubicar al 9 % de los días por llenar más habitaciones? Eso lo decide el negocio, no el código.

12. Intervalos de confianza

Un **intervalo de confianza (IC) al 95 %** es **un rango de valores plausibles** para la media (o la proporción) verdadera.

> **NO** significa «hay un 95 % de probabilidad de que el valor verdadero esté aquí». Significa que, **si repitiéramos el estudio muchas veces, el 95 % de los intervalos construidos así contendrían el valor verdadero**.

Ejemplo (proporción): de 6.000 reservas, $\hat{p}$ = 0,459 canceladas.

```
margen = 1.96 * np.sqrt(p_hat * (1 - p_hat) / n)      # 1,96 · √(0,459·0,541/6000) ≈ 0,0126
ic = (p_hat - margen, p_hat + margen)                  # ≈ (0,446 ; 0,472)
```

Se puede decir: «la tasa verdadera está **entre el 44,6 % y el 47,2 %**».

El tamaño de la muestra manda: con solo 100 reservas y $\hat{p}$ = 0,4, el margen sería 1,96·√(0,4·0,6/100) ≈ **0,096**: el IC iría de **30 % a 50 %** (mucho más ancho). Más datos → intervalo más estrecho → más seguridad.

Para una media (por ejemplo, la ocupación de un mes) se usa:

```
stats.t.interval(0.95, len(x) - 1, loc=x.mean(), scale=stats.sem(x))
```

Con 8 días de ocupaciones `[70,72,68,75,65,71,69,74]`: media 70,5 y IC al 95 % ≈ **(67,8 ; 73,2)**.

13. Contrastes de hipótesis

La lógica es un **juicio con presunción de inocencia**:

1. **H0 (hipótesis nula):** «no hay diferencia» (la ocupación es igual en festivos y en días normales).
2. Calculas el **p-valor**: *la probabilidad de ver una diferencia así de grande si H0 fuera cierta**.
3. Si **p < 0,05**, **rechazamos H0**: la diferencia es poco probable que sea casualidad.

```
stats.ttest_ind(festivos, normales, equal_var=False)      # compara dos medias
stats.chi2_contingency(tabla_canal)                       # ¿el canal influye en cancelar?
```

- **t de Student:** compara **medias** de dos grupos.
- **Chi-cuadrado:** comprueba si **dos categorías están relacionadas** (canal y cancelación).

Significativo no es lo mismo que importante

- El **p-valor** dice si es **casualidad o no**.
- El **tamaño del efecto** dice **cuánto importa**. d de Cohen = (media A − media B) / desviación combinada. Referencia: **0,2 pequeño · 0,5 medio · 0,8 grande**.

Ejemplo: con 6.000 reservas, una diferencia minúscula puede dar p = 0,001 (muy «significativa») y no tener ningún valor práctico. Con pocos datos, una diferencia enorme puede no salir significativa. **Mira siempre las dos cosas.**

> **Ojo con el p-valor:** *no* es la probabilidad de que H0 sea cierta. Y «no rechazo H0» **no** demuestra que no haya diferencia: quizá faltaban datos.

14. Correlación no es causalidad

Pregunta	Respuesta
Correlación calor ↔ ocupación	**−0,63** (más calor, menos ocupación)
¿Hay que «enfriar» el hotel para vender más?	**No**: el **invierno es temporada alta** y es la época más fresca

El **mes** influye a la vez en la temperatura y en la ocupación: es una **variable de confusión**. Al **controlar el mes** en una regresión múltiple:

```
smf.ols("ocupacion_pct ~ temperatura_c + festivo + C(mes)", data=df).fit()
```

el efecto de la temperatura **se diluye**, mientras que el del **festivo (≈ +9 puntos) resiste**.

> Con datos observacionales **no se demuestra causalidad**: se **descartan explicaciones simples**. Para demostrar causa hace falta un experimento.

15. Un vistazo bayesiano

En vez de un p-valor: **creencia inicial + datos = creencia actualizada**. Para una tasa con `c` cancelaciones de `n` reservas, la creencia actualizada es una **Beta(1 + c, 1 + n − c)**.

```
post_web      = rng.beta(1 + c_web, 1 + n_web - c_web, 10000)
prob_web_mayor = (post_web > post_directo).mean()
```

Ejemplo pequeño: web con 3 canceladas de 10, directo con 1 de 10. Simulando se obtiene `prob_web_mayor ≈ 0,84`: «*hay un 84 % de probabilidad de que la web cancele más que el directo*». **Es una frase que entiende un cliente**, a diferencia del p-valor.

16. CRUD desde Python (el paso 1 del reto)

Es lo mismo que el CRUD en SQL del Sprint 3, pero **escrito desde Python**:

```
import sqlite3
con = sqlite3.connect("turisdata.db")
con.execute("SELECT id_reserva FROM reservas WHERE id_cliente = ?", (id_cliente,))
con.execute("UPDATE reservas SET cancelada = 1 WHERE id_reserva = ?", (5046,))
con.commit()                  # confirmar; con.rollback() lo deshace
diaria.to_sql("ocupacion_diaria", con, if_exists="replace", index=False)    # CSV → base
```

- **Nunca pegues texto directamente en el SQL** (`"... WHERE id = " + dato`): usa `?` y pasa los valores aparte. Así evitas la **inyección SQL** (que alguien escriba código malicioso en un campo).
- **Nada es definitivo hasta** `commit`; `rollback` lo deshace; `rowcount` dice **cuántas filas** tocaste (si esperabas 1 y salen 6.000, algo va mal).
- El mismo CRUD se hace en **MongoDB** con `pymongo` / `mongomock`.

---

17. Dónde practicar cada cosa

Si no entiendes...	Mira la sección	Repaso de teoría	Practica en
Arrays, máscaras, broadcasting	1-4	—	`S05_01_numpy`
Producto matricial, sistemas, ecuación normal	5	Sprint 2: vectores y matrices	`S05_02_algebra_lineal`
Derivada, gradiente, tasa de aprendizaje	6-9	Sprint 2: derivadas y gradiente	`S05_03_gradiente_regresion`
Media, mediana, IC, Monte Carlo	10-12	Sprint 2: estadística	`S05_04_estadistica_descriptiva_ic`

Si no entiendes...	Mira la sección	Repaso de teoría	Practica en
p-valor, efecto, confusión, Bayes	13-15	Sprint 2: Bayes, sesgos y Simpson	`S05_05_contrastes_causalidad`
CRUD en Python	16	Sprint 3: SQL y NoSQL	`S05_06_crud_python`
Todo junto	todas	—	Reto `S05_07_reto_ocupacion`

18. Chuleta de vocabulario

Palabra	En lengua normal
Array	Tabla de números del mismo tipo
shape	Forma del array (filas, columnas)
Vectorizar	Operar con todo el array a la vez, sin bucles
Broadcasting	NumPy «estira» el array pequeño para poder operar
Máscara	Filtro de True/False para elegir elementos
Semilla	Número que hace que el azar sea repetible
z-score	Cuántas desviaciones típicas se aleja un valor de la media
Derivada	Pendiente en un punto
Gradiente	Derivadas de varias variables: la dirección de máxima subida
MSE	Error cuadrático medio
Tasa de aprendizaje	Tamaño del paso en el descenso del gradiente
Época	Una vuelta completa de entrenamiento
Monte Carlo	Simular muchas veces y contar
IC (intervalo de confianza)	Rango de valores plausibles para el valor verdadero
H0	Hipótesis nula: «no hay diferencia»
p-valor	Probabilidad de ver esto si H0 fuera cierta
Tamaño del efecto	Cuánto importa una diferencia
Variable de confusión	Algo que influye en las dos variables y crea una falsa relación
Inyección SQL	Atacar una base metiendo código en un campo de texto
commit / rollback	Confirmar / deshacer cambios en la base

19. Cómo estudiar estos apuntes

1. **Antes de cada cuaderno**, lee la sección que te indica la tabla del apartado 17.
2. **Comprueba a mano los ejemplos pequeños** (media 70, z = 1,41; los pasos del gradiente): si los entiendes con 3 números, los entenderás con 1.096.
3. **Ejecuta y cambia valores** (la tasa, la semilla) para ver qué se rompe.
4. **En el reto, no basta con el resultado:** hay que decir **cuánta confianza merece** (intervalo, tamaño de efecto) y **qué no se puede concluir** (causalidad).