README Sprint S05 · Matemáticas y estadística en código

Pregunta guía: ¿podemos demostrar con código lo que vimos en teoría?

Fechas: 4–5 de noviembre · **Horas:** 9 h (2 h teoría · 4 h práctica, incluye 1 h de CRUD · 3 h PBL)

📄 **Para imprimir:** todos los documentos del sprint en PDF, a color y ecofriendly, están juntos en la carpeta `pdf/` (descárgalos para que funcionen los enlaces).

> **Sigue el orden de arriba abajo y abre solo lo que pone en cada fila.** Los demás documentos del sprint son para consultar si te atascas (apartado «Si te atascas»). Los cuadernos **«en clase»** (carpeta `2_Practica/en_clase/`) son la versión corta que se hace en el aula; los completos son para casa.

Qué aprenderás

1. A manejar **datos numéricos con NumPy**: arrays, vectorización, *broadcasting* y álgebra lineal.
2. A **entrenar un modelo desde cero**: entender el gradiente y programar la regresión lineal con descenso del gradiente.
3. A hacer **estadística con Python**: describir datos, usar distribuciones, simular (Monte Carlo) y construir intervalos de confianza.
4. A **contrastar hipótesis** e interpretar p-valores, tamaños de efecto y la diferencia entre **correlación y causalidad**.
5. A hacer **CRUD desde Python** sobre SQLite y MongoDB y a dejar una base de datos poblada.

Día 1 · Miércoles 4/11

☐	Qué haces	Abre	Min
☐	🔔 Ceremonia · Planning del reto «¿La ocupación depende de esto?»	—	10
☐	📖 Teoría · NumPy: arrays, máscaras, vectorización y *broadcasting*	Presentación S05_01	25
☐	💻 Práctica · Arrays y vectorización (cuaderno «en clase»: ejercicios 1 y 3; lo que falte, en la tutoría)	Cuaderno S05_01	15
☐	🏠 **En casa** · Álgebra lineal con NumPy: vectores, matrices y sistemas de ecuaciones (cuaderno completo)	Cuaderno S05_02 · Presentación S05_02	40 (casa)

En clase: 50 min.

Al acabar el día, deberías poder decir:

☐ Sé hacer cálculos con arrays sin escribir bucles.

Día 2 · Jueves 5/11

☐	Qué haces	Abre	Min
☐	💻 Práctica · Descenso del gradiente y regresión desde cero (cuaderno «en clase»: ejercicios 4 y 5)	Cuaderno S05_03 · Presentación S05_03	40
☐	📖 Teoría · Estadística descriptiva, Monte Carlo e intervalos de confianza	Presentación S05_04	20
☐	💻 Práctica · Descriptiva e intervalos de confianza (cuaderno «en clase»: ejercicios 1 y 5)	Cuaderno S05_04	30
☐	💻 Práctica · CRUD con `sqlite3` (cuaderno «en clase»: ejercicios 1 y 3; el 3 es también el paso 1 del reto: cargar los datos en una base)	Cuaderno S05_06 · Presentación S05_06	25
☐	🎯 Reto · Cuaderno `S05_07`: mirar los datos → regresión desde cero → comparar con una librería → medir la seguridad del resultado → responder en 150 palabras (pasos 2–6; lo que falte, en la consolidación y la 6.ª hora)	Reto en una página	45
☐	🔔 Ceremonia · Entrega en `sprint-05/`, autoevaluación y coevaluación, y review y retrospectiva de los Sprints 4 y 5	—	40
☐	🏠 **En casa** · Contrastes de hipótesis, correlación y causalidad (cuaderno completo)	Cuaderno S05_05 · Presentación S05_05 · Versión «en clase»	40 (casa)

En clase: 3 h 20 min.

Al acabar el día, deberías poder decir:

☐ Sé ajustar una regresión con el descenso del gradiente y comprobar que da lo mismo que una librería.
☐ Sé medir lo seguro que es un resultado con un intervalo de confianza.
☐ Sé cargar datos en una base con `sqlite3` y responder al cliente con una conclusión y sus límites.

El reto en pocas palabras

Qué os pide el cliente. Al dueño de TurisData le han dicho dos cosas: *«cuando hace calor se llena menos»* y *«los festivos llenan»*. Antes de cambiar personal y precios, quiere saber **cuánto** cambia realmente la ocupación diaria con la temperatura y con los festivos, y **con qué seguridad** se puede afirmar. Os da tres años de datos diarios.

Qué vais a entregar: un cuaderno, una base de datos y la respuesta al cliente.

Niveles del reto. 🟢 Mínimo: la regresión simple desde cero y la respuesta al cliente con una cifra y su intervalo. 🟡 Estándar: el modelo con control (festivo y mes), la comparación con `statsmodels` y el p-valor, el intervalo y el tamaño del efecto explicados con palabras. 🔴 Extra: explicar con el control por mes por qué correlación no es causalidad, comparar varias tasas de aprendizaje y cuidar los gráficos.

Antes de empezar, probad la demo interactiva (muestra lo que tendréis al final). Para trabajar: reto en una página. Para entregar: qué se sube y rúbrica. Para consultar: ficha del reto (qué pide el cliente, ayudas y errores frecuentes) y cada paso explicado.

✅ Antes de cerrar el sprint (Definition of Done)

Archivos subidos en el repositorio del equipo, carpeta `sprint-05/` (marca cada uno cuando lo veas en GitHub): ☐ `S05_07_reto_ocupacion.ipynb` · lo modificáis
☐ `turisdata_reto.db` · lo genera el cuaderno
☐ `autoevaluacion_nombre.md` · **uno por persona** (la coevaluación va dentro del mismo fichero): plantilla

Total en `sprint-05/`: 2 ficheros del equipo + 1 hoja por persona (un equipo de 3 sube 5). Aparte: ocupacion_diaria.csv en `data/` si aún no está; los extras solo si los hacéis. La *review* y la *retro* no se suben.

Comprobaciones antes de dar el sprint por cerrado: ☐ Todos los `assert` del cuaderno pasan y reiniciar y ejecutar todo funciona
☐ `turisdata_reto.db` con la tabla `ocupacion_diaria` (1096 filas)
☐ Regresión coincide con `statsmodels`; hay p-valor, intervalo y tamaño del efecto interpretados
☐ Respuesta al cliente (≤ 150 palabras) con recomendación y límites
☐ Alguien que **no escribió esa parte** ha revisado el entregable con la rúbrica y lo ha anotado en el propio entregable

En casa (cuando puedas)

- Los **cuadernos completos** (🏠 para casa) de los que hiciste en clase la versión corta («en clase»). Traen **todos** los ejercicios, se autocorrigen y llevan una «Solución de referencia» plegada por si te quedas atascado: `S05_01` · `S05_03` · `S05_04` · `S05_06`.
- Si quieres repasar la teoría con calma: apuntes del sprint.

Si te atascas

1. Lee primero la parte «Si os atascáis» de la ficha completa del reto.
2. Mira el código explicado del cuaderno en el que estás.
3. Pregunta a tu equipo y, después, al docente. Si usas IA, cuenta en el README qué te dijo y qué comprobaste.

Todo el material, por carpetas

Las carpetas están **numeradas en el orden en que las usas**. Cada documento está en `.md`.

Carpeta	Qué hay
`1_Teoria/`	Las presentaciones del sprint y los apuntes para repasar
`2_Practica/`	Los cuadernos (Colab) y su explicación línea a línea en `codigo_explicado/`
`3_Reto/`	`1_Trabajar` (reto en una página, plantillas y datos) · `2_Entregar` (qué se sube, rúbrica y autoevaluación) · `3_Consultar` (ficha del reto y cada paso explicado)
`4_Referencia/`	Infografías del sprint

Cómo se trabaja un reto, en todos los sprints: método de trabajo.

Temario oficial de este sprint

Unidad	Conceptos que entran
UD 1b.5 · NumPy	Arrays, indexación, vectorización, broadcasting; álgebra lineal (dot, matmul, inversa, autovalores)
UD 1b.6 · Implementación de conceptos matemáticos	Derivadas numéricas, función de coste, descenso del gradiente y regresión lineal desde cero
UD 1b.7 · Estadística con Python	Estadística descriptiva con pandas; distribuciones con SciPy; simulación Monte Carlo · Bayes en código, correlación, contraste de hipótesis (t-test), intervalos de confianza
M6b · CRUD desde Python	sqlite3/SQLAlchemy y pandas.to_sql para cargar un dataset y consultarlo; pymongo (demostración)

Y ahora: Sprint 6 · Datos listos para modelar (viernes 6/11).

9 h (2 h teoría · 4 h práctica · 3 h PBL).