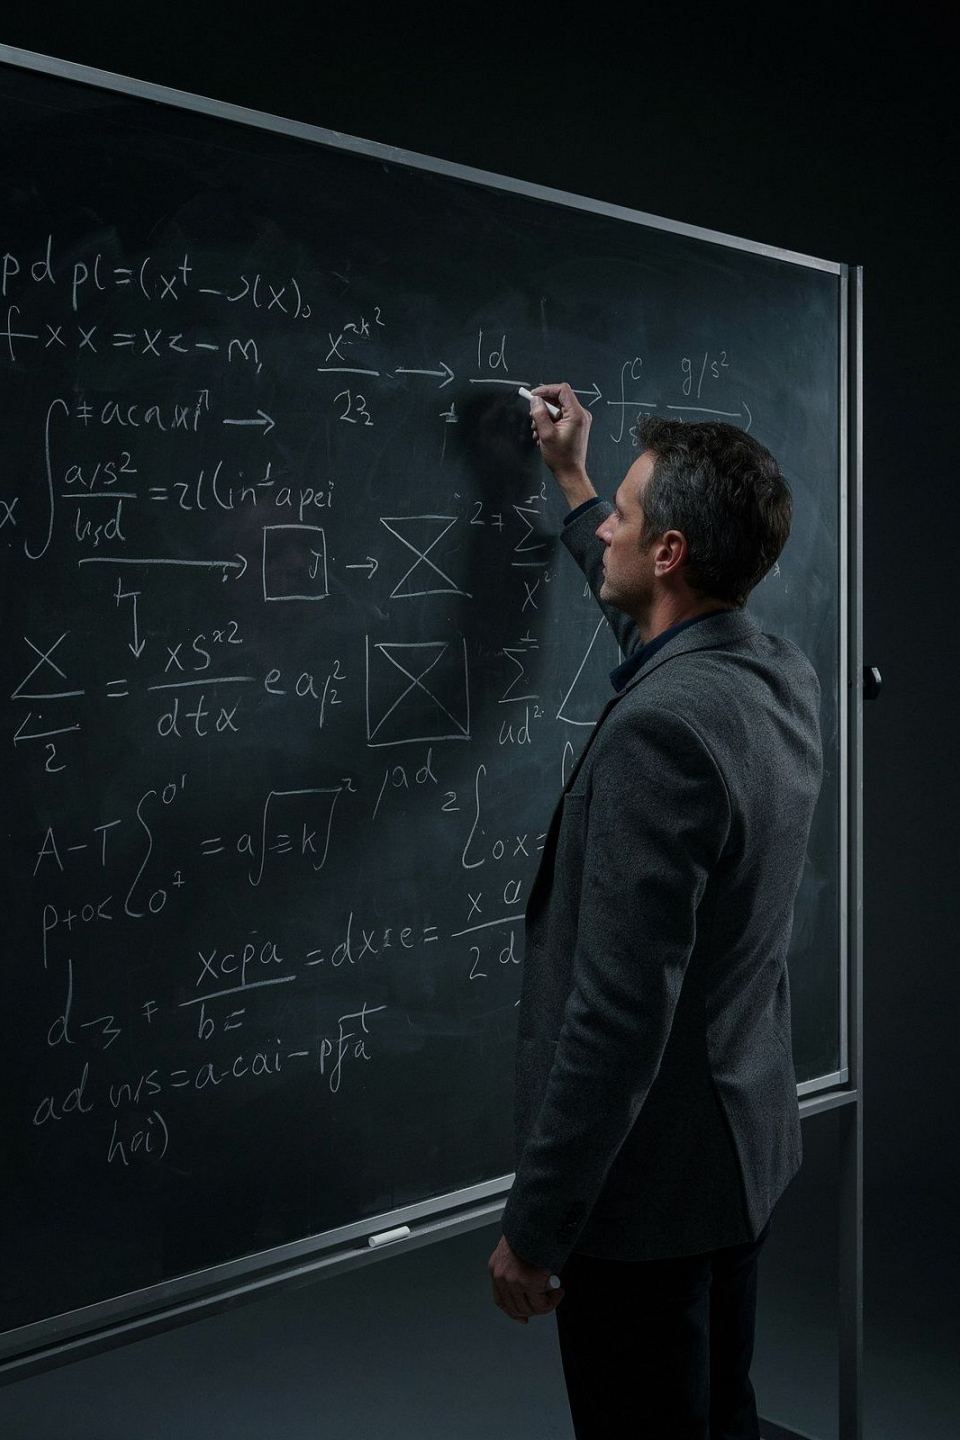


SPRINT 5 · MATEMÁTICAS Y ESTADÍSTICA EN CÓDIGO · S05.2

Descenso del gradiente y regresión desde cero

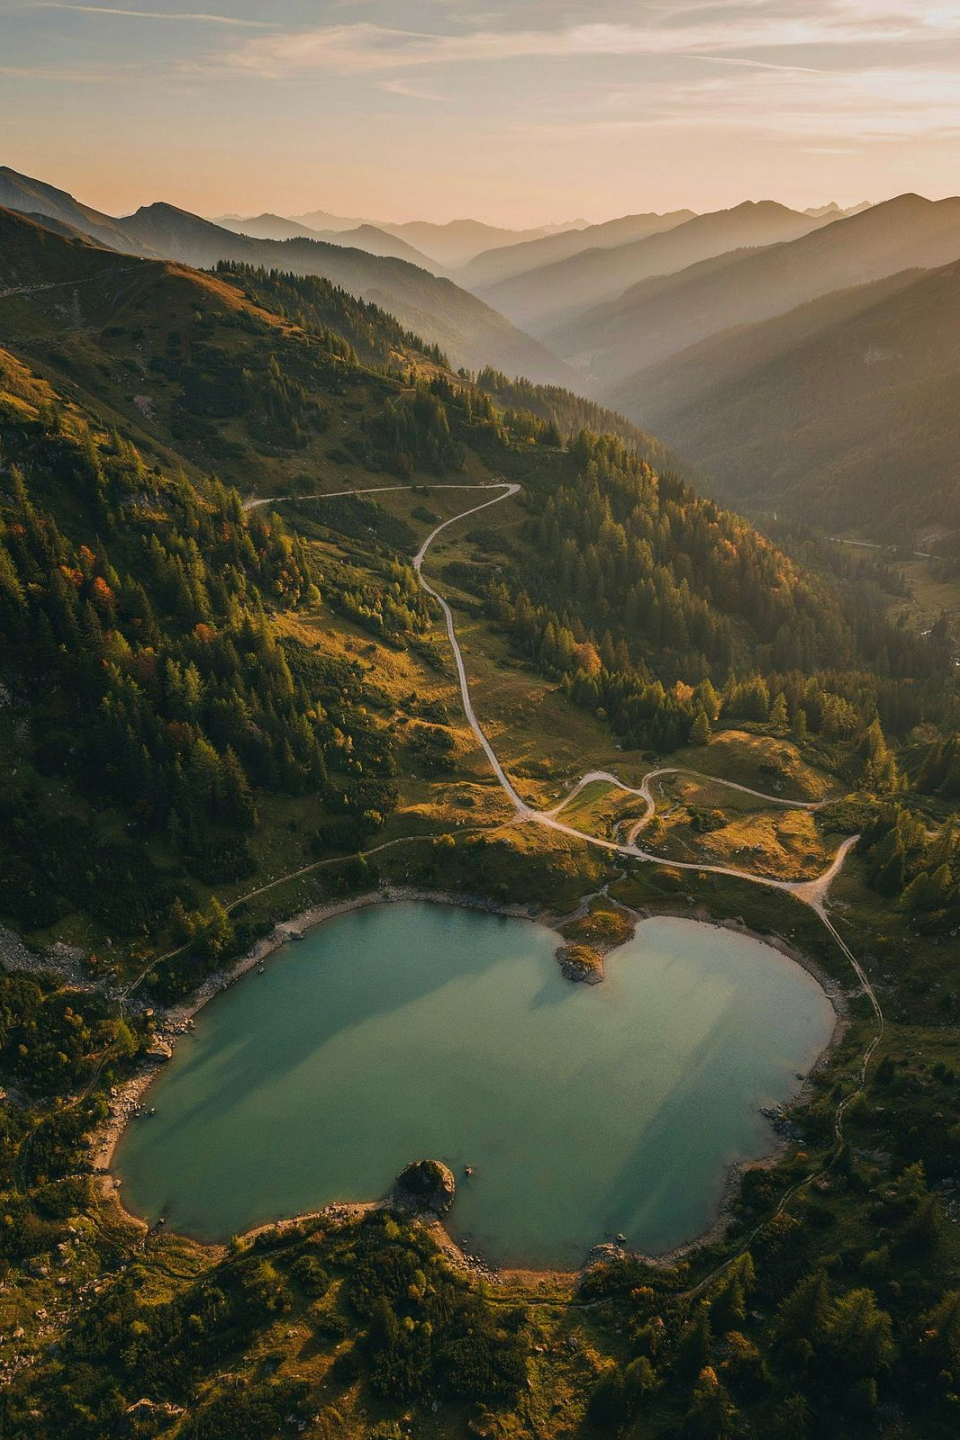
Así aprende un modelo: mide su error, mira hacia dónde baja y da un paso. Lo programamos con NumPy, sin librerías de IA.

La derivada: la pendiente en un punto

- Positiva: la curva sube.
- Negativa: baja.
- Cero: estamos en un mínimo o un máximo.

Se aproxima sin fórmulas con un h muy pequeño:

```
def derivada_numerica(func, x, h=1e-6):        # Ejercicio 1
    return (func(x + h) - func(x - h)) / (2 * h)
```



Función de coste: el error cuadrático medio

```
def mse(y_real, y_pred):                    # Ejercicio 2
    return np.mean((y_real - y_pred) ** 2)

mse_ingenuo = mse(ocupacion, ocupacion.mean())   # predecir siempre la media
```

- Al cuadrado: los errores grandes pesan más y no se cancelan.
- El modelo «ingenuo» (siempre la media) es la referencia a batir.

Descenso del gradiente en una dimensión

Empieza en cualquier sitio y da pasos cuesta abajo: x ← x – tasa · pendiente

```
# g(x) = x² - 6x + 20, mínimo en x = 3, derivada 2x - 6
x = 10
for _ in range(50):                    # Ejercicio 3
    x = x - 0.1 * (2 * x - 6)
```

La tasa de aprendizaje es el tamaño del paso: muy pequeña = lento; muy grande = se pasa del mínimo y puede divergir.

Regresión lineal: modelo y gradiente

- Modelo: ocupación ≈ w0 + w1 · temperatura, es decir y_pred = X @ w.
- Gradiente del MSE: $(2 / n) \cdot X^T (X w – y)$.
- Estandarizamos la variable (media 0, desv. 1) para que el descenso sea estable.

```
def gradiente_mse(X, y, w):                    # Ejercicio 4
    return (2 / len(y)) * X.T @ (X @ w - y)
```

El bucle de entrenamiento

```
def entrenar(X, y, tasa=0.1, epocas=200):       # Ejercicio 5
    w = np.zeros(X.shape[1])
    historial = []
    for _ in range(epocas):
        w = w - tasa * gradiente_mse(X, y, w)
        historial.append(mse(y, X @ w))
    return w, historial
```

El assert compara tu gradiente con el calculado por derivadas numéricas. La curva historial debe bajar.



Elegir la tasa de aprendizaje

Síntoma	Causa	Arreglo
El error sube o da nan	Tasa demasiado grande	Dividirla entre 10
Baja, pero muy despacio	Tasa pequeña o variables sin estandarizar	Estandarizar; más épocas
Pendientes absurdas en unidades originales	Olvidar deshacer la estandarización	coef / desviación

Ejercicio 6: con tasa = 2.5 y 30 épocas, comprueba que el entrenamiento diverge.

Comprobar con scikit-learn

```
pendiente = w[1] / desv                  # de «por desv. típica» a «por grado»
intercepto = w[0] - w[1] * media / desv
coinciden = np.isclose(pendiente, lr.coef_[0], atol=1e-3)   # Ejercicio 7
```

- Si tu modelo «desde cero» coincide con LinearRegression, lo has entendido.
- Mini-reto: regresión múltiple (temperatura, festivo y precio medio) con la misma función entrenar.
- Todo lo que viene después (redes neuronales incluidas) es este mismo bucle con más pesos.

Ahora, a practicar

Lo que viene a continuación está en tu repositorio.

CUADERNO · Descenso del gradiente y regresión desde cero (sprints/S05/notebooks/S05_03_gradiente_regresion) — 70 min.