

Estadística con Python y CRUD

Un recorrido completo desde el análisis descriptivo hasta las bases de datos, pasando por simulaciones, inferencia bayesiana y contrastes de hipótesis. Todo con código Python real y listo para aplicar.

MÓDULO 5.3

PYTHON · PANDAS · SCIPY · SQLALCHEMY



Contenidos del módulo

Este módulo combina estadística aplicada con gestión de datos, dos pilares fundamentales del análisis de datos moderno.

01

Estadística descriptiva con pandas

Resumen numérico y visualización básica de datos.

03

Simulación Monte Carlo

Estimación numérica mediante muestreo aleatorio.

05

Contraste de hipótesis e intervalos

T-test, p-valores e intervalos de confianza.

02

Distribuciones con SciPy

Modelos probabilísticos y ajuste de distribuciones.

04

Bayes en código

Actualización de creencias con datos reales.

06

CRUD desde Python

sqlite3, SQLAlchemy, to_sql y pymongo.

Estadística Descriptiva con Pandas

Pandas ofrece un conjunto de herramientas potente para obtener un primer vistazo cuantitativo de cualquier conjunto de datos de forma inmediata.

Métodos clave

- **df.describe()** — media, std, cuartiles
- **df.mean()** / **df.median()** — tendencia central
- **df.corr()** — correlaciones entre variables
- **df.value_counts()** — frecuencias absolutas

¿Por qué es el primer paso?

Antes de modelar o inferir, necesitas entender la forma, el centro y la dispersión de tus datos. La estadística descriptiva detecta valores atípicos, distribuciones sesgadas y variables constantes que podrían distorsionar cualquier análisis posterior.



Distribuciones de Probabilidad con SciPy

scipy.stats implementa más de 100 distribuciones continuas y discretas, desde la Normal hasta la Poisson, con una interfaz unificada y consistente.



Normal y t de Student

Para modelar fenómenos continuos y realizar inferencias con muestras pequeñas. **norm.pdf()**, **t.cdf()**.




Binomial y Poisson

Distribuciones discretas para contar eventos. Esenciales en experimentos A/B y análisis de frecuencias.



Ajuste de distribución

Con **scipy.stats.fit()** puedes encontrar automáticamente la distribución que mejor se ajusta a tus datos empíricos.



Generación de muestras

Usa **.rvs(size=n)** para generar observaciones aleatorias desde cualquier distribución parametrizada.

Simulación Monte Carlo

Monte Carlo convierte problemas analíticamente complejos en experimentos computacionales: se generan miles de escenarios aleatorios y se observa el comportamiento agregado del sistema.

1 · Definir el modelo

Identificar variables inciertas y sus distribuciones de probabilidad.

2 · Muestrear

Generar N realizaciones con `np.random` o `scipy.stats.rvs()`.

3 · Simular

Calcular el resultado del modelo para cada muestra generada.

4 · Agregar

Obtener media, percentiles e intervalos de confianza de los resultados.

📌 Cuanto mayor sea N (número de simulaciones), más precisa será la estimación. Valores típicos: de 10.000 a 1.000.000 iteraciones.



Bayes en Código Python

El enfoque bayesiano actualiza nuestras creencias previas (*prior*) a la luz de nuevos datos para obtener una creencia actualizada (*posterior*). Python permite implementarlo de forma explícita y transparente.

Teorema de Bayes

$$P(H|D) = \frac{P(D|H) \cdot P(H)}{P(D)}$$

Donde **P(H)** es el prior, **P(D|H)** es la verosimilitud y **P(H|D)** es el posterior que buscamos calcular.

Implementación práctica

- **PyMC** — modelado probabilístico completo
- **NumPy** — Bayes discreto manual
- **scipy.stats** — distribuciones conjugadas

Ejemplo clásico

Test médico con tasa de falsos positivos: dado un resultado positivo, ¿cuál es la probabilidad real de estar enfermo? Bayes responde combinando la prevalencia de la enfermedad con la precisión del test.

Contraste de Hipótesis e Intervalos de Confianza

El contraste de hipótesis permite decidir, con base estadística, si una diferencia observada en los datos es real o producto del azar. El **t-test** es el punto de entrada más utilizado.

t-test de una muestra

Contrasta si la media de una muestra difiere de un valor de referencia teórico.

`scipy.stats.ttest_1samp()`

t-test de dos muestras

Compara las medias de dos grupos independientes. Fundamental en experimentos A/B.

`scipy.stats.ttest_ind()`

p-valor e interpretación

Si $p < 0.05$, rechazamos H_0 . El p-valor no mide la magnitud del efecto, solo la evidencia contra la hipótesis nula.

Intervalos de confianza

Rango de valores plausibles para el parámetro. Más informativos que el p-valor solo.

`scipy.stats.t.interval()`



CRUD desde Python

Conectar Python con bases de datos relacionales y NoSQL es una habilidad imprescindible para cualquier analista de datos moderno.

¿Qué es CRUD?

Create · **Read** · Update · Delete — las cuatro operaciones fundamentales sobre cualquier base de datos, ya sea SQL o NoSQL.

sqlite3

Módulo estándar de Python para bases de datos relacionales locales. Sin instalación adicional, ideal para prototipado y aprendizaje.

SQLAlchemy

ORM y toolkit SQL de referencia en Python. Abstrae el dialecto SQL y permite trabajar con PostgreSQL, MySQL o SQLite sin cambiar el código.

pymongo

Driver oficial de MongoDB para Python. Permite operaciones CRUD sobre colecciones de documentos JSON con una API intuitiva.

sqlite3: La Base de Datos en un Fichero

El módulo **sqlite3** viene incluido en la librería estándar de Python y permite crear y gestionar bases de datos relacionales sin necesidad de instalar ningún servidor externo.

```
import sqlite3

# Conectar (crea el fichero si no existe)
conn = sqlite3.connect("datos.db")
cursor = conn.cursor()

# CREATE TABLE
cursor.execute("""
CREATE TABLE IF NOT EXISTS ventas (
    id INTEGER PRIMARY KEY,
    producto TEXT,
    importe REAL
)
""")

# INSERT (Create)
cursor.execute("INSERT INTO ventas VALUES (1, 'Laptop', 999.99)")

# SELECT (Read)
for row in cursor.execute("SELECT * FROM ventas"):
    print(row)

conn.commit()
conn.close()
```

SQLAlchemy y el Puente `to_sql`

SQLAlchemy es la biblioteca ORM de referencia en Python. Combinada con pandas, el método `to_sql()` permite volcar un DataFrame completo a una tabla SQL en una sola línea de código.

Con SQLAlchemy ORM

Define modelos como clases Python. El motor gestiona la traducción a SQL automáticamente, soportando múltiples motores: SQLite, PostgreSQL, MySQL.

- `create_engine()` — conexión al motor
- `Session()` — contexto transaccional
- `Base.metadata.create_all()` — crea tablas

DataFrame → SQL con pandas

El método `df.to_sql()` es la forma más rápida de persistir resultados de análisis directamente en una base de datos, sin escribir SQL manualmente.

```
df.to_sql(  
    "resultados",  
    con=engine,  
    if_exists="replace",  
    index=False  
)
```



pymongo: CRUD en MongoDB

MongoDB almacena documentos JSON en lugar de filas tabulares. **pymongo** expone una API directa y expresiva para trabajar con colecciones, ideal para datos semiestructurados o con esquema variable.

Conectar e insertar

```
client = MongoClient("mongodb://localhost:27017")  
db.ventas.insert_one({"producto": "Tablet", "importe": 349})
```

Consultar (Read)

```
db.ventas.find({"importe": {"$gt": 200}})
```

Usa operadores como **\$gt**, **\$lt**, **\$in** y **\$regex** para filtros potentes.

Actualizar y eliminar

```
db.ventas.update_one(filtro, {"$set": {"importe": 399}})  
db.ventas.delete_many({"importe": {"$lt": 10}})
```

Presentación del Reto

El reto integrador de este módulo pone en práctica todos los conceptos aprendidos en un flujo de trabajo real de extremo a extremo.



Carga y exploración

Importar un dataset real con pandas y aplicar estadística descriptiva completa.



Inferencia

Formular y contrastar hipótesis con t-test. Calcular e interpretar intervalos de confianza.



Análisis estadístico

Ajustar distribuciones con SciPy y realizar una simulación Monte Carlo sobre el fenómeno de interés.



Persistencia CRUD

Almacenar los resultados en SQLite con SQLAlchemy y demostrar al menos una operación en MongoDB.

📄 El reto se presentará ante la clase con código ejecutable y una breve exposición de los hallazgos estadísticos más relevantes.



Resumen y Próximos Pasos

Este módulo cubre el ciclo completo del análisis estadístico con Python: desde describir los datos hasta persistirlos en una base de datos, pasando por modelos probabilísticos, simulación e inferencia.



Estadística

Pandas + SciPy cubren descripción, distribuciones, simulación, Bayes y contrastes.



Bases de datos

sqlite3, SQLAlchemy y pymongo para CRUD en SQL y NoSQL desde Python.



Reto integrador

Aplicar todo el flujo en un proyecto real: análisis, inferencia y persistencia.

¡Manos al código! La mejor forma de dominar estas herramientas es practicando con datos reales.