Estadística con Python y CRUD

Con la serie diaria y las 6.000 reservas de TurisData respondemos preguntas del cliente con números, no con intuiciones.

SPRINT 5 · MATEMÁTICAS Y ESTADÍSTICA EN CÓDIGO · S05.3



Describir los datos (cuaderno S05_04)

Centro

Media (sensible a extremos) y mediana (el valor del medio).

Dispersión

Desviación típica y rango intercuartílico: quantile(.75) – quantile(.25).

Forma

Asimetría (skew); describe() da el resumen rápido.

```
resumen = {"media": serie.mean(), "mediana": serie.median(), "iqr": ...}    # Ejercicio 1
media_por_mes = df.groupby("mes")["ocupacion_pct"].mean()                    # Ejercicio 2
```

Distribuciones y simulación Monte Carlo

```
stats.binom.sf(9, 20, 0.459)          # Ejercicio 3: P(se cancelan 10 o más de 20)

# Ejercicio 4: 170 reservas para 100 habitaciones, 10.000 días simulados
presentados = (rng.random((10000, 170)) < (1 - 0.459)).sum(axis=1)
prob_reubicar = (presentados > 100).mean()      # ≈ 9 %
```

- norm y binom: .cdf, .sf, .ppf.
- Monte Carlo: si la fórmula es difícil, simula muchas veces y cuenta.
- La estadística da el número (≈ 9 % de días con reubicación); la decisión es del cliente.

Intervalos de confianza

Un IC al 95 % es un rango de valores plausibles para la media (o proporción) verdadera. No significa «hay un 95 % de probabilidad de que esté aquí».

```
p_hat = df["cancelada"].mean(); n_res = len(df)          # Ejercicio 5
margen = 1.96 * np.sqrt(p_hat * (1 - p_hat) / n_res)
ic_tasa = (round(p_hat - margen, 4), round(p_hat + margen, 4))
stats.t.interval(0.95, len(x) - 1, loc=x.mean(), scale=stats.sem(x))   # media de un mes
```

Mini-reto: ¿se solapan los IC de enero y septiembre? ¿Y eso es importante para el negocio?

Contrastes de hipótesis (cuaderno S05_05)

1. **H0**: «no hay diferencia» (ocupación igual en festivos y en días normales).
2. El p-valor es la probabilidad de ver una diferencia así de grande si H0 fuera cierta.
3. Si p < 0,05, rechazamos H0.

```
res = stats.ttest_ind(festivos, normales, equal_var=False)      # Ejercicio 1
d = (media_a - media_b) / desviacion_combinada                  # Ejercicio 2: d de Cohen
stats.chi2_contingency(tabla_canal)                             # Ejercicio 3: canal vs cancelación
```

Significativo no es lo mismo que importante: un p pequeño dice que no es casualidad; el tamaño del efecto (0,2 pequeño, 0,5 medio, 0,8 grande) dice cuánto importa.

Correlación no es causalidad

Pregunta	Respuesta
Correlación calor ↔️ ocupación	–0,63
¿Hay que «enfriar» el hotel?	No: el invierno es temporada alta y es la época más fresca
Variable de confusión	El mes influye en la temperatura y en la ocupación.

```
smf.ols("ocupacion_pct ~ temperatura_c + festivo + C(mes)", data=df).fit()  # Ejercicio 5
```

Al controlar el mes, el efecto de la temperatura se diluye; el del festivo (≈ +9 puntos) resiste. Con datos observacionales no se demuestra causalidad: se descartan explicaciones simples.

Un vistazo bayesiano

- En vez de un p-valor: creencia inicial + datos = creencia actualizada.
- Para una tasa con c canceladas de n: Beta(1 + c, 1 + n − c).

```
post_web = rng.beta(1 + c_web, 1 + n_web - c_web, 10000)
prob_web_mayor = (post_web > post_directo).mean()    # Ejercicio 6
```

Resultado: «hay un X % de probabilidad de que la web cancele más que el canal directo», una frase que sí entiende un cliente.

CRUD desde Python (cuaderno S05_06)

```
con = sqlite3.connect("turisdata.db")
con.execute("SELECT id_reserva FROM reservas WHERE id_cliente = ?", (id_cliente,))   # seguro
con.execute("UPDATE reservas SET cancelada = 1 WHERE id_reserva = ?", (5046,))
con.commit()                                                  # o con.rollback()
diaria.to_sql("ocupacion_diaria", con, if_exists="replace", index=False)          # CSV → base
```

- Nunca pegues texto en el SQL: usa ? y evitas la inyección SQL.
- Nada es definitivo hasta commit; rollback lo deshace; rowcount dice cuántas filas tocaste.
- Mismo CRUD en MongoDB con pymongo / mongomock. Es el paso 1 del reto: cargar los datos en una base.

Ahora, a practicar

Lo que viene a continuación está en tu repositorio.

- **CUADERNO** · Descriptiva, Monte Carlo e intervalos de confianza (sprints/S05/notebooks/S05_04_estadistica_descriptiva_ic) — 35 min.
- **CUADERNO** · Contrastes, causalidad, statsmodels y Bayes (sprints/S05/notebooks/S05_05_contrastes_causalidad) — 35 min.
- **CUADERNO** · CRUD con sqlite3 y mongomock (es también el paso 1 del reto: cargar los datos en una base) (sprints/S05/notebooks/S05_06_crud_python) — 30 min.
- **RETO** · Cuaderno S05_07: mirar los datos → regresión desde cero → comparar con una librería → medir la seguridad del resultado → responder en 150 palabras (pasos 2–6) (sprints/S05/guia/Reto_Sprint_05.md) — 45 min.