IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

ETAPA B · CONSTRUIR · SPRINT 5 DE 17

# README Sprint S05 · Matemáticas y estadística en código

*¿podemos demostrar con código lo que vimos en teoría?*

**FECHAS**
30/10 y 3/11

**HORAS**
12 h (3 h teoría · 6 h práctica, incluye 1 h de CRUD · 3 h PBL)

**ESTE README EN PDF**
a color · ecofriendly, para imprimir (descárgalo para que funcionen los enlaces; la vista previa de GitHub no los abre).

## Qué aprenderás

1. A manejar **datos numéricos con NumPy**: arrays, vectorización, *broadcasting* y álgebra lineal.
2. A **entrenar un modelo desde cero**: entender el gradiente y programar la regresión lineal con descenso del gradiente.
3. A hacer **estadística con Python**: describir datos, usar distribuciones, simular (Monte Carlo) y construir intervalos de confianza.
4. A **contrastar hipótesis** e interpretar p-valores, tamaños de efecto y la diferencia entre **correlación y causalidad**.
5. A hacer **CRUD desde Python** sobre SQLite y MongoDB y a dejar una base de datos poblada.

## Requisitos previos

- Haber hecho el Sprint 4 (Python básico, funciones, ficheros).
- Colab o Jupyter con Python 3.11. Los cuadernos usan `numpy`, `pandas`, `matplotlib`, `scipy`, `statsmodels`, `scikit-learn`, `sqlite3` y `mongomock`.
- Los datos (`ocupacion_diaria.csv`, `reservas_turisdata.csv`, `turisdata.db`) se descargan solos. Son **sintéticos**: sirven para practicar, no son estadísticas reales del turismo canario.

## Materiales del sprint

**Documentos del curso** (PDF y .md; las actividades van en la tabla siguiente)

| Material | Tema | Tiempo | Cuándo |
|---|---|---|---|
| Guía del sprint (PDF) · ecofriendly | Resumen del sprint: qué aprenderás, temario, material, reto y conclusión | 2 páginas | Antes de empezar |
| Reto completo, paso a paso (.md) · PDF · ecofriendly | Qué pide el cliente, pasos, rúbrica, ayudas y errores frecuentes | — | Antes del planning y durante el reto |
| Resumen del sprint en una página | Lámina con la pregunta del cliente, los pasos, lo que se entrega y lo que se aprende | — | Antes del planning |
| Infografías del reto | 3 láminas ilustradas del reto | — | Reto |
| Cómo se trabaja un reto | El método de trabajo de todos los retos | — | Antes del primer reto |

| Material | Tema | Tiempo | Cuándo |
|---|---|---|---|
| `S05.1 NumPy y algebra lineal.pdf` | NumPy y álgebra lineal: vectorización y *broadcasting* | 15 min | Teoría · viernes 30/10 |
| `S05.2 Descenso del gradiente y regresion desde cero.pdf` | Descenso del gradiente y regresión desde cero | 20 min | Teoría · viernes 30/10 |
| `S05.3 Estadistica con Python y CRUD.pdf` | Estadística con Python y CRUD | 15 min | Teoría · martes 3/11 |

**Material de las actividades**

Cuadernos en orden (5 h). Cada ejercicio se autocorrige con un `assert`: si falla, lee el mensaje y corrige.

| Cuaderno | Tema | Colab |
|---|---|---|
| `S05_01_numpy` | Arrays, vectorización, *broadcasting* | Abrir en Colab |
| `S05_02_algebra_lineal` | Matrices, sistemas, ecuación normal | Abrir en Colab |
| `S05_03_gradiente_regresion` | Descenso del gradiente y regresión desde cero | Abrir en Colab |
| `S05_04_estadistica_descriptiva_ic` | Descriptiva, Monte Carlo, intervalos de confianza | Abrir en Colab |
| `S05_05_contrastes_causalidad` | Contrastes, causalidad, `statsmodels`, Bayes | Abrir en Colab |
| `S05_06_crud_python` | CRUD con `sqlite3` y `mongomock` | Abrir en Colab |

## Orden de trabajo del sprint

Sigue los pasos **en este orden**: primero la teoría, después la práctica que la aplica y, por último, el reto. Los tiempos son orientativos; si el docente cambia el ritmo, mantén el orden.

**Viernes 30/10**

| Nº | Tipo | Qué se hace | Tiempo |
|---|---|---|---|
| 1 | Ceremonia | Planning del reto «¿La ocupación depende de esto?» | 10 min |
| 2 | Teoría | NumPy y álgebra lineal: vectorización y *broadcasting* | 15 min |
| 3 | Práctica | Arrays, vectorización y *broadcasting* | 35 min |
| 4 | Práctica | Matrices, sistemas y ecuación normal | 35 min |
| 5 | Teoría | Descenso del gradiente y regresión desde cero | 20 min |
| 6 | Práctica | Descenso del gradiente y regresión desde cero | 1 h 10 min |
| 7 | Práctica | Terminad los cuadernos pendientes, incluido el apartado «en casa», y poneos al día | 15 min |

**Martes 3/11**

| Nº | Tipo | Qué se hace | Tiempo |
|---|---|---|---|
| 8 | Teoría | Estadística con Python y CRUD | 15 min |
| 9 | Práctica | Descriptiva, Monte Carlo e intervalos de confianza | 35 min |
| 10 | Práctica | Contrastes, causalidad, `statsmodels` y Bayes | 35 min |
| 11 | Práctica | CRUD con `sqlite3` y `mongomock` (es también el paso 1 del reto: cargar los datos en una base) | 30 min |

| Nº | Tipo | Qué se hace | Tiempo |
|---|---|---|---|
| 12 | Reto | Cuaderno `S05_07`: mirar los datos → regresión desde cero → comparar con una librería → medir la seguridad del resultado → responder en 150 palabras (pasos 2–6) | 45 min |
| 13 | Ceremonia | Entrega en `sprint-05/`, autoevaluación y coevaluación, review y retrospectiva | 40 min |

## RETO Reto · «¿La ocupación depende de esto?»

Reto en PDF · ecofriendly · Cómo se trabaja un reto

**Ver el reto completo, explicado paso a paso** (qué se pide, cómo hacerlo, cómo usar la IA, errores frecuentes y autoevaluación).

**Contexto:** TurisData Canarias quiere saber cuánto cambia la ocupación con la temperatura y los festivos, y con cuánta seguridad. Tenéis su serie diaria de tres años (`ocupacion_diaria.csv`).

**Entregáis** (en la carpeta `sprint-05/` del repositorio del equipo):

- El cuaderno `S05_07_reto_ocupacion` (plantilla: Abrir en Colab), ejecutado de arriba abajo.
- La base `turisdata_reto.db` con la serie cargada y leída con SQL.
- Regresión desde cero (simple y con estacionalidad), comparada con `statsmodels`.
- Contraste, intervalos de confianza y p-valores, y una respuesta al cliente de máx. 150 palabras.

**Reglas:**

- Unas 2 h 30 min de reto; el descenso del gradiente lo escribís vosotros (la librería solo para contrastar).
- Semillas fijas; datos sintéticos, sin generalizar al turismo real.
- Nunca claves ni datos personales.

**Se valora:** corrección técnica, reproducibilidad, comunicación al cliente e IA responsable, más cifras con su incertidumbre y distinguir correlación de causalidad.

## Definition of Done · antes de cerrar el sprint

- [ ] Todos los `assert` del cuaderno pasan y reiniciar y ejecutar todo funciona
- [ ] `turisdata_reto.db` con la tabla `ocupacion_diaria` (1096 filas)
- [ ] Regresión coincide con `statsmodels`; hay p-valor, intervalo y tamaño del efecto interpretados
- [ ] Respuesta al cliente (≤ 150 palabras) con recomendación y límites
- [ ] Entregable subido a la carpeta `sprint-05/` del repositorio del equipo
- [ ] Autoevaluación y coevaluación rellenadas