ETAPA B · CONSTRUIR · SPRINT 5 DE 17

# README Sprint S05 · Matemáticas y estadística en código

*¿podemos demostrar con código lo que vimos en teoría?*

**FECHAS**
4–5 de noviembre

**HORAS**
9 h (2 h teoría · 4 h práctica, incluye 1 h de CRUD · 3 h PBL)

**ESTE README EN PDF**
a color · ecofriendly, para imprimir (descárgalo para que funcionen los enlaces; la vista previa de GitHub no los abre).

## Qué aprenderás

1. A manejar **datos numéricos con NumPy**: arrays, vectorización, *broadcasting* y álgebra lineal.
2. A **entrenar un modelo desde cero**: entender el gradiente y programar la regresión lineal con descenso del gradiente.
3. A hacer **estadística con Python**: describir datos, usar distribuciones, simular (Monte Carlo) y construir intervalos de confianza.
4. A **contrastar hipótesis** e interpretar p-valores, tamaños de efecto y la diferencia entre **correlación y causalidad**.
5. A hacer **CRUD desde Python** sobre SQLite y MongoDB y a dejar una base de datos poblada.

## Requisitos previos

- Haber hecho el Sprint 4 (Python básico, funciones, ficheros).
- Colab o Jupyter con Python 3.11. Los cuadernos usan `numpy`, `pandas`, `matplotlib`, `scipy`, `statsmodels`, `scikit-learn`, `sqlite3` y `mongomock`.
- Los datos (`ocupacion_diaria.csv`, `reservas_turisdata.csv`, `turisdata.db`) se descargan solos. Son **sintéticos**: sirven para practicar, no son estadísticas reales del turismo canario.

## Materiales del sprint

**Documentos del curso** (PDF y .md; las actividades van en la tabla siguiente)

| Material | Tema | Tiempo | Cuándo |
|---|---|---|---|
| Guía del sprint (PDF) · ecofriendly | Resumen del sprint: qué aprenderás, temario, material, reto y conclusión | 2 páginas | Antes de empezar |
| **Código explicado de los cuadernos** | Cada cuaderno explicado por escrito: recorrido de 10 minutos con el docente, glosario de sus palabras de código y qué hace cada celda y cada línea (para leerlo con calma, mientras o después de ejecutar) | A tu ritmo | Con cada cuaderno |
| **Carpeta del reto: `Reto_S05/`** | Todo el material del reto junto: ficha (.md y PDF), hoja de autoevaluación y coevaluación y láminas del reto | — | Antes del planning y durante el reto |

| Material | Tema | Tiempo | Cuándo |
|---|---|---|---|
| **Reto en una página** (.md) · PDF · ecofriendly | Lo esencial para trabajar con la ficha abierta: tres niveles (mínimo, estándar, extra), reparto del tiempo y frases para el informe | 1 página | Durante el reto |
| Reto completo, paso a paso (.md) · PDF · ecofriendly | Qué pide el cliente, pasos, rúbrica, ayudas y errores frecuentes | — | Antes del planning y durante el reto |
| Resumen del sprint en una página | Lámina con la pregunta guía, qué aprenderás, cómo se reparte el sprint (teoría, práctica y reto) y dónde estás en el curso | — | Antes del planning |
| El reto paso a paso · PDF con enlaces | Los pasos del reto con su día y minutos, el material de cada paso, los errores frecuentes y el uso de la IA | — | Durante el reto |
| Esquema del contenido y su relación con el reto | Qué presentación prepara cada pieza del entregable, con el material que se reutiliza después | — | Antes del planning y como guía durante el reto |
| Infografías del sprint | 2 láminas ilustradas | — | Antes del planning y durante el reto |
| Cómo se trabaja un reto | El método de trabajo de todos los retos | — | Antes del primer reto |
| `S05.1_NumPy_y_algebra_lineal.pdf` | NumPy y álgebra lineal: vectorización y *broadcasting* | 15 min | Teoría · día 1 del S05 |
| `S05.2_Descenso_del_gradiente_y_regresion_desde_cero.pdf` | Descenso del gradiente y regresión desde cero | 20 min | Teoría · día 1 del S05 |
| `S05.3_Estadistica_con_Python_y_CRUD.pdf` | Estadística con Python y CRUD | 15 min | Teoría · día 2 del S05 |

**Material de las actividades**

Cuadernos en orden (unas 4 h en clase). Cada ejercicio se autocorrige con un `assert`: si falla, lee el mensaje y corrige.

| Cuaderno | Tema | Colab |
|---|---|---|
| `apuntes_numpy_gradiente_y_estadistica.md` · PDF · ecofriendly | **Apuntes que complementan las diapositivas**: NumPy, descenso del gradiente, intervalos de confianza, contrastes, correlación y causalidad, y CRUD en Python explicados paso a paso con ejemplos que puedes comprobar a mano | Cuando quieras repasar la teoría |

| Cuaderno | Tema | Colab |
|---|---|---|
| `S05_01_numpy` | Arrays, vectorización, *broadcasting* | Abrir en Colab |
| `S05_02_algebra_lineal` | Matrices, sistemas, ecuación normal | Abrir en Colab |
| `S05_03_gradiente_regresion` | Descenso del gradiente y regresión desde cero | Abrir en Colab |
| `S05_04_estadistica_descriptiva_ic` | Descriptiva, Monte Carlo, intervalos de confianza | Abrir en Colab |
| `S05_05_contrastes_causalidad` | Contrastes, causalidad, `statsmodels`, Bayes | Abrir en Colab |
| `S05_06_crud_python` | CRUD con `sqlite3` y `mongomock` | Abrir en Colab |

## Orden de trabajo del sprint

Sigue los pasos **en este orden**: primero la teoría, después la práctica que la aplica y, por último, el reto. Los tiempos son orientativos; si el docente cambia el ritmo, mantén el orden.

**Día 1 del S05**

| Nº | Tipo | Qué se hace | Tiempo |
|---|---|---|---|
| 1 | Ceremonia | Planning del reto «¿La ocupación depende de esto?» | 10 min |
| 2 | Teoría | NumPy y álgebra lineal: vectorización y *broadcasting* | 25 min |
| 3 | Práctica | Arrays, vectorización y *broadcasting* (los ejercicios marcados «en clase») | 30 min |
| 4 | Teoría | Descenso del gradiente y regresión desde cero | 20 min |

**Día 2 del S05**

| Nº | Tipo | Qué se hace | Tiempo |
|---|---|---|---|
| 5 | Práctica | Descenso del gradiente y regresión desde cero (los ejercicios marcados «en clase») | 40 min |
| 6 | Teoría | Estadística con Python y CRUD | 20 min |
| 7 | Práctica | Descriptiva, Monte Carlo e intervalos de confianza (los ejercicios marcados «en clase») | 30 min |
| 8 | Práctica | CRUD con `sqlite3` y `mongomock` (es también el paso 1 del reto: cargar los datos en una base) | 25 min |
| 9 | Reto | Cuaderno `S05_07`: mirar los datos → regresión desde cero → comparar con una librería → medir la seguridad del resultado → responder en 150 palabras (pasos 2–6) | 45 min |
| 10 | Ceremonia | Entrega en `sprint-05/`, autoevaluación y coevaluación, y review y retrospectiva de los Sprints 4 y 5 | 40 min |

### RETO Reto · «¿La ocupación depende de esto?»

Reto en PDF · ecofriendly · Cómo se trabaja un reto

**Ver el reto completo, explicado paso a paso** (qué se pide, cómo hacerlo, cómo usar la IA, errores frecuentes y autoevaluación).

**Contexto:** TurisData Canarias quiere saber cuánto cambia la ocupación con la temperatura y los festivos, y con cuánta seguridad. Tenéis su serie diaria de tres años (`ocupacion_diaria.csv`).

**Entregáis** (en la carpeta `sprint-05/` del repositorio del equipo):

- El cuaderno `S05_07_reto_ocupacion` (plantilla: Abrir en Colab), ejecutado de arriba abajo.
- La base `turisdata_reto.db` con la serie cargada y leída con SQL.

- Regresión desde cero (simple y con estacionalidad), comparada con `statsmodels`.
- Contraste, intervalos de confianza y p-valores, y una respuesta al cliente de máx. 150 palabras.

**Reglas:**

- Unas 1 h 35 min entre el planning, el reto y la entrega; el descenso del gradiente lo escribís vosotros (la librería solo para contrastar).
- Semillas fijas; datos sintéticos, sin generalizar al turismo real.
- Nunca claves ni datos personales.

**Se valora:** corrección técnica, reproducibilidad, comunicación al cliente e IA responsable, más cifras con su incertidumbre y distinguir correlación de causalidad.

## Definition of Done · antes de cerrar el sprint

- [ ] Todos los `assert` del cuaderno pasan y reiniciar y ejecutar todo funciona
- [ ] `turisdata_reto.db` con la tabla `ocupacion_diaria` (1096 filas)
- [ ] Regresión coincide con `statsmodels`; hay p-valor, intervalo y tamaño del efecto interpretados
- [ ] Respuesta al cliente (≤ 150 palabras) con recomendación y límites
- [ ] Entregable subido a la carpeta `sprint-05/` del repositorio del equipo
- [ ] Autoevaluación y coevaluación rellenadas