README Sprint S05 · Matemáticas y estadística en código

¿podemos demostrar con código lo que vimos en teoría?

FECHAS
30/10 y 3/11

HORAS
12 h (3 h teoría · 6 h práctica, incluye 1 h de CRUD · 3 h PBL)

ESTE README EN PDF
a color · ecofriendly, para imprimir (descárgalo para que funcionen los enlaces; la vista previa de GitHub no los abre).

Qué aprenderás

1. A manejar **datos numéricos con NumPy**: arrays, vectorización, *broadcasting* y álgebra lineal.
2. A **entrenar un modelo desde cero**: entender el gradiente y programar la regresión lineal con descenso del gradiente.
3. A hacer **estadística con Python**: describir datos, usar distribuciones, simular (Monte Carlo) y construir intervalos de confianza.
4. A **contrastar hipótesis** e interpretar p-valores, tamaños de efecto y la diferencia entre **correlación y causalidad**.
5. A hacer **CRUD desde Python** sobre SQLite y MongoDB y a dejar una base de datos poblada.

Requisitos previos

- Haber hecho el Sprint 4 (Python básico, funciones, ficheros).
- Colab o Jupyter con Python 3.11. Los cuadernos usan `numpy`, `pandas`, `matplotlib`, `scipy`, `statsmodels`, `scikit-learn`, `sqlite3` y `mongomock`.
- Los datos (`ocupacion_diaria.csv`, `reservas_turisdata.csv`, `turisdata.db`) se descargan solos. Son **sintéticos**: sirven para practicar, no son estadísticas reales del turismo canario.

Materiales del sprint

Documentos del curso (PDF y .md; las actividades van en la tabla siguiente)

Material	Tema	Tiempo	Cuándo
Guía del sprint (PDF) · ecofriendly	Resumen del sprint: qué aprenderás, temario, material, reto y conclusión	2 páginas	Antes de empezar
Carpeta del reto: `Reto_S05/`	Todo el material del reto junto: ficha (.md y PDF), hoja de autoevaluación y coevaluación y láminas del reto	—	Antes del planning y durante el reto
Reto completo, paso a paso (.md) · PDF · ecofriendly	Qué pide el cliente, pasos, rúbrica, ayudas y errores frecuentes	—	Antes del planning y durante el reto
Resumen del sprint en una página	Lámina con la pregunta guía, qué aprenderás, cómo se reparte el sprint (teoría, práctica y reto) y dónde estás en el curso	—	Antes del planning

Material	Tema	Tiempo	Cuándo
El reto paso a paso · PDF con enlaces	Los pasos del reto con su día y minutos, el material de cada paso, los errores frecuentes y el uso de la IA	—	Durante el reto
Esquema del contenido y su relación con el reto	Qué presentación prepara cada pieza del entregable, con el material que se reutiliza después	—	Antes del planning y como guía durante el reto
Infografías del sprint	2 láminas ilustradas	—	Antes del planning y durante el reto
Cómo se trabaja un reto	El método de trabajo de todos los retos	—	Antes del primer reto
`S05.1_NumPy_y_algebra_lineal.pdf`	NumPy y álgebra lineal: vectorización y *broadcasting*	15 min	Teoría · día 1 del S05
`S05.2_Descenso_del_gradiente_y_regresion_desde_cero.pdf`	Descenso del gradiente y regresión desde cero	20 min	Teoría · día 1 del S05
`S05.3_Estadistica_con_Python_y_CRUD.pdf`	Estadística con Python y CRUD	15 min	Teoría · día 2 del S05

Material de las actividades

Cuadernos en orden (5 h). Cada ejercicio se autocorrige con un `assert`: si falla, lee el mensaje y corrige.

Cuaderno	Tema
`apuntes_numpy_gradiente_y_estadistica.md` · PDF · ecofriendly	**Apuntes que complementan las diapositivas**: NumPy, descenso del gradiente, intervalos de confianza, contrastes, correlación y causalidad, y CRUD en Python explicados paso a paso con ejemplos que puedes comprobar a mano
`S05_01_numpy`	Arrays, vectorización, *broadcasting*
`S05_02_algebra_lineal`	Matrices, sistemas, ecuación normal
`S05_03_gradiente_regresion`	Descenso del gradiente y regresión desde cero
`S05_04_estadistica_descriptiva_ic`	Descriptiva, Monte Carlo, intervalos de confianza
`S05_05_contrastes_causalidad`	Contrastes, causalidad, `statsmodels`, Bayes
`S05_06_crud_python`	CRUD con `sqlite3` y `mongomock`

Orden de trabajo del sprint

Sigue los pasos **en este orden**: primero la teoría, después la práctica que la aplica y, por último, el reto. Los tiempos son orientativos; si el docente cambia el ritmo, mantén el orden.

Día 1 del S05

Nº	Tipo	Qué se hace	Tiempo
1	Ceremonia	Planning del reto «¿La ocupación depende de esto?»	10 min
2	Teoría	NumPy y álgebra lineal: vectorización y *broadcasting*	15 min
3	Práctica	Arrays, vectorización y *broadcasting*	35 min
4	Práctica	Matrices, sistemas y ecuación normal	35 min
5	Teoría	Descenso del gradiente y regresión desde cero	20 min
6	Práctica	Descenso del gradiente y regresión desde cero	1 h 10 min
7	Práctica	Terminad los cuadernos pendientes, incluido el apartado «en casa», y poneos al día	15 min

Día 2 del S05

Nº	Tipo	Qué se hace	Tiempo
8	Teoría	Estadística con Python y CRUD	15 min
9	Práctica	Descriptiva, Monte Carlo e intervalos de confianza	35 min
10	Práctica	Contrastes, causalidad, `statsmodels` y Bayes	35 min
11	Práctica	CRUD con `sqlite3` y `mongomock` (es también el paso 1 del reto: cargar los datos en una base)	30 min
12	Reto	Cuaderno `S05_07`: mirar los datos → regresión desde cero → comparar con una librería → medir la seguridad del resultado → responder en 150 palabras (pasos 2–6)	45 min
13	Ceremonia	Entrega en `sprint-05/`, autoevaluación y coevaluación, review y retrospectiva	40 min

RETO Reto · «¿La ocupación depende de esto?»

Reto en PDF · ecofriendly · Cómo se trabaja un reto

Ver el reto completo, explicado paso a paso (qué se pide, cómo hacerlo, cómo usar la IA, errores frecuentes y autoevaluación).

Contexto: TurisData Canarias quiere saber cuánto cambia la ocupación con la temperatura y los festivos, y con cuánta seguridad. Tenéis su serie diaria de tres años (`ocupacion_diaria.csv`).

Entregáis (en la carpeta `sprint-05/` del repositorio del equipo):

- El cuaderno `S05_07_reto_ocupacion` (plantilla: Abrir en Colab), ejecutado de arriba abajo.
- La base `turisdata_reto.db` con la serie cargada y leída con SQL.
- Regresión desde cero (simple y con estacionalidad), comparada con `statsmodels`.
- Contraste, intervalos de confianza y p-valores, y una respuesta al cliente de máx. 150 palabras.

Reglas:

- Unas 2 h 30 min de reto; el descenso del gradiente lo escribís vosotros (la librería solo para contrastar).
- Semillas fijas; datos sintéticos, sin generalizar al turismo real.
- Nunca claves ni datos personales.

Se valora: corrección técnica, reproducibilidad, comunicación al cliente e IA responsable, más cifras con su incertidumbre y distinguir correlación de causalidad.

Definition of Done · antes de cerrar el sprint

- ☐ Todos los `assert` del cuaderno pasan y reiniciar y ejecutar todo funciona
- ☐ `turisdata_reto.db` con la tabla `ocupacion_diaria` (1096 filas)

- [ ] Regresión coincide con `statsmodels`; hay p-valor, intervalo y tamaño del efecto interpretados
- [ ] Respuesta al cliente (≤ 150 palabras) con recomendación y límites
- [ ] Entregable subido a la carpeta `sprint-05/` del repositorio del equipo
- [ ] Autoevaluación y coevaluación rellenadas