IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Conocer los datos con pandas

Mirar la tabla con calma antes de modelar

Sprint 6 · S06_01 · 55 min en clase (ejercicios 1, 2, 3 y 6)

PANDAS · EJERCICIO 1

Una tabla con nombre: el DataFrame

pandas es la librería de Python para trabajar con tablas; una tabla de pandas es un **DataFrame**: cada **fila** es una reserva y cada **columna**, una característica. **NaN** marca un hueco: un dato que falta.

reserva	canal	noches	precio_noche	fecha_llegada	cancelada
101	web	3	85	2026-03-10	0
102	directo	2	120	2026-03-14	0
103	web	5	70	2026-04-02	1
104	agencia	4	NaN	2026-04-09	1
105	web	2	95	2026-05-21	1

Mirar la tabla antes de modelar se llama EDA: análisis exploratorio de datos.

LOS CUATRO PRIMEROS COMANDOS · EJERCICIO 1

Siempre se empieza así

```
# CSV: fichero de texto con una reserva por línea y los valores separados por comas
df = pd.read_csv("mini.csv", parse_dates=["fecha_llegada"])
filas, columnas = df.shape    # (5, 6): 5 filas y 6 columnas
df.info()                     # precio_noche: 4 no nulos de 5
df.head()                     # las 5 primeras filas
df.describe()                 # noches: media 3.2, de 2 a 5
```

parse_dates

Lee la fecha **como fecha** (**datetime64**) y no como texto (**object**).

¿Faltan datos?

Si los **no nulos** de **info** son menos que las filas, **faltan valores**.

FILTRAR Y AGRUPAR · EJERCICIO 2

Quedarse solo con lo que interesa

Una **condición** da verdadero o falso para cada fila, y pandas se queda con las filas verdaderas.

```
df[df["canal"] == "web"]                                  # 3 filas: 101, 103 y 105
df[(df["noches"] > 3) & (df["canal"] == "agencia")]       # 1 fila: 104
df[(df["canal"] == "directo") | (df["noches"] > 4)]       # 2 filas: 102 y 103
```

& significa «y»

Se cumplen **las dos** condiciones a la vez.

| significa «o»

Basta con que se cumpla **una**.

Entre paréntesis

Cada condición lleva el suyo. Con **and** u **or**, pandas da error.

AGRUPAR · EJERCICIO 2

La media de un 0/1 es una tasa

canal	cancelada
web	0
directo	0
web	1
agencia	1
web	1

```
tasa = df.groupby("canal")["cancelada"].mean().round(2)
# agencia 1.00 · directo 0.00 · web 0.67
tasa.sort_values(ascending=False)
# agencia 1.00 · web 0.67 · directo 0.00
```

groupby agrupa las filas por canal y calcula **una media por grupo**. Como **cancelada** vale 0 o 1, esa media es la **tasa de cancelación**: la web cancela 2 de 3, es decir, 0,67.

✓ Compruébalo a mano: web = (0 + 1 + 1) / 3 = 0,67

UNIR TABLAS · EJERCICIO 3

Unir dos tablas con merge

Reservas

reserva	mes_llegada
101	3
102	3
103	4
104	5

Temporadas

mes_llegada	temporada
3	baja
4	alta
6	alta

Resultado

reserva	mes_llegada	temporada
101	3	baja
102	3	baja
103	4	alta
104	5	NaN

```
# on: la columna común · how="left": conserva todas las reservas
resultado = reservas.merge(temporadas, on="mes_llegada", how="left")
len(reservas), len(resultado)          # (4, 4): no se perdió ninguna
resultado["temporada"].isna().sum()    # 1: la 104 no tiene pareja
```

ELEGIR EL GRÁFICO · EJERCICIO 4 (CASA)

El gráfico depende del dato

Quiero ver…	Gráfico	Cómo se lee
Una numérica	Histograma	Cuántas reservas caen en cada tramo
Una categórica	Barras	Una barra por categoría: cuántas hay
Numérica por categoría	Diagrama de cajas	Caja = 50 % central · línea = mediana · puntos = datos raros
Dos numéricas	Dispersión	Un punto por reserva: ¿suben juntas?
Una fecha	Línea	El eje horizontal es el tiempo

```
# precios: estandar 60 y 70 · superior 90, 100 y 110 · familiar 140 y 150
mediana = df.groupby("tipo")["precio"].median()    # estandar 65 · familiar 145 · superior 100
mediana.plot(kind="bar")                           # una barra por tipo
```

pandas dibuja con **matplotlib**; **seaborn** añade gráficos estadísticos (cajas, dispersión, mapas de calor) con menos código.

CORRELACIONES · EJERCICIO 5 (CASA)

¿Qué variables se mueven juntas?

	noches	precio_noche	cancelada
noches	1,00	−0,62	−0,72
precio_noche	−0,62	1,00	0,23
cancelada	−0,72	0,23	1,00

La correlación va de **−1 a 1**: el **signo** dice la dirección y el **tamaño**, la fuerza. Aquí, a más noches, menos cancelaciones. Solo detecta relaciones «en línea recta».

```
r = corr["cancelada"].drop("cancelada")  # noches -0.72 · precio_noche 0.23
r.abs()                                  # noches 0.72 · precio_noche 0.23
r.abs().idxmax()                         # 'noches': la más ligada, aunque sea negativa
```

Correlación no es causalidad: que se muevan juntas no prueba que una cause la otra.

CALIDAD DEL DATO · EJERCICIO 6

Primer chequeo: duplicados y vacíos

reserva	canal	noches	precio_noche
101	web	3	85
102	directo	2	NaN
103	web	5	70
103	web	5	70
104	agencia	0	95
105	web	2	NaN

```
df.duplicated().sum()                    # 1
df["precio_noche"].isna().sum()          # 2
df["precio_noche"].isna().mean() * 100   # 33.33…
df["noches"].min()                       # 0
```

isna() marca con **True** cada celda vacía, y la **media** de **True**/**False** es la **proporción**: 2 de 6 = 33,3 %. Un **valor imposible** (0 noches) también es un defecto.

MINI-RETO · TRES HALLAZGOS (CASA)

De la cifra a la frase del gerente

Poco útil	Útil para un gerente
La media de **cancelada** por tarifa es 0,75 y 0,25.	Con tarifa flexible **cancela el 75 %** de las reservas, **3 veces más** que con la no reembolsable (25 %).

Una cifra

Que hayas calculado tú.

Una comparación

Frente a otro grupo o periodo.

Sin jerga

Sin **groupby** ni **NaN**: se entiende sin saber Python.

Mini-reto: escribe en `hallazgos` tres frases así, con una cifra cada una.

AMPLIACIÓN · DATOS GRANDES (CASA)

Cuando la tabla no cabe en memoria

Truco	Qué hace	Ejemplo
Leer solo lo necesario	Menos columnas y tipos pequeños desde la lectura	`pd.read_csv(ruta, usecols=["canal", "noches"])`
Leer por trozos	Procesa 100 000 filas cada vez, sin cargar todo	`for t in pd.read_csv(ruta, chunksize=100_000):`
Tipos más pequeños	`int8` en vez de `int64`; `category` para textos repetidos	`df["noches"].astype("int8")`
Formato columnar	Parquet: más compacto y rápido de leer que el CSV	`df.to_parquet("datos.parquet")` (necesita `pyarrow`)
Otras herramientas	Cuando pandas ya no basta	Polars, Dask o una base de datos

8 MB → 1 MB

Una columna de **1 000 000** de enteros pequeños ocupa **8 MB** como **int64** y **1 MB** como **int8**.

HOY HAS APRENDIDO

Mirar los datos antes de modelar

Mirar

shape, **info**, **head** y **describe** antes de nada

Preguntar

groupby para comparar grupos y **merge** para unir tablas

Comprobar

El gráfico según el dato; duplicados y vacíos antes de modelar

Siguiente: S06_02 · limpieza (el fichero sucio del cliente).