IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Limpiar datos sin hacer trampas

Teoría, práctica y, al final, material de consulta

Sprint 6 · S06_02 · teoría breve, 55 min de práctica y material de consulta

MÉTODO

Nunca limpies a ciegas

1 · Mide

¿A cuántas filas afecta el defecto?

2 · Decide

Qué hacer con él, y **anota por qué**.

3 · Escribe

El código que lo corrige.

4 · Comprueba

Vuelve a medir: ¿ha mejorado?

```
crudo = pd.read_csv(dato("reservas_sucio.csv"))   # el original: no se toca
d1 = crudo.copy()                                 # paso 1: trabajas en una copia
d2 = d1.copy()                                    # paso 2: otra copia nueva
```

Como en la consulta médica: primero la analítica, después el tratamiento. Con una copia por paso ves **cuánto cambia cada decisión** y puedes volver atrás.

MÉTODO · ACLARACIONES

Original y copias

crudo es el original

Lo cargas una vez con **read_csv** y **no lo modificas nunca**. Si algo sale mal, vuelves a él.

.copy() copia de verdad

Sin **.copy()**, **d1 = crudo** solo pone **otro nombre** al mismo objeto: cambiar **d1** cambiaría también **crudo**.

Una copia por paso

d1 (sin duplicados) → **d2** (precio) → **d3** (fechas) → **d4** (categorías) → **d5** (imposibles): cada una parte de la anterior.

Para qué sirve

Comparando dos copias seguidas ves **cuánto cambió** cada decisión y puedes deshacer un paso sin recargar el fichero.

DIAGNÓSTICO

Mide antes de corregir

Resultado de **resumen_calidad(tabla)** con 6 reservas. **Nulo** = hueco (dato que falta). La última columna la añadimos nosotros.

columna	tipo	nulos	pct_nulos	distintos	así se ven
noches	int64	0	0.00	5	3 · 2 · 4 · 1 · 5 · 2
adultos	float64	1	16.67	3	2.0 · NaN · 3.0 · 2.0 …
canal	object	0	0.00	5	Directo · directo · Agencia · DIRECTO …
precio_noche	object	1	16.67	4	72,50 · 88 · 95.10 · NaN …

precio_noche es object

object es texto: un precio no debería serlo. Aquí lo estropea la **coma**.

adultos es float64

Un entero no admite huecos: con **un nulo** la columna pasa a decimal.

canal: 5 distintos

Solo hay **2 canales**: están mal escritos.

DEFECTOS DE FORMA · UNO POR EJERCICIO

Los datos están, pero mal escritos

Ejercicio	Defecto	Cómo se ve	Por qué estropea el análisis
1	Duplicados	La misma reserva dos veces	Pesa el doble y puede caer a la vez en entrenamiento y en prueba
2	Tipos mal leídos	Un precio guardado como texto	No se puede sumar ni hacer la media
3	Fechas	Dos formatos en la misma columna	«03/04/2025» puede ser 3 de abril o 4 de marzo
4 (casa)	Categorías	Directo, «directo » y DIRECTO	Tres categorías para una sola

Un defecto por ejercicio: en el cuaderno arreglarás uno cada vez, del 1 al 4, en este orden.

Ejercicio 4 · antes: 3 categorías

`Directo` `directo` `DIRECTO`

→

después: 1

`directo`

No adivines: **averigua el origen del dato**. Y cuenta los nulos antes y después de cada conversión: puede crear nuevos.

VALORES IMPOSIBLES Y RAROS

Imposible no es lo mismo que raro

Valor encontrado	¿Qué es?	Qué hago
Precio de –30 € por noche	**Imposible**	Pasarlo a nulo
0 noches de estancia	**Imposible**	Pasarlo a nulo
Antelación de –6 días	**Imposible**	Recalcularla con las fechas
Suite a 420 € cuando el resto ronda 70 €	**Raro, pero posible**	Investigar; no borrar

Imposible: error seguro, se corrige. Raro: un outlier (valor atípico), se investiga.

Quién decide qué es imposible: **el negocio**, no el código.

VALORES RAROS · OUTLIERS

Un valor raro no es un error

Cómo se localiza

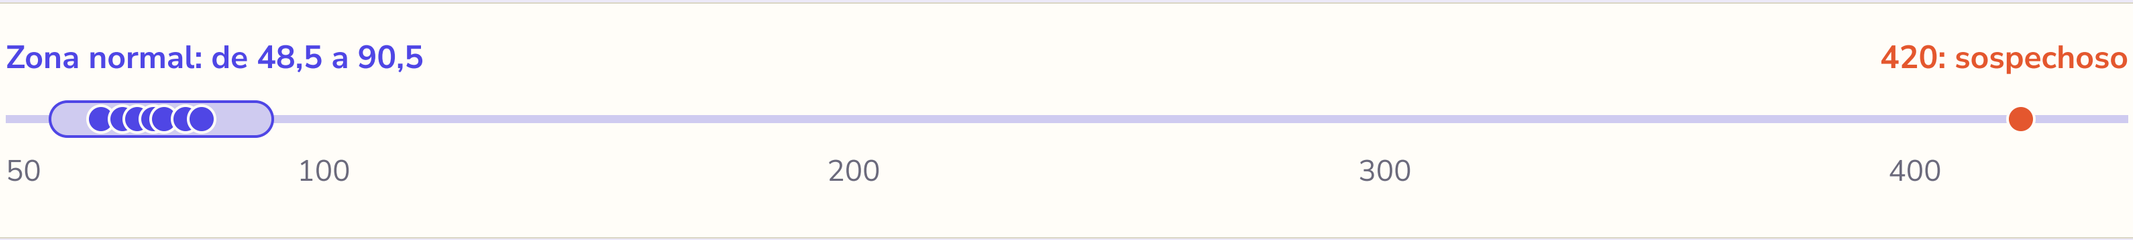
Se compara cada valor con **el grueso de los datos**: lo que queda muy lejos se marca como sospechoso.

La regla del IQR

Se mide el ancho de la zona central (entre el **cuartil 1** y el **cuartil 3**, el IQR) y se marca lo que se aleja más de **1,5 veces** ese ancho.

Marcar no es condenar

Puede ser una errata o una suite de lujo real: **se investiga, no se borra**.



El 1,5 es una convención, no una ley: sirve para señalar, no para decidir.

REGLAS DE NEGOCIO

Qué es imposible lo decide el negocio

La regla viene del negocio

Por ejemplo, un precio por noche **entre 30 y 500 €** o una estancia de **más de 0 noches**. Las pone quien conoce el negocio.

Fuera de la regla, nulo

El valor imposible pasa a **nulo**: queda claro que falta, en vez de falsear un dato.

No borres la fila

El resto de la fila sigue siendo válido: se tacha la casilla mala, no se tira el formulario.



Cuenta los nulos antes y después: la diferencia es lo que has invalidado.

COHERENCIA Y REPRODUCIBILIDAD

Cruza columnas: mandan las fechas

fecha_reserva	fecha_llegada	antelacion_dias	calculada
2025-05-02	2025-05-12	10	10
2025-05-10	2025-06-09	25	30
2025-06-01	2025-06-07	−6	6

```
calc = (r["fecha_llegada"] - r["fecha_reserva"]).dt.days   # 10, 30, 6
(calc != r["antelacion_dias"]).sum()                       # 2 no cuadran
r["antelacion_dias"] = calc                                # las fechas mandan
```

Si no cuadra, la fuente de verdad son las fechas: se recalcula toda la columna.

Reproducible: misma entrada, misma salida, sin arreglar el CSV a mano. Los pasos se juntan en una función.

ACLARACIONES · COHERENCIA

Leer el cálculo de la antelación

Restar dos fechas

Da un intervalo (**Timedelta**), por ejemplo «10 days»: la distancia entre las dos.

.dt.days

Convierte ese intervalo en un **número entero de días**, que sí se puede comparar con la columna.

!= y sum()

calc != antelacion_dias da **True** donde no cuadran; **sum()** las cuenta (2 en el ejemplo).

Por qué mandan las fechas

La antelación es un dato **derivado**: se calcula a partir de las fechas, así que si no cuadra, se recalcula.

NULOS

Un hueco: ¿olvido o respuesta?

Falta al azar

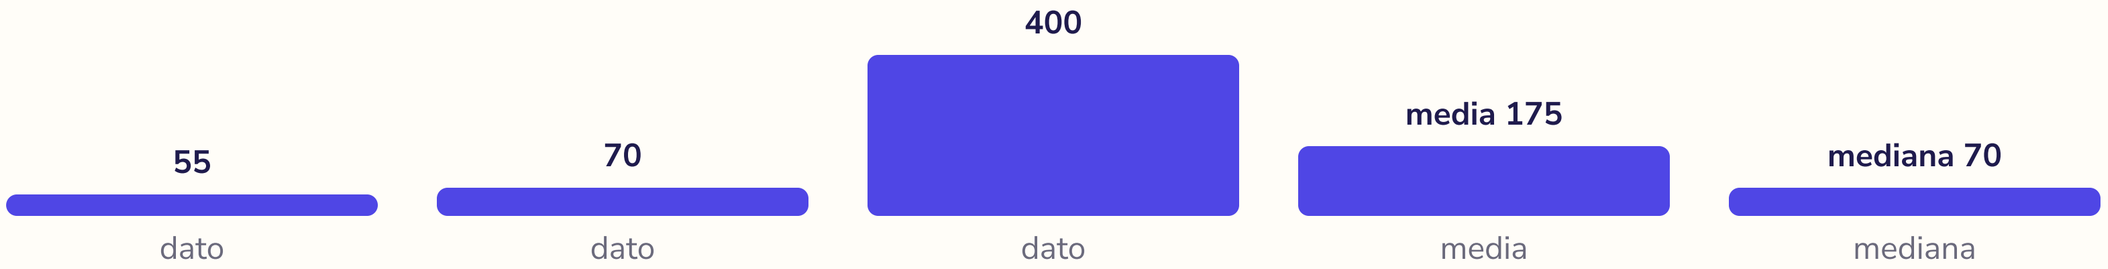
Pocos huecos: **imputar**, es decir, rellenar con la mediana (números) o la moda (texto).

Falta por algo

Un país vacío puede ser información: categoría **desconocido** o columna que avisa.

Falta casi todo

Si la columna está vacía en su mayoría, valora **quitarla**.



Aquí solo contamos y documentamos: imputar se hace dentro de un pipeline (S06_03).

PRÁCTICA · CUADERNO S06_02

Lo que haremos en el cuaderno

Parte	Qué haremos	Dónde
Secciones 1 y 2	Cargar **reservas_sucio.csv** y diagnosticar con **resumen_calidad**	Clase
Ejercicio 1	Contar duplicados y crear **d1** sin ellos, con el índice reiniciado	Clase
Ejercicio 2	Pasar **precio_noche** a número y contar los nulos nuevos	Clase
Ejercicio 3	Leer **fecha_reserva** con sus dos formatos y **fecha_llegada** con el suyo	Clase
Ejercicio 4	Normalizar **canal** y **pais**	Casa
Ejercicio 5	Dos reglas de negocio (precio y noches): lo imposible pasa a nulo	Clase
Sección 7	Cruzar fechas y antelación (se ejecuta y se lee)	Clase
Mini-reto	Función **limpiar_reservas** reproducible, con su resumen	Casa

En cada ejercicio: **mide** → **decide** → **escribe** → **comprueba**. La «Solución de referencia» está plegada: se abre solo después de intentarlo. Tras esta diapositiva: **material de consulta** con el código y las aclaraciones de cada ejercicio.

CONSULTA

Material de consulta: código y aclaraciones

Cuándo abrirlo

Después de intentar el ejercicio, o cuando algo no te salga. En clase no se proyecta.

Cómo está ordenado

En el **mismo orden que el cuaderno**: ejercicio 1, 2, 3, 4, 5 y mini-reto. Cada uno trae su código y sus aclaraciones.

Ejercicio	Tema	Diapositivas
1	Duplicados	14 y 15
2	Tipos mal leídos	16 y 17
3	Fechas	18 y 19
4 (casa)	Categorías	20 y 21
5	Imposibles y reglas de negocio	22, 23 y 24
Mini-reto (casa)	Todo en una función	25 y 26

CONSULTA · DUPLICADOS

La misma reserva, dos veces (ejercicio 1)

id_reserva	noches	duplicated()
301	2	False
302	5	False
302	5	True
303	3	False
304	4	False

```
tabla.duplicated().sum()          # 1
d1 = tabla.drop_duplicates()      # índice 0, 1, 3, 4
d1 = d1.reset_index(drop=True)    # índice 0, 1, 2, 3
```

Por qué quitarlo

La reserva **pesa el doble** y puede acabar en entrenamiento y en prueba a la vez.

Por qué reiniciar el índice

Tras quitar filas el número de fila queda con **huecos**; **reset_index** lo renumera.

CONSULTA · ACLARACIONES · DUPLICADOS

Leer duplicated() (ejercicio 1)

Marca la segunda copia

La primera aparición es **False**; las repeticiones son **True**. Por eso cuenta **1** y no 2.

sum() cuenta los True

Python trata **True** como 1 y **False** como 0: sumar una columna de verdadero/falso **cuenta** cuántos hay.

Ver las dos copias

duplicated(keep=False) marca **todas** las copias, también la primera: sirve para mirarlas antes de borrar.

El índice

Es el número de fila. Tras **drop_duplicates** quedan huecos (0, 1, 3, 4); **reset_index(drop=True)** renumera y **descarta** el índice viejo.

CONSULTA · TIPOS

Números escritos como texto (ejercicio 2)

Texto original	Tras convertir	Qué ha pasado
72,50	72.5	La coma pasa a punto: ya es un número
88	88.0	Sin coma: se convierte igual
vacío (NaN)	NaN	Ya estaba vacío
n/d	NaN	**Nulo nuevo**: coerce lo deja vacío. ¡Cuéntalos antes y después!

```
p = pd.Series(["72,50", "88", np.nan, "n/d"])
p.isna().sum()                                  # 1 nulo antes
n = pd.to_numeric(p.astype(str).str.replace(",", "."), errors="coerce")
n.isna().sum()                                  # 2 nulos después
```

CONSULTA · ACLARACIONES · TIPOS

Leer la conversión a número (ejercicio 2)

object es texto

Basta un valor con coma, como **72,50**, para que pandas lea **toda la columna** como texto.

Por qué **astype(str)**

str.replace solo funciona con texto: se pasa todo a texto, se cambia la coma por punto y **después** se convierte.

errors="coerce"

Lo que no se puede convertir (**n/d**) pasa a **NaN** en vez de dar error. Cómodo, pero **crea nulos nuevos**: cuéntalos.

NaN

Es el hueco de pandas («not a number»). Las medias lo ignoran, pero hay que decidir qué hacer con él.

CONSULTA · FECHAS

Dos formatos, dos lecturas (ejercicio 3)

«03/04/2025»: ¿3 de abril o 4 de marzo? **No adivines: lee cada grupo con su formato.**

texto	iso (año-mes-día)	esp (día/mes/año)	iso.fillna(esp)
2025-03-14	2025-03-14	NaT = fecha vacía	2025-03-14
27/01/2025	NaT	2025-01-27	2025-01-27
03/04/2025	NaT	2025-04-03	2025-04-03

```
iso = pd.to_datetime(f, format="%Y-%m-%d", errors="coerce")
esp = pd.to_datetime(f, format="%d/%m/%Y", errors="coerce")
(iso.isna() & esp.isna()).sum()     # 0: ninguna sin leer
f_ok = iso.fillna(esp)              # fechas completas
```

CONSULTA · ACLARACIONES · FECHAS

Leer los formatos de fecha (ejercicio 3)

format describe el texto

%Y-%m-%d: año de 4 cifras, mes y día, con guiones.
%d/%m/%Y: día, mes y año, con barras.

NaT

Es el **NaN** de las fechas: una fecha vacía. Con **errors="coerce"**, lo que no encaja en el formato queda así.

iso.fillna(esp)

Rellena los huecos de la primera lectura con la segunda: cada fila se queda con la lectura que **sí** funcionó.

Por qué no **mixed**

format="mixed" deja que pandas adivine fila a fila: lee **03/04/2025** como 4 de marzo y **no avisa**.

CONSULTA · CATEGORÍAS

Normalizar categorías (ejercicio 4, casa)

Valores originales	Cómo se arregla	Resultado
Directo · "directo " · DIRECTO	strip y lower (quita espacios, minúsculas)	directo (los 3)
web intermediaria	además, espacio por _	web_intermediaria
España · es · Portugal	diccionario con **map**	ES · ES · PT
Marruecos (no está en el diccionario)	**map** no lo conoce	**NaN**: nulo nuevo

```
canal2 = canal.str.strip().str.lower().str.replace(" ", "_")   # 6 categorías pasan a 3
pais2 = pais.str.strip().str.lower().map(equiv)                # equiv: dict de equivalencias
pais.isna().sum(), pais2.isna().sum()                          # (0, 1): ¡un nulo nuevo!
```

Es para casa. En clase, ejecuta la celda «Solución de referencia» para tener **d4** y seguir con el ejercicio 5.

CONSULTA · ACLARACIONES · CATEGORÍAS

Leer la normalización (ejercicio 4, casa)

El orden importa

Si **replace(" ", "_")** va antes que **strip()**, «directo » (con espacio final) queda como **directo_**. **Primero limpia los bordes.**

lower y no **upper**

upper daría **ESPAÑA**, que no se parece a **ES**: para escrituras distintas hace falta un diccionario.

map con diccionario

Cambia cada valor por su equivalente; lo que **no está** en el diccionario pasa a **NaN**.

Compara antes y después

Cuenta nulos antes y después (**isna().sum()**): si suben, el diccionario no conoce algún valor.

CONSULTA · REGLAS DE NEGOCIO

Convertir los imposibles en nulo (ejercicio 5)

Regla de ejemplo: el precio por noche debe estar **entre 30 y 500 €**.

```
p = pd.Series([64.0, -30.0, 78.5, 5000.0, 91.0, 12.0])
ok = p.between(30, 500)                    # True, False, True, False, True, False
limpio = p.where(ok)                       # 64.0, NaN, 78.5, NaN, 91.0, NaN
limpio.isna().sum() - p.isna().sum()       # 3 valores a nulo
```

between

¿Está en el rango? **Incluye** los dos extremos.

where

Conserva lo que cumple; **el resto pasa a nulo**.

¿Por qué no borrar la fila?

El resto de la fila sigue siendo válido: se tacha la casilla mala, no se tira el formulario.

CONSULTA · ACLARACIONES · REGLAS DE NEGOCIO

Leer between y where (ejercicio 5)

Una máscara

p.between(30, 500) da una serie de **True**/**False** del mismo tamaño que **p**. **Incluye** los dos extremos.

where(ok)

Conserva el valor donde la máscara es **True** y pone **NaN** donde es **False**.

Restar los nulos

limpio.isna().sum() - p.isna().sum() cuenta los nulos **nuevos**: así no sumas los que ya había.

Una regla por columna

En el cuaderno: una regla para **precio_noche** y otra para **noches**; **n_imposibles** suma las dos.

CONSULTA · ACLARACIONES · OUTLIERS

La regla del IQR paso a paso (ejercicio 5)

Precios: 58, 62, 65, 68, 70, 74, 77 y 420.

Paso	Qué es	Valor
Q1 (percentil 25)	Un cuarto de los datos queda por debajo	64,25
Q3 (percentil 75)	Tres cuartos quedan por debajo	74,75
IQR = Q3 − Q1	El ancho del «grueso» de los datos	10,5
Límite superior	Q3 + 1,5 · IQR	90,5
Límite inferior	Q1 − 1,5 · IQR	48,5

Solo el 420 queda fuera de [48,5; 90,5]. El 1,5 es una convención, no una ley.

CONSULTA · MINI-RETO

Todo en una función reproducible (mini-reto, casa)

```
def limpiar_reservas(tabla):
    t = tabla.copy()      # el original no se toca
    resumen = {"filas_antes": len(t)}
    ...                   # tus seis pasos
    return t, resumen
limpio, resumen = limpiar_reservas(crudo)
```

resumen (6 filas de ejemplo)	valor
filas_antes	6
duplicados_quitados	1
imposibles_a_nulo	2
antelaciones_recalculadas	1
filas_despues	5

Pasos, en este orden: **duplicados** → **precio** → **fechas** → **categorías** → **imposibles** → **antelación**.

Reproducible: misma entrada, misma salida. Nada de arreglar el CSV a mano.

CONSULTA · ACLARACIONES · MINI-RETO

Leer la estructura de la función (mini-reto, casa)

Recibe y devuelve

Entra la tabla cruda y salen **dos cosas**: la tabla limpia y el diccionario **resumen**.

El resumen cuenta

Una clave por paso (**filas_antes**, **duplicados_quitados**…): se calcula **midiendo antes y después** de cada paso.

Por qué ese orden

Duplicados primero (para no contar dos veces); precio a número antes de comprobar rangos; fechas antes de recalcular la antelación.

Reproducible

Si mañana llega otro fichero sucio, **limpiar_reservas(otro)** lo limpia con **las mismas reglas**.