IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Medir un modelo con honestidad

Baseline, métricas, validación cruzada y fuga de datos

Sprint 6 · S06_04 · 45 min en clase (ejercicios 1, 4 y 5)

EL PATRÓN DE SCIKIT-LEARN · EJERCICIO 1

Todos los modelos: fit, predict, score

Antelación (días)	5	12	20	35	60	90	120	150
Cancela (1 = sí)	0	0	0	0	1	0	1	1

```
modelo = LogisticRegression().fit(X_train, y_train)  # aprende
modelo.predict(X_test)                               # [0 0 0 0 0 0 0 1 1 1]
modelo.score(X_test, y_test)                         # 0.9
```

fit

Aprende con X (la antelación) e y (si canceló).

predict

Da la **clase** de las 10 reservas nuevas: 0 o 1.

score

La **nota**: el % de aciertos (exactitud).

EL BASELINE · EJERCICIO 1

Primero, un modelo tonto

El **baseline** predice **siempre la clase más frecuente**. Si tu modelo no lo supera claramente, no aporta nada.

10 reservas nuevas	1	2	3	4	5	6	7	8	9	10
Antelación (días)	8	15	22	30	45	55	70	95	130	160
Real (1 = cancela)	0	0	0	0	0	0	0	0	1	1
Baseline	0	0	0	0	0	0	0	0	0	0
Modelo	0	0	0	0	0	0	0	1	1	1

```
tonto = DummyClassifier(strategy="most_frequent").fit(X_train, y_train)
tonto.score(X_test, y_test)                                          # 0.8 (el modelo: 0.9)
round(modelo.score(X_test, y_test) - tonto.score(X_test, y_test), 2)  # 0.1 lo que aporta el modelo
```

Acertar y fallar, de dos formas cada uno

100 reservas	El modelo dice: no cancela	El modelo dice: cancela
Real: no cancela (80)	**70** · VN, acierto	**10** · FP, falsa alarma
Real: cancela (20)	**5** · FN, se nos escapa	**15** · VP, acierto

Positivo = lo que buscamos (que cancele). **Verdadero / falso** = si el modelo acertó. Las filas son la realidad y las columnas, la predicción.

```
confusion_matrix(y_real, y_pred)
# [[70 10]
#  [ 5 15]]
```

MÉTRICAS DE CLASIFICACIÓN

Cuatro notas, cuatro preguntas

Métrica	La pregunta	La cuenta	Resultado
Exactitud	¿Cuántas acierto en total?	(70 + 15) / 100	85 %
Precisión	De las que aviso «cancela», ¿cuántas cancelan?	15 / (15 + 10)	60 %
Recall	De las que cancelan, ¿cuántas encuentro?	15 / (15 + 5)	75 %
F1	Un solo número que equilibra precisión y recall	2 · 0,6 · 0,75 / (0,6 + 0,75)	0,67

¿Cuál mirar? Si perder una cancelación es caro, el **recall**. Si cada aviso cuesta dinero, la **precisión**.

El baseline «nunca cancela»: 80 % de exactitud y 0 % de recall. La exactitud sola engaña.

AUC-ROC · EJERCICIO 4

AUC: ¿ordena bien por riesgo?

Reserva	A	B	C	D	E
Probabilidad de cancelar	0,90	0,20	0,50	0,45	0,30
Real	cancela	no	no	cancela	no

2 que cancelan × 3 que no = **6 parejas**. ¿La que cancela tiene **más probabilidad**? Sí en 5 de 6 (solo falla D, 0,45, contra C, 0,50).

```
y_real = [1, 0, 0, 1, 0]
proba  = [0.9, 0.2, 0.5, 0.45, 0.3]
roc_auc_score(y_real, proba)  # 0.833
```

0,83

AUC = 5 / 6

1 = ordena perfecto · 0,5 = como tirar una moneda

MÉTRICAS DE REGRESIÓN · EJERCICIO 2 (CASA)

Cuando se predice un número

Precio por noche de 5 reservas (€)	A	B	C	D	E
Real	90	110	130	100	120
Predicción	100	105	125	115	120
Error (sin signo)	10	5	5	15	0

7 €

MAE

Error medio, en euros: (10 + 5 + 5 + 15 + 0) / 5.

mean_absolute_error

8,66 €

RMSE

Como el MAE, pero **castiga más** el error de 15.

mean_squared_error(...) ** 0.5

0,625

R^2

1 = perfecto · 0 = no mejora a predecir la media (110 €, MAE de 12 €).

r2_score

SOBREAJUSTE Y SESGO-VARIANZA · EJERCICIO 3 (CASA)

Memorizar no es aprender

Profundidad del árbol (nº de preguntas)	1	3	6	10
Acierto en entrenamiento	79,2 %	89,2 %	95,8 %	100 %
Acierto en prueba	73,8 %	85,0 %	72,5 %	68,8 %

Infraajuste

Muy simple: **alto sesgo**. Falla hasta en el entrenamiento.

Punto bueno

Entrenamiento y prueba **altos y parecidos**.

Sobreajuste

Memoriza: **alta varianza**. Brilla en el entrenamiento y falla en la prueba.

Si el entrenamiento sigue subiendo y la prueba baja, hay sobreajuste.

VALIDACIÓN CRUZADA · EJERCICIO 4

Cinco exámenes en vez de uno

	Ronda 1	Ronda 2	Ronda 3	Ronda 4	Ronda 5
Valida con	trozo 1	trozo 2	trozo 3	trozo 4	trozo 5
Entrena con	los otros 4	los otros 4	los otros 4	los otros 4	los otros 4
AUC	0,94	0,78	0,79	0,83	0,88

```
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=0)
notas = cross_val_score(modelo, X, y, cv=cv, scoring="roc_auc")
notas.mean(), notas.std()  # (0.843, 0.059)
```

Media 0,84: tu nota. Desviación 0,06: cuánto depende de la suerte (pequeña = estable).

FUGA DE DATOS · EJERCICIO 5

La prueba: ¿lo sabía al reservar?

Fuga de datos = el modelo usa información que **no tendría en el momento de predecir**.

Columna del hotel	¿Se conoce al reservar?	Decisión
canal	Sí: se elige al reservar	Se puede usar
noches	Sí: se indican al reservar	Se puede usar
habitacion_liberada	No: el hotel la marca al cancelar	**Fuga**
opinion_estancia	No: se escribe después de alojarse	**Fuga**
hora_checkin_real	No: solo existe si el cliente llega	**Fuga**

AUC sin la columna: 0,84

Un modelo honesto, con lo que se sabe al reservar.

AUC con **habitacion_liberada**: 0,99

¡Demasiado bueno! Desconfía: es la señal de fuga.

PARTICIÓN TEMPORAL · EJERCICIO 6 (CASA)

Con fechas, valida en el tiempo

Corte	Entrena con (el pasado)	Evalúa con (el futuro)
1	ene, feb, mar, abr	may, jun
2	ene a jun	jul, ago
3	ene a ago	sep, oct

```
cortes = TimeSeriesSplit(n_splits=3)
for pasado, futuro in cortes.split(X):
    print(pasado, futuro)  # 1.er corte: [0 1 2 3] [4 5]
```

Mezclando al azar

Puede evaluar **mar y sep** y entrenar con abr a ago y oct: el modelo **ha visto el futuro**.

10 reservas, una por mes y **ordenadas por fecha**: **TimeSeriesSplit** siempre entrena con el pasado y evalúa con lo más reciente.

MINI-RETO · TABLA DE RESULTADOS HONESTA (CASA)

Baseline y modelo, lado a lado

modelo	auc_cv_media	auc_cv_desv
baseline	0,50	0,00
logistica	0,84	0,06

Cómo se lee

Misma validación cruzada de 5 trozos para los dos. La **media** es la nota; la **desviación**, la estabilidad. El baseline siempre da 0,50.

Tu conclusión, en una frase

«Compensa: pasa de 0,50 a 0,84 y es estable.» Si no ganara con claridad al baseline, dirías que **no compensa**.

Ejemplo de un hotel imaginario. Pista: guarda las 5 notas de cada modelo en un diccionario y calcula **mean()** y **std()**.

HOY HAS APRENDIDO

Medir bien antes de presumir

Baseline

Siempre un modelo tonto que batir

Métricas

Según lo que cueste equivocarse: precisión, recall, AUC, MAE

Honestidad

Validación cruzada, sin fuga y, con fechas, en el tiempo

Siguiente: el reto del sprint y, después, el Sprint 7: modelos de regresión y clasificación.