Sprint 6 · Resultados de los cuadernos (sin código)

IFCD107 · Especialista en Inteligencia Artificial

- **Para explicar a clase** qué pide cada ejercicio y qué se obtiene, sin enseñar código.
- **Clase** = ejercicio del cuaderno «en clase» · **Casa** = solo en el cuaderno completo (`para_casa/`).
- Los números son los que salen al ejecutar los cuadernos con los datos del curso (turisdata).

S06_01 · Pandas: explorar los datos (EDA)

Ej.	Qué pide	Qué obtenemos
1 · clase	Cargar las reservas (con las fechas bien leídas) y mirar sus dimensiones	**6 000 reservas** y **18 columnas**
2 · clase	Tasa de cancelación según el depósito, de mayor a menor	Sin depósito **54 %** · parcial **41 %** · total **26 %**: cuanto más se paga por adelantado, menos se cancela
3 · clase	Unir las reservas con la tabla de temporadas sin perder ninguna y comparar cancelaciones	Temporada alta **47.9 %** · baja **43.8 %**; siguen siendo 6 000 filas (con 2 columnas más)
4 · casa	Mediana del precio por tipo de habitación y gráfico de barras	Estándar **77.6 €** · superior **105.7 €** · familiar **123.0 €** · suite **175.5 €**; la suite es la más cara
5 · casa	Qué variable se relaciona más con cancelar (mapa de correlaciones)	**Antelación de la reserva** (0.28): cuanto antes se reserva, más se cancela
6 · clase	Contar filas repetidas y el porcentaje de nulos en el país de origen	**0** filas repetidas · **2.3 %** de nulos en `pais_origen`

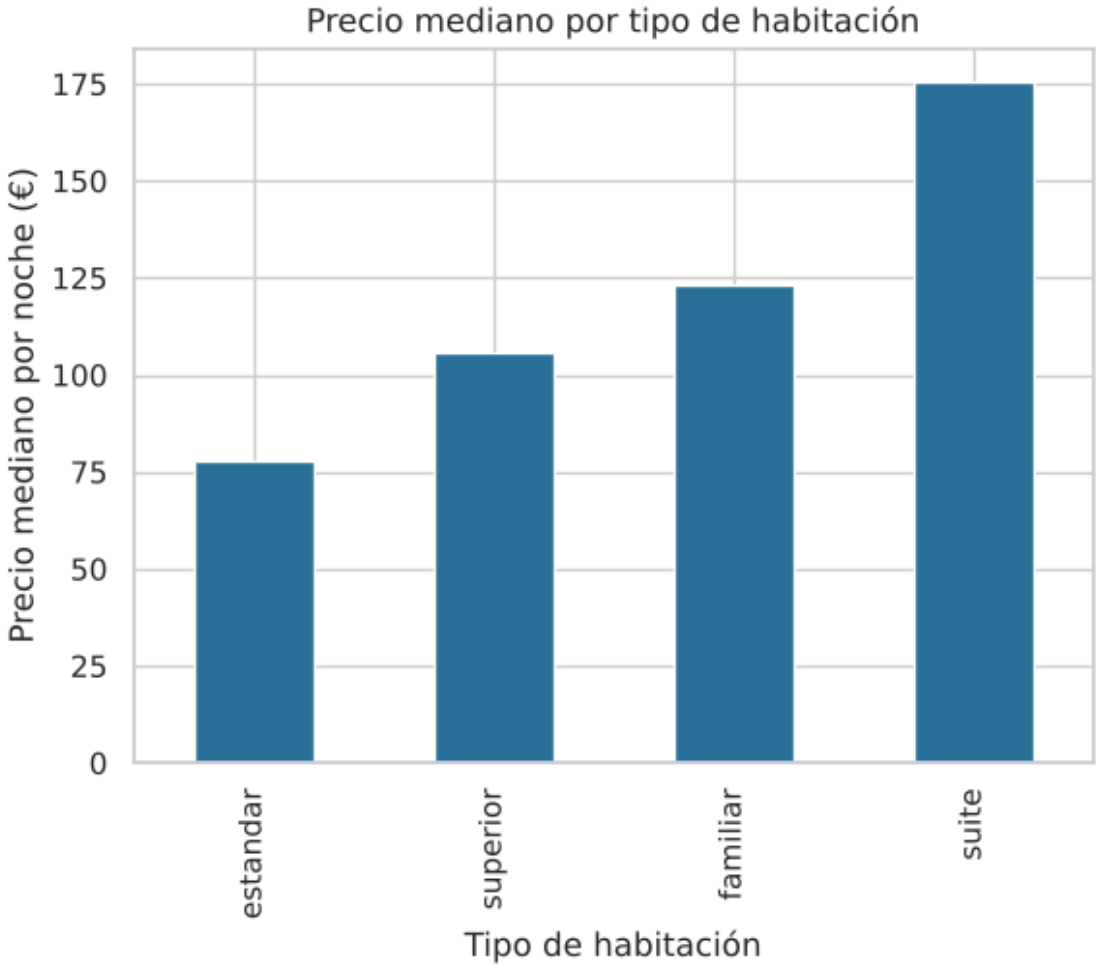


Figura 1. *Ejercicio 4 · Precio mediano por tipo de habitación: escalera clara de la estándar a la suite.*

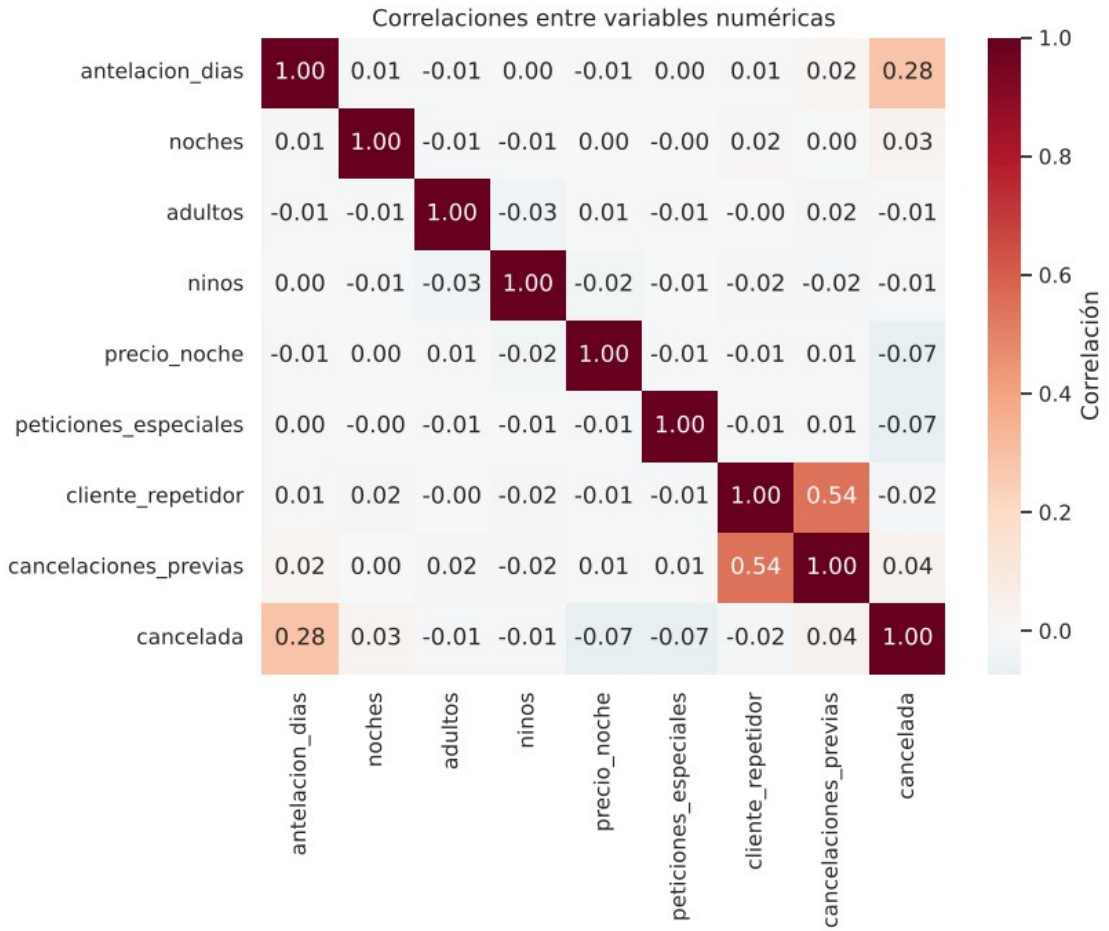


Figura 2. *Ejercicio 5 · Mapa de correlaciones: la antelación (0.28) es lo más ligado a cancelar; los clientes repetidores y sus cancelaciones previas se parecen entre sí (0.54).*

S06_02 · Limpieza de datos

Ej.	Qué pide	Qué obtenemos
1 · clase	Contar las filas repetidas y quitarlas	**45 duplicados**; quedan **1 500 filas** únicas
2 · clase	Pasar el precio a número (la coma decimal es un problema) y contar los nulos que salen	El precio ya es número; **79 precios** no se pudieron leer y quedan como nulos
3 · clase	Convertir las dos columnas de fecha, que venían en dos formatos distintos	Ambas columnas pasan a **fecha de verdad**; se pueden restar y ordenar
4 · casa	Unificar el canal (espacios, mayúsculas) y los países con el diccionario de equivalencias	Quedan **solo los 8 países válidos** y los canales escritos igual
5 · clase	Marcar como nulo (sin borrar filas) los precios fuera de 20–1000 € y las noches fuera de 1–60	**14 valores imposibles** convertidos en nulo

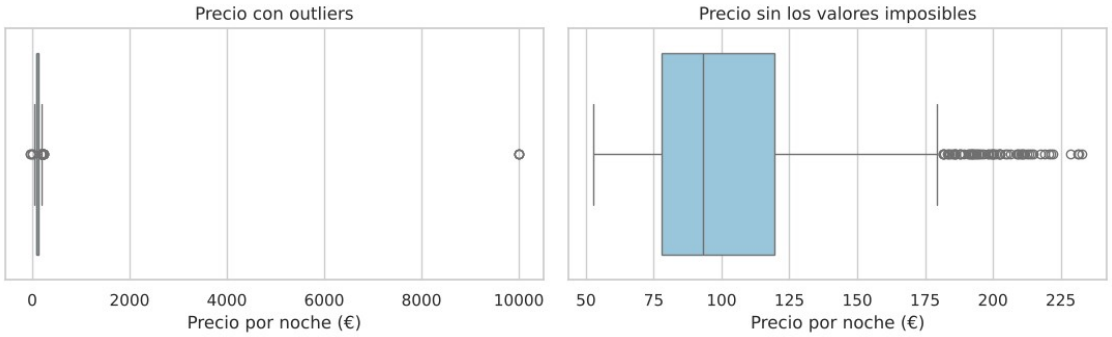


Figura 3. *Sección 6 · Con un valor imposible (10 000 €) el gráfico se aplasta (izquierda); tras limpiarlo se ve la distribución real, de 50 a 225 € (derecha).*

S06_03 · Preprocesado y pipelines

Ej.	Qué pide	Qué obtenemos
1 · casa	Separar entrenamiento (80 %) y prueba (20 %), manteniendo la proporción de cancelaciones	**1 200** reservas de entrenamiento y **300** de prueba
2 · clase	Escalar el precio entre 0 y 1 ajustando **solo con entrenamiento**	Mediana de relleno **93.65 €**; el precio de prueba queda entre 0 y 1
3 · casa	Codificar el depósito respetando su orden natural	`sin_deposito` → 0 · `parcial` → 1 · `total` → 2
4 · clase	Montar un preprocesado con dos ramas: números (mediana + escalado) y categorías (más frecuente + columnas 0/1)	La tabla pasa a **34 columnas** numéricas, sin nulos
5 · clase	Encadenar preprocesado y regresión logística en un solo objeto y medirlo en prueba	Exactitud **68 %**, frente a **53 %** de «decir siempre la clase mayoritaria»

S06_04 · Métricas y validación

Ej.	Qué pide	Qué obtenemos
1 · clase	Entrenar una regresión logística y compararla con el modelo «tonto»	Exactitud **67.2 %**: **13 puntos** mejor que el tonto
2 · casa	Predecir el precio con tipo de habitación y mes; medir el error	Error medio **11.8 €** · error cuadrático **14.9 €** · R^2 **0.80**
3 · casa	Elegir la profundidad del árbol con mejor resultado en prueba	Mejor profundidad **4**; con 20 la distancia entre entrenamiento y prueba llega a **0.40** (sobreajuste)
4 · clase	Validación cruzada de 5 partes con AUC	AUC por parte entre **0.74 y 0.78**; media **0.755**
5 · clase	Detectar variables que provocan fuga de información	Dos columnas que no se conocen al reservar: **importe_devuelto** y **fecha_cancelacion**
6 · casa	Validación respetando el orden del tiempo (4 cortes)	AUC entre **0.73 y 0.76**: parecido a la validación normal, el modelo aguanta el paso del tiempo

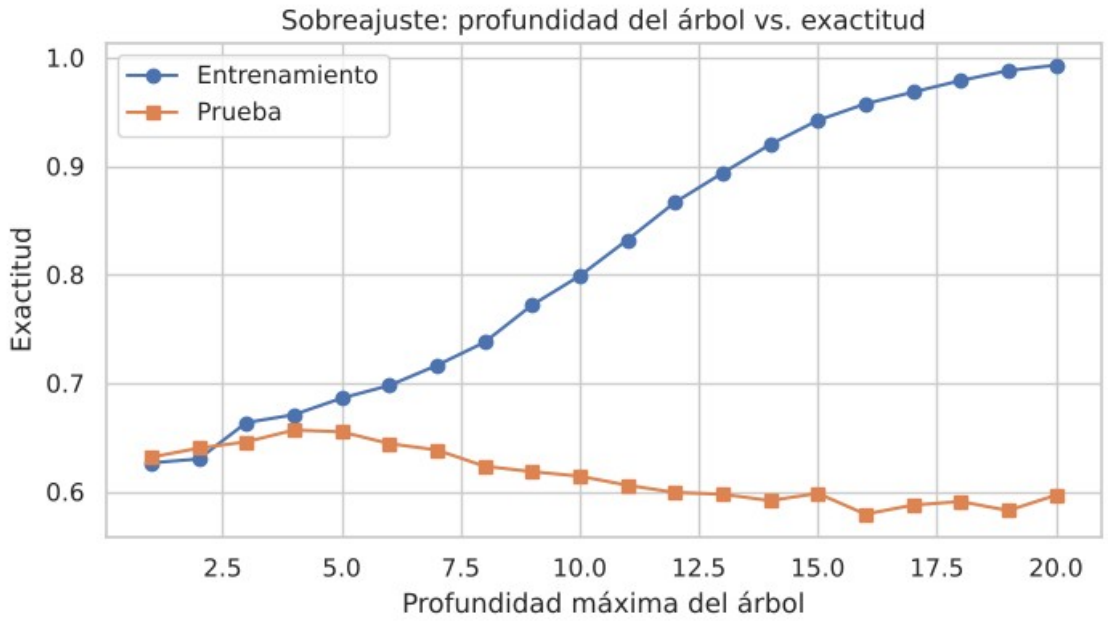


Figura 4. *Ejercicio 3 · Sobreajuste: con más profundidad el árbol acierta cada vez más en entrenamiento (azul) pero empeora en prueba (naranja).*

La historia del sprint

- **−12 puntos** · Con depósito total se cancela mucho menos que sin depósito (**26 %** frente a **54 %**).
- **45 · 79 · 14** · **Limpiar**: duplicados, precios ilegibles y valores imposibles antes de calcular nada.
- **68 % vs 53 %** · Un **pipeline** bien montado supera al modelo tonto, sin fugas entre entrenamiento y prueba.
- **0.755** · **AUC** estable (0.74–0.78) en validación cruzada: la medida es fiable.