IFCD107 · ESPECIALISTA EN IA

# Sprint 6 · Resultados

Explorar, limpiar y preparar los datos de reservas de Turisdata, y medir bien un modelo.

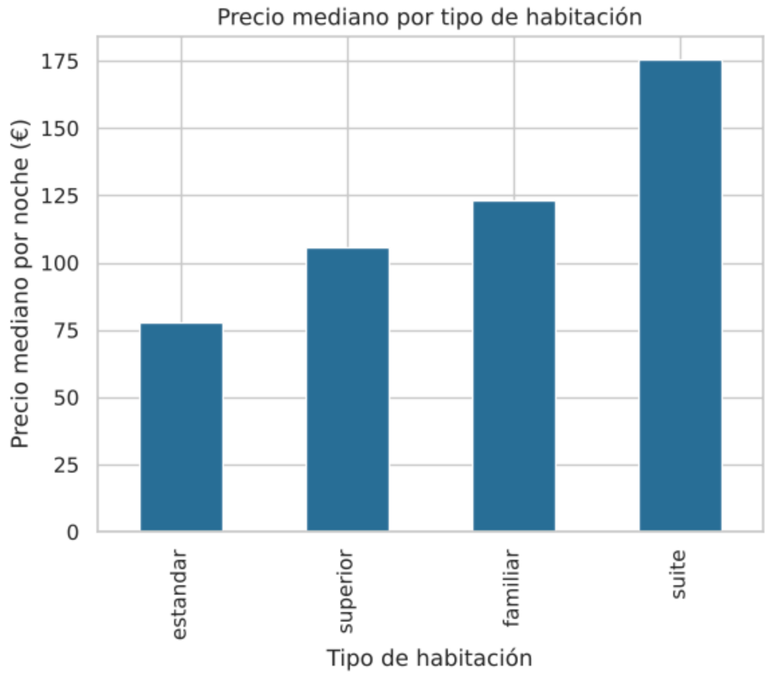
S06_01 · QUÉ PIDE Y QUÉ OBTENEMOS

# S06_01 • Pandas: explorar los datos (EDA)

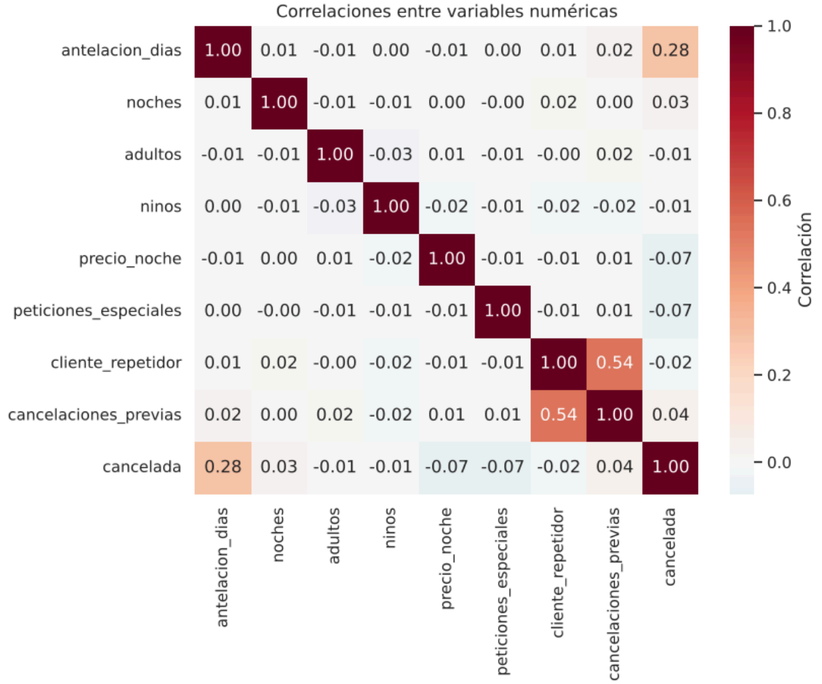
| Ej. | Qué pide | Qué obtenemos |
|---|---|---|
| **1 · clase** | Cargar las reservas (con las fechas bien leídas) y mirar sus dimensiones | **6 000 reservas** y **18 columnas** |
| **2 · clase** | Tasa de cancelación según el depósito, de mayor a menor | Sin depósito **54 %** · parcial **41 %** · total **26 %**: cuanto más se paga por adelantado, menos se cancela |
| **3 · clase** | Unir las reservas con la tabla de temporadas sin perder ninguna y comparar cancelaciones | Temporada alta **47.9 %** · baja **43.8 %**; siguen siendo 6 000 filas (con 2 columnas más) |
| **4 · casa** | Mediana del precio por tipo de habitación y gráfico de barras | Estándar **77.6 €** · superior **105.7 €** · familiar **123.0 €** · suite **175.5 €**; la suite es la más cara |
| **5 · casa** | Qué variable se relaciona más con cancelar (mapa de correlaciones) | **Antelación de la reserva** (0.28): cuanto antes se reserva, más se cancela |
| **6 · clase** | Contar filas repetidas y el porcentaje de nulos en el país de origen | **0** filas repetidas · **2.3 %** de nulos en `pais_origen` |

S06_01 · GRÁFICOS

# S06_01 • Pandas: explorar los datos (EDA)




Ejercicio 4 · Precio mediano por tipo de habitación: escalera clara de la estándar a la suite.



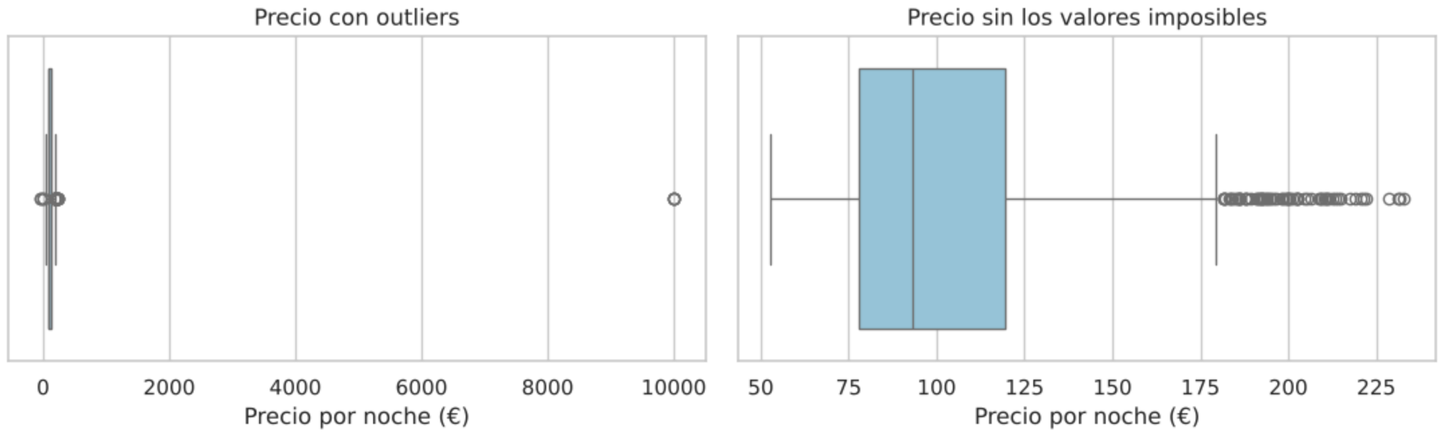

Ejercicio 5 · Mapa de correlaciones: la antelación (0.28) es lo más ligado a cancelar; los clientes repetidores y sus cancelaciones previas se parecen entre sí (0.54).

S06_02 · QUÉ PIDE Y QUÉ OBTENEMOS

# S06_02 • Limpieza de datos

| Ej. | Qué pide | Qué obtenemos |
|---|---|---|
| **1 · clase** | Contar las filas repetidas y quitarlas | **45 duplicados**; quedan **1 500 filas** únicas |
| **2 · clase** | Pasar el precio a número (la coma decimal es un problema) y contar los nulos que salen | El precio ya es número; **79 precios** no se pudieron leer y quedan como nulos |
| **3 · clase** | Convertir las dos columnas de fecha, que venían en dos formatos distintos | Ambas columnas pasan a **fecha de verdad**; se pueden restar y ordenar |
| **4 · casa** | Unificar el canal (espacios, mayúsculas) y los países con el diccionario de equivalencias | Quedan **solo los 8 países válidos** y los canales escritos igual |
| **5 · clase** | Marcar como nulo (sin borrar filas) los precios fuera de 20–1000 € y las noches fuera de 1–60 | **14 valores imposibles** convertidos en nulo |

# S06_02 • Limpieza de datos




Sección 6 · Con un valor imposible (10 000 €) el gráfico se aplasta (izquierda); tras limpiarlo se ve la distribución real, de 50 a 225 € (derecha).

S06_03 · QUÉ PIDE Y QUÉ OBTENEMOS

# S06_03 • Preprocesado y pipelines

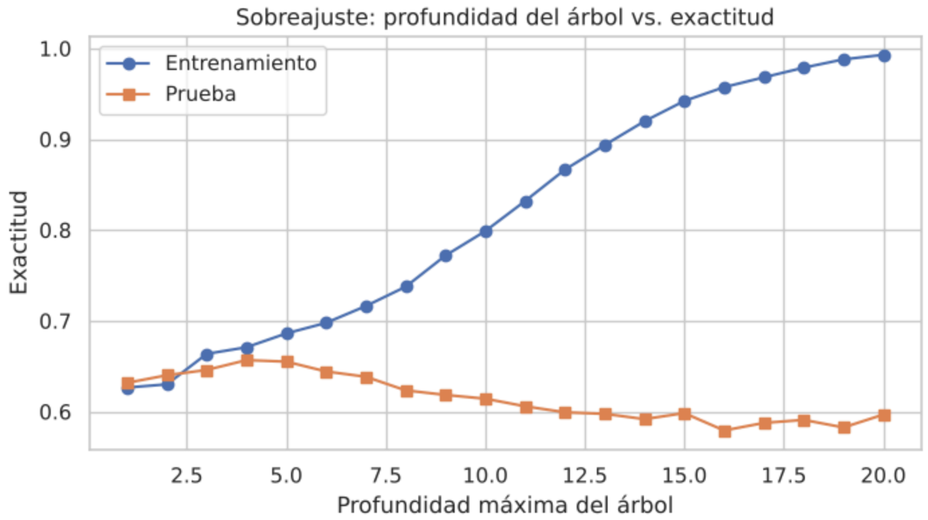
| Ej. | Qué pide | Qué obtenemos |
|---|---|---|
| **1 · casa** | Separar entrenamiento (80 %) y prueba (20 %), manteniendo la proporción de cancelaciones | **1 200** reservas de entrenamiento y **300** de prueba |
| **2 · clase** | Escalar el precio entre 0 y 1 ajustando **solo con entrenamiento** | Mediana de relleno **93.65 €**; el precio de prueba queda entre 0 y 1 |
| **3 · casa** | Codificar el depósito respetando su orden natural | `sin_deposito` → 0 · `parcial` → 1 · `total` → 2 |
| **4 · clase** | Montar un preprocesado con dos ramas: números (mediana + escalado) y categorías (más frecuente + columnas 0/1) | La tabla pasa a **34 columnas** numéricas, sin nulos |
| **5 · clase** | Encadenar preprocesado y regresión logística en un solo objeto y medirlo en prueba | Exactitud **68 %**, frente a **53 %** de «decir siempre la clase mayoritaria» |

S06_04 · QUÉ PIDE Y QUÉ OBTENEMOS

# S06_04 • Métricas y validación

| Ej. | Qué pide | Qué obtenemos |
|---|---|---|
| **1 · clase** | Entrenar una regresión logística y compararla con el modelo «tonto» | Exactitud **67.2 %**: **13 puntos** mejor que el tonto |
| **2 · casa** | Predecir el precio con tipo de habitación y mes; medir el error | Error medio **11.8 €** · error cuadrático **14.9 €** · $R^2$ **0.80** |
| **3 · casa** | Elegir la profundidad del árbol con mejor resultado en prueba | Mejor profundidad **4**; con 20 la distancia entre entrenamiento y prueba llega a **0.40** (sobreajuste) |
| **4 · clase** | Validación cruzada de 5 partes con AUC | AUC por parte entre **0.74 y 0.78**; media **0.755** |
| **5 · clase** | Detectar variables que provocan fuga de información | Dos columnas que no se conocen al reservar: **importe_devuelto** y **fecha_cancelacion** |
| **6 · casa** | Validación respetando el orden del tiempo (4 cortes) | AUC entre **0.73 y 0.76**: parecido a la validación normal, el modelo aguanta el paso del tiempo |

# S06_04 • Métricas y validación




Ejercicio 3 · Sobreajuste: con más profundidad el árbol acierta cada vez más en entrenamiento (azul) pero empeora en prueba (naranja).

PARA LLEVARSE

# La historia del sprint

| | |
|---|---|
| **–12 puntos** | Con depósito total se cancela mucho menos que sin depósito (**26 %** frente a **54 %**). |
| **45 • 79 • 14** | **Limpiar**: duplicados, precios ilegibles y valores imposibles antes de calcular nada. |
| **68 % vs 53 %** | Un **pipeline** bien montado supera al modelo tonto, sin fugas entre entrenamiento y prueba. |
| **0.755** | **AUC** estable (0.74–0.78) en validación cruzada: la medida es fiable. |