Sprint 6 · Datos listos para modelar

¿están los datos en condiciones de entrenar algo fiable?

FECHAS
4–5 de noviembre

HORAS
12 h (4 h teoría · 4 h práctica guiada · 4 h PBL)

CONTENIDOS
M2 (rol del Data Scientist, pandas, visualización, limpieza y preprocesado) y M3 UD 3.1–3.2 (flujo con scikit-learn, pipelines, métricas y validación).

Qué aprenderás

1. Explorar una tabla con pandas y elegir el gráfico adecuado para cada tipo de dato.
2. Encontrar defectos en un dataset (nulos, duplicados, *outliers*, tipos y fechas mal formados, categorías inconsistentes) y **razonar de dónde vienen**.
3. Construir un **pipeline** reproducible (`ColumnTransformer` + `Pipeline`) que impute, escale y codifique sin fuga de datos.
4. Medir un modelo con honestidad: *baseline*, métricas, validación cruzada, partición temporal.
5. Reconocer y evitar la **fuga de datos** (*data leakage*).

Requisitos previos

- Sprint 4 y 5: Python básico, NumPy y algo de estadística con pandas.
- Cuenta de Google (para Colab) o el entorno local del curso (Python 3.11).
- Datos: `datos/reservas_turisdata.csv` (limpio) y `datos/reservas_sucio.csv` (el del reto). Los notebooks los descargan solos si no los encuentran.

Prácticas

Notebook	Tema	Tiempo
`S06_01_pandas_eda`	pandas, EDA y visualización exploratoria; primer chequeo de calidad	55 min
`S06_02_limpieza`	Limpieza: duplicados, tipos, fechas, categorías, imposibles, nulos	65 min
`S06_03_preprocesado_pipeline`	Escalado, codificación, `ColumnTransformer` y `Pipeline`	50 min
`S06_04_metricas_validacion`	Baseline, métricas, sobreajuste, validación cruzada, fuga y partición temporal	60 min

Cada notebook tiene ejercicios con `assert`: si la celda de comprobación no da error, vas bien. Si terminas antes, dedica tiempo a las preguntas de reflexión del final de cada notebook.

RETO Reto PBL · «Datos sucios, cliente impaciente» (unas 3 h, en equipo)

En pocas palabras (léelo primero)

Qué os pide el cliente. TurisData os envía por correo un fichero de reservas exportado **a mano desde varios sistemas** (`reservas_sucio.csv`). El gerente quiere un primer modelo de cancelaciones «para ayer», pero **no se fía de los datos** (con razón). Os pide dos cosas:

1. Un **informe corto** que diga **qué está mal en los datos y por qué**.
2. Un **proceso automático** que deje los datos listos cada vez que le llegue un fichero así, con un primer modelo sencillo de referencia (un *baseline*).

Los datos reales están siempre sucios. Fechas escritas de varias maneras, países con distintos nombres, números negativos imposibles, filas repetidas, huecos… Limpiarlos es entre el 60 y el 80 % del trabajo en un proyecto de IA. En este reto aprenderéis a **encontrar los defectos, decidir qué hacer con cada uno y dejarlo todo escrito en código** para que se pueda repetir.

Qué vais a hacer, en seis pasos:

1. **Hacer un inventario** de los defectos del fichero (qué, dónde, cuántas filas).
2. **Explicar la causa probable** de cada uno y **decidir qué tratamiento** le dais (y por qué).
3. **Escribir una función de limpieza** en código (`limpiar_reservas`). Nada de arreglar el CSV a mano.

4. **Montar un pipeline** de preprocesado (imputar huecos, escalar números, codificar categorías) que aprenda **solo con los datos de entrenamiento**.
5. **Entrenar un modelo de referencia (*baseline*)** y compararlo con un modelo «tonto» mediante validación cruzada.
6. **Escribir el informe y el README.**

Qué vais a entregar: un repositorio o carpeta con `informe_calidad.md`, `reto_S06.ipynb` y `README.md`.

Qué vais a aprender haciéndolo: a **desconfiar de los datos**, a limpiar de forma **reproducible** y a evitar la **fuga de información** del test al entrenamiento.

Cuánto tiempo: unas 3 horas en equipo entre el planning, el reto y la entrega (4 y 5/11).

Núcleo y extra. Núcleo: inventario de defectos, función de limpieza y *baseline* con su *pipeline*. Extra: informe más detallado y comparativa de variantes de limpieza.

Palabras que van a aparecer en este reto

Palabra	Qué significa, en sencillo
EDA (análisis exploratorio)	Mirar los datos con tablas y gráficos antes de modelar, para entenderlos
Defecto de calidad	Un problema del dato: huecos (nulos), duplicados, valores imposibles, formatos mezclados…
Imputar	Rellenar un hueco con un valor razonable (la mediana, la categoría más frecuente…)
Outlier (valor atípico)	Un valor muy raro. A veces es un error; a veces es real. Hay que decidir
Pipeline	Una cadena de pasos de preparación y modelo que se ejecuta siempre igual
Train / test	Los datos con los que entrena el modelo (train) y los que quedan guardados para evaluarlo (test)
Fuga de datos	Cuando información del test «se cuela» en el entrenamiento y los resultados parecen mejores de lo que son
Baseline	Modelo sencillo de referencia. Cualquier modelo mejor debe superarlo
DummyClassifier	Un «modelo tonto» que, por ejemplo, siempre responde la clase más frecuente. Es el suelo con el que comparar
Validación cruzada	Entrenar y evaluar varias veces con particiones distintas para tener una medida más fiable
Reproducible	Que otra persona pueda ejecutar el cuaderno de arriba abajo y obtener lo mismo

Contexto del cliente. TurisData Canarias nos manda por correo un fichero exportado a mano desde varios sistemas: `reservas_sucio.csv`. Quieren un primer modelo de cancelaciones "para ayer", pero el gerente no se fía de los datos. Nos pide **un informe corto que le diga qué está mal y por qué**, y **un proceso que deje los datos listos cada vez que le llegue un fichero así**, con un modelo de referencia (*baseline*).

Qué se entrega (un repositorio o carpeta con):

1. `informe_calidad.md` (o PDF), 1–2 páginas: tabla de defectos (qué, dónde, cuántas filas, causa probable, tratamiento y su justificación) y las preguntas que haríais al cliente. Plantilla en `plantillas/informe_calidad_plantilla.md`.
2. `reto_S06.ipynb`: notebook con el EDA, la función de limpieza y el **pipeline** de preprocesado + un modelo baseline evaluado con validación cruzada.
3. `README.md` con instrucciones para reproducirlo (versiones de librerías, cómo ejecutar).

Restricciones.

- Solo librerías del curso (pandas, scikit-learn, matplotlib, seaborn…).
- Nada de editar el CSV a mano: toda corrección debe estar en código.
- Todo estadístico aprendido de los datos (medianas, medias, categorías) debe ajustarse **solo con train**.
- No se descarta ninguna fila sin justificarlo en el informe.

Criterios de evaluación (0–4 cada uno; misma rúbrica de todos los retos):

Criterio	1 · Insuficiente	2 · Suficiente	3 · Bueno	4 · Excelente
Corrección técnica	Errores que invalidan el resultado	Correcto con fallos menores	Correcto y bien justificado	Correcto, justificado y con alternativas comparadas
Reproducibilidad	No se puede volver a ejecutar	Se ejecuta con ayuda	Se ejecuta desde el README	Además incluye datos o script y versiones fijas

Criterio	1 · Insuficiente	2 · Suficiente	3 · Bueno	4 · Excelente
Análisis y comunicación al cliente	Solo código o cifras sin interpretar	Interpretación básica	Conclusiones claras para el cliente	Recomendación accionable con límites explicados
IA responsable	No se considera	Menciones genéricas	Riesgos específicos identificados	Medidas aplicadas y evaluadas

Pista de IA responsable: ¿qué pasa si el país de origen se imputa mal? ¿Podría el modelo discriminar por nacionalidad? ¿Hay columnas que no deberían usarse?

Pasos sugeridos.

- **Miércoles 4/11:** *planning* (25 min) con el reparto de roles (Scrum Master y responsable técnico rotan); tras las prácticas 1–2, inventario de defectos con `resumen_calidad` y gráficos (60 min). Primer borrador de la tabla del informe.
- **Jueves 5/11:** función `limpiar_reservas`, comprobación antes/después y separación train/test; *pipeline* de preprocesado (práctica 3) y *baseline* con validación cruzada (práctica 4) (80 min).
- **Cierre del jueves:** informe, README y ensayo de 5 minutos (25 min); autoevaluación y coevaluación; **review + retrospectiva** (última hora).

Guía paso a paso para principiantes

Paso 1 · Planning y reparto de roles (miércoles 4/11, 25 minutos)

1. Elegid **Scrum Master y responsable técnico** de este sprint (no pueden repetir quienes lo fueron en el anterior).
2. Pasad al tablero las tareas: inventario de defectos, función de limpieza, pipeline, baseline, informe, README.
3. Decidid quién empieza cada una, sabiendo que **todo el equipo** debe entender todo.

Paso 2 · Inventario de defectos (miércoles 4/11, 60 minutos)

1. Cargad `reservas_sucio.csv` y ejecutad la función `resumen_calidad` de las prácticas. Mirad: tipos de columnas, nulos, duplicados, valores mínimos y máximos.
2. Haced gráficos (histogramas, conteo por categoría). A veces el defecto se ve mejor dibujado.
3. **Por cada defecto, rellenad una fila en la tabla del informe** (`informe_calidad_plantilla.md`):

Campo	Ejemplo (inventado)
Qué	Fechas de llegada en dos formatos (`2025-07-03` y `03/07/2025`)
Dónde	Columna `fecha_llegada`
Filas	183 de 2.000
Causa probable	Dos sistemas de origen exportan con formato distinto
Tratamiento	Convertir todas a formato ISO con `pd.to_datetime(..., dayfirst=...)`
Justificación	No se pierde información y evita errores al ordenar por fecha

Apuntad también las **preguntas que haríais al cliente** («¿qué significa un precio de 0 €? ¿es cortesía o un error?»).

Paso 3 · Función de limpieza y separación train/test (jueves 5/11, 40 minutos)

1. Escribid `limpiar_reservas(df)`: una función que recibe la tabla sucia y devuelve la tabla limpia aplicando **todos** vuestros tratamientos. **No toquéis el CSV a mano.**
2. **Comprobad antes y después** (nulos, duplicados, rangos). Si una corrección no se nota, no sirve.
3. **Separad train y test ANTES de calcular medianas, medias o categorías frecuentes.** Esos valores se aprenden **solo con train** y se aplican luego al test. Si calculáis la mediana con todos los datos, el test «se contamina» (fuga).
4. **No descartéis ninguna fila sin justificarlo** en el informe.

Paso 4 · Pipeline y baseline (jueves 5/11, 40 minutos)

1. Construid un `Pipeline` de scikit-learn con tres pasos: **imputar** huecos, **escalar** números y **codificar** categorías.
2. Añadid un **modelo de referencia** (por ejemplo, regresión logística).
3. Evaluadlo con **validación cruzada** y comparadlo con un `DummyClassifier`. Si vuestro modelo no mejora al «tonto», algo falla.
4. Pensad en la métrica: si solo se cancela el 20 %, un modelo que dice «nunca cancelan» acierta el 80 %. Por eso conviene mirar métricas que tengan en cuenta las cancelaciones (recall, F1…).

Paso 5 · Informe, README y ensayo (jueves 5/11, 25 minutos)

1. Completad el informe (1–2 páginas): tabla de defectos, tratamientos justificados y preguntas al cliente.

2. En `README.md`: cómo ejecutar el cuaderno, qué versiones de librerías usáis y en qué orden.
3. Comprobad que **«Reiniciar y ejecutar todo»** funciona sin errores.
4. Ensayad la review (5 minutos) y preparad la retro.

Cómo usar la IA en este reto

La limpieza de datos es un terreno donde la IA ayuda mucho, pero **donde también introduce errores sutiles**.

Para qué	Ejemplo de petición	Qué tenéis que comprobar
Entender una función de pandas	«Explícame `fillna`, `drop_duplicates` y `to_datetime` con un ejemplo muy pequeño»	Que probáis cada ejemplo y lo entendéis
Depurar un error	«Este código da `KeyError: 'precio'`. El DataFrame tiene estas columnas: *[lista]*. ¿Qué puede pasar?»	Que arreglas la causa, no solo el síntoma
Revisar la fuga	«Aquí está mi pipeline: *[código]*. ¿Hay alguna operación que use el test para aprender?»	Que entendéis **por qué** hay o no fuga
Redactar el informe	«Reescribe esta tabla de defectos de forma más clara»	Que **no cambie cifras ni defectos**

Reglas del reto:

- **Solo librerías del curso.** No instaléis paquetes extra que os «arreglen» los datos automáticamente.
- **Toda corrección debe estar en el código**, no en el CSV ni en un clic de Excel.
- Declarad en el README qué habéis hecho con IA y qué habéis verificado.
- **Pista de IA responsable:** ¿qué pasa si el país de origen se imputa mal? ¿Podría el modelo discriminar por nacionalidad? ¿Hay columnas que no deberían usarse? Respondedlo en el informe.

Errores frecuentes (y cómo evitarlos)

Error	Por qué ocurre	Cómo evitarlo
Calcular la mediana con **todos** los datos antes de partir	«Total, es solo la mediana»	Partid primero; ajustad imputación y escalado **solo con train** (dentro del `Pipeline`)
Borrar filas «raras» sin avisar	Se quieren datos limpios	Cada fila eliminada se **cuenta y se justifica**
Informe que dice «hay nulos» sin más	Falta el análisis	Para cada defecto: dónde, cuántas filas, causa, tratamiento y razón
Un modelo que «acierta el 80 %» y se celebra	La exactitud engaña con clases desiguales	Comparadlo con `DummyClassifier`
Cuaderno que solo funciona si ejecutas las celdas en cierto orden	Se editaron celdas sueltas	*Reiniciar y ejecutar todo*
Usar columnas que delatan la respuesta	Parece que ayudan	Preguntad por cada una: ¿se conoce **al reservar**?

Un buen resultado se parece a...

- **Tabla de defectos:** 6–10 filas completas con las seis columnas; los tres más graves destacados.
- **Función de limpieza:** una sola función, con docstring, que devuelve una tabla sin los defectos y **un resumen de lo que ha cambiado**.
- **Resultado del baseline:** una frase como *«Nuestro modelo obtiene un F1 medio de 0,58 ± 0,03, frente a 0,00 del modelo tonto»* (cifras de ejemplo).

Antes de entregar: autoevaluación rápida

Pregunta	Sí / No
¿El informe recoge todos los defectos con causa probable y tratamiento?	
¿El cuaderno se ejecuta de principio a fin sin errores?	
¿Imputación, escalado y codificación se ajustan **solo con train**?	
¿Hay un baseline (`DummyClassifier`) y un modelo comparados con validación cruzada?	
¿El README tiene instrucciones y versiones de librerías?	

Pregunta	Sí / No
¿Hemos respondido a la pregunta de IA responsable (país de origen, discriminación)?	
¿Está subido a Git, con autoevaluación y coevaluación?	

Si os atascáis

- **No encontramos más defectos:** probad `df.describe()`, `df.isna().sum()`, `df.duplicated().sum()` y `df[columna].value_counts()` en cada columna.
- **No sabemos si algo es un error o un dato real:** apuntadlo como **pregunta para el cliente** y explicad qué hacéis mientras tanto.
- **Una función de pandas no hace lo que queremos:** probadla con un ejemplo de 3 filas inventadas.
- Más ayuda: Cómo se trabaja un reto.

Qué se enseña en la review (5 min por equipo): la tabla de defectos (los 3 más graves y por qué), el pipeline en marcha desde cero (`Restart & Run all`) y la métrica del baseline frente a un modelo "tonto".

Preguntas de la retrospectiva: ¿qué defecto nos costó más encontrar? ¿Qué decisión de limpieza discutimos más? ¿Qué haríamos distinto con el siguiente fichero del cliente?

Definition of Done

- [ ] El informe de calidad recoge todos los defectos encontrados con causa probable y tratamiento.
- [ ] El notebook se ejecuta de principio a fin sin errores (`Restart & Run all`).
- [ ] El pipeline ajusta imputación, escalado y codificación solo con train.
- [ ] Hay un baseline (`DummyClassifier`) y un modelo, comparados con validación cruzada.
- [ ] README con instrucciones y versiones de las librerías.
- [ ] Subido a Git; autoevaluación y coevaluación rellenadas.

Recursos

- Documentación de scikit-learn: *Pipelines and composite estimators* y *Cross-validation*.
- Documentación de pandas: *Working with missing data* y `pd.to_datetime`.
- Guía de usuario de scikit-learn: *Common pitfalls and recommended practices* (fuga de datos).
- Galería de seaborn (elección de gráficos).
- Tu propio `resumen_calidad` de la práctica 1: reutilízalo.