Sprint 6 · Datos listos para modelar

¿están los datos en condiciones de entrenar algo fiable?

FECHAS
4–5 de noviembre

HORAS
12 h (4 h teoría · 4 h práctica guiada · 4 h PBL)

CONTENIDOS
M2 (rol del Data Scientist, pandas, visualización, limpieza y preprocesado) y M3 UD 3.1–3.2 (flujo con scikit-learn, pipelines, métricas y validación).

Qué aprenderás

1. Explorar una tabla con pandas y elegir el gráfico adecuado para cada tipo de dato.
2. Encontrar defectos en un dataset (nulos, duplicados, *outliers*, tipos y fechas mal formados, categorías inconsistentes) y **razonar de dónde vienen**.
3. Construir un **pipeline** reproducible (`ColumnTransformer` + `Pipeline`) que impute, escale y codifique sin fuga de datos.
4. Medir un modelo con honestidad: *baseline*, métricas, validación cruzada, partición temporal.
5. Reconocer y evitar la **fuga de datos** (*data leakage*).

Requisitos previos

- Sprint 4 y 5: Python básico, NumPy y algo de estadística con pandas.
- Cuenta de Google (para Colab) o el entorno local del curso (Python 3.11).
- Datos: `datos/reservas_turisdata.csv` (limpio) y `datos/reservas_sucio.csv` (el del reto). Los notebooks los descargan solos si no los encuentran.

Prácticas

Notebook	Tema	Tiempo
`S06_01_pandas_eda`	pandas, EDA y visualización exploratoria; primer chequeo de calidad	45 min
`S06_02_limpieza`	Limpieza: duplicados, tipos, fechas, categorías, imposibles, nulos	55 min
`S06_03_preprocesado_pipeline`	Escalado, codificación, `ColumnTransformer` y `Pipeline`	40 min
`S06_04_metricas_validacion`	Baseline, métricas, sobreajuste, validación cruzada, fuga y partición temporal	45 min

Cada notebook tiene ejercicios con `assert`: si la celda de comprobación no da error, vas bien. Si terminas antes, dedica tiempo a las preguntas de reflexión del final de cada notebook.

RETO Reto PBL · «Datos sucios, cliente impaciente»

Qué os pide el cliente. TurisData os envía por correo un fichero de reservas exportado **a mano desde varios sistemas** (`reservas_sucio.csv`). El gerente quiere un primer modelo de cancelaciones «para ayer», pero **no se fía de los datos** (con razón). Os pide dos cosas:

1. Un **informe corto** que diga **qué está mal en los datos y por qué**.
2. Un **proceso automático** que deje los datos listos cada vez que le llegue un fichero así, con un primer modelo sencillo de referencia (un *baseline*).

Qué vais a entregar: un repositorio o carpeta con `informe_calidad.md`, `reto_S06.ipynb` y `README.md`.

Cuánto tiempo: unas 2 horas y 5 minutos en equipo entre el planning, el reto y la entrega (4 y 5/11).

Núcleo y extra. Núcleo: inventario de defectos, función de limpieza y *baseline* con su *pipeline*. Extra: informe más detallado y comparativa de variantes de limpieza.

Ficha completa del reto (pasos, rúbrica, ayudas y errores frecuentes): Reto_Sprint_06.md · **Qué hacemos cada día:** Guía día a día