Guía Sprint S06 · Datos listos para modelar

¿están los datos en condiciones de entrenar algo fiable?

FECHAS
4–5 de noviembre

HORAS
12 h (4 h teoría · 4 h práctica guiada · 4 h PBL)

Qué aprenderás

1. Explorar una tabla con pandas y elegir el gráfico adecuado para cada tipo de dato.
2. Encontrar defectos en un dataset (nulos, duplicados, *outliers*, tipos y fechas mal formados, categorías inconsistentes) y **razonar de dónde vienen**.
3. Construir un **pipeline** reproducible (`ColumnTransformer` + `Pipeline`) que impute, escale y codifique sin fuga de datos.
4. Medir un modelo con honestidad: *baseline*, métricas, validación cruzada, partición temporal.
5. Reconocer y evitar la **fuga de datos** (*data leakage*).

Temario

Los conceptos que entran en este sprint (temario oficial del curso):

Unidad	Conceptos que entran
M2 · Exploración del conjunto de datos (UD 2.1 a 2.5)	Funciones del Data Scientist; datos estructurados, no estructurados y series temporales · read_csv, info, describe, filtrado, agrupación, uniones · matplotlib, seaborn, plotly; elección del gráfico según el tipo de dato · Nulos, duplicados, outliers, tipos incorrectos; detección de defectos y de sus causas · Escalado, codificación de categóricas, reducción de dimensionalidad, separación train/test
UD 3.1	Flujo de trabajo con scikit-learn: estimadores, pipelines, validación cruzada
UD 3.2	Métricas y evaluación: MAE/RMSE/R^2, precisión/recall/F1, ROC-AUC, sesgo-varianza, GridSearchCV

Material del sprint

Presentaciones

Presentación	Tema	Tiempo
S06.1	Datos, pandas y visualización exploratoria	30 min
S06.2	Limpieza y preprocesado	30 min
S06.3	scikit-learn: métricas y validación	25 min

Actividades

Actividad	Tiempo
pandas, EDA y primer chequeo de calidad	45 min
Limpieza: duplicados, tipos, fechas, categorías, imposibles y nulos	55 min
Escalado, codificación, `ColumnTransformer` y `Pipeline`	40 min
Baseline, métricas, validación cruzada y fuga de datos	45 min

RETO Reto PBL · «Datos sucios, cliente impaciente»

Qué os pide el cliente. TurisData os envía por correo un fichero de reservas exportado **a mano desde varios sistemas** (`reservas_sucio.csv`). El gerente quiere un primer modelo de cancelaciones «para ayer», pero **no se fía de los datos** (con razón). Os pide dos cosas:

1. Un **informe corto** que diga **qué está mal en los datos y por qué**.
2. Un **proceso automático** que deje los datos listos cada vez que le llegue un fichero así, con un primer modelo sencillo de referencia (un *baseline*).

Qué vais a entregar: un repositorio o carpeta con `informe_calidad.md`, `reto_S06.ipynb` y `README.md`.

Cuánto tiempo: unas 2 horas y 5 minutos en equipo entre el planning, el reto y la entrega (4 y 5/11).

Núcleo y extra. Núcleo: inventario de defectos, función de limpieza y *baseline* con su *pipeline*. Extra: informe más detallado y comparativa de variantes de limpieza.

Ficha completa del reto (pasos, rúbrica, ayudas y errores frecuentes): Reto_Sprint_06.md · **Qué hacemos cada día:** Guía día a día

Conclusión del Sprint 6

Al acabar este sprint...

- Mi equipo tiene el inventario de defectos del fichero sucio.
- Sé limpiar duplicados, tipos y fechas con pandas.
- Notebook de EDA, pipeline e informe de defectos en `sprint-06/`.
- Autoevaluación y coevaluación rellenadas.

Y ahora: Sprint 7 · ML supervisado: regresión y clasificación (viernes 6/11).