

Sprint 6 · Datos listos para modelar

PREGUNTA GUÍA: ¿ESTÁN LOS DATOS EN CONDICIONES DE ENTRENAR ALGO FIABLE?

3-5 DE NOVIEMBRE

11 H TOTALES

Contenidos: M2 (rol del Data Scientist, pandas, visualización, limpieza y preprocesado) y M3 UD 3.1–3.2 (flujo con scikit-learn, pipelines, métricas y validación).

4 h Teoría

Rol de Data Scientist, pandas, preprocesado, scikit-learn, métricas y validación

4 h Práctica guiada

4 notebooks de EDA, limpieza, pipelines y métricas con comprobaciones automáticas

3 h Reto PBL

«Datos sucios, cliente impaciente»: auditar dataset sucio, pipeline y baseline

¿Qué aprenderás?

- 1

Exploración y gráficos adecuados

Explorar una tabla con pandas y elegir el gráfico adecuado para cada tipo de dato.
- 2

Detección y causa de defectos

Encontrar defectos en un dataset (nulos, duplicados, outliers, tipos y fechas mal formados, categorías inconsistentes) y razonar de dónde vienen.
- 3

Pipelines reproducibles

Construir un pipeline reproducible (ColumnTransformer + Pipeline) que impute, escale y codifique sin fuga de datos.
- 4

Medición honesta de modelos

Medir un modelo con honestidad: baseline, métricas, validación cruzada y partición temporal.
- 5

Evitar fuga de datos

Reconocer y evitar activamente la fuga de datos (data leakage).

⚠

Requisitos previos: Sprint 4 y 5 (Python básico, NumPy y estadística con pandas) · Cuenta de Google (Colab) o entorno local (Python 3.11) · Datos: `datos/reservas_turisdata.csv` y `datos/reservas_sucio.csv` (descarga automática en notebooks).

Prácticas del sprint

Notebook	Tema	Tiempo
S06_01_pandas_eda	pandas, EDA y visualización exploratoria; primer chequeo de calidad	60 min
S06_02_limpieza	Limpieza: duplicados, tipos, fechas, categorías, imposibles, nulos	70 min
S06_03_preprocesado_pipeline	Escalado, codificación, ColumnTransformer y Pipeline	55 min
S06_04_metricas_validacion	Baseline, métricas, sobreajuste, validación cruzada, fuga y partición temporal	65 min

Ficha del reto PBL · «Datos sucios, cliente impaciente»

TURISDATA CANARIAS

3 H EN EQUIPO

Contexto del cliente: TurisData Canarias nos manda por correo un fichero exportado a mano desde varios sistemas: `reservas_sucio.csv`. Quieren un primer modelo de cancelaciones "para ayer", pero el gerente no se fía de los datos. Nos pide **un informe corto que le diga qué está mal y por qué**, y **un proceso que deje los datos listos cada vez que le llegue un fichero así**, con un modelo de referencia (*baseline*).

Qué se entrega

Un repositorio o carpeta con los siguientes artefactos revisados en la review:

1 · informe_calidad.md (o PDF)

1–2 páginas: tabla de defectos (qué, dónde, cuántas filas, causa probable, tratamiento y su justificación) y preguntas para el cliente (plantilla en `guias/S06/informe_calidad_plantilla.md`).

2 · reto_S06.ipynb

Notebook con el EDA, la función de limpieza y el pipeline de preprocesado + modelo baseline evaluado con validación cruzada.

3 · README.md

Instrucciones completas para reproducirlo (versiones de librerías y cómo ejecutar).

Restricciones del reto

• Librerías del curso

Solo librerías oficiales del curso (pandas, scikit-learn, matplotlib, seaborn...).

• Sin edición manual

Nada de editar el CSV a mano: toda corrección debe estar documentada en código.


• Ajuste solo con train

Todo estadístico aprendido de los datos (medianas, medias, categorías) debe ajustarse solo con train.

• Justificación de descartes

No se descarta ninguna fila sin justificarlo explícitamente en el informe.

Pasos sugeridos (3 h de reto)



¿ Qué se enseña en la review (5 min por equipo): la tabla de defectos (los 3 más graves y por qué), el pipeline en marcha desde cero (*Restart & Run all*) y la métrica del baseline frente a un modelo "tonto".

Preguntas de la retrospectiva

- ¿Qué defecto nos costó más encontrar?
- ¿Qué decisión de limpieza discutimos más?
- ¿Qué haríamos distinto con el siguiente fichero del cliente?

Criterios de evaluación

RÚBRICA DE RETOS

0 A 4 POR CRITERIO

Cada entregable se evalúa de **0 a 4 puntos** en los cuatro criterios de la rúbrica de retos del curso. La evaluación de equipo: la justificación técnica, la reproducibilidad y la comunicación clara con el cliente son fundamentales. A continuación se detalla la descripción de cada nivel.

Criterio	1 · Insuficiente	2 · Suficiente	3 · Bueno	4 · Excelente
Corrección técnica	Errores que invalidan el resultado	Correcto con fallos menores	Correcto y bien justificado	Correcto, justificado y con alternativas comparadas
Reproducibilidad	No se puede volver a ejecutar	Se ejecuta con ayuda	Se ejecuta desde el README	Además incluye datos o script y versiones fijas
Análisis y comunicación al cliente	Solo código o cifras sin interpretar	Interpretación básica	Conclusiones claras para el cliente	Recomendación accionable con límites explicados
IA responsable	No se considera	Menciones genéricas	Riesgos específicos identificados	Medidas aplicadas y evaluadas

 **Pista de IA responsable:** ¿qué pasa si el país de origen se imputa mal? ¿Podría el modelo discriminar por nacionalidad? ¿Hay columnas que no deberían usarse?

¿Cómo llegar al nivel Excelente?



Alternativas comparadas

Justifica cada decisión de imputación, codificación o descarte comparando con métodos alternativos en el informe.



Reproducibilidad total

Entorno fijado con versiones exactas en el README, datos disponibles y ejecución limpia de principio a fin.



Medidas de IA responsable

Evalúa el impacto ético de variables sensibles como nacionalidad y aplica salvaguardas explícitas contra sesgos.



Recomendación accionable

Traduce métricas técnicas y validación cruzada en recomendaciones de negocio claras y con límites explícitos para el cliente.

Definition of Done y recursos

CHECKLIST FINAL

DOCUMENTACIÓN

BUENAS PRÁCTICAS

Antes de dar por cerrado el Sprint 6, cada equipo debe verificar el siguiente checklist. La **Definition of Done** asegura que los datos preprocesados, el pipeline y el modelo de referencia son reproducibles, fiables y están documentados de forma transparente.

Checklist Definition of Done

- ☐ El informe de calidad recoge todos los defectos encontrados con causa probable y tratamiento
- ☐ El notebook se ejecuta de principio a fin sin errores (Restart & Run all)
- ☐ El pipeline ajusta imputación, escalado y codificación solo con train
- ☐ Hay un baseline (DummyClassifier) y un modelo, comparados con validación cruzada
- ☐ README con instrucciones y versiones de las librerías
- ☐ Subido a Git; autoevaluación y coevaluación rellenas

Preguntas de retrospectiva

Dedicad los últimos minutos del sprint a responder estas tres preguntas en equipo tras la review con el cliente:

- ¿Qué defecto nos costó más encontrar?
- ¿Qué decisión de limpieza discutimos más?
- ¿Qué haríamos distinto con el siguiente fichero del cliente?

Recursos recomendados

Documentación técnica y guías oficiales recomendadas para resolver dudas y profundizar en buenas prácticas de preprocesado y modelado:

1

Pipelines y estimadores compuestos · scikit-learn

Documentación oficial de scikit-learn sobre *Pipelines and composite estimators* y *Cross-validation*.

2

Tratamiento de nulos y fechas · pandas

Documentación oficial de pandas: *Working with missing data* y función `pd.to_datetime`.

3

Prevención de fuga de datos · scikit-learn

Guía de usuario de scikit-learn: *Common pitfalls and recommended practices* (fuga de datos / data leakage).

4

Galería de gráficos · seaborn

Galería oficial de seaborn para selección de visualizaciones exploratorias según el tipo de variable.

5

Resumen de calidad del curso

Tu propia función `resumen_calidad` desarrollada en la práctica 1: reutilízala para auditar el dataset.

- ☐ Aseguraos de probar el notebook completo con un **Restart & Run all** limpio antes de la entrega final.