README Sprint S06 · Datos listos para modelar

Pregunta guía: ¿están los datos en condiciones de entrenar algo fiable?
Fechas: 6 y 9 de noviembre · **Horas:** 12 h (3 h teoría · 5 h práctica · 4 h PBL)

📄 **Para imprimir:** todos los documentos del sprint en PDF, a color y ecofriendly, están juntos en la carpeta `pdf/` (descárgalos para que funcionen los enlaces).

> **Sigue el orden de arriba abajo y abre solo lo que pone en cada fila.** Los demás documentos del sprint son para consultar si te atascas (apartado «Si te atascas»). Si el tiempo aprieta, haz solo lo que está por encima de la línea «🏠 A partir de aquí, en casa» de cada cuaderno: lo demás es para casa.

Qué aprenderás

1. Explorar una tabla con pandas y elegir el gráfico adecuado para cada tipo de dato.
2. Encontrar defectos en un dataset (nulos, duplicados, *outliers*, tipos y fechas mal formados, categorías inconsistentes) y **razonar de dónde vienen**.
3. Construir un **pipeline** reproducible (`ColumnTransformer` + `Pipeline`) que impute, escale y codifique sin fuga de datos.
4. Medir un modelo con honestidad: *baseline*, métricas, validación cruzada, partición temporal.
5. Reconocer y evitar la **fuga de datos** (*data leakage*).

Día 1 · Viernes 6/11

☐	Qué haces	Abre	Min
☐	🔔 Ceremonia · Planning del reto «Datos sucios, cliente impaciente» y reparto de roles	—	10
☐	📖 Teoría · Datos, pandas y visualización exploratoria	Presentación S06.1	30
☐	💻 Práctica · pandas, EDA y primer chequeo de calidad (hasta la línea 🏠 del cuaderno)	Cuaderno S06_01	45
☐	🎯 Reto · Arrancar el inventario de defectos del fichero sucio (pasos 1–2)	Reto en una página	30
☐	📖 Teoría · Limpieza y preprocesado	Presentación S06.2	30
☐	💻 Práctica · Limpieza: duplicados, tipos, fechas, categorías, imposibles y nulos (hasta la línea 🏠 del cuaderno)	Cuaderno S06_02	55

En clase: 3 h 20 min.

Al acabar el día, deberías poder decir:

☐ Mi equipo tiene el inventario de defectos del fichero sucio.
☐ Sé limpiar duplicados, tipos y fechas con pandas.

Día 2 · Lunes 9/11

☐	Qué haces	Abre	Min
☐	💻 Práctica · Escalado, codificación, `ColumnTransformer` y `Pipeline` (hasta la línea 🏠 del cuaderno)	Cuaderno S06_03	40
☐	🎯 Reto · Función de limpieza, partición train/test, *pipeline* y *baseline* (pasos 3–4)	Reto en una página	30
☐	📖 Teoría · scikit-learn: métricas y validación	Presentación S06.3	30
☐	💻 Práctica · *Baseline*, métricas, validación cruzada y fuga de datos (hasta la línea 🏠 del cuaderno)	Cuaderno S06_04	45
☐	🎯 Reto · Informe, README y ensayo (paso 5)	Reto en una página	20
☐	🔔 Ceremonia · Entrega en `sprint-06/`, autoevaluación y coevaluación, review y retrospectiva	—	35

En clase: 3 h 20 min.

Al acabar el día, deberías poder decir:

☐ Sé encontrar los defectos de un fichero sucio y razonar de dónde vienen.
☐ Sé montar un *pipeline* que imputa, escala y codifica sin fuga de datos.
☐ Sé comprobar con un *baseline* y validación cruzada si un modelo mejora de verdad.

El reto en pocas palabras

Qué os pide el cliente. TurisData os envía por correo un fichero de reservas exportado **a mano desde varios sistemas** (`reservas_sucio.csv`). El gerente quiere un primer modelo de cancelaciones «para ayer», pero **no se fía de los datos** (con razón). Os pide dos cosas:

Qué vais a entregar: un repositorio o carpeta con `informe_calidad.md`, `reto_S06.ipynb` y `README.md`.

Núcleo y extra. Núcleo: inventario de defectos, función de limpieza y *baseline* con su *pipeline*. Extra: informe más detallado y comparativa de variantes de limpieza.

Antes de empezar, probad la demo interactiva (muestra lo que tendréis al final). Para trabajar: reto en una página. Para entregar: qué se sube y rúbrica. Para consultar: ficha del reto (qué pide el cliente, ayudas y errores frecuentes) y cada paso explicado.

✅ Antes de cerrar el sprint (Definition of Done)

Archivos subidos en el repositorio del equipo, carpeta `sprint-06/` (marca cada uno cuando lo veas en GitHub): ☐ `informe_calidad.md` · lo creáis a partir de una plantilla
☐ `reto_S06.ipynb` · lo creáis
☐ `README.md` · lo modificáis
☐ `autoevaluacion_nombre.md` · **uno por persona** (la coevaluación va dentro del mismo fichero): plantilla

Total en `sprint-06/`: 3 ficheros del equipo + 1 hoja por persona (un equipo de 3 sube 6). Aparte: reservas_sucio.csv en `data/` si aún no está; los extras solo si los hacéis. La *review* y la *retro* no se suben.

Comprobaciones antes de dar el sprint por cerrado: ☐ Notebook ejecutable de principio a fin (`Restart & Run all`)
☐ El informe recoge cada defecto con causa probable y tratamiento
☐ Hay *baseline* (`DummyClassifier`) y un modelo, comparados con validación cruzada
☐ Alguien que **no escribió esa parte** ha revisado el entregable con la rúbrica y lo ha anotado en el propio entregable

En casa (cuando puedas)

- Los ejercicios de cada cuaderno que **no** se hacen en clase. Se autocorrigen, y debajo llevan una «Solución de referencia» plegada por si te quedas atascado.
- Si quieres repasar la teoría con calma: apuntes del sprint.

Si te atascas

1. Lee primero la parte «Si os atascáis» de la ficha completa del reto.
2. Mira el código explicado del cuaderno en el que estás.
3. Pregunta a tu equipo y, después, al docente. Si usas IA, cuenta en el README qué te dijo y qué comprobaste.

Todo el material, por carpetas

Las carpetas están **numeradas en el orden en que las usas**. Cada documento está en `.md`.

Carpeta	Qué hay
`1_Teoria/`	Las presentaciones del sprint y los apuntes para repasar
`2_Practica/`	Los cuadernos (Colab) y su explicación línea a línea en `codigo_explicado/`
`3_Reto/`	`1_Trabajar` (reto en una página, plantillas y datos) · `2_Entregar` (qué se sube, rúbrica y autoevaluación) · `3_Consultar` (ficha del reto y cada paso explicado)
`4_Referencia/`	Infografías del sprint

Cómo se trabaja un reto, en todos los sprints: método de trabajo.

Temario oficial de este sprint

Unidad	Conceptos que entran
M2 · Exploración del conjunto de datos (UD 2.1 a 2.5)	Funciones del Data Scientist; datos estructurados, no estructurados y series temporales · read_csv, info, describe, filtrado, agrupación, uniones · matplotlib, seaborn, plotly; elección del gráfico según el tipo de dato · Nulos, duplicados, outliers, tipos incorrectos; detección de defectos y de sus causas · Escalado, codificación de categóricas, reducción de dimensionalidad, separación train/test
UD 3.1	Flujo de trabajo con scikit-learn: estimadores, pipelines, validación cruzada
UD 3.2	Métricas y evaluación: MAE/RMSE/R^2, precisión/recall/F1, ROC-AUC, sesgo-varianza, GridSearchCV

Y ahora: Sprint 7 · ML supervisado: regresión y clasificación (martes 10/11).

12 h (3 h teoría · 5 h práctica · 4 h PBL).