IFCD107 · SPRINT 6 · EL RETO PASO A PASO

Datos sucios, cliente impaciente

TurisData Canarias os manda por correo un fichero de reservas, reservas_sucio.csv, exportado a mano desde varios sistemas.

EN BREVE Qué os piden

EL ENCARGO

TurisData Canarias os manda por correo un fichero de reservas, reservas_sucio.csv, exportado a mano desde varios sistemas. El gerente quiere un primer modelo que prediga qué reservas se cancelan «para ayer», pero no se fía de los datos (con razón).

LO QUE HACÉIS

Planning · Inventario · Función · Pipeline · Informe

LO QUE ENTREGÁIS

informe_calidad.md · reto_S06.ipynb · README.md · reservas_sucio.csv

CÓMO SE HACE Los pasos, uno a uno

Día 1 — 40 min de reto

1 Planning y reparto de roles

10 min

- Elegir Scrum Master y responsable técnico de este sprint (no pueden repetir quienes lo fueron en el anterior).
- Leer los apartados 1 y 3 de esta ficha y decidir hasta qué nivel queréis llegar.
- Pasar al tablero las tareas y decidir quién empieza cada una.

2 Inventario de defectos

30 min

- Abrir un cuaderno nuevo en Colab (reto_S06), cargar reservas_sucio.csv y pasar resumen_calidad.
- Buscar defectos con tablas y gráficos, categoría por categoría.
- Rellenar una fila de la tabla del informe por cada defecto (mínimo 6).
- Apuntar las preguntas que haríais al cliente.

MATERIAL
- **informe_calidad_plantilla.md** — sprints/S06/3_Reto/1_Trabajar/plantillas/informe_calidad_plantilla.md
- **S06_01** — Cuaderno en Colab
- **S06_02** — Cuaderno en Colab

Día 2 — 50 min de reto

3 Función de limpieza y partición train/test

15 min

- Escribir limpiar_reservas(df): una función con docstring que aplica todos vuestros tratamientos.
- Comprobar el antes y el después.
- Separar train y test.

MATERIAL
- **S06_02** — Cuaderno en Colab
- **S06_03** — Cuaderno en Colab

4 Pipeline y baseline

15 min

- Construir un Pipeline que impute, escale y codifique.
- Añadir un modelo de referencia y un DummyClassifier.
- Compararlos con validación cruzada y escribir la frase del resultado.

MATERIAL
- **S06_03** — Cuaderno en Colab
- **S06_04** — Cuaderno en Colab

5 Informe, README y revisión con la rúbrica

20 min

- Completar informe_calidad.md a partir de la plantilla.
- Rellenar el README.md y comprobar Reiniciar y ejecutar todo.
- Pedir a alguien que no escribió esa parte que revise con la rúbrica y anote el resultado.

MATERIAL
- **entrega y rúbrica** — sprints/S06/3_Reto/2_Entregar/entrega_y_rubrica.md
- **Cómo entregar en GitHub** — material/5. Como_entregar_en_GitHub.md

✓ Antes de entregar

- Repasad la hoja «Entrega y rúbrica»: todos los ficheros de la tabla A, subidos a la carpeta del sprint.
- Cada persona rellena y sube su hoja de autoevaluación y coevaluación.

MATERIAL
- **Entrega y rúbrica** — sprints/S06/3_Reto/2_Entregar/entrega_y_rubrica.md
- **Autoevaluación y coevaluación** — sprints/S06/3_Reto/2_Entregar/autoevaluacion_y_coevaluacion.md
- **Cómo entregar en GitHub** — material/5. Como_entregar_en_GitHub.md
- **Cómo se trabaja un reto** — material/4. Como_se_trabaja_un_reto.md

PARA EVITAR Errores frecuentes

ERROR 1
Calcular la mediana con todos los datos antes de partir
Partid primero; imputación y escalado se ajustan solo con train, dentro del Pipeline

ERROR 2
Borrar filas «raras» sin avisar
Cada fila eliminada se cuenta y se justifica en el informe

ERROR 3
Informe que dice «hay nulos» sin más
Para cada defecto: dónde, cuántas filas, causa, tratamiento y razón

ERROR 4
Un modelo que «acierta mucho» y se celebra
Comparadlo con DummyClassifier y mirad F1 o ROC-AUC

CON IA Para qué sirve y qué hay que comprobar

USO DE LA IA
Entender una función de pandas
Comprobad que probáis cada ejemplo y lo entendéis

USO DE LA IA
Depurar un error
Comprobad que arregláis la causa, no solo el síntoma

USO DE LA IA
Revisar la fuga
Comprobad que entendéis por qué hay o no fuga

Si la IA os hace un cálculo o un texto, comprobadlo y escribid dónde la habéis usado.

Ficha completa: sprints/S06/3_Reto/3_Consultar/Reto_Sprint_06.md