

Datos, pandas y exploración (EDA)

El cliente nos ha pasado su histórico de reservas y quiere «meter IA». Antes de modelar hay que conocer los datos.

SPRINT 6 · DATOS LISTOS PARA MODELAR · S06.1

Qué hace un Data Scientist y qué datos maneja

Qué hace

Explora, limpia, modela y comunica: traduce datos en decisiones para el negocio.

Tipos de dato

Estructurados (tablas, CSV, SQL), no estructurados (texto, imagen, audio) y series temporales.

Dónde estamos

Tabla estructurada: reservas_turisdata.csv, 6.000 reservas, una fila por reserva y cancelada como objetivo.

Regla de oro: primero mide, luego decide.

Los pasos del sprint: explorar → limpiar → preparar → medir.

Cargar e inspeccionar (Ejercicio 1)

```
import pandas as pd
df = pd.read_csv(dato("reservas_turisdata.csv"))

df.shape          # ¿cuántas filas y columnas?
df.info()         # tipo de cada columna y nulos
df.head()         # primeras filas
df.describe()     # resumen de las numéricas
```

Lo primero siempre: ¿cuántas filas y columnas? ¿de qué tipo es cada una? ¿hay nulos?

Filtrar y agrupar (Ejercicio 2)

```
df[df["canal"] == "directo"]                    # filtro booleano
df[(df["noches"] > 7) & (df["tarifa"] == "flexible")]

tasa_por_deposito = df.groupby("deposito")["cancelada"].mean()
```

- La media de una columna 0/1 es una tasa: cancelada.mean() = proporción de canceladas.
- groupby + media responde a «¿cancela más un grupo que otro?».

Unir tablas con merge (Ejercicio 3)

```
df = df.merge(temporadas, on="mes_llegada", how="left")   # left: no perdemos reservas
```

- A menudo la información está repartida en varias tablas.
- how="left" conserva todas las reservas aunque falte la fila en la otra tabla.
- Comprueba siempre las filas antes y después: si cambian, la unión duplicó o perdió datos.

El gráfico según el dato (Ejercicio 4)

Quiero ver...	Gráfico	Ejemplo con TurisData
Una variable numérica	Histograma	precio_noche
Numérica por categorías	Diagrama de cajas	precio_noche por tipo_habitacion
Dos numéricas	Dispersión	antelacion_dias frente a precio_noche
Una categórica	Barras	reservas por canal

```
mediana_por_tipo = df.groupby("tipo_habitacion")["precio_noche"].median()
```

Relaciones entre variables y calidad del dato

```
corr = df.select_dtypes("number").corr()          # Ejercicio 5
var_mas_ligada = corr["cancelada"].drop("cancelada").abs().idxmax()

filas_duplicadas = df.duplicated().sum()          # Ejercicio 6
pct_nulos_pais = df["pais_origen"].isna().mean() * 100
```

- Correlación mide relación lineal; no prueba causalidad (lo vimos en el Sprint 5).
- Primer chequeo de calidad: duplicados, nulos, rangos imposibles.

Mini-reto: tres hallazgos para el cliente

Con lo que has explorado, escribe tres hallazgos que un gerente entendería sin saber Python.

- Cada hallazgo = una cifra + una frase («los clientes sin depósito cancelan X veces más»).
- Apóyate en tasa_por_deposito, mediana_por_tipo y la matriz corr.
- Los mismos pasos 1–2 del reto de este sprint: inventario de defectos del fichero sucio.

Ahora, a practicar

Lo que viene a continuación está en tu repositorio.

CUADERNO · pandas, EDA y primer chequeo de calidad	(sprints/S06/notebooks/S06_01_pandas_eda) — 45 min.
RETO · Arrancar el inventario de defectos del fichero sucio (pasos 1–2)	(sprints/S06/guia/Reto_Sprint_06.md) — 30 min.